FINE-TUNING MODEL *YOU ONLY LOOK ONCE* V8M UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN *SMEAR* DARAH

TUGAS AKHIR

IVAN FULVIAN PITOYO

122430064



PROGRAM STUDI TEKNIK BIOMEDIS

FAKULTAS TEKNOLOGI INDUSTRI

INSTITUT TEKNOLOGI SUMATERA

2026

FINE-TUNING MODEL *YOU ONLY LOOK ONCE* V8M UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN SMEAR DARAH

TUGAS AKHIR

IVAN FULVIAN PITOYO

122430064



PROGRAM STUDI TEKNIK BIOMEDIS

FAKULTAS TEKNOLOGI INDUSTRI

INSTITUT TEKNOLOGI SUMATERA

2026

LEMBAR PENGESAHAN

Laporan Tugas Akhir dengan judul "*FINE-TUNING* MODEL *YOU ONLY LOOK ONCE* V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN *SMEAR* DARAH" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan di serahkan sebelumnya, baik sebagian atau seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.



Lampung Selatan, 30 Juli 2026
Penulis,
Ivan Fulvian Pitoyo
122430064

Diperiksa dan disetujui oleh,

Pembimbing I	Pembimbing II
Martin Clinton Tosima Manullang, Ph.D.	I Gde Eka Dirgayussa, M.Si
NIP.199301092019031017	NIP. 198905032024061001

Disahkan oleh,
Koordinator Program Studi Teknik Biomedis
Fakultas Teknik Industri
Institut Teknologi Sumatera

Rudi Setiawan, S.T., M.T.
NIP. 199306032022031008

HALAMAN PERNYATAAN ORISINALITAS

Tugas akhir ini adalah karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan benar.

Nama	**:** Ivan Fulvian Pitoyo
NIM	**:** 122430064
Tanda Tangan	**:**
Tanggal	**:** 30 Juli 2026

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik eInstitut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : Ivan Fulvian Pitoyo

NIM : 122430064

Program Studi : Teknik Biomedis

Fakultas : Fakultas Teknologi Industri

Jenis karya : Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Sumatera **Hak Bebas Royalti Noneksklusif (Non- exclusive Royalty Free Right)** atas karya ilmiah saya yang berjudul:

Fine-Tuning Model You Only Look Once V8m Untuk Deteksi Parasit Malaria Pada Citra Mikroskopis Sediaan Smear Darah

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (database), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta. Demikian pernyataan ini saya buat dengan sebenarnya

Dibuat di: Lampung Selatan

Pada tanggal: 30 juli 2026

Yang Menyatakan (Ivan Fulvian Pitoyo)

ABSTRAK

FINE-TUNING MODEL *YOU ONLY LOOK ONCE* V8M UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN SMEAR DARAH

Ivan Fulvian Pitoyo (122430064)

Pembimbing: Martin Clinton Tosima Manullang, Ph.D, I Gde Eka Dirgayussa, M.Si

RINGKASAN

Malaria masih menjadi tantangan kesehatan signifikan di Indonesia, khususnya di wilayah endemis seperti Lampung, di mana diagnosis konvensional melalui pemeriksaan mikroskopis manual bergantung pada ketelitian tenaga medis yang rentan terhadap kelelahan mata akibat observasi berkelanjutan tanpa henti. Penelitian ini mengembangkan sistem deteksi otomatis parasit malaria spesies *Plasmodium falciparum* dan *Plasmodium vivax* pada citra mikroskopis sediaan *smear* darah menggunakan pendekatan *fine-tuning* model *You Only Look Once* (YOLO) v8m yang telah dilatih sebelumnya dengan dataset COCO. Dataset citra mikroskopis dari Puskesmas Hanura mengalami permasalahan ketidakseimbangan kelas, sehingga diterapkan augmentasi data (*noise*, *brightness*, *flip*) dan diuji tiga skenario penanganan *imbalance*, yaitu *oversampling* dengan rasio 1:2, *global augmentation*, dan *undersampling* dengan rasio 1:1. Optimasi *hyperparameter* dilakukan menggunakan algoritma Optuna sebanyak 153 *trial* untuk menemukan kombinasi *learning rate*, *momentum*, dan *weight decay* terbaik. Hasil evaluasi menunjukkan Skenario I (*oversampling*) sebagai model terbaik dengan capaian mAP@50 sebesar 91%, mAP@50-95 sebesar 59%, *Precision* 86%, *Recall* 83%, dan *F1-Score* 84%, unggul dibanding Skenario II yang mengalami misklasifikasi lintas-spesies berisiko klinis fatal, serta Skenario III yang menghasilkan banyak *false positive* akibat kehilangan sampel referensi. Model terbaik ini kemudian diintegrasikan ke dalam antarmuka pengguna grafis (GUI) berbasis Python dan OpenCV yang terhubung dengan kamera mikroskop untuk mendukung skrining malaria otomatis dan *real-time* di Puskesmas Hanura. Penelitian ini membuktikan bahwa strategi penanganan ketidakseimbangan kelas melalui *oversampling* terkontrol lebih efektif dibanding augmentasi global maupun *undersampling* ekstrem dalam menjaga keandalan klinis sistem deteksi berbasis *deep learning* untuk diagnosis malaria.

Kata kunci: *Deep Learning*, Malaria, Mikroskop, *Object Detection*, YOLOv8

ABSTRACT

FINE-TUNING OF YOU ONLY LOOK ONCE V8 MODEL FOR MALARIA PARASITE DETECTION IN MICROSCOPIC BLOOD SMEAR IMAGES

Ivan Fulvian Pitoyo (122430064)

Supervisor(s): Martin Clinton Tosima Manullang, Ph.D, I Gde Eka Dirgayussa, M.Si

SUMMARY

Malaria remains a significant health challenge in Indonesia, particularly in endemic regions such as Lampung, where conventional diagnosis via manual microscopy depends heavily on the precision of medical personnel, who are prone to fatigue-induced errors from prolonged observation. This research develops an automated detection system for the malaria parasite species *Plasmodium falciparum* and *Plasmodium vivax* in microscopic thin blood smear images using a fine-tuning approach on the *You Only Look Once* (YOLO) v8m model, pre-trained on the COCO dataset. The dataset obtained from Puskesmas Hanura exhibited a class imbalance problem, addressed through data augmentation (noise, brightness, flip) and evaluation across three imbalance-handling scenarios: oversampling at a 1:2 ratio, global augmentation, and undersampling at a 1:1 ratio. Hyperparameter optimization was performed using the Optuna algorithm across 153 trials to identify the optimal combination of learning rate, momentum, and weight decay. Evaluation results identified Scenario I (oversampling) as the best-performing model, achieving mAP@50 of 91%, mAP@50-95 of 59%, Precision of 86%, Recall of 83%, and F1-Score of 84%, outperforming Scenario II, which suffered fatal-risk cross-species misclassification, and Scenario III, which produced numerous false positives from the loss of reference samples. The best model was integrated into a graphical user interface (GUI) built with Python and OpenCV, connected to a microscope-mounted camera, to support automatic, real-time malaria screening at Puskesmas Hanura. This research demonstrates that controlled oversampling for handling class imbalance is more effective than global augmentation or extreme undersampling in preserving the clinical reliability of deep learning-based malaria detection systems.

Keywords: Deep Learning, Malaria, Microscope, Object Detection, YOLOv8

KATA PENGANTAR

Puji syukur senantiasa penulis panjatkan kehadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia yang diberikan, sehingga penyusunan Laporan Tugas Akhir yang berjudul *"FINE-TUNING MODEL YOU ONLY LOOK ONCE V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN SMEAR DARAH"* dapat diselesaikan dengan baik. Laporan Tugas Akhir ini dimaksudkan untuk memenuhi salah satu persyaratan kelulusan dalam meraih gelar Sarjana Teknik pada Program Studi Teknik Biomedis, Jurusan Teknologi Produksi dan Industri, Institut Teknologi Sumatera. Penulis menyadari bahwa penyusunan Tugas Akhir ini, mulai dari tahap rekayasa pra-pemrosesan citra medis hingga evaluasi kinerja algoritma kecerdasan buatan, tidak akan dapat diselesaikan tanpa bimbingan, arahan, dan dukungan fasilitas dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Bapak Prof. Dr. I Nyoman Pugeg Aryantha, selaku Rektor Institut Teknologi Sumatera.
2. Bapak Hadi Teguh Yudistira S.T., Ph.D., selaku Dekan Fakultas Teknik Industri Institut Teknologi Sumatera.
3. Bapak Rudi Setiawan, S.T., M.T., selaku Koordinator Program Studi Teknik Biomedis Institut Teknologi Sumatera.
4. Bapak Martin Clinton Tosima Manullang, Ph.D., selaku Dosen Pembimbing I, yang telah meluangkan waktu dan pikiran untuk membimbing, memberikan masukan analitis yang

komprehensif, serta memvalidasi rekayasa sistem kecerdasan buatan dalam penelitian ini.

5. Bapak I Gde Eka Dirgayussa, M.Si., selaku Dosen Pembimbing II, atas saran konstruktif terkait pengolahan citra medis dan ketelitian dalam mengarahkan fundamental metodologi penelitian.
6. Institut Teknologi Sumatera, yang telah memberikan izin dan akses terhadap dataset primer citra sediaan darah mikroskopis yang menjadi subjek utama penelitian ini.
7. Terima kasih kepada LPDP atas dukungan pendanaan yang diberikan sehingga penelitian operasional komputasional ini dapat berjalan lancar.

Penulis menyadari bahwa sistem deteksi dan Laporan Tugas Akhir ini masih memiliki berbagai keterbatasan. Oleh karena itu, segala bentuk kritik dan saran yang bersifat membangun sangat diharapkan. Akhir kata, semoga Tugas Akhir ini dapat memberikan kontribusi secara ilmiah bagi pengembangan rekayasa teknologi medis di masa depan.

Tempat penyusunan TA, 30Juli 2026

Penulis,

Ivan Fulvian Pitoyo

PERSEMBAHAN

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala Rahmat dan karunia sehingga saya dapat menyelesaikan lembar demi lembar perjalanan panjang ini. Dengan segala kerendahan hati, karya kecil ini saya persembahkan kepada:

1. Tuhan Yang Maha Esa Sumber segala ilmu pengetahuan, etenangan, dan kekuatan. Terima kasih atas petunjuk, perlindungan, dan kemudahan yang tiada henti, terutama di saat-saat paling buntu dalam menyelesaikan penelitian ini. Semua pencapaian ini pada akhirnya hanyalah titipan darinya.

2. Ayah dan Ibu Tercinta Dua sosok paling berjasa dan tak tergantikan dalam hidup saya. Terima kasih atas peluh, keringat, kasih sayang, dan doa-doanya yang selalu mengudara tanpa henti. Setiap baris kalimat dalam skripsi ini tidak akan pernah cukup untuk membalas pengorbanan kalian. Karya ini adalah bentuk bakti dan hadiah kecil untuk mengukir senyum bangga di wajah kalian.

3. Saudara dan Keluarga Besar Terima kasih atas segala bentuk dukungan moral, perhatian, dan semangat yang selalu diberikan dari rumah. Terima kasih telah selalu mengingatkan saya bahwa selalu ada tempat yang hangat untuk kembali setelah lelah berjuang.

MOTTO

“Menjembatani batas laboratorium dengan dunia nyata dengan tujuan untuk menyelamatkan kehidupan”

DAFTAR ISI

LEMBAR PENGESAHAN ..... **iii**

HALAMAN PERNYATAAN ORISINALITAS ..... **iv**

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS ..... **v**

ABSTRAK ..... **vi**

ABSTRACT ..... **vii**

KATA PENGANTAR ..... **viii**

PERSEMBAHAN ..... **x**

MOTTO ..... **xi**

DAFTAR ISI ..... **xii**

DAFTAR TABEL ..... **xvi**

DAFTAR GAMBAR ..... **xvii**

BAB I PENDAHULUAN **19**

1.1 Latar Belakang 19

1.2 Perumusan Masalah 23

1.3 Tujuan Penelitian 24

1.4 Hipotesis 24

1.5 Ruang Lingkup Penelitian 25

1.6 Sistematika Penulisan 26

BAB II TINJAUAN PUSTAKA **29**

2.1 Mikroskop 29

2.2 Malaria 33
2.3 Deep Learning 41
2.4 Convolutional Neural Network (CNN) 43
2.4.1 Convolutional Layer 45
2.4.2 Pooling Layer 47
2.4.3 Fully Connected Layer 50
2.4.4 Arsitektur CNN 53
2.5 Algoritma YOLO (*You Only Look Once*) 57
2.6 *Hyperparameter* 68
2.7 *State of The Art* 72
BAB III METODOLOGI PENELITIAN 83
3.1 Jenis Penelitian 83
3.2 Waktu dan Tempat Pelaksanaan 84
3.3 Alat dan Bahan 84
3.3.1 Alat 84
3.3.2 Bahan 91
3.4 Metode dan Persamaan yang Digunakan 91
3.4.1 Fungsi Kerugian (*Loss Function*) 91
3.4.2 Parameter Optimasi (AdamW) 93
3.4.3 Metrik Evaluasi Kinerja Sistem 93
3.5 Diagram Alir Penelitian 96
3.5.1 Studi Literatur 97

3.5.2 Pengumpulan Dataset 97
3.5.3 Pre-Processing Data..... 97
3.5.4 Training Model..... 98
3.5.5 Evaluasi Model..... 98
3.5.6 Pembuatan GUI 99
3.5.7 Analisis Data 99
3.6 Langkah Penelitian secara Spesifik 99
3.6.1 Proses Training Model..... 104
3.6.2 Proses Training..... 107
3.6.3 Integrasi *Hardware* dan *Software*..... 109
3.6.4 Uji Implementasi 113
3.7 Interpretasi Data/Analisis Data..... 113
BAB IV HASIL DAN PEMBAHASAN 115
4.1 Pengolahan Dataset Citra Mikroskopis 115
4.1.1 Penyesuaian Resolusi 115
4.1.2 Implementasi Augmentasi Data..... 116
4.1.3 Pembagian Dataset 118
4.2 Fine-Tuning Model YOLOv8m..... 118
4.3 Analisis Pengaruh Distribusi dan Augmentasi Dataset 122
4.3.1 Skenario I: Pelatihan dengan *Oversampling*..... 123
4.3.2 Skenario II: Pelatihan Dengan *Global Augmentation* 131
4.3.3 Skenario III: Pelatihan Dengan *Undersampling*..... 138

4.4 Evaluasi Performa Sistem Deteksi Model 150
4.4.1 AnalisisAkurasi Spasial (mAP@50 Dan mAP@50-95) . 156
4.4.2 Analisis Keseimbangan Diagnosis Klinis (*Precision, Recall,* dan *F1-Score*) 158
4.5 Implementasi Perancangan Antarmuka Pengguna (GUI)..... 161
BAB V KESIMPULAN **164**
5.1 Kesimpulan..... 164
5.2 Saran 166
DAFTAR PUSTAKA **169**
LAMPIRAN **184**

DAFTAR TABEL

Tabel 2.1 Citra dan Karakteristik Fase Parasit falciparum 34
Tabel 2.2 Citra Dan Karakteristik Parasit Vivax 37
Tabel 2.3 Rangkuman Performa Metrik Arsitektur 54
Tabel 2.4 Rata-rata Kecepatan Pemrosesan Arsitektur..... 55
Tabel 2.5 Analisis Persentase Error Deteksi..... 56
Tabel 2.6 Detail Fungsi Blok Komponen Arsitektur YOLOv8. 65
Tabel 2.7 State Of The Art..... 72
Tabel 3.1 Spesifikasi Alat Software dan Hardware 85
Tabel 3.2 Daftar Bahan Penelitian 91
Tabel 3.3 Rangkuman Jumlah Komposisi dan Label Dataset 101
Tabel 3.4 Pembagian Data Final Training 103
Tabel 3.5 Konfigurasi *Hyperparameter*..... 108
Tabel 4.1 Hasil Data Resizing 116
Tabel 4.2 Hasil Augmentasi Data Yang Dilakukan..... 117
Tabel 4.3 Distribusi Pembagian Dataset Akhir Citra..... 118
Tabel 4.4 Hyperparameter Final 119
Tabel 4.5 Hyperparameter Test 121
Tabel 4.6 Hasil Eksperimen Hyperparameter..... 121
Tabel 4.7 Rekap Hasil Model Skenario 150
Tabel 4.8 Hasil Evaluasi Dengan Test Set Serta Validasi 153

DAFTAR GAMBAR

Gambar 2.1 Jenis Tipe Mikroskop Berdiri Pertama Kali..... 30
Gambar 2.2 Skematik Electron Microscope 31
Gambar 2.3 Arsitektur CNN 44
Gambar 2.4 Proses Komputasi Convolutional Layer..... 46
Gambar 2.5 Proses Perhitungan Pooling Layer 49
Gambar 2.6 Proses Flattening dan Koneksi. 51
Gambar 2.7 Ilustrasi Hasil Deteksi YOLO 59
Gambar 2.8 Perbandingan YOLOv8..... 60
Gambar 2.9 Arsitektur YOLOv8 61
Gambar 3.1 Diagram Alir Penelitian 96
Gambar 3.2 Diagram Alir Penelitian Spesifik 100
Gambar 3.3 Tahap Training Model..... 106
Gambar 3.4 Design GUI 110
Gambar 3.5 Lokasi Penyimpanan File..... 112
Gambar 4.1 Hasil Pembagian Labels Dalam Training Skenario 1 . 124
Gambar 4.2 Hasil Width vs Height Scatter Plot Skenario 1 125
Gambar 4.3 Hasil Grafik scatter plot Skenario 1 126
Gambar 4.4 Hasil Proses Training Skenario 1 127
Gambar 4.5 Hasil Kurva F1-Confidence Skenario 1 128
Gambar 4.6 Hasil Confusion Matrix Skenario 1..... 129
Gambar 4.7 Hasil Kurva Recall Skenario I..... 130
Gambar 4.8 Hasil Pembagian Labels Dalam Training Skenario 2 . 131
Gambar 4.9 Hasil Scatter Plot Width vs Height Skenario 2 132
Gambar 4.10 Hasil Scatter Plot xy Skenario 2..... 133
Gambar 4.11 Hasil Proses Training Model Skenario 2..... 134
Gambar 4.12 Hasil Kurva Confidence F1 Curve Skenario 2..... 135
Gambar 4.13 Hasil Confusion Matriks Skenario 2 136

Gambar 4.14 Hasil Kurva Recall Confidence Skenario 2 137
Gambar 4.15 Hasil Pembagian Data 1:1 Skenario 3 138
Gambar 4.16 Hasil Grafik Distribusi 140
Gambar 4.17 Hasil Grafik Height vs Width 141
Gambar 4.18 Hasil Training Model Skenario 3 142
Gambar 4.19 Grafik F1-Curve Skenario 3 144
Gambar 4.20 Confusion Matrix Skenario 3 146
Gambar 4.21 Hasil Curva Recall Skenario 3 148
Gambar 4.22 GUI Antarmuka Pengguna 162

BAB I
PENDAHULUAN

1.1 Latar Belakang

Penyakit Malaria menjadi salah satu penyakit yang sangat menlar secara global, terutama di negara-negara tropis seperti di Indonesia. World Health Organization (WHO) menyatakan bahwa pada tahun 2023 sendiri terdapat 263 juta kasus malaria dan 597.000 yang meninggal dikarenakan malaria[1]. Di dalam Indonesia sendiri pada tahun 2024 kasus malaria sudah mencapai 443.530 kasus dengan kasus positif malaria mencapai 89% di Provinsi Papua[2]. Pada tahun 2019 sampai tahun 2020, terdapat total 403 kasus di lampung, pada rentang umur 15-64 tahun, tempat yang menjadi titik paling utama terkenai penyakit malaria di lampung terdapat di desa pesawaran, dimana parasit yang umum terkenai para warga adalah *plasmodium vivax*[3]. Diagnosis secara dini dan akurat menjadi salah satu hal yang sangat penting dalam penanganannya, hal ini dikarenakan dengan diagnosis secara cepat pasien dapat mendapatkan pengobatan yang sesuai, sehingga menurunkan tingkat resiko komplikasi serius hingga kematian pada pasien.

Metode diagnosis malaria yang menjadi *gold standard* sampai sekarang adalah pemeriksaan darah pasien menggunakan mikroskopis pada sediaan darah tepi (*thick smear* dan *thin smear*)[4]. Selain pemeriksaan mikroskopis, terdapat juga beberapa metode lainnya, seperti teknologi konvensional sampai molekuler, dimana masing-masing memiliki keunggulan dan kekurangan masing-masing[5]. Salah satu alternatif yang dapat digunakan adalah *Rapid Diagnostic Test* (RDTs). Metode ini menawarkan solusi yang cepat dan terjangkau,

sehingga sangat berguna di daerah endemis. RDTs mudah digunakan dan memberikan hasil dalam waktu singkat, meskipun memiliki kelemahan berupa potensi hasil negatif palsu (*false-negative*), tanpa memberikan gambaran secara kuantitatif. Selain itu, terdapat juga beberapa metode lainnya yang memberikan tingkat sensitivitas yang tinggi seperti *Polymerase Chain Reaction* (PCR), dimana metode PCR ini menggunakan sensor untuk mendeteksi DNA yang terdapat dalam parasit dengan sensitivitas 98-100% dan memiliki spesifitas 84-94%[6]. Selain itu, terdapat juga beberapa metode lainnya seperti *Loop-Mediated Isothermal Amplification* (LAMP) yang menunjukkan potensi besar untuk digunakan sebagai alat testing di tempat langsung[7]. Meskipun seperti itu, metode mikroskopis ini termasuk dalam metode konvensional namun dianggap sebagai *gold standard* dalam dunia kesehatan untuk melakukan pendeteksi penyakit malaria[8]. Hal ini dikarenakan kemampuannya yang unik dalam memberikan informasi diagnostik yang komprehensif dan tidak tertandingi oleh metode lain [5]. Metode ini tidak hanya memungkinkan identifikasi definitif kelima spesies *Plasmodium* pada manusia, tetapi juga mampu melakukan kuantifikasi jumlah parasit (*parasitemia*) secara akurat. Hal ini termasuk sangat penting untuk manajemen klinis dan pemantauan respons pengobatan[9]. Hal ini juga didukung dengan visualisasi secara langsung parasit, dimana yang sering terlewatkan oleh proses diagnosis oleh metode lain[6][9]. Namun, proses identifikasi parasit malaria masih sangat bergantung pada tenaga medis atau analis yang bersedia di lokasi. Keterbatasan ini sering menimbulkan subjektivitas, kelahan visual dan memungkinkan kesalahan deteksi, terutama pada kasus dengan parasitemia rendah[10].

Efektivitas penggunaan mikroskopi sebagai metode *gold standard* sudah menunjukkan variabilitas yang sangat signifikan di lapangan dengan kekurangan dan kelebihan yang sangat jelas. Keunggulan metode ini terletak pada kemampuannya untuk memberikan informasi diagnostik yang komprehensif dengan meliputi berbagai spesies dan dapat mengkuantifikasikan parasitemia untuk memandu intensitas pengobatan, dan indikator keparahan penyakit [6]. Meskipun begitu, performa yang menghasilkan nilai yang lebih rendah. Berdasarkan studi yang dilakukan oleh A. Amir,dkk menyatakan bahwa tingkat sensitivitas pada metode mikroskop atau proses pendeteksian dengan *gold standard* ini hanya 74.5% dan spesifitas 59%[9]. Keterbatasan ini sangat bergantung pada keahlian teknisi, dimana mereka secara minimum dapat mendeteksi serendahnya 5 parasit/µL darah, dibandingkan dengan tenaga medis biasa dapat mencapai 50 – 100 parasit/µL [9][6]. Proses ini juga memerlukan waktu yang cukup lama antara 20 sampai dengan 40 menit, tergantung dengan kualitas preparat, mikroskop, dan juga keterampilan tenaga medis. Terutama apabila hasil yang di keluarkan berupa negatif, maka hasil tersebut harus di lakukan evaluasi ulang setelah 12 sampai 24 jam kemudian[11]. Ketergantungan terhadap hal ini yang dapat membuka jalan untuk adanya potensi kesalahan, terutama pada daerah yang memiliki sumber daya manusia dan alat yang memadai.

Setelah melakukan *literature review* terkait malaria di Puskesmas Hanura Daerah Provinsi Lampung juga menunjukkan bahwa dalam proses praktik lapangan, proses deteksi malaria masih sangat bergantung kepada metode mirkoskopis secara manual yang dilakukan oleh satu tenaga kerja medis, hal ini juga menjadi tantangan bagi mereka dikarenakan kelelahan mata yang dialami oleh tenaga

medis dikarenakan melakukan observasi secara *non-stop* untuk jangka waktu yang lama. Selain itu, berdasarkan penelitian yang dilakukan oleh Dinas Kesehatan Provinsi Lampung, upaya pengendalian penyakit malaria di Lampung diperlukannya dukungan dan inovasi terbaru secara teknologi untuk proses deteksi secara cepat dan akurat dengan mengingat keterbatasannya tenaga medis dan besarnya beban kerja di lapangan langsung.

Dalam hal ini, dengan perkembangan teknologi digital dapat membuka peluang besar untuk meningkatkan kapabilitas mikroskop konvensional dan cara kerjanya. Beberapa studi sudah menunjukkan bahwa integrasi modul kamera dan model YOLOv8 untuk proses deteksi dapat digunakan dalam praktik pada berbagai bidang. Dalam studi yang dilakukan oleh Aisyah Widayani, dkk. pada tahun 2024 menyatakan bahwa metode YOLOv8 berhasil dalam melakukan deteksi untuk tumor otak, deteksi kanker payudara, dan juga melakukan analisis radiografi gigi dengan tingkat akurasi validasi dan akurasi pelatihan mencapai 95%[12]. Pada bidang arsitektur dan mesin, Ezzedini, dkk. pada tahun 2024 membuktikan bahwa model YOLOv8 memberikan hasil yang sangat baik dalam proses mendeteksi *locomotive* dan kapal yang ada di area lautan beserta ikan-ikannya, dimana tingkat akurasi yang di berikan mencapai 76%[13].

Meskipun begitu, penerapan teknologi tersebut dalam proses deteksi malaria secara *real-time* pada citra mikroskopis masih sangat terbatas. Maka oleh karena itu, penelitian ini dilakukan dengan fokus kepada pembuatan sistem untuk melakukan proses diagnosis secara *real-time* dengan kamera yang terpasang pada mikrsokop secara

langsung dengan metode YOLOv8 dengan tujuan untuk mengidentifikasi *plasmodium vivax* dan *plasmodium falciparum*.

Dengan penelitian tersebut, diharapkan hasil yang dikeluarkan dapat menjadi solusi untuk proses deteksi dengan metode mikroskopis konvensional dan menjawab kebutuhan dari pihak puskesmas hanura yang disebabkan oleh lama proses waktu pemeriksaan, ketergantungan kepada tenaga medis, kekurangannya tenaga medis, dan menurunkan resiko kesalahan diagnosis. Dengan pelatihan model YOLOv8 kepada citra darah yang telah melalui tahap isolasi dan juga pemrosesan, sistem akan dirancang untuk membedakan *P.Falciparum, P.Vivax*, dalam dataset yang didapatkan di pesawaran[7].

1.2 Perumusan Masalah

Berdasarkan latar belakang yang ada, permasalahan yang dapat diangkat adalah :

1. Bagaimana merancang sistem deteksi malaria berbasis YOLOv8m pada citra mikrosxkopis sediaan darah tebal?
2. Bagaimana mengevaluasi performa model yang telah dilatih menggunakan metrik standar (*mAP, Precision, Recall, F1-Score*) untuk memastikan keandalannya dalam mengatasi masalah ketidakseimbangan kelas?
3. Bagaimana mengimplementasikan model deteksi tersebut ke dalam sebuah Antarmuka Pengguna Grafis (GUI) agar dapat dioperasikan bersama mikroskop konvensional untuk skrining secara langsung?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang di ambil, adapun tujuan dalam melakukan penelitian ini adalah :

1. Menyusun dan mengolah dataset citra mikroskopis sediaan darah tebal sebagai data pelatihan dan pengujian model YOLOv8.
2. Melakukan *fine-tuning* sistem berbasis YOLOv8 untuk deteksi penyakit malaria pada mikroskop dengan smear darah tebal.
3. Mengevaluasi performa sistem deteksi malaria berbasis YOLOv8 menggunakan parameter persisi, mAP50, mAP50-95, recall, F1-score.
4. Membuat antarmuka GUI yang secara *real-time*, dapat di install di dalam komputer puskesmas tanpa perlu merakit *hardware* mahal.

1.4 Hipotesis

Dalam penelitian ini, terdapat hipotesis yang diajukan yaitu sebagai berikut:

Hipotesis Nol (H_0):

H_{01} Sistem deteksi malaria berbasis model YOLOv8m yang dioptimasi pada citra mikroskopis sediaan darah tebal tidak mampu mengenali parasit malaria secara komputasional dan gagal mencapai target performa dengan nilai metrik $mAP_{50} \geq 90\%$, $mAP_{50-95} \geq 60\%$, *F1-Score* $\geq 70\%$, serta *recall*, *precision* $\geq 90\%$.

Hipotesis Alternatif (H_1):

H_{11} Sistem deteksi malaria berbasis model YOLOv8m yang dioptimasi pada citra mikroskopis sediaan darah tebal mampu

mengenali parasit malaria secara komputasional dan berhasil mencapai target performa dengan nilai metrik $mAP_{50} \geq 90\%$, $mAP_{50-95} \geq 60\%$, *F1-Score* $\geq 70\%$, serta *recall*, *precision* $\geq 90\%$.

Sistem deteksi malaria berbasis model YOLOv8m yang di optimasi pada citra mikroskopis dengan sediaan darah tebal dapat mengenali parasit malaria dengan secara baik dengan nilai metrik mAP50 mencapai >90%,mAP50-95 >60% F1-Score >70%, dan recall, precision>90% . Diharapkan sistem ini dapat memberikan sistem deteksi yang konsisten serta dapat mengurangi tingkat subjektivitas dan kesalahan dalam melakukan identifikasi pada pemeriksaan mikroskopis konvensional berdasarkan dataset yang ada.

1.5 Ruang Lingkup Penelitian

Penelitian ini dibatasi pada pengembangan sistem deteksi malaria berbasis YOLOv8 secara mikroskopis menggunakan mikroskop pada sediaan darah tebal. Dikarenakan adanya keterbatasan pada data dan dana, maka penelitan ini memanfaatkan dataset citra mikroskopis malaria yang di dapatkan dari Provinsi Lampung, Pesawaran, Desa Hanura dengan hasil kerjasama dengan pihak tenaga kesehatan untuk mengambil data primer.

Sistem yang dikembangkan dengan melakukan implementasi kepada perangkat lunak dengan menggunakan komputer dan atau laptop yang ada. Oleh karena itu, dikarenakan tidak akan ada pembahasan secara klinis terhadap cara pengobatan, maka penelitian ini hanya berfokus pada sistem atau proses deteksi malaria parasit dalam citra mikroskopis dan tidak melakukan deteksi terhadap sel darah merah yang utuh.

Performa YOLOv8 dilakukan dengan parameter seperti mAP-50, mAP 50-95, F1-Score, recall dan precision terbatas pada dataset yang digunakan. Penelitian ini dilakukan dengan uji validasi klinis dengan bantuan tenaga medis melakukan klarifikasi dan validasi terhadap hasil yang sudah dilakukan.

1.6 Sistematika Penulisan

Secara keseluruhan, penyusunan laporan Tugas Akhir ini mengikuti standar format penulisan akademik yang telah ditetapkan, yaitu menggunakan jenis huruf *Times New Roman* dengan ukuran 12 pt dan jarak baris 1,5 spasi. Penggunaan tanda desimal dalam laporan ini disimbolkan dengan tanda koma (,), sedangkan pemisah ribuan disimbolkan dengan tanda titik (.). Untuk memberikan gambaran yang komprehensif dan terstruktur mengenai alur penelitian, sistematika penulisan laporan ini dibagi ke dalam lima bab utama yang saling berkesinambungan, dengan rincian sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan dasar dan arah pelaksanaan penelitian yang meliputi latar belakang masalah mengenai urgensi diagnosis malaria, perumusan masalah, tujuan penelitian, manfaat penelitian, ruang lingkup dan batasan masalah (terfokus pada spesies *Plasmodium falciparum* dan *Plasmodium vivax*), serta sistematika penulisan laporan.

BAB II TINJAUAN PUSTAKA

Bab ini membahas landasan teori dan kajian literatur yang mendasari penelitian, meliputi konsep dasar penyakit malaria, karakteristik morfologi parasit, prinsip sediaan darah mikroskopis, konsep dasar *Deep Learning* dan *Convolutional Neural Network* (CNN), arsitektur model *You Only Look Once* versi 8 (YOLOv8), teknik augmentasi data,

metrik evaluasi kinerja arsitektur (seperti *Precision, Recall,* dan mAP), serta prinsip perancangan Antarmuka Pengguna Grafis (GUI).

BAB III METODE PENELITIAN

Bab ini menjelaskan secara rinci kerangka kerja dan prosedur operasional pelaksanaan penelitian. Pembahasan di dalamnya mencakup penentuan jenis penelitian, spesifikasi alat dan bahan (perangkat keras maupun lunak), serta langkah-langkah penelitian yang dimulai dari proses akuisisi dataset citra mikroskopis terbuka, prapemrosesan dan augmentasi data, perancangan skenario distribusi kelas data (*hybrid class balancing*), proses pelatihan model YOLOv8, pencarian *hyperparameter*, prosedur evaluasi metrik, hingga tahap implementasi model ke dalam sistem GUI.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil penelitian beserta pembahasannya secara mendalam, meliputi pengolahan dataset citra mikroskopis (proses cutting, penyesuaian resolusi, augmentasi data, dan pembagian dataset), pelaksanaan fine-tuning model YOLOv8m melalui pencarian hyperparameter optimal menggunakan algoritma Optuna, analisis pengaruh distribusi dan augmentasi dataset yang dibandingkan melalui tiga skenario (oversampling, global augmentation, dan undersampling), evaluasi performa sistem deteksi menggunakan metrik Precision, Recall, F1-Score, mAP@50, dan mAP@50-95, serta implementasi model terbaik ke dalam rancangan Antarmuka Pengguna Grafis (GUI).

BAB V KESIMPULAN

Bab ini memaparkan kesimpulan akhir penelitian yang menjawab rumusan masalah, tujuan, dan hipotesis yang telah ditetapkan pada Bab I, mencakup ringkasan hasil pengolahan dataset, karakteristik konvergensi ketiga skenario fine-tuning, capaian performa terbaik

model YOLOv8m, serta keberhasilan implementasinya ke dalam Antarmuka Pengguna Grafis (GUI). Selain itu, bab ini juga memuat saran bagi pengembangan penelitian selanjutnya, meliputi perluasan dataset, perbandingan dengan arsitektur deteksi objek lain, penambahan deteksi spesies Plasmodium lainnya, optimasi model untuk perangkat dengan sumber daya terbatas, serta pengembangan fitur tambahan pada GUI.

BAB II
TINJAUAN PUSTAKA

2.1 Mikroskop

Sejarah perkembangan teknologi observasi mikroskopis berawal pada abad ke-13 ketika Salvino D'Armate merancang prototipe kacamata pertama. Alat sederhana ini menggunakan prinsip pembiasan cahaya untuk menghasilkan perbesaran visual sebesar 6x hingga 10x pada satu mata, yang saat itu umum digunakan untuk mengamati detail objek kecil seperti serangga atau struktur tanaman. Selanjutnya, pada akhir abad ke-16, Zacharias Jansen bersama ayahnya di Belanda menguji coba penggabungan beberapa lensa ke dalam sebuah tabung. Eksperimen inilah yang kelak menjadi cikal bakal terciptanya instrumen optik modern seperti mikroskop dan teleskop[14].

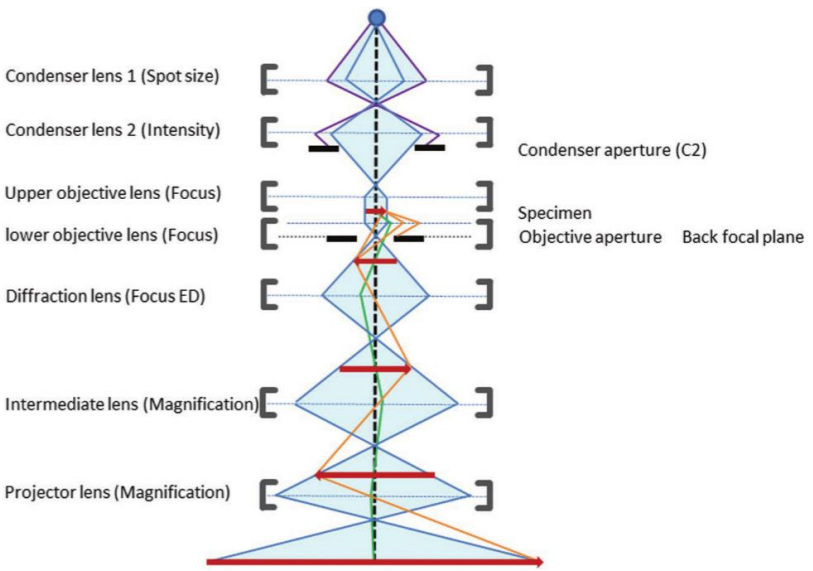
Meskipun Jansen berhasil menciptakan perangkat pembesar, mikroskop generasi awal tersebut masih memiliki banyak kelemahan. Dengan tingkat perbesaran yang masih rendah serta kualitas resolusi gambar yang buruk, alat tersebut belum memenuhi standar presisi untuk observasi ilmiah yang mendalam. Terobosan besar kemudian dicapai oleh ilmuwan Belanda, Antonie van Leeuwenhoek. Ia merancang mikroskop sederhana berlensa tunggal yang tingkat distorsinya jauh lebih rendah dibandingkan mikroskop majemuk di eranya, bahkan mampu menembus perbesaran hingga lebih dari 200 kali[15]. Berkat instrumen buatannya ini, Leeuwenhoek berhasil mengamati berbagai spesimen biologis secara detail, mulai dari sel darah merah (eritrosit), bakteri, hingga spermatozoa. Kualitas visual yang revolusioner ini membuat desain mikroskop Leeuwenhoek diadaptasi sebagai standar utama dalam dunia mikroskopi selama puluhan tahun[16].



Gambar 2.1 Jenis Tipe Mikroskop Berdiri Pertama Kali [17].

Memasuki abad ke-19, perkembangan mikroskop mengalami lompatan yang sangat signifikan melalui kolaborasi Carl Zeiss, Ernst Abbe, dan Otto Schott. Mereka berhasil merancang mikroskop modern tipe berdiri yang dilengkapi dengan lensa apokromatik, yang dapat dilihat pada gambar 2.1. Inovasi ini sangat krusial karena mampu mengoreksi aberasi sferis maupun kromatik, sehingga menghasilkan citra yang jauh lebih tajam dengan resolusi spasial mencapai 0,2 μm[18]. Pencapaian ini sekaligus menjadi tonggak awal standardisasi dan reproduktifitas manufaktur instrumen optik. Walaupun demikian, inovasi ini juga secara tidak langsung memperlihatkan batas fisik fundamental dari cahaya tampak. Ernst Abbe merumuskan sebuah teori yang dikenal sebagai "Batas Abbe" (*Abbe limit*), yang membuktikan bahwa mikroskop optik konvensional difraksi cahaya tidak akan mampu membedakan dua titik yang jaraknya lebih kecil dari setengah panjang gelombang cahaya yang digunakan (sekitar 200 nm)[19]. Keterbatasan fisik ini menjadi kendala utama dalam mengobservasi objek berskala nanometer, seperti struktur internal virus maupun detail

organel sel [14]. Untuk menembus batas difraksi cahaya tersebut, Ernst Ruska, Max Knoll, dan Bodo von Borries merintis penemuan mikroskop elektron pada dekade 1930-an. Dengan memanfaatkan berkas electron yang memiliki panjang gelombang jauh lebih pendek dibandingkan foton Cahaya instrumen seperti *Transmission Electron Microscope* (TEM) dan *Scanning Electron Microscope* (SEM) mampu menghasilkan tingkat perbesaran hingga jutaan kali lipat. Penemuan revolusioner ini membuka lembaran baru yang mengubah lanskap penelitian di bidang ilmu material dan biologi sel[20].



Gambar 2.2 Skematik Electron Microscope [21].

Merujuk pada skematik di Gambar 2.2, terlihat jelas perbedaan fundamental arsitektur mikroskop elektron dibandingkan dengan mikroskop optik konvensional. Mikroskop ini tidak lagi menggunakan lensa optik kaca, melainkan memanfaatkan rangkaian medan elektromagnetik seperti *condenser lens*, *objective lens*, dan *projector lens* untuk memfokuskan tembakan sinar elektron secara terpusat

melewati spesimen. Konfigurasi lintasan elektron inilah yang memungkinkan instrumen tersebut memecahkan batasan difraksi foton dan memproyeksikan struktur mikro dengan resolusi spasial berskala sub-nanometer.

Berdasarkan rekam jejak evolusi tersebut, mikroskop secara etimologi yang diserap dari bahasa Yunani *mikrós* (kecil) dan *skopeîn* (melihat) dapat didefinisikan sebagai instrumen esensial untuk memvisualisasikan objek renik yang tak kasat mata [19]. Meskipun purwarupa pertamanya telah berusia lebih dari 350 tahun [22], mikroskop modern terus berkembang pesat dengan mengintegrasikan berbagai prinsip pencitraan mutakhir, mulai dari sistem optik, elektron, hingga *scanning probe* demi menghasilkan visualisasi beresolusi sangat tinggi[23], Pada era kontemporer, lompatan teknologi telah melahirkan teknik-teknik canggih seperti *super-resolution fluorescence microscopy* dan *confocal laser scanning microscopy*, yang memungkinkan analisis presisi pada skala seluler maupun sub-seluler [24]. Pada era kontemporer, lompatan teknologi telah melahirkan teknik-teknik canggih seperti *super-resolution fluorescence microscopy* dan *confocal laser scanning microscopy*, yang memungkinkan analisis presisi pada skala seluler maupun sub-seluler. Rangkaian inovasi ini mengukuhkan posisi mikroskop sebagai instrumen fundamental yang menggerakkan kemajuan sains dan kedokteran masa kini, dengan peran krusial di berbagai disiplin ilmu seperti *life sciences*, nanoteknologi, ilmu material, sampai kedokteran gigi [25],[26],[27].

2.2 Malaria

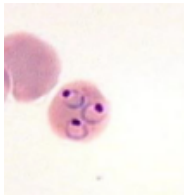
Malaria adalah penyakit menular yang ditularkan melalui vektor (*vector-borne*) yang disebabkan oleh parasit protozoa dari genus *Plasmodium*, yang ditransmisikan ke manusia melalui gigitan nyamuk *Anopheles* betina yang terinfeksi. Dari berbagai spesies yang ada, lima di antaranya menginfeksi manusia *P. falciparum, P. vivax, P. malariae, P. ovale*, dan *P. knowlesi* dengan *P. falciparum* bertanggung jawab atas sebagian besar kasus yang parah dan fatal. Penyakit ini merupakan masalah kesehatan masyarakat global yang utama, dengan sekitar setengah populasi dunia berisiko pada tahun 2020. Beban penyakit ini tetap signifikan, dengan perkiraan 247 juta kasus di seluruh dunia pada tahun 2023 menurut WHO, dan telah menyebabkan 409.000 kematian pada tahun 2019, terutama berdampak pada anak-anak di bawah usia lima tahun. Penyakit ini endemik di negara-negara tropis dan subtropis, di mana faktor lingkungan seperti keberadaan tempat perkembangbiakan nyamuk memainkan peran penting dalam penularannya. Upaya pengendalian bergantung pada diagnosis dini melalui mikroskopi darah, pengobatan tepat waktu, dan manajemen vektor yang kuat, meskipun tantangan terus berlanjut karena siklus hidup parasit yang kompleks dan penyebaran resistensi obat[28].

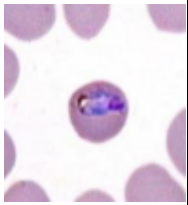
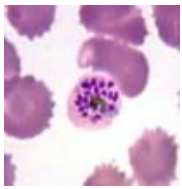
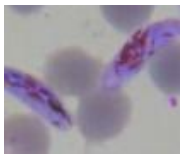
Jenis *Plasmodium* yang sering menyerang manusia adalah *Plasmodium Falciparum* dan *Plasmodium Vivax* pada area asia tenggara sendiri sampai jenis *P. falciparum* memiliki jenis penyakitnya sendiri apabila sudah mencapaitingkat keparahan yang tinggi, yaitu *Severe falciparum Malaria*[29]. Kedua jenis ini, memiliki penjelasan dan citra masing-masing dapat dilihat pada gambar 2.1 yang dapat membantu dalam proses pembuatan tugas akhir ini yang di ambil dari beberapa jurnal.

1. *Plasmodium falciparum*

P. falciparum merupakan jenis parasit orgaisme interselular yang menjadi penyebab terjadinya malaria pada daerah tropik atau malaria tropika, bentuk malaria yang paling bahaya untuk manusia[30][31]. *P. falciparum* termasuk sebagai parasit apicomplexan yang membutuhkan manusia atau inang serta vektro berupa nyamuk *anopheles* untuk membantu dalam menyebarkan dirinya serta menyelesaikan siklus hidupnya[30]. Parasit ini memiliki beberapa fase dalam siklus hidupnya, salah satunya termasuk sebagai fase darah dalam inang manusia, dimana parasit ini akan menginvasi eritrosit dan menjalani siklus replikasi aseksual yang berulang setiap 48 jam, melewati tahap cincin, *trofozoit* dan *skizon.* Selama siklus eritrositik ini, sebagian kecil merozoit yang sedang berkembang tidak melanjutkan replikasi aseksual, tetapi berdefiriansi menjadi gametosit jantan dan betina yang termasuk sebagai tahap seksual yang esensial untuk transmisi kembali kepada nyamuk [32]. Hal ini dapat dilihat tahap perkembangannya dan karakteristik setiap fasenya pada tabel 2.1. Parasit *P. falciparum* sudah memiliki resistansi yang tinggi terhadap beberapa obat, seperti klorokuin dan artemisinin.

Tabel 2.1 Citra dan Karakteristik Fase *Parasit falciparum*[33]

Spesies	Stadium	Citra Gambar	Karakteristik
P. falciparum	*Ring*		Sitoplasma Tebal dan halus dengan satu atau dua titik kromatin kecil. Eritrosit (RBC)

Spesies	Stadium	Citra Gambar	Karakteristik
			yang terinfeksi tidak membesar. Infeksi ganda dalam satu RBC sering terjadi.
	Trophzoite		Jarang terlihat dalam sediaan darah perifer Merupakan perkembangan dari stadium ring dengan sitoplasma lebih padat.
	Schizont		Jarang ditemukan di darah perifer. Mengandung sekitar 8–24 merozoit kecil. Pigmen gelap.
	Gametocyte		Berbentuk sabit atau seperti sosis, khas untuk P. falciparum. Kromatin berbentuk massa tunggal pada

Spesies	Stadium	Citra Gambar	Karakteristik
			makrogametosit (betina) dan lebih menyebar pada mikrogametosit (jantan)

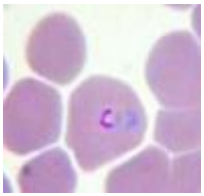
2. *Plasmodium Vivax*:

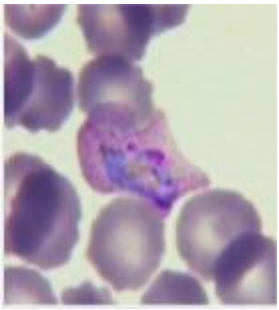
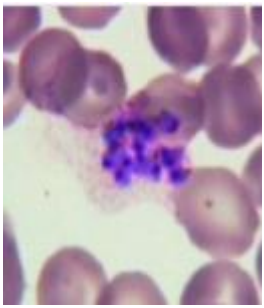
Plasmodium vivax termasuk dalam subgenus Plasmodium dan merupakan salah satu penyebab malaria tertiana, yaitu malaria dengan pola demam setiap 48 jam. Salah satu karakteristik biologis terpentingnya adalah kemampuannya membentuk hipnozoit, yaitu bentuk dorman di dalam hepatosit (sel hati) yang dapat bertahan dalam waktu lama dan menyebabkan relaps (kekambuhan) meskipun parasit sudah tidak terdeteksi lagi di darah perifer[34]. Karena itu, terapi infeksi P. vivax tidak hanya menargetkan stadium eritrositik, tetapi juga harus mencakup eradikasi stadium hati. Dalam siklus intra-eritrositnya, P. vivax cenderung menginfeksi eritrosit muda (retikulosit), yang berkontribusi pada pembesaran sel darah merah yang terinfeksi. Parasit ini juga mulai memproduksi gametosit relatif lebih awal selama perkembangan dalam darah, sehingga potensi penularan ke nyamuk Anopheles dapat terjadi bahkan pada fase awal infeksi[34], [35].

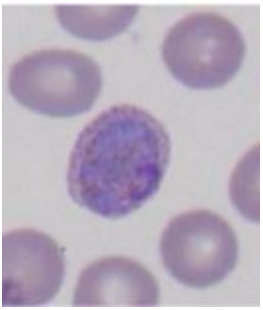
Secara epidemiologis, infeksi *P. vivax* sangat berkaitan dengan keberadaan antigen Duffy (Duffy antigen receptor for chemokines/DARC) pada permukaan eritrosit. Individu dengan

fenotipe Duffy-negatif memiliki resistensi alami terhadap sebagian besar strain P. vivax karena parasit kesulitan memasuki eritrosit tanpa reseptor tersebut[34]. Hal ini menjelaskan mengapa P. vivax jarang ditemukan di Afrika Tengah dan Afrika Barat, wilayah dengan prevalensi tinggi populasi Duffy-negatif. Secara morfologis, P. vivax memiliki ciri khas berupa pembesaran eritrosit yang terinfeksi, bentuk trofozoit yang amoeboid, serta adanya bintik Schüffner pada pewarnaan Giemsa[36]. Bentuk-bentuk perkembangan parasit dalam darah perifer meliputi stadium ring, trofozoit, skizon, dan gametosit ditampilkan pada Tabel 2.2 berikut.

Tabel 2.2 Citra Dan Karakteristik Parasit *Vivax[33]*

Spesies	Stadium	Citra Gambar	Karakteristik
P.vivax	*Ring*		Memiliki titik kromatin yang relatif besar. Sitoplasma dapat berkembang menjadi bentuk amoeboid seiring maturase.

Spesies	Stadium	Citra Gambar	Karakteristik
	Trophozoite		Sitoplasma jelas bersifat amoeboid dengan titik kromatin besar. Tampak pigmen halus berwarna kuning kecokelatan (hemozoin).
	Schizont		Berukuran besar dan dapat hampir memenuhi seluruh sel darah merah yang terinfeksi. Mengandung sekitar 12–24 merozoit.

Spesies	Stadium	Citra Gambar	Karakteristik
	Gametocyte		Berbentuk bulat hingga oval. Memiliki pigmen cokelat yang tersebar. Dapat hampir memenuhi RBC yang terinfeksi.

Diagnosis malaria dapat ditegakkan melalui evaluasi klinis berdasarkan tanda dan gejala seperti demam periodik, menggigil, sakit kepala, anemia, dan splenomegali. Namun, pendekatan klinis saja memiliki tingkat akurasi yang terbatas karena gejalanya sering menyerupai penyakit tropis lain, seperti demam tifoid, dengue, atau infeksi virus lainnya, serta adanya kemungkinan koinfeksi yang dapat memperburuk gambaran klinis. Oleh karena itu, konfirmasi laboratorium sangat diperlukan untuk memastikan diagnosis.

Salah satu metode diagnostik utama adalah pemeriksaan mikroskopis sediaan darah tepi, baik darah Tebal. Pemeriksaan ini memungkinkan identifikasi spesies Plasmodium, penentuan stadium perkembangan parasit (ring, trofozoit, skizon, gametosit), serta estimasi tingkat parasitemi. Citra mikroskopis yang dihasilkan menjadi dasar dalam membedakan karakteristik morfologis seperti yang telah dijelaskan sebelumnya pada P. falciparum dan P. vivax.

Selain mikroskopi, tersedia juga rapid diagnostic test (RDT) berbasis deteksi antigen. Metode ini bekerja secara imunokromatografi

dengan mendeteksi antigen spesifik malaria dalam sampel darah dalam jumlah kecil. Antigen yang umum ditargetkan antara lain histidine-rich protein 2 (HRP-2) yang spesifik untuk P. falciparum, serta enzim seperti parasite lactate dehydrogenase (pLDH) dan aldolase yang dapat ditemukan pada berbagai spesies Plasmodium. RDT memberikan hasil yang relatif cepat dan praktis, terutama di daerah dengan keterbatasan fasilitas laboratorium, meskipun sensitivitas dan spesifisitasnya dapat bervariasi tergantung kepadatan parasit dan variasi genetik parasit (seperti delesi gen HRP-2).

Meskipun pemeriksaan mikroskopis masih dianggap sebagai gold standard karena kemampuannya mengidentifikasi spesies dan menghitung parasitemia secara langsung, metode ini memiliki beberapa keterbatasan. Proses pemeriksaan membutuhkan waktu, ketelitian tinggi, serta tenaga analis yang terlatih, dan hasilnya dapat bersifat subjektif tergantung pengalaman pemeriksa. Variasi kualitas preparat dan pewarnaan juga dapat memengaruhi akurasi[37]. Secara umum, terdapat dua jenis sediaan yang digunakan, yaitu sediaan darah tipis (*thin smear*) dan sediaan darah tebal (*thick smear*). Sediaan darah tipis digunakan untuk mempertahankan morfologi sel darah merah secara utuh sehingga sangat berguna untuk identifikasi spesies dan stadium parasit secara detail. Sebaliknya, sediaan darah tebal menampung volume darah yang lebih banyak dalam area yang lebih kecil, sehingga memiliki sensitivitas yang jauh lebih tinggi untuk melakukan skrining dan mendeteksi keberadaan parasit secara cepat. Penelitian ini secara khusus menggunakan sediaan darah tebal (*thick smear*) yang diperoleh langsung dari pasien di Puskesmas Hanura. Pada proses pembuatan preparat sediaan darah tebal, darah tidak difiksasi menggunakan

metanol sebelum pewarnaan. Hal ini menyebabkan sel darah merah mengalami lisis (pecah atau hancur) selama proses persiapan.

Untuk memperjelas objek di bawah mikroskop, preparat sediaan darah tebal diwarnai menggunakan pewarnaan *giemsa*. Pewarnaan Giemsa merupakan teknik pewarnaan standar yang memberikan kontras visual pada sel, di mana kromatin (inti) parasit malaria akan menyerap warna merah atau ungu kehitaman, sementara sitoplasma parasit akan berwarna biru. Pewarnaan ini sangat krusial untuk membedakan struktur parasit dari komponen darah lainnya.

Karakteristik sediaan darah tebal dengan pewarnaan Giemsa ini sangat mendasari batasan deteksi pada penelitian ini. Karena sel darah merah telah lisis dan hancur, objek yang dideteksi oleh model *deep learning* bukanlah sel darah merah yang terinfeksi secara utuh, melainkan parasit malaria itu sendiri. Model YOLOv8m yang dikembangkan bertugas untuk melokalisasi dan mengklasifikasikan komponen parasit tersebut (*Plasmodium falciparum* atau *Plasmodium vivax*) di antara sisa-sisa artefak lisis, kotoran pewarnaan, dan sel darah putih (*leukosit*) yang masih utuh pada lapang pandang mikroskop.

2.3 Deep Learning

Deep learning merupakan salah sub-bidang khusus seperti *machine learning* yang didefinisikan sebagai konsep pembelajaran mesin berbasis jaringan saraf tiruan (*artificial neural networks*)[38], [39]. Metode ini terinspirasi dari struktur dan fungsi otak manusia, menggunakan arsitektur jaringan saraf dengan banyak lapisan (*multi-layered*) untuk mempelajari pola dan representasi kompleks secara otomatis dari kumpulan data dalam skala besar[40][41].

Perbedaan mendasar antara *deep learning* dengan *machine learning* konvensional terletak pada pendekatan ekstraksi fitur. Algoritma *machine learning* dasar seringkali memiliki keterbatasan dalam menangani tugas kompleks yang melibatkan data tidak terstruktur seperti gambar, suara, dan video. Hal ini karena *machine learning* konvensional sangat bergantung pada proses rekayasa fitur (*feature en*

gineering) secara manual, di mana seorang ahli harus merancang dan mengekstrak fitur relevan dari data mentah sebuah proses yang memakan waktu dan tenaga[40][42]. Sebaliknya, kemampuan fundamental *deep learning* adalah secara otomatis menemukan dan mengekstrak fitur-fitur yang dibutuhkan langsung dari data mentah, sehingga meminimalisir intervensi manusia[43].

Konsep “deep” atau "dalam" pada *deep learning* merujuk pada keberadaan banyak lapisan tersembunyi (*hidden layers*) di antara lapisan input dan output. Jaringan saraf tiruan ini terdiri dari komponen inti berupa neuron yang saling terhubung. Setiap lapisan dirancang untuk mempelajari fitur secara hierarkis: lapisan awal mungkin hanya akan mendeteksi fitur sederhana seperti tepi atau warna pada sebuah gambar, sementara lapisan yang lebih dalam akan mampu mengenali bentuk, tekstur, hingga objek yang utuh[41], [44]. Kemampuan untuk memproses informasi secara non-linear melalui banyak lapisan inilah yang memungkinkan *deep learning* unggul dalam ekstraksi fitur, identifikasi pola, dan klasifikasi[40][45].

Beberapa arsitektur model *deep learning* yang paling dikenal antara lain:

1. *Convolutional Neural Network* (CNN): Dirancang khusus untuk memproses data berbentuk grid seperti gambar. CNN sangat efektif untuk tugas-tugas visi komputer, termasuk klasifikasi dan deteksi objek.

2. *Recurrent Neural Network* (RNN): Didesain untuk data sekuensial atau data deret waktu, seperti teks atau suara. RNN memiliki "memori" untuk memproses informasi dari input sebelumnya.

3. *Transformers*: Arsitektur modern yang menggunakan mekanisme *self-attention* dan telah menjadi standar untuk tugas-tugas pemrosesan bahasa alami (*Natural Language Processing*) yang canggih[40][46].

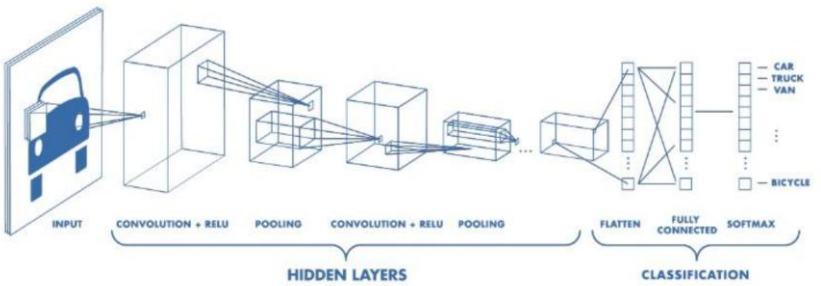
Untuk menjalankan tugasnya, *deep learning* membutuhkan data dengan volume yang sangat besar guna membangun model dengan tingkat akurasi yang tinggi. Selain itu, eksekusi pelatihan model *deep learning* juga menuntut daya komputasi yang besar. Oleh karena itu, penggunaan *Graphics Processing Unit* (GPU) menjadi sangat penting, karena GPU telah dioptimalkan secara khusus untuk mempercepat proses pelatihan model secara signifikan[47][40]. Meskipun unggul dalam performa pada data kompleks, model *deep learning* sering dianggap sebagai *"black box"* karena proses pengambilan keputusannya yang sulit ditelusuri, berbeda dengan algoritma *machine learning* tradisional yang seringkali lebih mudah diinterpretasikan[48].

2.4 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah salah satu arsitektur *deep learning* berbasis jaringan saraf tiruan (JST) yang dirancang secara khusus untuk memproses data berstruktur grid, seperti

citra visual dua dimensi. Keunggulan utama CNN dibandingkan jaringan saraf konvensional (*Multi-Layer Perceptron*) terletak pada kemampuannya untuk mengekstraksi dan mempelajari representasi fitur spasial secara otomatis dan hierarkis tanpa memerlukan ekstraksi fitur manual. Berkat kemampuan ini, CNN secara luas diimplementasikan dalam berbagai tugas *computer vision*, mulai dari klasifikasi citra, segmentasi semantik, hingga deteksi objek yang kompleks [49].

Secara arsitektural, CNN dibangun oleh serangkaian lapisan (*layers*) yang saling terhubung dan terbagi menjadi dua blok fungsi utama: *Feature Extraction Layer* (Lapisan Ekstraksi Fitur) dan *Classification Layer* (Lapisan Klasifikasi). Blok ekstraksi fitur utamanya terdiri dari *Convolutional Layer* dan *Pooling Layer* yang bertugas mengubah citra mentah menjadi peta fitur (*feature maps*). Sementara itu, blok klasifikasi umumnya terdiri dari *Fully Connected Layer* yang bertugas mengolah kumpulan fitur berdimensi tinggi tersebut menjadi probabilitas kelas keluaran.



Gambar 2.3 Arsitektur CNN[50].

Melalui ilustrasi Gambar 2.3, keseluruhan alur kerja dari arsitektur *Convolutional Neural Network* (CNN) dapat diamati secara

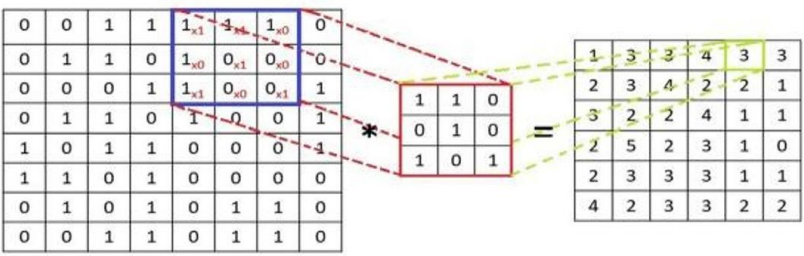
terstruktur. Proses dimulai dari tahap penerimaan citra masukan pada matriks *Input*, yang kemudian diteruskan ke dalam blok *Hidden Layers* untuk mengalami proses ekstraksi fitur secara hierarkis melalui kombinasi operasi konvolusi, fungsi aktivasi non-linier, dan *pooling*. Setelah fitur-fitur spasial esensial berhasil diekstrak dan direduksi dimensinya, peta fitur tersebut diratakan (*flatten*) menjadi vektor satu dimensi agar dapat diproses oleh blok *Classification Layer* (*Fully Connected* dan *Softmax*) untuk menghasilkan probabilitas tebakan kelas akhir.

2.4.1 Convolutional Layer

Convolutional Layer merupakan fondasi komputasi utama dari arsitektur CNN yang bertanggung jawab untuk melakukan operasi ekstraksi fitur dari citra masukan. Lapisan ini beroperasi dengan menggeserkan sejumlah matriks filter (*kernel*) di seluruh area citra masukan untuk melakukan operasi matematika perkalian matriks secara berulang (dot product). Proses ini menghasilkan feature map yang merepresentasikan pola-pola visual tertentu, seperti garis tepi (edges), gradien warna, hingga bentuk objek yang kompleks, sambil tetap mempertahankan struktur tata letak spasial dari citra asli[49], [50].

Setiap filter di dalam *convolutional layer* hanya berinteraksi dengan sebagian kecil area dari citra pada satu waktu, yang dikenal dengan istilah *local receptive field*. Konsep ini memungkinkan model untuk melakukan pembagian bobot (*parameter sharing*), di mana satu filter yang sama digunakan secara berulang di seluruh area gambar. Mekanisme ini tidak hanya mengurangi jumlah parameter komputasi secara drastis sehingga model menjadi lebih efisien, tetapi juga menciptakan sifat translasi invarian (*spatial invariance*). Sifat ini sangat

penting dalam analisis citra mikroskopis karena memungkinkan model untuk mengenali parasit malaria terlepas dari posisinya pada kaca preparat[49], [51]. Secara matematis, lapisan konvolusi beroperasi menggunakan sebuah matriks filter (sering juga disebut sebagai *kernel*) untuk menghitung nilai konvolusi dari citra masukan dan mengekstrak fitur-fitur fundamentalnya. Filter ini memiliki dimensi yang lebih kecil dibandingkan citra asli, namun memuat parameter bobot (*weights*) yang akan terus diperbarui selama proses pelatihan. Untuk memahami bagaimana ekstraksi fitur ini terjadi secara spasial, ilustrasi komputasi sederhana dari operasi konvolusi dapat dilihat pada Gambar 2.4.



Gambar 2.4 Proses Komputasi Convolutional Layer[50].

Berdasarkan Gambar 2.4, mekanisme ekstraksi fitur dimulai ketika matriks filter meluncur (*sliding*) setahap demi setahap melintasi matriks piksel citra masukan. Pada setiap pergeserannya, jaringan menghitung perkalian titik (*dot product*) antara nilai bobot pada filter dengan nilai intensitas piksel citra yang berada tepat di bawahnya, kemudian menjumlahkannya. Rangkaian proses matematis ini menghasilkan sebuah matriks dua dimensi baru yang dikenal sebagai *Activation Map* atau peta aktivasi. Hasil dari operasi konvolusi selanjutnya dilewatkan ke dalam sebuah fungsi aktivasi non-linier untuk menentukan apakah informasi fitur tersebut cukup kuat untuk

diteruskan ke lapisan berikutnya[52]–[54]. Salah satu fungsi aktivasi yang paling dominan digunakan adalah *Rectified Linear Unit* (ReLU). ReLU sangat populer karena struktur matematisnya yang sederhana, yaitu mengubah semua nilai input negatif menjadi nol dan membiarkan nilai positif tetap sama (Persamaan 2.1). Hal ini membuat waktu komputasi menjadi sangat cepat dan membantu mempercepat konvergensi gradien selama proses pelatihan [53], [55].

$$\psi(x) = \begin{cases} 0 & \text{if } x < 0, \\ x & \text{if } x \geq 0 \end{cases} \qquad (2.1)$$

Dalam praktiknya, ketika operasi konvolusi diterapkan pada citra, ukuran dimensi spasial dari *feature map* yang dihasilkan cenderung akan menyusut secara bertahap. Hal ini dapat menyebabkan hilangnya informasi spasial penting yang berada di tepi gambar (piksel perbatasan). Untuk menanggulangi masalah ini, CNN menerapkan teknik *padding*, yaitu penambahan deretan piksel semu (biasanya bernilai nol, atau *zero-padding*) di sekeliling batas luar citra masukan sebelum operasi konvolusi dilakukan. Teknik ini memastikan bahwa setiap piksel, termasuk yang berada di tepi, mendapatkan kesempatan komputasi yang sama[56], [57], [58].

2.4.2 Pooling Layer

Pooling Layer atau lapisan *subsampling*, umumnya disisipkan di antara dua *convolutional layer* yang berurutan. Lapisan ini berfungsi untuk mereduksi dimensi spasial (tinggi dan lebar) dari peta fitur secara progresif, tanpa mengubah kedalaman (jumlah saluran/filter) dari peta fitur tersebut[59]. Reduksi ini krusial untuk menekan jumlah parameter

dan beban komputasi secara keseluruhan, sekaligus mencegah terjadinya *overfitting*, yaitu suatu kondisi di mana model menghafal data latih namun gagal berkinerja baik pada data baru[60], [61]. Peta fitur (*feature map*) yang dihasilkan oleh *convolutional layer* seringkali masih memiliki sensitivitas yang tinggi terhadap lokasi persis dari sebuah fitur di dalam citra. Untuk mengatasi sensitivitas tersebut dan mengurangi beban komputasi, arsitektur CNN umumnya menyisipkan *Pooling Layer* untuk melakukan *downsampling* (pengurangan dimensi spasial tinggi dan lebar). Berbeda dengan lapisan konvolusi, operasi pada *pooling layer* murni menggunakan fungsi matematika sederhana dan sama sekali tidak melibatkan parameter bobot yang dapat dipelajari (*learnable weights*).

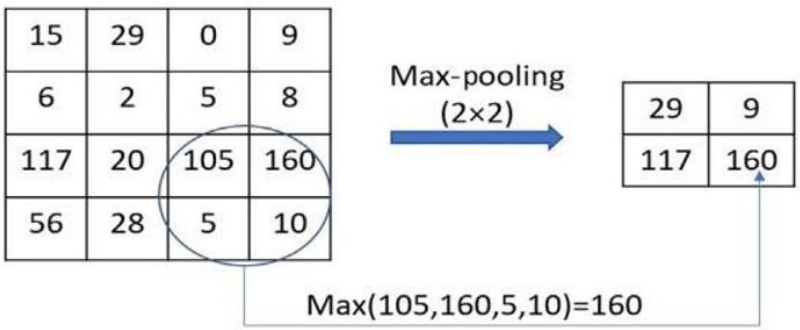
Secara teknis, operasi *downsampling* di dalam lapisan ini diatur oleh dua parameter utama, yaitu:

1. Filter Size (Ukuran Kernel): Menentukan seberapa luas area spasial pada peta fitur (misalnya matriks berukuran 2x2 piksel) yang akan diringkas atau disederhanakan menjadi satu nilai representasi tunggal.

2. Stride (Langkah Geser): Menentukan jarak pergeseran kernel saat memindai area peta fitur. Penggunaan matriks 2x2 dengan *stride* bernilai 2 akan menghasilkan area pemindaian yang saling tidak tumpang tindih (*nonoverlapping*), sehingga dimensi citra akan menyusut tepat menjadi setengah dari ukuran aslinya[50], [62], [63].

Dua operasi matematis yang paling umum digunakan dalam proses *pooling* adalah *Max Pooling* (mengambil nilai tertinggi) dan

Average Pooling (mengambil nilai rata-rata), seperti yang diilustrasikan pada Gambar 2.5.



Gambar 2.5 Proses Perhitungan Pooling Layer

Berdasarkan visualisasi komputasi pada Gambar 2.5, pada operasi Max Pooling, filter mengevaluasi sekumpulan piksel dalam area cakupannya dan hanya mengekstrak nilai piksel yang paling tinggi. Dalam konteks deteksi citra mikroskopis malaria, *Max Pooling* sangat direkomendasikan karena kemampuannya dalam menonjolkan fitur-fitur yang paling tajam dan dominan, seperti bercak kromatin pekat pada *Plasmodium* atau batas tepi dinding sel darah, sambil mengabaikan *noise* di latar belakang. Sebaliknya, operasi Average Pooling menghitung nilai rata-rata dari seluruh piksel dalam area cakupan, yang menghasilkan representasi fitur yang secara visual lebih halus (*smooth*)[50], [64]

Penyusutan dimensi spasial melalui *pooling layer* ini memberikan dampak yang sangat signifikan terhadap ketahanan (*robustness*) model. Dalam dimensi peta fitur yang lebih kecil dan padat, lokasi fitur parasit cenderung menjadi tetap dan stabil (*translation invariance*) meskipun posisi objek parasit tersebut

bergeser, terputar, atau sedikit berbeda orientasinya pada citra masukan. Lebih lanjut, peta fitur yang telah mengalami proses *pooling* (sering disebut *pooled feature map*) memiliki karakteristik yang identik dengan peta konvolusi, yaitu tersusun atas neuron-neuron. Namun, karena lapisan ini tidak dilengkapi dengan fungsi aktivasi (seperti ReLU), nilai matematis hasil ekstraksi *Max* atau *Average* secara otomatis dan langsung merepresentasikan nilai keluaran (*output*) dari neuron pada *pooling layer* tersebut untuk diteruskan ke tahap klasifikasi[52], [61], [65].

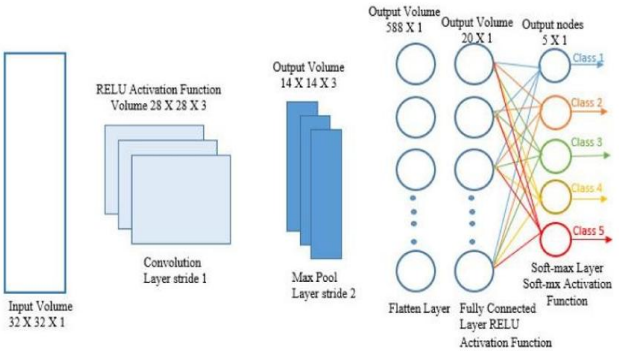
2.4.3 Fully Connected Layer

Setelah citra masukan melewati serangkaian *Convolutional Layer* dan *Pooling Layer*, arsitektur CNN pada umumnya akan diakhiri dengan satu atau lebih *Fully Connected Layer* (FC Layer)[49], [51]. Jika lapisan-lapisan sebelumnya bertindak sebagai ekstraktor fitur hierarkis yang mengidentifikasi pola visual secara spasial, maka FC Layer berfungsi sebagai unit penalaran (*reasoning unit*) dan pengambil keputusan akhir. Dinamakan "terhubung penuh" karena setiap neuron pada lapisan ini memiliki koneksi langsung yang berbobot (*weighted connection*) dengan seluruh neuron yang ada pada lapisan sebelumnya, mengadopsi struktur jaringan saraf tiruan tradisional (*Multi-Layer Perceptron*)[66].

1. Transisi Dimensi (*Flattening*)

Sebelum data dapat diproses oleh FC Layer, terdapat sebuah proses transisi krusial yang disebut *flattening*. Peta fitur keluaran dari *pooling layer* terakhir masih berupa matriks tiga dimensi (tinggi x lebar x kedalaman saluran). Proses *flattening* meruntuhkan struktur spasial

tersebut dan meratakannya menjadi sebuah susunan vektor fitur satu dimensi (1D).



Gambar 2.6 Proses Flattening dan Koneksi [50].

Sebagaimana diilustrasikan pada Gambar 2.6, sebelum dapat diproses oleh *Fully Connected Layer*, peta fitur (*feature map*) keluaran dari *pooling layer* terakhir yang masih berupa matriks tiga dimensi harus diruntuhkan struktur spasialnya. Melalui proses *flattening*, nilai-nilai tersebut diratakan menjadi sebuah susunan vektor fitur satu dimensi (1D)[67]. Vektor 1D hasil *flattening* ini tidak lagi merepresentasikan piksel di koordinat X dan Y, melainkan telah menjadi representasi abstrak matematis tingkat tinggi yang siap dikalikan dengan bobot (*weights*) jaringan untuk dievaluasi probabilitas kelasnya[66][68].

2. Komputasi Matematis dan Probabilitas Kelas

Di dalam FC Layer, operasi matematis yang terjadi adalah perkalian titik (*dot product*) antara vektor input dengan matriks bobot jaringan, ditambahkan dengan nilai bias, lalu dilewatkan pada fungsi aktivasi akhir. Untuk tugas klasifikasi multikelas (misalnya

membedakan *Plasmodium falciparum*, *Plasmodium vivax*, atau sel sehat), lapisan *output* paling ujung biasanya menggunakan fungsi aktivasi *Softmax*[69]. Fungsi Softmax bertugas mengonversi nilai numerik mentah (*logits*) dari neuron menjadi distribusi probabilitas dengan rentang nilai 0 hingga 1, di mana total seluruh probabilitas kelas akan berjumlah 1 (100%). Hal ini memungkinkan model untuk memberikan prediksi yang dapat diinterpretasikan secara statistik, misalnya: model yakin 88% bahwa objek yang terdeteksi adalah *P. vivax* dan 12% kemungkinan berupa artefak[70], [71].

3. Kompleksitas Parameter dan Teknik Regularisasi (*Dropout*)

Salah satu kelemahan fundamental dari *Fully Connected Layer* (FC Layer) adalah beban komputasi yang sangat ekstrem akibat kuantitas parameter yang masif. Sebagai ilustrasi, apabila peta fitur terakhir memiliki dimensi spasial 7 x 7 x 512, proses *flattening* akan mengonversinya menjadi sebuah vektor berukuran 25.088 elemen[72]. Jika FC Layer pertama dirancang memiliki 4.096 neuron, maka model harus menghitung lebih dari 102 juta koneksi bobot (*weights*) hanya pada satu lapisan tersebut[73]. Meskipun kapasitas parameter yang besar ini memungkinkan model untuk mempelajari detail fitur mikroskopis sel darah yang sangat kompleks, kondisi ini juga memicu kerentanan jaringan terhadap *overfitting*. *Overfitting* merupakan suatu anomali di mana model kehilangan kemampuan generalisasinya karena hanya "menghafal" data latih, sehingga akurasinya akan menurun drastis saat dihadapkan pada citra baru[74].

Untuk menghindari risiko tersebut, teknik regularisasi seperti *Dropout* secara lazim diterapkan pada FC Layer. Mekanisme *Dropout* beroperasi dengan cara menonaktifkan (memutus koneksi) sejumlah

neuron secara acak pada persentase tertentu misalnya 50% di setiap siklus iterasi pelatihan[75]. Pendekatan ini mencegah jaringan saraf agar tidak terlalu bergantung pada satu atau dua jalur koneksi spesifik tertentu, serta memaksa model untuk mendistribusikan pembelajarannya secara merata ke seluruh neuron. Hasilnya, model deteksi menjadi jauh lebih tangguh (*robust*) dan tetap akurat ketika diuji menggunakan data citra sediaan darah baru yang belum pernah diobservasi sebelumnya[68], [73], [76].

2.4.4 Arsitektur CNN

Convolutional Neural Network telah menjadi landasan struktural yang mendorong evolusi berbagai algoritma pendeteksi objek modern. Dalam perkembangannya, arsitektur dasar CNN telah dimodifikasi dan dikembangkan menjadi berbagai model mutakhir yang dirancang untuk menyeimbangkan antara tingkat akurasi dan efisiensi komputasinya [77][78].

Secara umum, arsitektur pendeteksi objek berbasis CNN terbagi menjadi dua kategori utama: model *two-stage detector* seperti Faster R-CNN yang memisahkan proses pencarian lokasi objek dan klasifikasi, serta model *one-stage detector* seperti YOLO (*You Only Look Once*), SSD (*Single Shot MultiBox Detector*), dan *EfficientDet* yang melakukan lokalisasi dan klasifikasi secara simultan dalam satu jaringan utuh[79].

Perbedaan pendekatan arsitektural ini menghasilkan karakteristik kinerja yang bervariasi ketika diuji pada dataset citra beresolusi tinggi, termasuk dalam tugas analisis citra medis mikroskopis. Beberapa studi komparatif terkini (2020-2026) yang mengkaji performa berbagai arsitektur deteksi objek mulai dari generasi

awal hingga literasi paling mutakhir seperti YOLOv11 dan YOLOv12 menunjukkan pola perbandingan metrik evaluasi seperti yang dirangkum pada Tabel 2.3 [80], [81].

Tabel 2.3 Rangkuman Performa Metrik Arsitektur

Arsitektur	Precision	Recall	mAP@0.5
YOLOv4	0.82	0.81	0.82
YOLOv5	0.85	0.84	0.86
YOLOv7	0.87	0.86	0.87
YOLOv8	0.89	0.88	0.89
YOLOv11	0.91	0.90	0.91
YOLOv12	0.93	0.91	0.92
Faster R-CNN	0.88	0.85	0.86
SSD	0.78	0.75	0.76
EfficientDet	0.84	0.82	0.83

Berdasarkan Tabel 2.3, dapat diamati bahwa keluarga arsitektur YOLO secara konsisten menunjukkan peningkatan performa dari generasi ke generasi. Proses ini dilakukan dengan menggunakan dataset normal dari gambar 2.7. Varian *state of the art* terbaru seperti YOLOv11 dan YOLOv12 mencatatkan tingkat akurasi puncak melampaui 90%, yang didorong oleh optimasi modul *attention* tingkat lanjut dan efisiensi *parameter sharing*. Kendati demikian, YOLOv8 tetap mempertahankan posisinya sebagai *milestone* yang paling

signifikan dalam arsitektur deteksi objek. Dengan adopsi *anchotr free detection* dan nilai mAP mencapai 0.89, YOLOv8 dinilai sebagai arsitektur yang paling teruji validitas dan stabilitasnya secara luas untuk berbagai implementasi sistem medis nyata, jika dibandingkan dengan versi-versi eksperimental terbarunya [62],[82].

Selain akurasi, elemen fundamental lain yang menjadi tolok ukur implementasi sistem deteksi terutama untuk kebutuhan diagnosis klinis yang bersifat *real time* adalah kecepatan pemrosesan model atau *Frame Per Second* (FPS). Perbandingan efisiensi komputasi dari masing-masing arsitektur disajikan pada Tabel 2.4.

Tabel 2.4 Rata-rata Kecepatan Pemrosesan Arsitektur[62]

Arsitektur	**Rata-rata FPS**
YOLOv4	45
YOLOv5	60
YOLOv7	55
YOLOv8	65
YOLOv11	72
YOLOv12	78
Faster R-CNN	12
SSD	38

Data kecepatan komputasi pada Tabel 2.4 menegaskan kelemahan utama dari arsitektur *two-stage* seperti Faster R-CNN, yang

hanya mencatatkan 12 FPS sehingga kurang ideal untuk analisis *real-time*. Di sisi lain, generasi YOLOv8 hingga YOLOv12 mendominasi ranah inferensi berkecepatan tinggi. Rentang kecepatan 65 hingga 78 FPS membuktikan bahwa pembaruan pada blok konvolusi internal YOLO sukses menyeimbangkan antara tingginya akurasi diagnosis medis dengan rendahnya latensi inferensi [62].

Untuk memberikan analisis yang lebih komprehensif, performa sebuah arsitektur juga harus ditinjau dari profil kesalahan (*error profile*) yang dihasilkannya selama proses deteksi objek. Tabel 2.5 membedah tingkat persentase kegagalan model dalam tiga kategori utama: *Partially Detected*,*Misclassified*, dan *Missed*.

Tabel 2.5 Analisis Persentase *Error* Deteksi[82]

Arsitektur	**Partially Detected**	**Misclassified**	**Missed**
YOLOv4	12%	8%	9%
YOLOv5	10%	6%	7%
YOLOv7	8%	5%	6%
YOLOv8	5%	3%	4%
YOLOv11	4%	2%	3%
YOLOv12	3%	2%	2%
Faster R-CNN	7%	4%	8%
SSD	15%	11%	10%

EfficientDet	11%	8%	8%

Objek parasit mikroskopis seperti *Plasmodium* sangat rentan mengalami klasifikasi silang (*misclassification*) dengan artefak kotoran pada kaca preparat. Merujuk pada Tabel 2.5, seri arsitektur YOLO terbaru sukses menekan angka *missed detection* hingga di bawah 5%. Hal ini sangatlah krusial, karena metrik *False Negative* yang rendah merupakan syarat mutlak agar sebuah sistem dapat digunakan untuk memvalidasi tingkat kepadatan parasit pasien di puskesmas atau laboratorium klinik.

Secara keseluruhan, komparasi ini memperkuat justifikasi bahwa keluarga arsitektur YOLO (khususnya YOLOv8 yang telah sangat stabil dan tervalidasi luas) merupakan landasan algoritma yang paling rasional dan andal untuk dikembangkan dalam sistem diagnosis otomatis sediaan darah malaria [12], [62], [82].

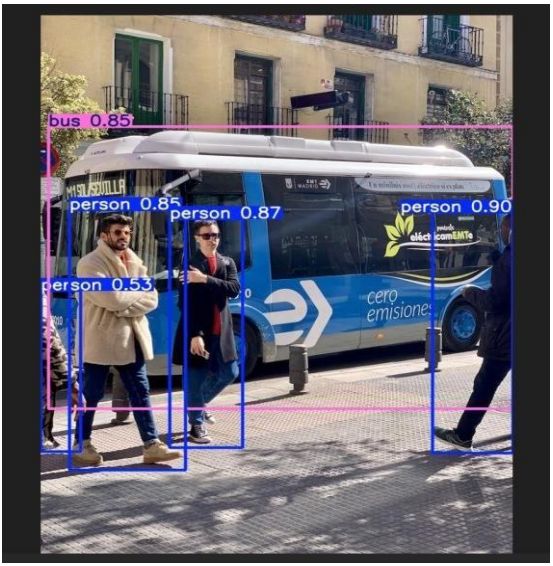
2.5 Algoritma YOLO (*You Only Look Once*)

Algoritma *You Only Look Once* (YOLO) termasuk sebagai salah satu algoritma yang sangat populer dalam mendeteksi objek, gambar, serta visi komputer. Kemampuan YOLO dalam melakukan deteksi objek atau gambar secara *real-time* memiliki tingkat akurasi yang tinggi. Maka oleh karena itu, penggunaan YOLO menjadi pilihan utama untuk mayoritas dalam berbagai aplikasi modern. YOLO sendiri sudah mengeluarkan berbagai versi dimulai dengan YOLOv1 hingga YOLOv12. Setiap versi YOLO membawa peningkatan yang signifikan dalam kecepatan, akurasi, serta efisiensi dalam proses training, tentu

juga memberikan berbagai fitur tambahan dalam proses deteksi objek[83], [84].

Penggunaan YOLO dapat menghasilkan bounding box yang dapat memperkirakan keberadaan objek secara kotak, kecuali YOLO versi awal. Hal ini diikuti oleh klarifikasi dengan CNN untuk menentukkan keberadaan objek dalam *bounding box* tersebut. YOLO sendiri menggunakan pendekatan berbeda, yaitu hanya menggunakan CNN hanya satu kali untuk memprediksi semua jenis objek yang ada dalam *bounding box* tersebut dan membagikan gambar menjadi grid S x S, Dimana setiap sel bertanggung jawab dalam memprediksi *bounding boxes*, tingkat *confidence* dari masing-masing sel dan probabilitas kelas serta ukuran grid (S) dari gambar tersebut [12], [85].

Mekanisme kerja YOLO dalam mendeteksi objek atau gambar dimulai dengan gambar *input* dibagi menjadi *grid* S x S. Setiap sel *grid* memiliki tanggung jawab untuk memprediksi objek yang pusatnya jatuh dalam sel tersebut. Dalam proses deteksi YOLO area atau *box* yang lebih terang pada gambar *input* memiliki tingkat probabilitas deteksi yang lebih tinggi untuk menentukkan objek kelas yang sesuai. Benda yang berada dalam sel tersebut akan menghasilkan *heatbox* dari area Lokasi objek. Setelah memprediksi *bounding box* dan *confident score*, YOLO menghasilkan banyak kotak dengan tingkat *overlapping* yang tinggi. NMS (*Non-Maximum Suppresion*) menghasilkan kotak yang *overlapping* atau tumpeng tinggi dengan memilih kotak skor kepercayaan tinggi. Dalam Gambar 2. (Isi) terlihat berbagai kotak warna-warni atau prediksi awal YOLO yang difilter menjadi lebih sedikit. Akhirnya, algoritm menghasilkan deteksi final berupa bounding box dengan skor kepercayaan tinggi yang lolos proses NMS[86], [87].

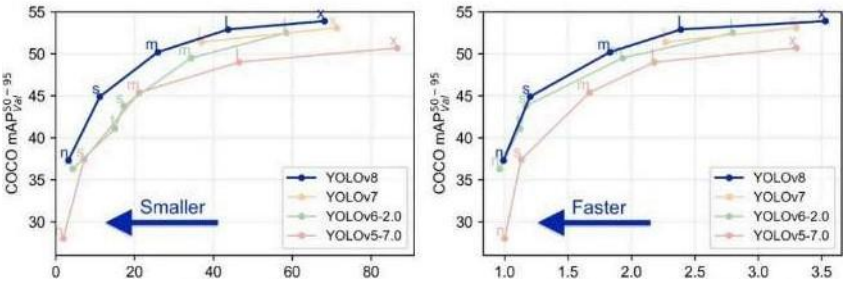


Gambar 2.7 Ilustrasi Hasil Deteksi YOLO[87].

Dalam konteks Gambar 2.7 terlihat berbagai kotak warna-warni yang merupakan prediksi awal di filter menjadi sedikit. Yang dimana akhirnya algoritma akan menentukkan deteksi final berupa bounding box dengan tingkat kepercayaan terhadap hasil gambar.

Model YOLOv8 masih termasuk sebagai model evolusi yang baru dari algoritma deteksi objek *You Only Look Once*, model YOLO ini memberikan kemampuan untuk mendeteksi virus-virus yang ada dalam *slide* darah merah tebal. Dengan memberikan arsitektur yang lebih efisien dan akurat dibandingkan model-model YOLO sebelumnya, YOLOv8 dapat mendeteksi perbedaan antara virus *falciparum* dan virus *vivax* dalam *slide* darah merah tebal, sel darah merah, dan sel darah putih. Kemampuan model ini dalam mendeteksi virus memungkinkan pengamatan secara lanjut atas perbedaan bentuk-bentuk virus yang mungkin tidak dapat terdeteksi oleh manusia secara

langsung dan membantu dalam proses deteksi secara langsung atau *real-time*[87].

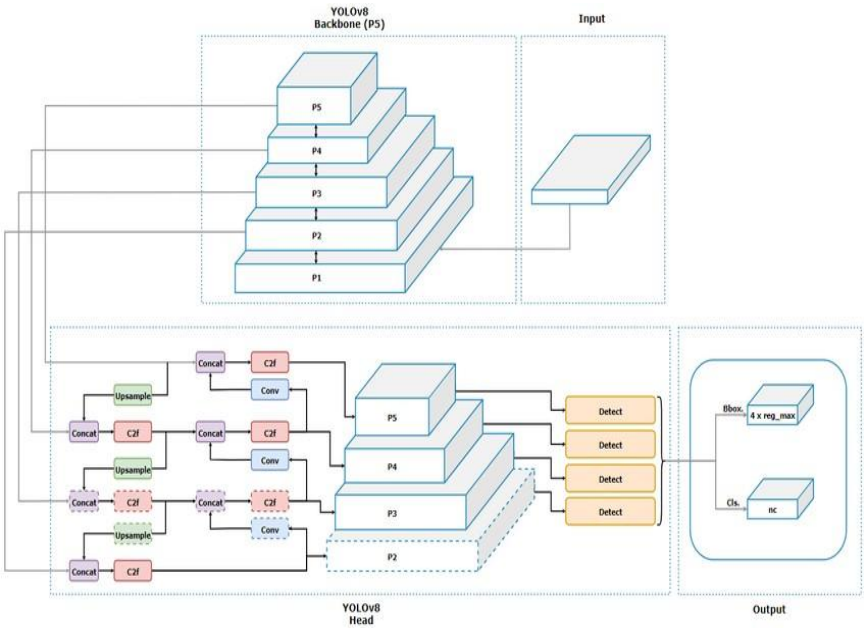


Gambar 2.8 Perbandingan YOLOv8 [88].

Gambar 2.8 menunjukkan perbedaan efektivitas YOLOv8 dengan yang sebelumnya (YOLOv7, YOLOv6, dan YOLOv5) yang dilatih semua pada gambar resolusi 640, dimana berdasarkan gambar itu menjelaskan bahwa YOLOv8 memberikan hasil yang lebih akurat dan memberikan persisi yang lebih baik daripada yang sebelumnya menggunakan parameter-parameter yang sama. Di dalam YOLOv8 ada beberapa fitur yang baru dan lebih baik dibandingkan YOLO versi sebelumnya:

1. Meningkatnya akurasi serta kecepatan dibandingkan dengan versi YOLO sebelumnya.
2. *Backbone* yang telah diperbarui dengan perubahan modul C3 menjadi C2f (*Cross Stage Partial Bottleneck* dengan 2 konvolusi). Modul ini menggantikan modul C3 dengan mengoptimalisasikan aliran gradien dan menangkap fitur tingkat tinggi secara lebih efisien.
3. Menambah modul fusi fitur (*Neck)* yang di optimalkan untuk integrasi informasi atau data spasial dalam berbagai dimensi.

4. Melakukan transisi terhadap sistem deteksi *Anchor-free* (tanpa kotak jangkar) sehingga dapat membuat model menjadi lebih fleksibel dalam proses memprediksi pusat objek dengan berbagai ukuran[84], [89].



Gambar 2.9 Arsitektur YOLOv8[90].

Berdasarkan Gambar 2.9, arsitektur YOLOv8 secara fundamental dibangun atas tiga komponen utama, yaitu *Backbone*, *Neck*, dan *Head*. Masing-masing komponen memiliki peran spesifik dalam memproses citra masukan hingga menghasilkan prediksi deteksi akhir yang akurat. Berikut adalah rincian dari masing-masing komponen:

a. Backbone

Backbone merupakan bagian awal dari arsitektur yang bertugas sebagai pengekstraksi fitur (*feature extractor*) dari citra *input* sediaan

darah mikroskopis. Berbeda dengan versi sebelumnya, YOLOv8 memodifikasi arsitektur CSPDarknet dengan memperkenalkan modul C2f (*Cross Stage Partial Bottleneck with 2 convolutions*).

1. Modul C2f

Modul ini menggantikan modul C3 pada YOLOv5, yang dirancang untuk memperkaya aliran informasi gradien (*gradient flow*) sekaligus menjaga agar komputasi tetap ringan.

2. SPPF (*Spatial Pyramid Pooling Fast)*

SPPF berada di bagian belakang dari backbone, dimana modul ini berfungsi untuk mengumpulkan fitur atau *pooling* spasial dari berbagai ukuran dan menghubungkannya agar model mampu mengenali objek tanpa dipengaruhi oleh variasi ukuran citra yang digunakan atau data yang digunakan.

b. Neck

Bagian tengah arsitektur YOLOv8, yang secara teknis disebut sebagai *Neck*, berfungsi sebagai jembatan integrasi fitur antara *Backbone* dan *Head*. Struktur *Neck* pada YOLOv8 mengadopsi evolusi dari konsep FPN (*Feature Pyramid Network*) dan PANet (*Path Aggregation Network*) yang bertujuan untuk melakukan ekstraksi fitur secara multi-skala. Bagian ini sangat krusial dalam deteksi parasit malaria karena objek target memiliki variasi ukuran yang signifikan, mulai dari stadium *ring* yang sangat kecil hingga gametosit yang lebih besar [84], [91].

Proses Integrasi fitur pada *neck* YOLOv8 dilakukan dengan melalui 2 aliran informasi utama, yaitu:

1. Jalur *Top Down*

Aliran *Top-Down* bertujuan untuk menyebarkan informasi semantik tingkat tinggi (fitur abstrak) dari lapisan *Backbone* yang lebih dalam ke peta fitur (*feature maps*) yang memiliki resolusi spasial lebih tinggi. Proses ini melibatkan operasi *upsampling* untuk menyamakan dimensi spasial peta fitur. Melalui jalur ini, detail visual pada citra sediaan darah diperkaya dengan pemahaman kontekstual mengenai karakteristik morfologi parasit, sehingga model dapat membedakan antara artefak kotoran mikroskopis dengan parasit yang sesungguhnya [80], [91].

2. Jalur *Bottom Up*

Sedangkan, jalur *bottom up* memperkuat pelokalan objek dengan membawa informasi spasial yang memiliki tingkat persisi yang tinggi. Proses integrasi ini dilakukan dengan operasi *concatenation* (*Concat*), dimana fitur dari *backbone* digabungkan secara langsung dengan fitur *upscaling*. Penggabungan ini bertujuan untuk memastikan informasi tekstur halus dari membran sel darah dan parasite tetap terjaga meskipun melewati banyak lapisan konvolusi [91], [92].

3. Peran Modul C2f dalam *Neck*

Pada YOLOv8, efisiensi fusi fitur ditingkatkan melalui penggunaan modul C2f (*Cross Stage Partial Bottleneck with 2 convolutions*). Di bagian *Neck*, modul C2f dikonfigurasi dengan parameter *shortcut = false*. Penghapusan koneksi *shortcut* pada bagian ini bertujuan untuk menyaring informasi dan mengurangi redundansi data sebelum diteruskan ke bagian *Head*. Implementasi modul C2f dengan nilai kedalaman (*n*) yang bervariasi memungkinkan jaringan

untuk melakukan pengolahan fitur secara non-linear tanpa menambah beban komputasi yang berlebihan, yang sangat penting untuk mempertahankan kecepatan inferensi [12], [80].

c. *Head*

Komponen terakhir pada sisi kanan Gambar 2.9 adalah *Head*, yang memiliki peran vital dalam merumuskan hasil akhir deteksi. YOLOv8 menerapkan struktur *Decoupled Head*, yang memisahkan tugas prediksi menjadi dua cabang paralel: cabang klasifikasi dan cabang regresi kotak pembatas atau *bounding box*. Pemisahan ini dilakukan untuk meminimalisir konflik antara tugas klasifikasi objek dan penentuan lokasi presisi, yang terbukti meningkatkan akurasi deteksi pada objek medis yang padat [91].

Blok *Detect* pada bagian *Head* beroperasi pada tiga skala resolusi yang berbeda guna menjamin fleksibilitas deteksi terhadap variasi ukuran parasit:

1. Skala P3 (80×80×256) : Digunakan untuk mendeteksi objek berukuran kecil (*small objects*) melalui resolusi spasial yang tinggi.
2. Skala P4 (40×40×512) : Digunakan untuk deteksi objek berukuran sedang (*medium objects*).
3. Skala P5 (20×20×512) : Digunakan untuk deteksi objek berukuran besar (*large objects*) dengan fitur semantik yang lebih kuat [12], [92].

Lebih jauh lagi, secara arsitektural meskipun tidak dijabarkan secara rinci pada diagram tingkat tinggi tersebut kinerja YOLOv8 ditopang oleh beberapa modul pemrosesan internal yang menjadi

fondasi jaringannya. Berdasarkan literatur resmi Ultralytics, arsitektur ini dibangun berdasarkan referensi [12],[91] :

a. Modul *Conv*: Terdiri dari operasi konvolusi standar yang diikuti oleh *Batch Normalization* dan aktivasi *SiLU* untuk menstabilkan ekstraksi fitur sel darah.

b. Modul *Bottleneck*: Menerapkan struktur residual dengan koneksi *skip* untuk menjaga integritas informasi spasial parasit pada lapisan yang sangat dalam.

c. Modul SPPF (*Spatial Pyramid Pooling - Fast*): Berfungsi mengekstraksi fitur multi-skala secara efisien sebelum aliran data masuk ke bagian *Neck.*

d. Modul C2f (*Cross Stage Partial Fusion*): Evolusi dari modul terdahulu yang secara strategis menggabungkan *bottleneck* untuk menciptakan representasi fitur malaria yang kaya namun tetap efisien secara komputasi sehingga memungkinkan deteksi secara *real-time*.

Tabel 2.6 Detail Fungsi Blok Komponen Arsitektur YOLOv8 [12], [80], [84], [91]–[93].

Blok Komponen	Keterangan
Backbone	Bagian dasar jaringan yang berfungsi sebagai pengekstraksi fitur (feature extractor) utama. Penggunaan modul C2f (Cross Stage Partial Bottleneck with 2 convolutions) memungkinkan model untuk menangkap informasi gradien yang lebih kaya dan detail morfologi parasit pada

Blok Komponen	Keterangan
	sediaan darah tanpa meningkatkan beban komputasi secara signifikan.
Spatial Pyramid Pooling - Fast	Lapisan yang berfungsi mengumpulkan fitur spasial dari berbagai ukuran (*receptive fields*) melalui operasi pooling yang cepat. Komponen ini memastikan model memiliki pemahaman konteks global terhadap citra mikroskopis sebelum data diteruskan ke bagian fusi fitur.
Neck	Bertindak sebagai jembatan integrasi fitur yang menggabungkan informasi detail spasial tingkat rendah dengan informasi semantik tingkat tinggi melalui jalur *Top-Down* dan *Bottom-Up*. Struktur ini sangat krusial untuk mempertahankan eksistensi fitur parasit yang berukuran sangat kecil.
Upsample & *Concat*	Operasi untuk meningkatkan resolusi spasial (*Upsampling*) dan menggabungkan peta fitur dari lapisan berbeda (*Concatenation*). Hal ini membantu menjaga resolusi detail visual agar parasit stadium ring atau titik kecil lainnya tidak terabaikan selama proses konvolusi yang dalam.
Decoupled Head	Bagian akhir jaringan yang memisahkan tugas prediksi menjadi dua cabang paralel: klasifikasi (cls) untuk menentukan jenis parasit dan regresi (bbox) untuk menentukan posisi kotak pembatas.

Blok Komponen	Keterangan
	Pemisahan ini meningkatkan akurasi karena setiap tugas dapat dioptimalkan secara mandiri.
Anchor Free Mechanism	Metode deteksi objek yang memprediksi pusat parasit secara langsung tanpa menggunakan kotak jangkar (*anchor boxes*) yang kaku. Pendekatan ini membuat model lebih fleksibel dalam mengenali berbagai bentuk dinamis parasit malaria, terutama pada stadium amoeboid.
Loss Function	Komponen penghitung galat yang terdiri dari *Binary Cross Entropy* untuk akurasi kelas, *Complete IoU* untuk presisi geometri kotak pembatas, dan *Distribution Focal Loss* untuk memperhalus estimasi batas objek, terutama pada area parasit yang padat atau saling tumpang tindih.

Dalam tabel 2.6 menjelaskan proses penlaian keberhasilan deteksi untuk YOLOv8 dilakukan dengan menentukkan beberapa metrics penting yang dapat menjadi tolak ukur keberhasilan kinerja model. Berikut ada beberapa parameter atau *metrics* yang harus diperhatikan :

1. mAP (*mean Average Precision)* tinggi

mAP merupakan metrik evaluasi paling komprehensif untuk mengukur performa model deteksi objek. Metrik ini mengkalkulasi area

di bawah kurva *Precision-Recall* pada nilai ambang batas *Intersection over Union* (IoU) tertentu. Ada mAP@0.5 (mAP50): Mengukur akurasi deteksi dengan syarat *bounding box* prediksi memiliki tumpeng tindih seminimalnya 50% dengan *ground truth*. Untuk deteksi sel darah dan parasite malaria mikroskopis, pencapaian mAP50% diatas 85% sampai dengan 90% sudah dapat dianggap sebagai standar kinerja yang bagus dan siap untuk diuji lapangan atau klinis[84]. Lalu ada mAP@0.5:0.95: mAP ini mengukur rata-rata persisi dari ambang batas IoU 50% sampai dengan 95% dengan interval 5%. Metrik ini bertujuan untuk menunjukkan seberapa persisi model membingkai bentuk parasit yang tidak beraturan secara geometris [91]

2. Analisis *Confussion Metrics* tinggi

Berbeda dengan deteksi objek umum, deteksi parasit malaria menuntut keseimbangan yang ketat untuk meminimalisir kesalahan diagnosis (*misdiagnosis*). Kinerja ini diukur melalui *precision, recall,* dan *F1-Score* menunjukkan bahwa model memiliki kemampuan yang baik dalam proses deteksi dan mengklarifikasikan objek yang benar. Nilai mAP50 90%, mAP50-95 70% dan *F1-Score* diatas 80% dianggap menunjukkan performa yang sangat baik [92], [93].

2.6 *Hyperparameter*

Hyperparameter merupakan variabel konfigurasi eksternal yang nilainya ditentukan secara manual sebelum proses pelatihan (*training*) dimulai. Berbeda dengan parameter internal, seperti bobot dan bias, yang diperbarui secara otomatis oleh jaringan selama pelatihan, *hyperparameter* berfungsi untuk mengontrol perilaku keseluruhan algoritma pembelajaran. Dalam arsitektur YOLOv8, pemilihan kombinasi *hyperparameter* yang tepat sangat krusial untuk

memastikan model mampu mengekstraksi fitur parasit malaria dengan tingkat presisi yang tinggi secara efisien [91].

Salah satu parameter paling esensial dalam proses optimasi ini adalah *initial learning rate* (lr0) yang bekerja beriringan dengan fungsi *optimizer*. *Learning rate* menentukan besarnya langkah pembaruan bobot model pada setiap iterasi berdasarkan gradien fungsi kerugian (*loss function*). Selain *initial learning rate*, parameter *final learning rate fraction* (lrf) turut memegang peranan penting dalam mengatur skema penurunan laju pembelajaran (*learning rate scheduler*) di sepanjang proses pelatihan. Berbeda dengan lr0 yang menetapkan besaran langkah pembaruan bobot pada awal pelatihan, lrf merepresentasikan rasio pengali terhadap lr0 yang menentukan besarnya *learning rate* pada epoch terakhir, dengan hubungan matematis dinyatakan sebagai $lr_{akhir} = lr0 \times lrf$. Penurunan *learning rate* secara bertahap ini krusial untuk menjaga stabilitas konvergensi model menjelang akhir pelatihan, sebab langkah pembaruan bobot yang masih besar pada *epoch-epoch* akhir berisiko membuat model melewati (*overshoot*) titik minimum optimal yang telah dicapai, sehingga merusak bobot yang sebelumnya sudah terkalibrasi dengan baik. Dalam penelitian ini, parameter lrf dikombinasikan dengan skema *cosine learning rate* (*cos_lr*) untuk menghasilkan kurva penurunan *learning rate* yang halus, memungkinkan model melakukan penyesuaian akhir secara presisi tanpa mengalami fluktuasi ekstrem pada tahap akhir *training*. Penggunaan *optimizer* AdamW (*Adam with Weight Decay Fix*) menuntut penentuan *learning rate* yang sangat presisi. Nilai *learning rate* yang terlalu tinggi dapat menyebabkan fluktuasi yang ekstrem sehingga model gagal mencapai konvergensi dan justru melewati titik minimum global. Sebaliknya, nilai yang terlalu rendah

akan menyebabkan proses konvergensi berjalan sangat lambat dan rentan membuat model terjebak pada area minimum lokal [49], [94].

Selain *learning rate*, pengaturan *batch size* dan jumlah *epoch* juga memegang peranan penting dalam menyeimbangkan stabilitas dan efisiensi komputasi. *Batch size* menentukan jumlah sampel citra yang diproses ke dalam memori sebelum bobot model diperbarui. Pengaturan *batch size* yang lebih besar dapat menstabilkan estimasi gradien selama pelatihan, namun menuntut kapasitas memori GPU yang jauh lebih besar. Sementara itu, *epoch* merujuk pada satu siklus iterasi lengkap di mana seluruh dataset telah melewati jaringan saraf. Jumlah *epoch* yang optimal diperlukan agar model memiliki waktu yang cukup untuk mempelajari pola morfologi *Plasmodium*, tanpa berujung pada kondisi di mana model sekadar menghafal data dan kehilangan kemampuan generalisasinya [54], [84].

Tujuan utama dari penyesuaian *hyperparameter* ini adalah mencapai kondisi *best fitting*, yaitu titik keseimbangan ideal antara kompleksitas model dan kemampuan generalisasinya terhadap data baru. Ketidakseimbangan dalam proses ini dapat memicu dua fenomena kegagalan utama, yaitu *underfitting* dan *overfitting*. *Underfitting* terjadi jika model terlalu sederhana untuk menangkap pola kompleks pada data sediaan darah, yang ditandai dengan tingginya tingkat kesalahan baik pada tahap pelatihan maupun validasi. Sebaliknya, *overfitting* terjadi ketika model terlalu rumit sehingga cenderung "menghafal" detail dan *noise* pada data latih secara berlebihan. Kondisi *overfitting* ini menghasilkan akurasi yang terlihat sangat tinggi pada data latih, namun performanya akan menurun drastis saat diuji menggunakan citra darah baru yang belum pernah dilihat sebelumnya [73], [74].

Untuk menghindari risiko *overfitting* dan memastikan model berhenti belajar pada titik akurasi puncaknya, penelitian ini menerapkan teknik *early stopping* beserta pengaturan *patience*. *Early stopping* merupakan mekanisme regulasi yang akan menghentikan proses pelatihan secara otomatis jika tidak ditemukan peningkatan performa pada data validasi setelah melewati sejumlah *epoch* tertentu. Batas toleransi inilah yang didefinisikan sebagai nilai *patience*. Pengaturan nilai *patience* yang terkalibrasi dengan baik memungkinkan model untuk mengakhiri pelatihan tepat sebelum kurva validasi menunjukkan tren penurunan, sehingga efisiensi waktu komputasi dapat tercapai tanpa mengorbankan akurasi deteksi penyakit[94].

2.7 *State of The Art*

Tabel 2.7 *State Of The Art*

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
A Deep Architecture Based On Attention Mechanisms For Effective End-To-End Detection Of Early And Mature Malaria Parasites In A Realistic Scenario	2025	Zedda, L., Loddo, A., & Di Ruberto, C.	Pengembangan framework deteksi berbasis deep learning dengan mekanisme atensi, memperluas model YOLO-SPAM dan YOLO-PAM.	Menunjukkan akurasi tinggi dalam mendeteksi empat spesies malaria pada seluruh stadium infeksi (awal dan matang) dalam skenario realistik.
Review Of Application Yolov8 In Medical Imaging	2024	Widayani, A., Putra, A. M., Maghriebi, A. R., & Ridho, M. H. F.	Studi literatur sistematis mengevaluasi performa YOLOv8 pada berbagai modalitas seperti (X-Ray, CT-Scan, dan MRI).	YOLOv8 mencapai performa tinggi pada tumor otak (*Precision* >0,92, mAP >0,93) dan *Recall* (mAP

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
				0,87) menggunakan optimizer SGD.
Yolov8-CAB: Improved Yolov8 For Real-Time Object Detection	2024	Talib, M., Al-Noori, A. H. Y., & Suad, J.	Integrasi Context Attention Block (CAB) dan modifikasi Spatial Attention (SA) untuk meningkatkan ekstraksi fitur pada blok C2f.	Peningkatan signifikan pada akurasi deteksi objek kecil dan kemampuan ekstraksi fitur lemah tanpa menambah kompleksitas model yang besar.
What Is Yolov8: An In-Depth Exploration Of The Internal Features	2024	Yaseen, M.	Analisis mendalam fitur internal YOLOv8 (CSPNet backbone, FPN+PAN neck, dan Anchor-free approach).	Mengonfirmasi keunggulan YOLOv8 dalam hal presisi dan kemampuan real-time dibandingkan YOLOv5 pada benchmark COCO dan Roboflow 100.

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
Fracture Detection In Pediatric Wrist Trauma X-Ray Images Using Yolov8 Algorithm	2023	Ju, R. Y., & Cai, W.	Penggunaan algoritma YOLOv8 yang dikombinasikan dengan teknik augmentasi data intensif pada dataset GRAZPEDWRI-DX.	Mencapai nilai mAP50 sebesar 0,638, melampaui performa YOLOv7 dan model YOLOv8 orisinal dalam mendeteksi fraktur tulang anak.
Image Analysis And Machine Learning For Detecting Malaria	2018	Poostchi, M., Silamut, K., Maude, R. J., Jaeger, S., & Thoma, G.	Tinjauan teknik pengolahan citra, cell segmentation, dan klasifikasi otomatis untuk sediaan darah Tebal dan tebal.	Membuktikan Deep Learning mampu melakukan automatis diagnosis dengan mengatasi variasi morfologi dan artefak.
YOLO-Tryppa: A Novel YOLO-Based Approach For Rapid And Accurate	2025	Mura, D. A., Zedda, L.,	Modifikasi arsitektur YOLO khusus untuk parasit berukuran kecil (small objects) dengan mengeliminasi head P5 dan	Menghasilkan AP50 sebesar 71,3%, mengatasi masalah hilangnya fitur pada deteksi parasit berukuran mikro

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
Detection Of Small Trypanosoma Parasites		Loddo, A., & Di Ruberto, C.	mengoptimalkan head P2 menggunakan ghost convolutions.	dengan beban komputasi (GFLOPs) yang lebih rendah.
Automatic Patient-Level Recognition Of Four Plasmodium Species On Thin Blood Smear By A Real-Time Detection Transformer (RT-DETR) Object Detection Algorithm	2024	Guemas, E., Routier, B., dkk.	Penggunaan algoritma Real-Time Detection Transformer (RT-DETR) untuk membedakan 4 spesies Plasmodium pada citra sediaan darah Tebal dengan dataset masif (24.720 citra).	RT-DETR mampu mencapai akurasi tingkat pasien yang tinggi (99,8%), membuktikan bahwa arsitektur bebas-anchor (anchor-free) sangat superior untuk citra malaria.
Insights Into AI-Driven Malaria Diagnosis: A Systematic Review With	2025	Tiong, Jia Ying,	Tinjauan sistematis membandingkan CNN, Transfer Learning, dan YOLO/Faster R-CNN khusus untuk tahapan	Menemukan bahwa tantangan terbesar saat ini adalah ketidakseimbangan kelas (class imbalance) dan

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
Implications For Plasmodium Knowlesi			darah Plasmodium (termasuk knowlesi).	kurangnya anotasidataset, yang mana metode seperti YOLO terbukti efektif jika dikombinasikan dengan adaptasi domain.
Automatic Recognition Of Parasitic Products In Stool Examination Using Object Detection Approach	2022	Naing, K. M., Boonsang, S., dkk.	Komparasi algoritma deteksi objek (YOLOv3, YOLOv4-Tiny, Faster R-CNN, SSD) untuk mendeteksi parasit pada sampel medis menggunakan Artificial Intelligence.	Arsitektur keluarga YOLO menunjukkan keseimbangan terbaik antara kecepatan (real-time) dan presisi pengenalan morfologi parasit dibandingkan SSD dan Faster R-CNN.

Penelitian yang dilakukan oleh Zedda, Loddo, dan Di Ruberto (2025) menunjukkan pendekatan yang komprehensif dalam pengenalan objek medis berskala mikro menggunakan arsitektur berbasis *Deep Learning*. Penelitian ini berjudul *"A deep architecture based on attention mechanisms for effective end-to-end detection of early and mature malaria parasites in a realistic scenario"*. Penelitian ini mengintegrasikan arsitektur keluarga YOLO dengan mekanisme atensi untuk mendeteksi parasit malaria secara *end-to-end* dari sediaan darah. Model berhasil mencapai akurasi yang tinggi dalam mengenali empat spesies *Plasmodium* yang berbeda pada seluruh stadium infeksi, baik pada fase awal maupun matang. Keberhasilan ini disebabkan oleh kemampuan mekanisme jaringan dalam mempertahankan fitur spasial dari parasit berukuran sangat kecil yang sering kali hilang pada lapisan konvolusi dalam. Penelitian ini membuktikan bahwa arsitektur bebas-jangkar (*anchor-free*) sangat tangguh dalam menangani variasi morfologi parasit di skenario klinis yang realistis. Keterkaitan penelitian ini dengan tugas akhir yang sedang dikembangkan adalah memberikan landasan arsitektural yang kuat bahwa penggunaan YOLOv8 yang secara bawaan telah mengadopsi sistem *anchor-free* dan *Decoupled Head* merupakan pilihan algoritma yang paling mutakhir dan tepat untuk mendeteksi stadium awal parasit pada citra mikroskopis.

Penelitian yang dilakukan oleh Tiong . (2025) memberikan perspektif yang sangat kritis terhadap tantangan implementasi kecerdasan buatan dalam diagnosis medis melalui tinjauan sistematis berjudul *"Insights into AI-Driven malaria diagnosis: A systematic review with implications for Plasmodium knowlesi"*. Penelitian yang dipublikasikan oleh Elsevier ini mengevaluasi berbagai teknik mulai

dari prapemrosesan hingga metode deteksi objek seperti YOLO dan Faster R-CNN dalam mendiagnosis tahapan darah parasit malaria. Hasil studi secara tegas menyoroti bahwa kendala paling persisten yang membatasi performa model AI saat ini adalah fenomena ketidakseimbangan kelas (*class imbalance*) pada *dataset* medis serta kurangnya anotasi yang berkualitas. Evaluasi ini membuktikan bahwa tanpa penanganan ketidakseimbangan data yang memadai, model cenderung mengalami bias terhadap kelas yang dominan. Keterkaitan penelitian ini dengan tugas akhir yang dilakukan adalah sebagai justifikasi utama atas penerapan strategi pembobotan kelas (*class weights* / image_weights). Strategi tersebut secara langsung menjawab kesenjangan riset yang disoroti oleh Tiong ., dengan memastikan model tidak bias meskipun jumlah *dataset* kelas *Vivax* jauh lebih mendominasi dibandingkan kelas *Falciparum*.

Penelitian yang dilakukan oleh Talib, Al-Noori, dan Suad (2024) berfokus pada inovasi efisiensi ekstraksi fitur melalui penelitian berjudul *"YOLOv8-CAB: Improved YOLOv8 for Real-time object detection"*. Penelitian ini memodifikasi struktur internal YOLOv8 dengan menambahkan *Context Attention Block* (CAB) dan mempertebal blok C2f (*Coarse-to-Fine*). Model yang dikembangkan berhasil mencapai peningkatan performa yang tajam dalam melokalisasi objek-objek berukuran kecil tanpa meningkatkan kompleksitas komputasi model secara berlebihan. Hal ini disebabkan oleh optimalisasi blok C2f yang mampu mengekstraksi fitur lemah (*weak features*) pada latar belakang gambar yang bervariasi. Penelitian ini secara empiris membuktikan bahwa kedalaman blok C2f memainkan peran paling vital dalam menjaga kualitas representasi visual dari objek kecil hingga ke tahap prediksi akhir. Keterkaitan

penelitian ini dengan tugas akhir yang diusulkan adalah memperkuat argumen teoritis bahwa struktur blok C2f pada YOLOv8 memiliki peran yang signifikan dalam menjaga detail tepi parasit agar tidak mengalami *vanishing gradient*, sehingga deteksi dapat tetap presisi pada perbesaran mikroskopis tertentu.

Penelitian yang dilakukan oleh Widayani . (2024) memberikan wawasan spesifik mengenai penerapan varian YOLO pada berbagai modalitas citra klinis dalam artikel berjudul *"Review of Application YOLOv8 in Medical Imaging"*. Penelitian ini mengevaluasi kinerja YOLOv8 dalam deteksi lesi dan klasifikasi penyakit pada pencitraan seperti X-Ray, CT-Scan, dan MRI. Model ini secara konsisten mencetak nilai *mean Average Precision* (mAP) yang tinggi, termasuk pada deteksi kanker payudara dengan rata-rata mAP 0,87. Keberhasilan ini sangat dipengaruhi oleh konfigurasi parameter pelatihan, di mana penggunaan fungsi optimasi algoritma yang tepat secara langsung menentukan akurasi klasifikasi. Keterkaitan penelitian ini dengan penelitian peneliti adalah memberikan pijakan ilmiah untuk melakukan eksperimen *hyperparameter tuning* secara komprehensif. Berdasarkan temuan tersebut, tugas akhir ini memodifikasi parameter fundamental (seperti *learning rate*, momentum, dan *weight decay*) untuk memastikan model YOLOv8 mencapai titik konvergensi terbaik pada citra sediaan darah.

Penelitian oleh Mura, Zedda, Loddo, dan Di Ruberto (2025) berjudul *"YOLO-Tryppa: A Novel YOLO-Based Approach for Rapid and Accurate Detection of Small Trypanosoma Parasites"* memperkenalkan modifikasi khusus untuk parasit renik. Penelitian ini mengusulkan model YOLO-Tryppa yang mengeliminasi *head* prediksi

P5 dan mengoptimalkan *head* P2 untuk meningkatkan lokalisasi objek kecil. Hasilnya menunjukkan pencapaian nilai AP50 sebesar 71,3%, yang membuktikan bahwa penyesuaian pada skala prediksi sangat krusial untuk objek yang hanya mencakup beberapa piksel dalam citra mikroskopis. Keterkaitan penelitian ini dengan tugas akhir adalah memberikan bukti bahwa untuk parasit darah, fokus deteksi pada skala spasial yang lebih halus (seperti P3 pada YOLOv8 standar) adalah kunci utama. Hal ini mendukung eksperimen tugas akhir dalam mempertahankan resolusi *input* yang tinggi (640 piksel) agar fitur parasit stadium *ring* tetap dapat terdeteksi oleh jaringan.

Penelitian yang dilakukan oleh Guemas . (2024) berjudul *"Automatic patient-level recognition of four Plasmodium species on thin blood smear by a real-time detection transformer (RT-DETR) object detection algorithm"* mengeksplorasi penggunaan algoritma berbasis *Transformer*. Penelitian ini menggunakan *dataset* masif sebanyak 24.720 citra untuk melatih model RT-DETR dalam membedakan empat spesies malaria. Model ini mampu mencapai akurasi tingkat pasien hingga 99,8%, yang menunjukkan bahwa pendekatan berbasis *real-time transformer* dapat menyaingi model konvensional. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai pembanding teknologi deteksi objek terkini. Meskipun RT-DETR menunjukkan akurasi yang luar biasa, penggunaan YOLOv8 dalam tugas akhir ini dipilih karena efisiensi beban komputasinya (GFLOPs) yang lebih rendah, sehingga lebih memungkinkan untuk diimplementasikan pada perangkat mikroskop digital dengan spesifikasi perangkat keras menengah di daerah endemik.

Penelitian oleh Naing . (2022) berjudul *"Automatic recognition of parasitic products in stool examination using object detection approach"* membandingkan performa berbagai algoritma deteksi seperti YOLOv3, YOLOv4-Tiny, Faster R-CNN, dan SSD. Hasil penelitian menunjukkan bahwa arsitektur keluarga YOLO memberikan keseimbangan paling optimal antara kecepatan pemrosesan (*real-time*) dan presisi pengenalan morfologi parasit dibandingkan model SSD. Model YOLO mampu mengenali detail tekstur parasit pada sampel medis secara konsisten. Keterkaitan penelitian ini dengan tugas akhir yang disusun adalah mengonfirmasi bahwa pemilihan keluarga YOLO (dalam hal ini versi terbaru, YOLOv8) adalah langkah yang tepat secara teknis untuk mencapai target sistem deteksi yang tidak hanya akurat secara medis, tetapi juga efisien secara waktu untuk kebutuhan diagnosis massal.

Penelitian yang dipresentasikan oleh Yaseen (2024) melalui artikel *"WHAT IS YOLOV8: AN IN-DEPTH EXPLORATION OF THE INTERNAL FEATURES OF THE NEXT-GENERATION OBJECT DETECTOR"* melakukan analisis mendalam terhadap inovasi arsitektur YOLOv8. Penelitian ini membedah keunggulan integrasi *CSPNet backbone*, *FPN+PAN neck*, serta transisi menuju sistem *anchor-free*. Hasil analisis menunjukkan peningkatan signifikan pada *benchmark* Microsoft COCO dibandingkan versi YOLOv5. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai sumber referensi teknis utama dalam Bab 2 Tinjauan Pustaka. Penjelasan Yaseen mengenai bagaimana modul C2f dan *Decoupled Head* bekerja menjadi landasan teori dasar bagi tugas akhir ini dalam menjelaskan mengapa YOLOv8 memiliki kapabilitas ekstraksi fitur yang lebih kuat untuk objek kecil seperti parasit malaria dibandingkan pendahulunya.

Penelitian oleh Ju dan Cai (2023) berjudul *"Fracture detection in pediatric wrist trauma X-ray images using YOLOv8 algorithm"* menyoroti pentingnya teknik augmentasi data dalam pencitraan medis. Penelitian ini menggunakan algoritma YOLOv8 untuk mendeteksi fraktur tulang pada anak dan berhasil mencapai nilai mAP50 sebesar 0,638. Keberhasilan ini didorong oleh penerapan berbagai teknik augmentasi citra yang mampu menangkap variasi data yang terbatas. Keterkaitan penelitian ini dengan tugas akhir Ivan adalah memperkuat metodologi pada Bab 3 terkait penggunaan augmentasi spasial dan warna. Sebagaimana riset Ju dan Cai, tugas akhir ini memanfaatkan augmentasi untuk memperluas variasi citra sediaan darah, sehingga model menjadi lebih tangguh terhadap perbedaan pencahayaan mikroskop dan kualitas pewarnaan Giemsa.

Penelitian fundamental oleh Poostchi . (2018) berjudul *"Image analysis and machine learning for detecting malaria"* memberikan gambaran historis dan perkembangan teknik diagnosis malaria otomatis. Penelitian ini meninjau transisi dari pengolahan citra klasik menuju era *Deep Learning* untuk mengatasi tantangan variasi morfologi parasit dan artefak sediaan. Kesimpulan penelitian menekankan bahwa *Deep Learning* adalah solusi masa depan untuk diagnosis malaria yang andal. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai fondasi latar belakang masalah. Dengan merujuk pada tinjauan Poostchi, tugas akhir ini memposisikan diri untuk menjawab tantangan otomatisasi diagnosis tersebut melalui penggunaan YOLOv8 yang merupakan representasi teknologi *Deep Learning* paling mutakhir saat ini.

BAB III
METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini merupakan jenis penelitian kuantitatif yang dirancang dengan pendekatan penelitian terapan (*applied research*) dalam area pemrosesan citra medis dan kecerdasan buatan. Pendekatan kuantitatif digunakan karena proses evaluasi kinerja model deteksi parasit malaria diukur secara objektif menggunakan parameter matematis dan metrik statistik, seperti *Mean Average Precision* (mAP), presisi (*precision*), sensitivitas (*recall*), dan *F1-Score*, yang diekstraksi secara komputasional.

Sifat terapan dalam penelitian ini dititikberatkan pada tahap pengembangan dan optimasi sistem. Proses ini mencakup *fine-tuning* arsitektur *You Only Look Once* versi 8 (YOLOv8m) yang dilatih pada dataset COCO dengan melakukan *transfer learning* dengan melatih ulang model tersebut secara *custom* terhadap dataset malaria yang ada dengan tujuan untuk menyesuaikan head kepada *p.falciparum* dan *p.vivax,* melalui penyesuaian iteratif pada *hyperparameter* fundamental yaitu *learning rate*, momentum, dan *weight decay* menggunakan *optimizer* AdamW. Selain itu, penelitian ini juga menerapkan teknik pembobotan kelas (*class weights*) sebagai bentuk rekayasa komputasional untuk menguji ketangguhan model dalam menangani kondisi ketidakseimbangan data (*class imbalance*) antara kelas *Plasmodium falciparum* dan *Plasmodium vivax* pada sediaan mikroskopis.

3.2 Waktu dan Tempat Pelaksanaan

Penelitian ini dilaksanakan sekitar sembilan bulan, dimulai dari bulan Agustus 2025 sampai April 2026 yang dilaksanakan di Insitut Teknologi Sumatera, Lampung Selatan untuk perancangan pengintegrasian modul kamera, mikroskop, dan juga pengambilan data primer secara langsung dengan preparat.

3.3 Alat dan Bahan

Adapun alat dan bahan yang diperlukan dalam penelitian ini akan dijelaskan dalam beberapa poin berikut.

3.3.1 Alat

Berikut ini adalah daftar alat yang digunakan dalam penelitian ini, beserta spesifikasi, jumlah dan fungsinya, sebagaimana tercantum pada Tabel 3.1.

Tabel 3.1 Spesifikasi Alat Software dan Hardware

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
Hardware	Laptop ASUS TUF GAMING A16	• AMD Ryzen 7 260 w/ Radeon 780M Graphics, 3800 Mhz, 8 Core(s), 16 Logical Processor(s) • 16 GB RAM • NVIDIA GFORCE RTX 5060 8GB • 1 TB SSD • Windows 11 Home 64-bit	1 Buah	Sebagai pusat komputasi, digunakan untuk menjalankan *software* pengolahaan citra dan model YOLO
	Mikroskop	• Lensa okuler Monokuler, Perbesaran 10x • Lensa objektif 4x-100x	1 Buah	Berfungsi sebagai pembesaran sampel darah sehingga parasite dapat terlihat dalam mikroskop secara detail
	Modul Kamera	• Resolusi 4K • *Output* : HDMI / *Type-C*	1 Buah	Berfungsi untuk menangkap citra mikroskopis melalui lensa mikroskop
Software	Visual Studio Code	• *Versi 1.115* • *Virtual Enviroment (venv)* • *Pytorch* • *Python 3.12.3* • *Ultralystics V8.y.z* (8.4.7) • *CUDA v13.2* • *Absl-Py 2.3.1* • *Astunparse 1.6.3* • *Catkin-Pkg 1.1.0*	-	Berperan sebagai wadah pembuatan model YOLO serta *Training Data*

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
		• *Certifi 2025.11.12* • *Cffi 2.0.0* • *Charset-Normalizer 3.4.4* • *Contourpy 1.3.3* • *Cryptography 46.0.3* • *Cycler 0.12.1* • *Distro 1.9.0* • *Docutils 0.22.3* • *Empy 4.2* • *Filelock 3.20.3* • *Flatbuffers 25.9.23* • *Fonttools 4.61.0* • *Fsspec 2026.1.0* • *Gast 0.7.0* • *Google-Pasta 0.2.0* • *Grpcio 1.76.0* • *H5py 3.15.1* • *Idna 3.11* • *Importlib_Metadata 8.7.0* • *Jinja2 3.1.6* • *Joblib 1.5.3* • *Keras 3.13.0* • *Kiwisolver 1.4.9*		

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
		• *Labelimg 1.8.6* • *Lark 1.3.1* • *Libclang 18.1.1* • *Lxml 6.0.2* • *Markdown 3.10* • *Markdown-It-Py 4.0.0* • *Markupsafe 3.0.3* • *Matplotlib 3.10.7* • *Mdurl 0.1.2* • *Ml_Dtypes 0.5.4* • *Mpmath 1.3.0* • *Namex 0.1.0* • *Netifaces 0.11.0* • *Networkx 3.6.1* • *Numpy 2.2.6* • *Opencv-Python 4.12.0.88* • *Opt_Einsum 3.4.0* • *Optree 0.18.0* • *Packaging 25.0* • *Pandas 2.3.3* • *Pillow 12.0.0* • *Polars 1.37.1* • *Polars-Runtime-32 1.37.1*		

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
		• *Protobuf 6.33.2* • *Psutil 7.1.3* • *Pycparser 2.23* • *Pygments 2.19.2* • *Pyparsing 3.2.5* • *Pyqt5 5.15.11* • *Pyqt5-Qt5 5.15.2* • *Pyqt5_Sip 12.18.0* • *Python-Dateutil 2.9.0.* • *Pytz 2025.2* • *Pyyaml 6.0.3* • *Requests 2.32.5* • *Rich 14.2.0* • *Rosdistro 1.0.1* • *Rospkg 1.6.0* • *Scikit-Learn 1.8.0* • *Scipy 1.16.3* • *Seaborn 0.13.2* • *Setuptools 80.9.0* • *Six 1.17.0* • *Sympy 1.14.0* • *Tensorboard 2.20.0* • *Tensorboard-Data-Server 0.7.2*		

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
		• *Tensorflow 2.20.0* • *Termcolor 3.2.0* • *Threadpoolctl 3.6.0* • *Torch 2.7.0.Dev20250310+Cu124* • *Torchvision 0.22.0.Dev20250226+Cu124* • *Typing_Extensions 4.15.0* • *Tzdata 2025.3* • *Ultralytics 8.4.7* • *Ultralytics-Thop 2.0.18* • *Urllib3 2.6.2* • *Werkzeug 3.1.4* • *Wheel 0.45.1* • *Wrapt 2.0.1* • *Zipp 3.23.0* • *seed=42*		
	LabelImg	• *Operating System* : Windows 10 atau lebih • *Python requirments* : Minimum *Python* 2.6 • CPU : 2 x 64-bit, 2.8 GHz atau lebih	-	Berperan dalam membantu proses membuat dan mengambil *dataset* parasit malaria menggunakan format *labelimg* YOLO agar setiap gambar memiliki *bounding box* dan file teks berisi dengan informasi *bounding box* tersebut.

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
		• *Memory*: 16 GB RAM minimum, dengan 1600 MHz DDR3		
	OS	• *Windows 11*	-	Untuk melakukan komputasi dalam komputer.

3.3.2 Bahan

Berikut adalah beberapa bahan yang digunakan dan diperlukan selama melakukan penelitian ini, lengkap dengan jumlah dan fungsinya, sebagaimana di tampilkan dalam Tabel 3.2.

Tabel 3.2 Daftar Bahan Penelitian

Nama Bahan	Jumlah	Kegunaan
Data Set Citra Mikroskopis Smear Darah Tebal	2 Dataset (2 kelas/2300 Citra)	Berfungsi sebagai bahan latihan dan ujian bagi *Deep Learning Model* YOLOv8

3.4 Metode dan Persamaan yang Digunakan

Pengembangan sistem deteksi parasit malaria dalam penelitian ini didasarkan pada arsitektur *Deep Learning* YOLOv8m yang mengintegrasikan mekanisme ekstraksi fitur, lokalisasi objek, dan klasifikasi dalam satu jaringan saraf konvolusional terpadu. Untuk memandu proses pelatihan (*training*) agar mencapai konvergensi optimal, digunakan serangkaian persamaan matematis yang mencakup fungsi kerugian dan metrik evaluasi sebagai berikut.

3.4.1 Fungsi Kerugian (*Loss Function*)

Model YOLOv8 dioptimalkan menggunakan fungsi kerugian total (L_{total}) yang menggunakan tiga jenis perhitungan untuk memastikan presisi geometris dan akurasi klasifikasi. Komponen tersebut meliputi :

1. *Classification Loss* (BCE)

Classification Loss dalam penelitian ini digunakan untuk mengukur kesalahan model dalam membedakan antara kelas *Plasmodium falciparum* dan *Plasmodium vivax*. Persamaan ini di dasarkan pada *Binary Cross-Entropy* (BCE) yang menghitung perbedaan antara probabilitas prediksi dan label aktual:

$$Lcls = -\frac{1}{N}\sum_{i=1}^{N}[Yi\log(Pi) + (1-Yi)\log(1-Pi)]\ [90] \quad (3.1)$$

Dimana N termasuk sebagai jumlah sampel, Yi Adalah label biner (0 atau 1), dan Pi adalah skor probabilitas yang dihasilkan model[90].

2. *Bounding Box Regression Loss* (CloU)

Untuk meningkatkan akurasi pelokalan koordinat parasit yang berukuran kecil pada sediaan darah, penelitian ini menggunakan metode *Complete Intersection over Union* (CloU). CloU sendiri mempertimbangkan tumpeng tindih area, jarak pusat kota, dan konsistensi ratio aspek kotak pembatas itu sendiri :

$$LCIoU = 1 - IoU + \frac{p^2(b,b^{gt})}{c^2} + av\ [93] \qquad (3.2)$$

Dalam konteks pencitraan medis dan penelitian ini, penggunaan CloU menjadi sangat krusial dalam meminimalisir deviasi posisi kotak merah pada objek mikroskopis [91].

3. *Distribution Focal Loss* (DFL)

DFL dalam penelitian ini berfungsi untuk memperhalus estimasi batas kotak pembatas pada kondisi di mana batas objek parasit

tidak terlalu jelas atau saling tumpeng tindih dengan sel darah merah lainnya.

3.4.2 Parameter Optimasi (AdamW)

Proses pembaruan bobot jaringan saraf dalam penelitian ini dikendalikan oleh *optimizer* AdamW (*Adam with Weight Decay Fix*). Algoritma ini dipilih oleh peneliti karena kemampuannya dalam memisahkan penanganan peluruhan bobot (*Weight Decay*) dari pembaruan gradien utama, hal ini dapat menghilangkan kejadiannya *overfitting* pada *dataset* malaria yang memiliki ketimpangan kelas yang besar. Persamaan pembaruan bobot w pada langkah waktu t :

$$w_{t+1} = wt - n_t \left(\frac{\widehat{m_t}}{\sqrt{\widehat{v_t}+\epsilon}} + \lambda w_t \right) [95] \quad (3.3)$$

Dimana n mempresentasikan learning rate, $\widehat{m}_t$dan $\widehat{v}_t$ adalah estimasi momen gradien, sementara λ adalah parameter tingkat *weight decay* sebesar 0.005 yang di terapkan dalam penelitian ini.

3.4.3 Metrik Evaluasi Kinerja Sistem

Keberhasilan sistem yang mengendali morfologi parasit diukur secara kuantitatif melalui metrik statistic yang dihitung berdasarkan nilai hasil *confusion matrix*. Parameter ini mencakup berbagai hal dari *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), *False Negative* (FN) :

1. *Intersection over Union* (IoU)

IoU merupakan acuan dasar ilmiah untuk menentukan apakah sebuah kotak prediksi yang dihasilkan oleh model (B_{pred}) dapat dinyatakan sebagai tebakan yang benar (*True Positive*) atau salah (*False Positive*) dengan membandingkannya terhadap kotak pelabelan

asli dari pakar atau *ground truth* (B_{gt}) Persamaan matematis IoU dinyatakan sebagai berikut:

$$\text{IoU} = \frac{Luas\,(B_{pred} \cap B_{gt})}{Luas(B_{pred} \cup B_{gt})} [96] \qquad (3.4)$$

2. Sensitivitas (*Recall*)

Sensitivitas atau *recall* untuk mengukur model dalam menemukan kembali seluruh parasit malaria yang ada di dalam citra:

$$Recall = \frac{TP}{TP+FN} [93] \qquad (3.5)$$

3. Presisi (*Precision*)

Presisi atau *precision* mengukur tingkat keandalan model dalam memprediksi parasite tanpa terdistraksi oleh artefak atau kotoran:

$$Precision = \frac{TP}{TP+FP} [93] \qquad (3.6)$$

4. F1-*Score*

F1-*score* digunakan sebagai indikator keseimbangan antara persisi dan sensitivitas dalam klarifikasi diagnosis medis:

$$F1 - score = 2\,x\,\frac{precision\,x\,recall}{precision+recall} [93] \qquad (3.7)$$

Dalam konteks diagnosis medis seperti malaria, parameter Sensitivitas (*Recall*) memiliki prioritas tertinggi karena kesalahan sistem dalam melewatkan sel yang terinfeksi (*False Negative*) dapat berakibat fatal bagi pasien. Oleh karena itu, metrik ini dievaluasi secara ketat bersama dengan F1-Score untuk memastikan keandalan model pada kondisi sediaan darah yang realistis [93].

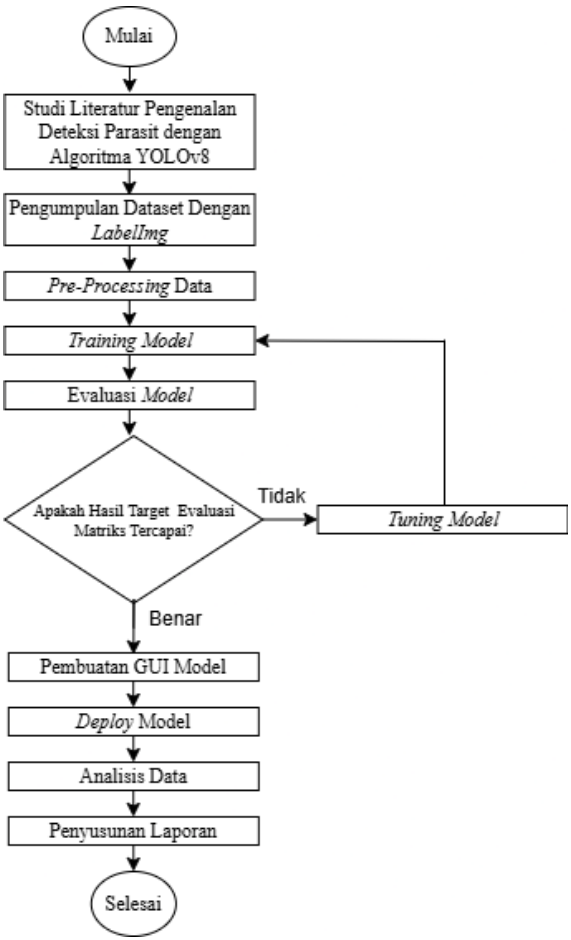
5. *Mean Average Precision* (mAP) 50

Metrik ini digunakan sebagai tolak ukur utama dalam deteksi objek yang menghitung rata-rata presisi pada berbagai tingkat sensitivitas dengan ambang batas IoU 0,5. [92], [97].

6. *Mean Average Precision* (mAP) 50-95

mAP@50-95 (atau mAP@[0.50:0.95]) merupakan metrik evaluasi yang paling ketat dan komprehensif dalam arsitektur YOLO modern. Metrik ini tidak menggunakan satu ambang batas IoU tunggal, melainkan mengkalkulasi nilai rata-rata mAP dari 10 tingkatan ambang batas IoU yang bervariasi, dimulai dari IoU = 0,50 hingga IoU = 0,95 dengan kenaikan interval *step* sebesar 0,05 [97].

3.5 Diagram Alir Penelitian



Gambar 3.1 Diagram Alir Penelitian

Sesuai dengan diagram alir 3.1 tahapan penelitian ini terbagi menjadi secara keseluruhan 4 tahap utama, dimulai dengan *image processing*, *pre-processing* data, *training data,* dan integrasi model YOLOv8 dengan modul kamera yang ada. Tahapan penelitian ini akan dijelaskan dalam beberapa sub bab berikut.

3.5.1 Studi Literatur

Langkah pertama diawali dengan tahap Studi Literatur Pengenalan Deteksi Parasit dengan Algoritma YOLOv8m. Pada fase esensial ini, dilakukan kajian komprehensif terhadap berbagai literatur dan publikasi ilmiah terkini yang relevan. Hal ini difokuskan pada karakteristik morfologi citra mikroskopis parasit malaria, penanganan data tidak seimbang (*class imbalance*), serta bedah arsitektur mutakhir YOLOv8 seperti mekanisme ekstraksi fitur pada modul C2f dan sistem pelokalan *anchor-free*. Pemahaman teoritis ini menjadi pijakan fundamental sebelum memulai perancangan sistem secara teknis.

3.5.2 Pengumpulan Dataset

Langkah selanjutnya adalah, tahap Pengumpulan Dataset dengan *LabelImg*. Proses pelabelan dan penentuan posisi koordinat parasit pada citra sediaan darah tebal ini divalidasi secara langsung oleh tenaga ahli laboratorium kesehatan (analis parasitologi) Puskesmas Hanura untuk menjamin akurasi kedudukan *ground truth* sebelum digunakan dalam proses pelatihan model. Citra-citra mentah tersebut kemudian diproses menggunakan perangkat lunak LabelImg untuk melakukan anotasi secara manual. Proses anotasi ini bertujuan untuk membuat kotak pembatas (*bounding box*) pada objek target dan memberikan label kelas spesifik (seperti *Plasmodium falciparum* atau *Plasmodium vivax*), yang kelak berfungsi sebagai data kebenaran dasar (*ground truth*) bagi model.

3.5.3 Pre-Processing Data

Dataset berlabel kemudian dialirkan ke dalam tahapan Pre-Processing Data. Tahapan ini sangat krusial untuk menormalisasi variasi data dan membersihkan gangguan visual yang tidak diinginkan.

Proses pra-pemrosesan mencakup penyesuaian resolusi citra menjadi ukuran standar masukan YOLOv8m (640x640 piksel), penyesuaian kontras pencahayaan mikroskop, serta augmentasi data spasial. Tindakan manipulasi ini bertujuan untuk memperkaya variabilitas fitur agar model memiliki ketahanan (*robustness*) yang tinggi saat mengenali parasit dengan orientasi yang berbeda-beda.

3.5.4 Training Model

Dataset yang telah diolah, selanjutnya digunakan pada tahap Training Model. Pada fase ini, arsitektur YOLOv8 dilatih secara komputasional untuk mengenali pola parasit berdasarkan dataset latih. Setelah serangkaian iterasi (*epoch*) selesai, alur berlanjut ke tahap Evaluasi Model, di mana performa jaringan diuji menggunakan dataset validasi. Kinerja model dikuantifikasi menggunakan parameter metrik evaluasi standar seperti *Confusion Matrix*, presisi, *recall*, dan tingkat *Mean Average Precision* (mAP@50) untuk menilai kemampuan generalisasinya terhadap citra baru.

3.5.5 Evaluasi Model

Hasil evaluasi tersebut kemudian bermuara pada titik keputusan (*decision node*). Apabila hasil evaluasi (seperti nilai mAP atau keseimbangan F1-Score) dirasa belum memenuhi target atau terindikasi mengalami *overfitting/underfitting*, maka alur akan berbelok ke tahap Tuning Model. Pada proses iteratif ini, dilakukan penyesuaian ulang terhadap nilai *hyperparameter* (seperti *learning rate*, *optimizer* AdamW, atau pembobotan fungsi kerugian) sebelum sistem dikembalikan ke tahap pelatihan. Siklus ini akan terus berulang hingga model berhasil mencapai konvergensi dan tingkat akurasi yang diharapkan.

3.5.6 Pembuatan GUI

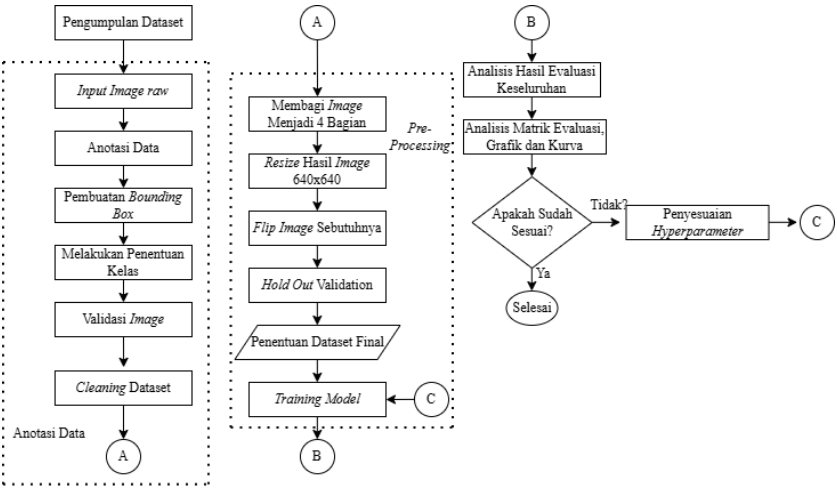
Jika model dinyatakan telah memenuhi atau melampaui target matriks evaluasi dengan menyatakan Ya, langkah selanjutnya adalah Pembuatan GUI Model. Tahap ini bertujuan untuk mengemas arsitektur *Deep Learning* yang kompleks ke dalam Antarmuka Pengguna Grafis (*Graphical User Interface*). Setelah antarmuka selesai dibangun, tahapan Deploy Model dilakukan guna mengimplementasikan sistem secara fungsional. Proses *deployment* ini memungkinkan model beroperasi secara *real-time* atau luring untuk menganalisis citra mikroskopis di lingkungan operasional yang sebenarnya.

3.5.7 Analisis Data

Pasca implementasi, dilakukan Analisis Data secara mendalam terhadap keluaran sistem. Analisis ini meninjau perbandingan hasil deteksi prediktif model terhadap hasil observasi manual oleh tenaga medis, guna mengidentifikasi margin galat yang mungkin timbul saat sistem dihadapkan pada sediaan darah baru. Keseluruhan alur metodologi penelitian ini akhirnya dirangkum secara formal dalam tahap Penyusunan Laporan Tugas Akhir, sebelum keseluruhan rangkaian eksperimen dan pengembangan sistem dinyatakan Selesai.

3.6 Langkah Penelitian secara Spesifik

Langkah Penelitian dimulai dengan pengumpulan dataset dengan labelimg memiliki proses yang cukup panjang, proses tersebut dapat dilihat pada Gambar 3.2.



Gambar 3.2 Diagram Alir Penelitian Spesifik

1) Persiapan Dataset

Proses dimulai dari pengecekan terhadap dataset. Penelitian ini menggunakan dataset yang terdiri diri dari citra mikroskopis sediaan darah total yang sudah di anotasikan, yang dikumpulkan secara langsung pada desa hanura, lampung selatan. Citra-citra tersebut diambil melalui lensa okuler mikroskop dengan pembesaran 100x menggunakan kamera ponsel. Semua citra disimpan dalam ruang warna RGB dengan resolusi 3.024×4.032 piksel. Dataset ini dikategorikan ke dalam dua kelas: sediaan darah yang terinfeksi P. *falciparum*, sediaan darah yang terinfeksi P.*vivax*. Secara keseluruhan, dataset ini mencakup 2300 citra sediaan darah tebal (pada tingkat mikroskop) yang diperoleh dari berbagai pasien, baik yang terinfeksi maupun yang terasumsi terinfeksi. Status infeksi semua pasien dikonfirmasi menggunakan metode gold standard, yaitu pemeriksaan mikroskopis sediaan darah tebal dan Tebal.

Citra pada tingkat mikroskop ini kemudian diproses lebih lanjut untuk menghasilkan 2300 citra berlabel secara individual pada tingkat seluler (Tabel 3.3). Proses anotasi dataset dilakukan oleh seorang ahli mikroskopis dari Puskesmas Hanura di Hanura, yang memverifikasi keberadaan infeksi, mengidentifikasi spesies parasit, serta secara manual memberi label pada setiap citra untuk menandai parasit dan sel darah putih.

Tabel 3.3 Rangkuman Jumlah Komposisi dan Label Dataset

Subset	**Jumlah Citra**	**Parasit Berlabel**
P.falciparum	217	218
P.Vivax	2083	4282
Total	2300	4500

Citra-citra yang telah dianotasi ini kemudian dikatalogkan dan disimpan dalam Google *Drive*. Dataset ini sebelumnya telah divalidasi, dianalisis, dan dipublikasikan oleh tim penelitian yang sama, sehingga dapat dijadikan acuan yang kredibel dalam penelitian ini. Jumlah data yang di miliki berdasarkan dari tabel 3.3 termasuk sebagai data *imbalance* terkhususi pada kelas *P.falciparum* hal ini dilakukan beberapa augmentasi data. Mengingat keterbatasan waktu pelatihan dan kapasitas komputasi, penelitian ini hanya menggunakan citra dari total dataset yang tersedia. Pemilihan subset dilakukan secara acak dan merata dari tiap kelas, serta diatur langsung melalui skrip pemrograman pada tahap pemuatan data, guna memastikan efisienso proses tanpa mengganggu distribusi label pada dataset.

2) *Resizing Citra Dataset*

Setelah melakukan persiapan dataset, tahap selanjutkan dilakukan dengan *resizing* dataset. Hal ini bertujuan untuk melakukan pemfokusan kepada parasit yang ada, memisahkan elemen-elemen yang penting dan tidak penting dan menghindari *overfitting* dalam data. Citra mikroskopis dari dataset original yang beresolusi 3024x 4032 piksel akan di-*cut* menjadi 4 bagian dengan tujuan untuk membesarkan gambar citra parasit tanpa mengubah piksel citra berdasarkan koordinat bounding box dari meta data dataset yang berukuran 640 x 640 piksel.

3) *Pre-processing*

Dataset harus diamati apakah kondisinya sudah cukup baik atau masih kurang. Jika kurang baik, maka perlu dilakukan *pre-processing*. Tahap ini sangat penting untuk menghilangkan noise atau gangguan yang dapat mengaburkan informasi dalam gambar, serta membuang bagian-bagian yang tidak diperlukan agar hasil pengolahan selanjutnya lebih akurat. Berikut ini adalah teknik *pre-processing* yang akan dilakukan, seluruh citra yang ditampilkan diambil dari jurnal karya Briceno, dkk. yang berjudul "*Deep Learning-Based Malaria Parasite Detection: You Only Live Once Model for Accurate Species Identification of Plasmodium Falciparum and Plasmodium Vivax"* dan juga metode yang diajukan sendiri dalam pembuatan sistem ini.

a) Augmentasi Data

Dalam dataset yang diambil terdapat beberapa tantangan dalam *image* hal ini berupa *image* citra yang di ambil, bentuk parasit yang bervariasi sehingga pada proses training dapat menurunkan tingkat akurasi hasil akhir. Untuk mengatasi itu dilakukan proses

augmentasi data, Dimana dilakukan *flip* atau rotasi secara 90° untuk menyesuaikan dengan *image* yang lainnya, penambahan *noise* pada gambar, dan penambahan atau pengurangan *brightness* secara random pada gambar. Dilakukan juga *mosaic* augmentasi dengan menggabungkan 4 gambar menjadi 1 dengan pengubahan gambar menjadi 1280x1280 secara sementara sebelum dilakukan *random perpective* dan dilakukan *cutting* menjadi 640x640 agar dapat dibaca oleh YOLO itu sendiri.

4) Pembagian Dataset (*Hold Out Validation*)

Dataset yang telah melalui tahap pra-pemrosesan kemudian dibagi ke dalam tiga subset utama, yaitu data *training* (pelatihan) dan data *validation* (validasi). Pada penelitian ini, metode evaluasi yang digunakan adalah *Hold-Out Validation* dengan rasio pembagian statis sebesar 80:10:10. Artinya, 80% dari total citra digunakan untuk melatih model agar mampu mengenali dan mengekstraksi fitur parasit secara mendalam, sedangkan 10% digunakan secara eksklusif untuk memvalidasi performa model dan 10% data digunakan untuk melakukan pengujian terhadap evaluasi model nanti dan mendeteksi terjadinya *overfitting* selama proses pelatihan dalam table 3.4.

Tabel 3.4 Pembagian Data Final Training

No	**Data *Training***	**Data *Validation***	**Data *Test***
1	80	10	10

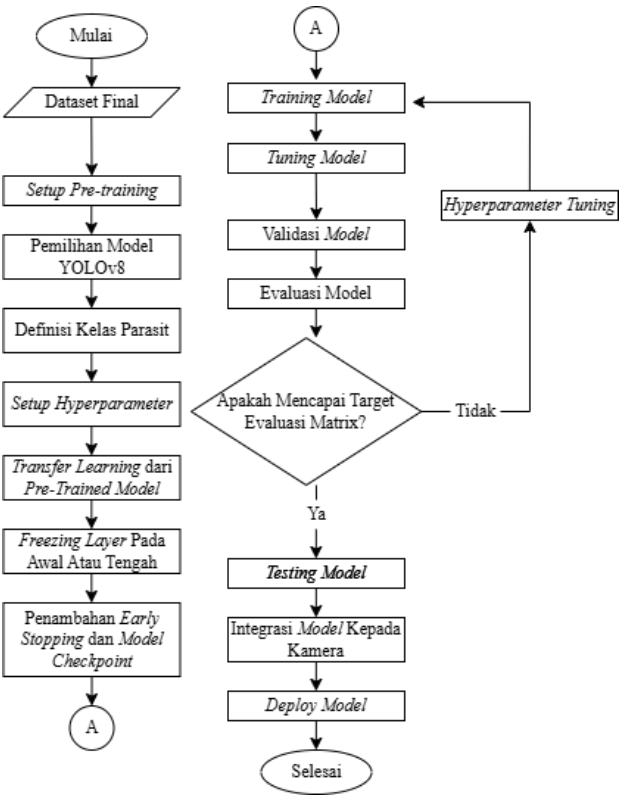
Penggunaan metode *Hold-Out Validation* dengan rasio 80:10:10 dipilih sebagai pengganti *K-Fold Cross Validation* dengan

beberapa justifikasi ilmiah dan teknis. Pertama, pelatihan arsitektur *deep learning* mutakhir seperti YOLOv8 untuk deteksi objek beresolusi tinggi menuntut beban komputasi memori GPU dan waktu yang sangat massif [98]. Menggunakan K-Fold (misalnya 5-fold) berarti mengulang proses training penuh sebanyak 5 kali yang dinilai tidak efisien secara komputasional. Kedua, dataset telah diacak (shuffle) secara terstruktur sebelum dibagi (menggunakan konfigurasi *random seed* yang statis) untuk memastikan distribusi kelas P. falciparum dan P. vivax tersebar secara proporsional. Dengan ukuran dataset yang ada, rasio 80% data latih dan 10% data validasi dan 10% *test* telah terbukti secara empiris cukup stabil untuk menghasilkan model dengan tingkat generalisasi dan Mean Average Precision (mAP) yang tinggi tanpa mengalami bias data [94].

3.6.1 Proses Training Model

Pada proses *training model* disesuaikan dengan kebutuhan sistem pemantauan secara terus menerus atau berkelanjutan. Model dilatih dengan *dataset* yang ada dimana menjawab dan mencerminkan kondisi deteksi nyata. Pada tahapan ini difokuskan kepada kemampuan model untuk mengenali dan mempelajari berbagai parasite yang ada dalam malaria dan mempertahankan akurasi dan persisi selama periode deteksi yang lama. Peneliti menerapkan algoritma YOLOv8 yang melibatkan desain jaringan neural baru yang dikembangkan untuk disesuaikan kepada bentuk parasit dan berbagai macam parasit yang ada dalam malaria dengan tujuan untuk meningkatkan performa, akurasi, persisi, dan mengurangi beban kerja tenaga medis yang ada di Desa Hanura. Proses *training* model meliputi beberapa tahapan seperti, *pre-training setup*, *training process*, *validation model*, dan *testing model*. Seperti yang diberikan pada Gambar 3.1.

Penelitian ini menerapkan teknik *Transfer Learning* dan *Fine-Tuning* menggunakan bobot pra-latih (*pre-trained weights*) yolov8m.pt yang sebelumnya telah dilatih secara ekstensif pada dataset COCO (berisi 80 kelas objek umum). Karena dataset malaria memiliki karakteristik spasial yang sangat spesifik, *fine-tuning* dilakukan dengan melatih ulang (*retraining*) lapisan-lapisan konvolusi dan menyesuaikan *head* klasifikasi agar secara eksklusif mendeteksi dua kelas target, yaitu *P. falciparum* dan *P. vivax*. Pendekatan ini memanfaatkan pengetahuan dasar (ekstraksi bentuk dan tepi tepi) dari model awal, untuk mempercepat proses konvergensi dan meningkatkan akurasi deteksi parasit.



Gambar 3.3 Tahap Training Model

Berdasarkan Gambar 3.3 peneliti akan menentukkan dataset final, menentukkan parameter-parameter untuk dimasukkan dan digunakan dalam proses *training*. Selanjutnya peneliti akan menentukkan *base model* YOLOv8 yang akan digunakan, dalam kasus ini peneliti memilih *base model* YOLOv8m, lalu menentukkan pengaturan lingkungan pengembangan, dan instansi *library* yang mendukung peneliti dalam proses pelatihan model.

Konfigurasi pelatihan model diimplementasikan menggunakan berkas berekstensi YAML (*Yet Another Markup Language*) yang berfungsi sebagai cetak biru utama sistem. Berkas ini memuat spesifikasi teknis yang krusial, meliputi jalur direktori dataset (*directory paths*), definisi arsitektur jaringan, dan skema augmentasi data. Pendefinisian jumlah dan nama kelas dalam konfigurasi ini sangat vital agar model dapat membedakan morfologi spesifik antar spesies parasit malaria. Selain itu, berkas ini juga mengatur *hyperparameter* pelatihan esensial seperti *batch size*, *learning rate*, dan jenis *optimizer* untuk memastikan stabilitas proses pembelajaran model.

Peneliti menggunakan metode *transfer learning*, hal ini dikarenakan menjadi salah satu metode yang sangat berguna dan bagus bagi peneliti untuk memungkinkan membuat model baru untuk belajar tanpa harus membuat model dari nol. Proses *transfer learning* dapat menghemat waktu peneliti dalam proses model untuk belajar, terutama apabila data pembelajaran tidak banyak (2500 dataset). Dimana, peneliti menggunakan *callback*, *weight decay*, pengubahan *learning rate*, dan *logging*.

3.6.2 Proses Training

Setelah melakukan *pre-training setup*, peneliti mulai melakukan proses *training* yang dimulai dengan melakukan konfigurasi umum yang telah di tentukan sebelumnya. Hal ini dilakukan dengan tujuan untuk mengetahui dan memberikan pengetahuan dasar kepada model untuk melakukan pelatihan. Model dilatih dengan menggunakan *Visual Studio Code* yang memberikan setting *hyperparameter* yang cukup konsisten, hal ini termasuk *learning rate, batch size, epoch,* dan *optimizer*. Hal ini dilakukan untuk memberikan konsistensi yang pas dan sesuai untuk membandingkan antara masing-masing *skenario* dan juga menghindari adanya bias.

Berikutnya peneliti melakukan berbagai perbandingan *hyperparameter* yang dilakukan atau dicoba untuk menemukan konfigurasi model yang paling bagus dan cocok untuk melakukan penelitian, seperti *learning rate, batch size, epoch,* pemilihan *optimizer*, *weight decay*, dan *callback*. Peneliti juga melakukan *review* terhadap kinerja model dan juga arsitektur model untuk menemukan hasil yang optimal.

Proses pelatihan menggunakan *optimizer* AdamW, dengan fungsi kerugian yang terdiri dari tiga komponen sebagaimana telah dijelaskan pada Sub bab 3.4.1, yaitu *Binary Cross-Entropy* (BCE) untuk menghitung kesalahan klasifikasi kelas parasit, *Complete Intersection over Union* (CIoU) untuk mengukur seberapa tepat posisi *bounding box* yang diprediksi, dan *Distribution Focal Loss* (DFL) untuk memperhalus prediksi batas kotak deteksi. Ketiga nilai kerugian ini dijumlahkan menjadi satu nilai *loss* total yang dipakai model untuk memperbarui bobotnya di setiap iterasi pelatihan. *Hyperparameter*

ditetapkan berdasarkan kombinasi yang stabil, dengan konfigurasi Tabel 3.5 sebagai berikut :

Tabel 3.5 Konfigurasi *Hyperparameter*

Kategori	Parameter	Nilai
Konfigurasi Dasar & Sistem	*epochs*	150
	imgsz	640
	batch	8
	workers	2
	patience	50
Optimasi & Kecepatan Belajar	*optimizer*	AdamW
	lr0	0.000218
	lrf	0.00426
	momentum	0.8652
	weight_decay	8.35×10^{-5}
	cos_lr	TRUE
Pemanasan Jaringan (Warmup)	*warmup_epochs*	6.69
	warmup_momentum	0.9422
	warmup_bias_lr	0.1

Konfigurasi ini dipilih untuk menjaga keseimbangan antara kecepatan konvergensi dan stabilitas pelatihan. Dengan pendekatan ini, diharapkan model mampu mempelajari fitur morfologis khas dari citra sel darah terinfeksi malaria secara akurat dan konsisten pada setiap skenario pelatihan.

Setiap *training* yang telah dilatih dievaluasi secara terpisah menggunakan metrik seperti akurasi, *precision*, *recall*, dan *F1-score*. Kurva *loss* dan akurasi per *epoch* divisualisasikan untuk memantau dinamika pelatihan sekaligus mendeteksi potensi overfitting atau underfitting. Hasil evaluasi model ini berupa berbagai macam metrik seperti recall, precision, f1-score, mAP@50, dan mAP@50-95. Metrik-metrik ini dihitung berdasarkan nilai yang diperoleh dari confusion matrix, yang mencakup *True Positives*(TP), *True Negatives q*(TN), *False Positives*(FP), *False Negatives*(FN), *Bounding Box Ground Truth* (B_{gt}) dan *Bounding Box Predict* (B_{pred}).

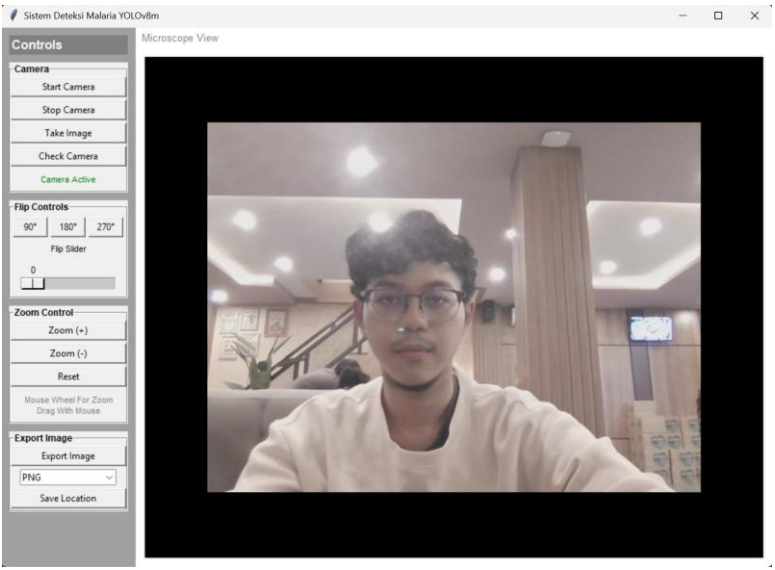
Setelah pelatihan, evaluasi keseluruhan dilakukan untuk memperoleh gambaran performa model secara agregat. Hasil evaluasi mencakup perhitungan rata-rata akurasi pada seluruh scenario, serta analisis distribusi kesalahan melalui confusion matrix. Analisis ini memungkinkan identifikasi skenario terbaik dengan mempertimbangkan tidak hanya akurasi, tetapi juga kestabilan loss, distribusi kesalahan, dan generalisasi model terhadap variasi data.

3.6.3 Integrasi *Hardware* dan *Software*

Tahap ini berfokus pada integrasi *webcam* atau *eyepiece camera* sebagai modul akuisisi citra dengan mikroskop konvensional, serta model YOLOv8 yang telah dilatih untuk mengklasifikasikan parasit malaria pada sel darah merah. Kamera digunakan untuk menangkap citra mikroskopis secara *real-time*, kemudian citra tersebut dialirkan untuk diproses secara digital menggunakan bahasa pemrograman *Python* dengan bantuan pustaka *OpenCV*.

Proses *pre-processing* pada tahap integrasi meliputi penyesuaian resolusi, peningkatan kontras, dan normalisasi warna agar

citra memenuhi syarat standar masukan model. Setelah citra siap, proses analisis dilakukan menggunakan bobot model terbaik (*best.pt*) melalui *framework PyTorch* dan pustaka *ultralytics*. Hasil inferensi yang dihasilkan berupa identifikasi spesies parasit, apakah terinfeksi *Plasmodium falciparum* atau *Plasmodium vivax*, yang kemudian ditampilkan secara visual melalui antarmuka pengguna grafis (GUI). Untuk mengoptimalkan kecepatan deteksi pada perangkat dengan daya komputasi terbatas, penelitian ini juga mempertimbangkan teknik optimasi seperti kuantisasi model atau konversi ke format yang lebih ringan hal ini juga untuk memastikan sistem dapat beroperasi dengan latensi yang sangat rendah. Hasil visual melalui antarmuka pengguna grafis atau GUI dapat dilihat pada Gambar 3.4.



Gambar 3.4 Design GUI

Pada gambar ini terlihat baseline atau kerangka awal dari GUI, dimana di dalam GUI ini sendiri memiliki beberapa kategori fitur dimulai dari *camera*, *flip control*, *zoom control*, dan *export image*.

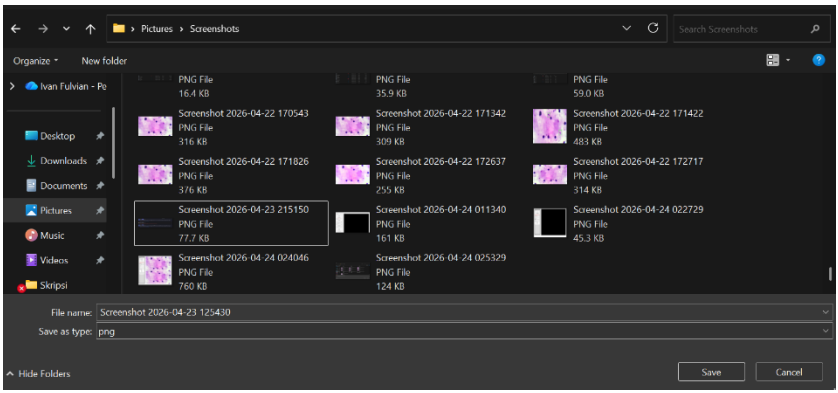
Di dalam masing-masing kategori fitur memiliki beberapa tombol atau fitur sendiri, dimulai dengan *camera* di dalam kategori fitur *camera* memiliki tombol *start camera* hal ini berfungsi untuk memulai proses atau model untuk model mulai melakukan identifikasi terhadap gambar yang diberi. Sedangkan, penggunaan *stop camera* berfungsi untuk menghentikan proses deteksi model yang sedang dilakukan atau mematikan kamera yang digunakan agar berhenti untuk mendeteksi hal ini akan menyebabkan area yang sebelumnya terdapat gambar dari parasit akan menghasilkan warna hitam. Berikutnya ada *take image* hal ini bertujuan untuk mengambil gambar dari hasil deteksi yang sudah dilakukan. Lalu, terdapat *check camera* tombol ini berfungsi untuk memberitahu pengguna terkait terdeteksinya *camera* atau tidak di dalam GUInya, apabila tidak terdeteksi maka akan memberikan teks "*camera not detected* " atau "*camera detected* " dalam warna merah.

Berikutnya terdapat fitur *flip controls*, fitur ini memiliki tujuan untuk melakukan rotasi terhadap gambar yang sudah diberi dengan harapan dapat meningkatkan tingkat akurasi atau mempermudah pengguna dalam melakukan pendeteksian secara manual apabila perlu. Di dalam fitur *flip controls* terdapat beberapa tombol lagi dimulai dengan 90°, 180°, 270°. Dengan adanya slider untuk melakukan rotasi secara *custom* atau sesuai kebutuhan pengguna dengan maskimum slider 360°.

Lalu, terdapat fitur *zoom control,* fitur ini memberikan pengguna kemampuan untuk melakukan pembesaran gambar sesuai kebutuhan dari pengguna dengan harapan dapat meningkatkan akurasi dari model atau mempermudah pengguna dalam melihat parasit. Di dalam fitur *zoom control* ini memiliki beberapa tombol lainnya, dimulai

dengan *zoom* (+), fitur ini memberikan kemampuan pengguna untuk melakukan pembesaran gambar secara bertahap dengan tingkat pembesaran 10%. Lalu, terdapat fitur *zoom* (-) dengan kemampuan kebalikannya dari *zoom* (+) yang memberikan kemampuan kepada pengguna untuk melakukan memperkecilkan ukuran gambar. Berikutnya, terdapat fitur *reset* hal ini bertujuan untuk melakukan *reset* terhadap peningkatan atau penurunan *zoom* yang telah dilakukan oleh pengguna.

Berikutnya terdapat fitur *export image* hal ini memberikan kemampuan kepada pengguna untuk menyimpan hasil gambar dari GUI langsung ke dalam *folder* atau *file* yang ada di dalam perangkat pengguna, dengan memberikan tempat penyimpanan yang *custom* atau menyesuaikan dengan kebutuhan pengguna. Contoh tempat penyimpanan gambar dapat dilihat pada gambar 3.5.



Gambar 3.5 Lokasi Penyimpanan File

Tempat penyimpanan gambar dapat disimpan di dalam *folder* tertentu atau pengguna dapat membuat *folder* baru khusus untuk gambar-gambar yang sudah atau akan di ambil.

3.6.4 Uji Implementasi

Setelah proses integrasi berhasil diselesaikan, langkah berikutnya adalah melakukan uji implementasi. Tahap ini bertujuan untuk menguji implementasi sistem yang telah dikembangkan, dengan fokus pada integrasi model YOLO dengan mikroskop konvensional melalui modul kamera digital. Uji implementasi dilakukan dengan dataset digital, dimana pada tahap ini, model YOLO yang telah dilatih diuji menggunakan *slide* preparate sel darah Tebal untuk memastikan akurasi deteksi P.falciparum, P.vivax.

3.7 Interpretasi Data/Analisis Data

Tahap interpertasi data termasuk sebagai langkah yang sangat krusial dalam penelitian ini, hal ini berfungsi sebagai evaluasi kinerja sistem deteksi malaria berbasis YOLOv8 yang telah di kembangkan. Setelah proses pengujian model selesai dilakukan, hasil inferensi tidak hanya dilihat dari sebatas angka metrik komputasional saja, namun juga diinterpertasikan relevansinya terhadap standar atau *gold standard* diagnosis klinis. Analisis ini bertujuan untuk mengonfirmasi apakah sistem yang dirancang telah mampu mengenali dan membedakan kelas *plasmodium falciparum* dan *plasmodium vivax* pada citra mikroskopis sediaan darah secara akurat, persisi dan sesuai dengan hipotesis awal penelitian.

Secara kuantitatif, cara melakukan interpretasi data adalah dengan mengevaluasi performa algoritmik model berdasarkan parameter statistik yang diturunkan dari *Confusion Matrix*, yaitu Akurasi, Presisi, *Recall*, *F1-Score*, dan *Mean Average Precision* (mAP@50). Teori dan asumsi yang dipakai dalam analisis ini adalah bahwa untuk sistem deteksi pencitraan medis penyakit menular seperti

malaria, nilai sensitivitas (*Recall*) memiliki tingkat prioritas yang sangat krusial. Hal ini dilandaskan pada asumsi klinis bahwa meminimalkan *False Negative* (sistem gagal mendeteksi parasit yang sebenarnya ada di darah pasien) jauh lebih penting dibandingkan menekan *False Positive* (sistem mendeteksi artefak kotoran sebagai parasit), karena kesalahan melewatkan sel yang terinfeksi dapat berakibat fatal bagi penanganan pengobatan pasien. Pencapaian target evaluasi seperti mAP50% yang tinggi akan menjadi indikator utama bahwa model telah mengekstraksi fitur dengan baik dan layak untuk tahap implementasi.

Selanjutnya, secara kualitatif, data hasil deteksi berupa pelokalan kotak pembatas (*bounding box*) dari model YOLOv8 akan divalidasi melalui metode komparatif. Data yang digunakan sebagai pembanding mutlak (*ground truth*) dalam penelitian ini adalah hasil diagnosis dan anotasi manual yang telah dikonfirmasi oleh ahli mikroskopis dari Puskesmas Desa Hanura, yang bertindak sebagai representasi metode *gold standard*. Apabila ditemukan anomali atau kesalahan deteksi (*misclassification*), maka analisis data akan dilanjutkan untuk mengidentifikasi faktor penyebabnya secara visual, seperti pengaruh kualitas sediaan preparat, penumpukan sel darah putih, atau munculnya artefak *vignetting* akibat keterbatasan *Field of View* (FoV) dari lensa mikroskop. Melalui perbandingan klinis ini, hasil interpretasi pada akhirnya dapat membuktikan seberapa andal dan konsisten sistem yang dibangun dalam mendampingi serta mengurangi beban kerja tenaga medis di lapangan.

BAB IV
HASIL DAN PEMBAHASAN

4.1 Pengolahan Dataset Citra Mikroskopis

Tahap awal dan krusial dalam penelitian ini adalah pengolahan dataset primer citra mikroskopis sediaan darah tebal (*thick smear*) yang diperoleh dari Puskesmas Hanura, Kabupaten Pesawaran, Lampung. Validitas dan kualitas representasi fitur pada fase prapemrosesan ini memegang peranan vital karena model *deep learning* sangat bergantung pada kualitas data masukan (*garbage in, garbage out*). Karakteristik sediaan darah tebal yang diwarnai dengan Giemsa. Hal ini dilakukan untuk membuat latarbelakang dalam preparat menjadi jernih biru pucat atau pucat kemerahan agar sel-sel eritrosit warna kontras dan jelas [99].

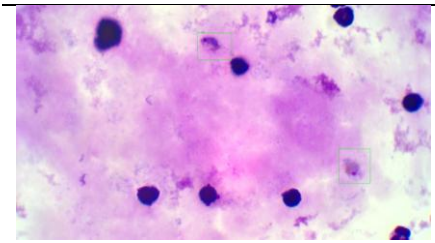
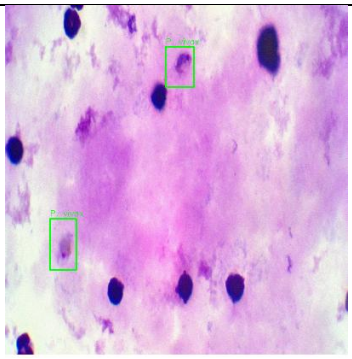
Secara keseluruhan, dataset primer yang berhasil diakuisisi berjumlah 2.300 citra digital. Distribusi citra tersebut terdiri dari 217 citra sediaan yang terinfeksi *Plasmodium falciparum* dan 2.083 citra yang terinfeksi *Plasmodium vivax*. Kompleksitas semakin meningkat pada tingkat pelabelan objek (*bounding box*), di mana terdapat total 4.500 anotasi parasit murni yang diverifikasi bersama pakar, dengan rincian ketimpangan data yang sangat mencolok yaitu 4.282 *bounding box* untuk *Plasmodium vivax* dan hanya 218 *bounding box* untuk *Plasmodium falciparum.*

4.1.1 Penyesuaian Resolusi

Citra mentah (*raw image*) dari kamera mikroskop awalnya memiliki resolusi spasial yang sangat besar, yaitu 3.024 × 4.032 piksel. Memproses citra dengan resolusi tersebut secara langsung akan membebani memori komputasi (VRAM GPU) secara berlebihan dan memperlambat waktu inferensi. Oleh karena itu, dilakukan proses

resizing citra menjadi 640 × 640 piksel dam menggabungkan 4 gambar citra menjadi 1 disaat proses *train* [100].

Tabel 4.1 Hasil Data *Resizing*

Sebelum	Sesudah
	

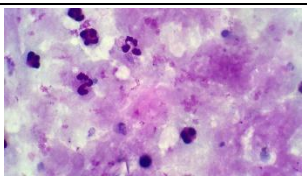
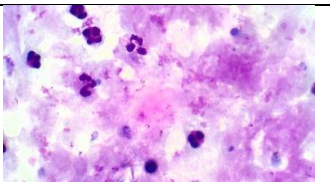
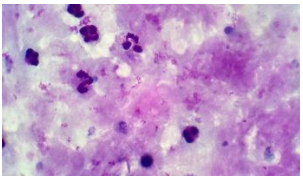
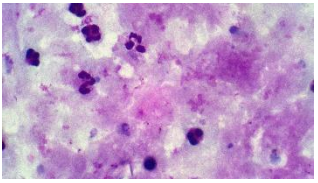
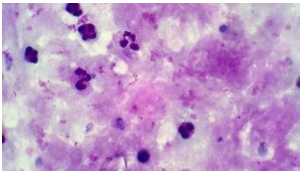
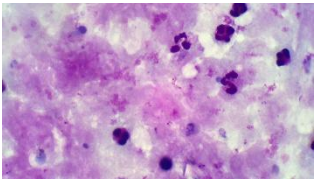
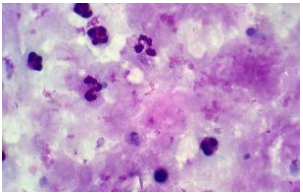
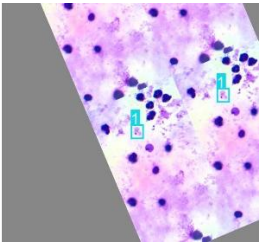
Hasil *Resizing* yang di tunjukkan pada tabel 4.1 memiliki tujuan untuk mengurangi beban secara komputasional serta juga membuat agar model YOLO bisa membaca dan ekstraksi fitur-fitur pentingnya pada fase *backbone* dari YOLO itu sendiri. Di tambah dengan fitur *mosaic* yang menambahkan 4 gambar menjadi 1 dengan resolusi sementara 1280x1280 dan dilakukan *cutting* dan resize menjadi 640x640 agar dapat dibaca kembali oleh YOLO.

4.1.2 Implementasi Augmentasi Data

Salah Satu Tantangan terbesar dalam rekayasa dataset medis adalah menangani fenomena ketidakseimbangan kelas (*class imbalance*). Berdasarkan rekapitulasi data anotasi, sampel *P. vivax* mendominasi secara ekstrem dibandingkan *P. falciparum*. Apabila model YOLOv8m dilatih secara langsung menggunakan kondisi sekarang ini, model akan mengalami bias secara mayoritas dan gagal

melakukan klasifikasi pada kelas minoritas (*P. Falciparum*). Augmentasi difokuskan pada manipulasi spasial, salah satunya dengan melakukan operasi putaran dinamis (penyesuaian orientasi *flip*) pada citra latih dan untuk mengurangi terjadinya kelas *bias* disaat proses training.

Tabel 4.2 Hasil Augmentasi Data Yang Dilakukan

Subset	Sebelum	Sesudah
Brightness		
Penambahan *Noise*		
Flip		
Mosaic		

Dengan menggunakan augmentasi di table 4.2 secara langsung membantu YOLOv8m untuk tidak hanya menghafal dari bentuk ataupun warna dari dataset yang sudah ada. Hal ini secara langsung

meningkatkan ketahanan model dalam mengenali parasit pada berbagai variasi sediaan di bawah mikroskop [101].

4.1.3 Pembagian Dataset

Setelah seluruh citra melalui tahap prapemrosesan dan augmentasi, dataset dibagi menggunakan metode *Hold-Out Validation*. Untuk memastikan evaluasi kinerja model bersifat objektif, rasio pembagian dataset ditetapkan secara ketat pada skala 80:10:10 yang dapat dilihat pada tabel 4.3.

Tabel 4.3 Distribusi Pembagian Dataset Akhir Citra

Kategori Data	Presentase
Train Set	80%
Validation Set	10%
Test Set	10%

Penguncian 10% alokasi data sebagai data uji (*Test Set*) yang sepenuhnya terpisah dari siklus pelatihan Tabel 4.3 adalah parameter metodologis penting. Langkah ini secara langsung menjamin bahwa model terhindar dari fenomena kebocoran data (*data leakage*), sehingga metrik evaluasi akhir benar-benar merepresentasikan kemampuan generalisasi sistem saat memproses sampel sediaan darah baru[102].

4.2 Fine-Tuning Model YOLOv8m

Tahap berikutnya pelaksanaan proses pelatihan model dengan menerapkan metode *transfer learning* dan *fine-tuning* pada arsitektur YOLOv8m (Medium). Pendekatan *fine-tuning* dipilih karena model pra-latih (*pretrained weights*) *yolov8m.pt* telah memiliki pemahaman dasar yang kuat dalam mengekstraksi fitur visual tingkat rendah seperti

garis, tepi, dan orientasi spasial dari dataset COCO. Melalui *fine-tuning*, bobot jaringan tersebut disesuaikan kembali secara mendalam agar adaptif terhadap karakteristik morfologi mikroskopis parasit malaria *P.falciparum* dan *P.vivax* [103]. Untuk menghindari terjadinya kelemahan pencarian parameter secara manual (*trial-and-error*) yang tidak efisien dan rentan terhadap bias subjektif, proses pencarian kombinasi *hyperparameter* terbaik dilakukan secara otomatis menggunakan algoritma *Optuna*[104].

Eksperimen optimasi dijalankan sebanyak 153 kali simulasi (*trials*) untuk pencarian parameter yang paling bagus terhadap karakteristik sediaan darah tebal. Setelah dilakukan trial untuk menemukan parameter terbaik ditmukan parameter yang mencapai besar 90% mAP pada Tabel 4.4 sebagai berikut :

Tabel 4.4 Hyperparameter Final

Parameter	**Nilai**
epochs	150
Imgsize	640
batch	8
workers	2
patience	30
optimizer	AdamW
lr0	0.000218
lrf	0.00426
momentum	0.8652
weight decay	8.35×10^{-5}

Penetapan konfigurasi parameter pada Tabel 4.5 memberikan justifikasi ilmiah terhadap performa model, dimana model mencapai target evaluasi. Keberhasilan model dalam mengekstraksi fitur visual parasit malaria meningkat pada orkestrasi tiga *hyperparameter* fundamental yang mengendalikan proses pembaruan bobot matematis, yaitu *learning rate*, *momentum*, dan *weight decay*. Hal ini dikarenakan terdapatnya overfitting pada saat proses training sehingga ketiga ini memiliki efek yang sangat tinggi terhadap hasil training/trial. Ketiga parameter ini membentuk mekanisme kontrol utama untuk mencapai titik akurasi tertinggi tanpa merusak representasi pengetahuan yang sudah ada di dalam arsitektur jaringan[105],[106].

Penetapan *initial learning rate* (*lr0*) pada angka yang sangat kecil, yaitu 0,000218, merupakan langkah esensial dalam skenario *fine-tuning* citra medis. Nilai laju pembelajaran yang rendah ini secara matematis mengurangi risiko terjadinya *catastrophic forgetting*, di mana model dapat kehilangan representasi fitur spasial umum yang telah dipelajari dari *pretrained.* [107].

Sebagai penyeimbang dari laju pembelajaran yang lambat, *momentum* ditetapkan pada nilai 0,8652 untuk memberikan pembelajaran yang hati-hati selama proses optimasi *gradient descent*. [108]. Dilanjutkan dengan parameter *weight decay* yang dioptimasi pada $8{,}346 \times 10^{-5}$ (0,00008346) berperan sebagai mekanisme regularisasi L2 (*Ridge Regression*) yang bekerja secara presisi. Hal ini dapat dilihat pada tabel 4.5 [109].

Tabel 4.5 Hyperparameter Test

Parameter	Nilai
epochs	150
Imgsize	640
batch	8
workers	2
patience	30
optimizer	AdamW
lr0	0.000218 – 0.0003
lrf	0.00426 – 0.006
momentum	0.8652 – 0.9
weight decay	8.35×10-5 – 9×10-5

Sebelum melakukan eksperimen terhadap augmentasi data dengan hyperparameter tertentu, dilakukan eksperimen terhadap seluruh hyperparameter yang dilakukan untuk menemukan hyperparameter apa yang memberikan hasil terhadap mAP@50 tertinggi. Dimana hasil eksperimen ini dapat dilihat pada Tabel 4.6

Tabel 4.6 Hasil Eksperimen Hyperparameter

Parameter	Nilai	mAP@50	mAP@50-95
lr0	0.0003	86.1%	56.2%
lrf	0.006	84.8%	55.6%
momentum	0.9	88.88%	57.92%
weight_decay	9×10-5	84%	54.9%

Untuk mengoptimalkan arsitektur jaringan sebelum menetapkan model final, dilakukan fase pencarian *hyperparameter* (*hyperparameter tuning*) melalui *grid search*. Fase ini bertujuan untuk mengidentifikasi konfigurasi matematis mana yang paling efektif dalam mendongkrak akurasi deteksi, khususnya pada metrik mAP@50 dan mAP@50-95. Pengujian dilakukan dengan menyeleksi beberapa variabel kunci komputasional, yaitu penyesuaian *initial learning rate* (lr0), *weight decay*, *momentum*, dan *final learning rate fraction* (lrf), yang seluruhnya dieksekusi menggunakan dataset dengan menggunakan dataset *oversampling* untuk menghindari bias kelas.

Berdasarkan hasil komparasi eksperimen yang terekam pada Tabel 4.6, konfigurasi *hyperparameter* pada tabel 4.4 muncul sebagai kombinasi yang paling efektif dalam menghasilkan performa tertinggi. Konfigurasi ini berhasil menyentuh titik puncak fungsional dengan capaian mAP@50 maksimal sebesar 0,91 dan mAP@50-95 sebesar 0,59.

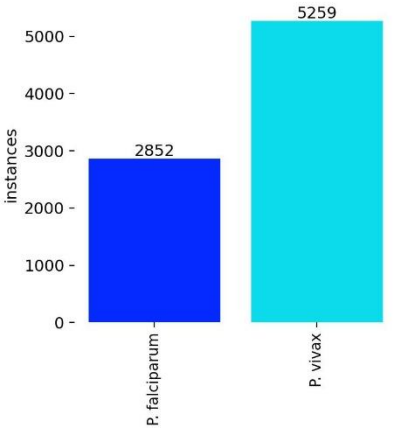
4.3 Analisis Pengaruh Distribusi dan Augmentasi Dataset

Pada tahap ini, evaluasi pelatihan model dilakukan menggunakan konfigurasi *hyperparameter* terbaik. Eksperimen difokuskan pada analisis perbandingan tiga skenario distribusi dan augmentasi data yang berbeda guna mengidentifikasi strategi paling optimal dalam menangani ketidakseimbangan kelas (*class imbalance*) pada sediaan darah mikroskopis. Proses augmentasi pada skenario menghasilkan peningkatan jumlah citra dari 2300 menjadi 2728 gambar, augmentasi pada skenario 2 meningkatkan citra menjadi 6900, dengan skenario 3 menjadi 1946. Penambahan variasi citra bertujuan memperkaya karakteristik data yang dipelajari model sehingga model

tidak hanya mengenali pola dari satu orientasi atau kondisi pencahayaan tertentu. Dengan begitu, augmentasi diharapkan meningkatkan kemampuan generalisasi model terhadap data baru. Pada penelitian ini, pengaruh augmentasi dievaluasi melalui performa model pada tahap pengujian yang ditunjukkan oleh nilai precision, recall, F1-score, dan mAP

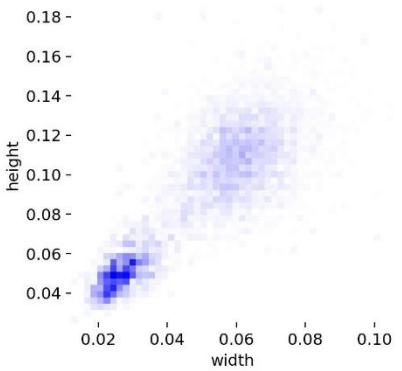
4.3.1 Skenario I: Pelatihan dengan *Oversampling*

Pada skenario pertama, manipulasi data difokuskan secara eksklusif pada kelas minoritas (*P. falciparum*). Augmentasi dilakukan untuk melipatgandakan jumlah citra *Falciparum* hingga mencapai rasio 1:2 terhadap *P. vivax*. Strategi ini bertujuan untuk meningkatkan representasi spasial dari *ring-form Falciparum* tanpa merusak variasi natural dari morfologi *Vivax* yang sudah cukup banyak. Berdasarkan kurva pelatihan, pendekatan ini menghasilkan konvergensi yang paling stabil dan metrik *Mean Average Precision* (mAP) tertinggi, membuktikan bahwa rasio 1:2 memberikan keseimbangan optimal antara variasi fitur medis dan beban komputasi[79], [108], [110]. Proses *oversampling* ini mengubah total dataset yang di dapatkan memiliki total jumlah gambar menjadi 2728 gambar dan label menjadi 2852 label *P.Falciparum* dengan 5259 label *P.Vivax* dapat dilihat pada Gambar 4.1.



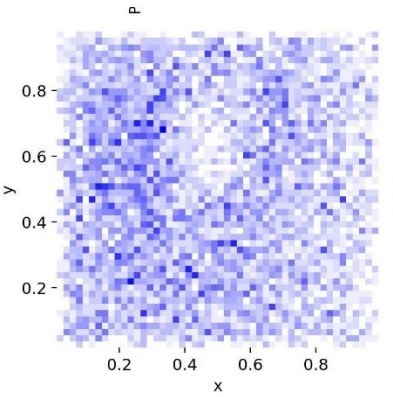
Gambar 4.1 Hasil Pembagian Labels Dalam Training Skenario 1

Berdasarkan Gambar 4.1 menunjukkan hasil distribusi label setelah augmentasi data pada kelas *P. falciparum*. Strategi *oversampling* dengan rasio 1:2 ini diterapkan untuk mencegah *overfitting* sekaligus menghindari bias terhadap kelas mayoritas. Rasio 1:2 dipilih agar model tetap dapat mempelajari variasi morfologi alami *P. vivax* secara luas. Secara langsung, representasi *P. falciparum* juga cukup untuk memastikan fitur cincinnya (*ring form*) dapat terdeteksi oleh jaringan konvolusi model [110]. Analisis terkait luas objek parasit ini selanjutnya dibuktikan pada grafik *scatter plot* dimensi kotak pembatas di Gambar 4.2.



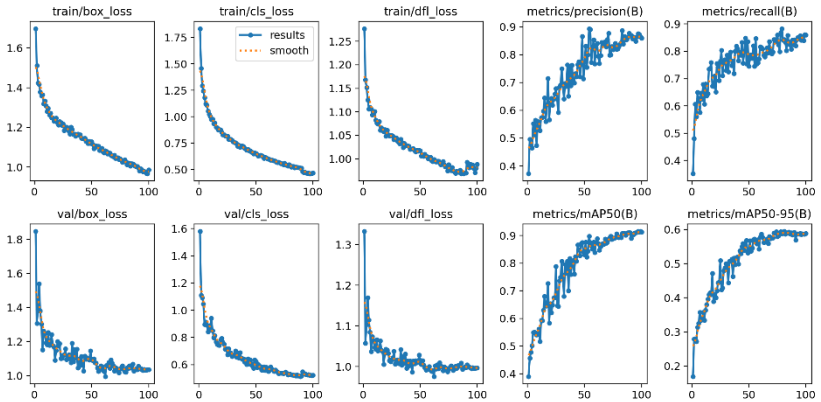
Gambar 4.2 Hasil Width vs Height Scatter Plot Skenario 1

Berdasarkan Gambar 4.2 analisis pada grafik dimensi kotak pembatas (*width vs height scatter plot*) mengkonfirmasikan terkait dengan permasalahan utama model dalam deteksi parasit malaria. Hampir seluruh klaster titik terkonsentrasi pada area sudut kiri bawah grafik (berada di area nilai 0,02 hingga 0,06 relatif terhadap dimensi citra). Hal ini membuktikan bahwa ukuran parasit malaria sangat kecil dan menempati kurang dari 10% area citra sediaan darah tebal. Karakteristik ini menjadi alasan utama digunakannya *learning rate* yang sangat rendah (0,000218) pada *optimizer* AdamW sangat diperlukan, hal ini dikarenakan laju pembelajaran yang agresif dapat membuat model melewati fitur-fitur spasial berukuran sangat kecil [111]. Penggunaan hyperparameter ini dengan melakukan *oversampling* terhadap *P.Falciparum* menunjukkan model tidak mengalami bias secara spasial, dapat dilihat pada gambar 4.5.



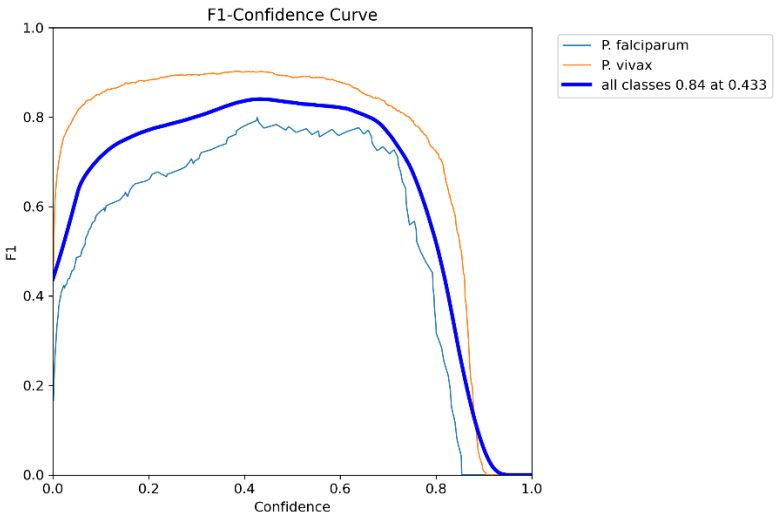
Gambar 4.3 Hasil Grafik scatter plot Skenario 1

Berdasarkan gambar 4.3 menunjukkan persebaran yang merata di seluruh kuadran citra tanpa adanya klasterisasi fokal di area tertentu (titik biru tersebar mirip dengan *white noise*). Distribusi lokasi yang acak dan merata ini sangat ideal karena mencegah model mengalami bias spasial. Model dipaksa untuk benar-benar mempelajari fitur biologis dan warna kromatin *Giemsa* dari parasit, bukan sekadar menghafal kebiasaan posisi kemunculan parasit di tengah atau di sudut lensa mikroskop. Sinergi antara distribusi kelas 1:2 dengan keberagaman posisi spasial dan kombinasi *hyperparameter* yang presisi ini yang menjadikan Skenario I sebagai konfigurasi eksperimen dengan tingkat generalisasi terbaik. Sehingga efek dari konfigurasi eksperimen ini terhadap proses pembelajaran model dievaluasi pada kurva kerugian di Gambar 4.6



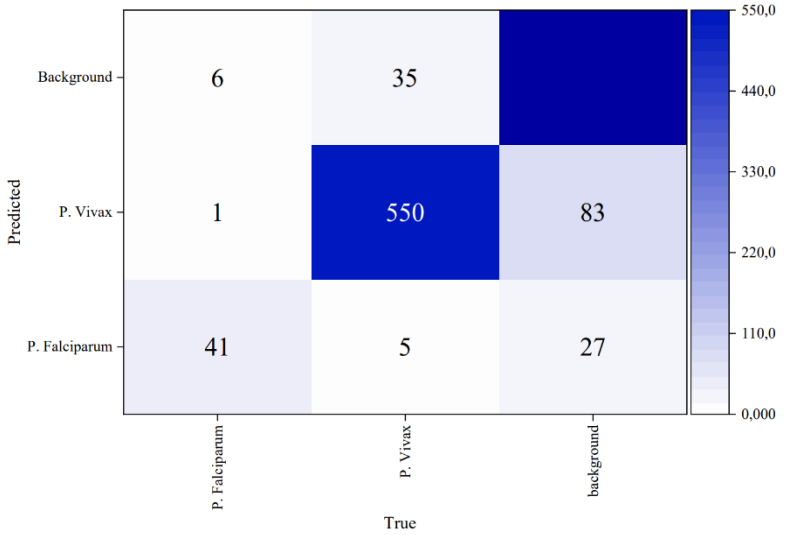
Gambar 4.4 Hasil Proses Training Skenario 1

Berdasarkan gambar 4.4 Grafik ini memvisualisasikan perjalanan optimasi jaringan konvolusi selama 100 siklus pembelajaran (*epoch*). Deretan grafik di sebelah kiri menunjukkan penurunan nilai kerugian (*loss*) secara konsisten pada fase awal. Terdapat indikasi *overfitting* ringan pada *epoch* akhir, khususnya pada metrik *box_loss* di mana jarak antara kurva pelatihan dan validasi sedikit melebar. Namun, kondisi ini tidak memengaruhi performa akhir secara signifikan. Grafik di sebelah kanan membuktikan bahwa nilai metrik mAP50 tetap stabil mendekati 0,90 tanpa mengalami penurunan performa. Hal ini mengonfirmasi bahwa arsitektur jaringan berhasil mengekstraksi fitur tanpa mengalami kerusakan fungsional[112]. Keseimbangan lokalisasi ini dianalisis lebih spesifik pada kurva F1-Confidence di Gambar 4.7.



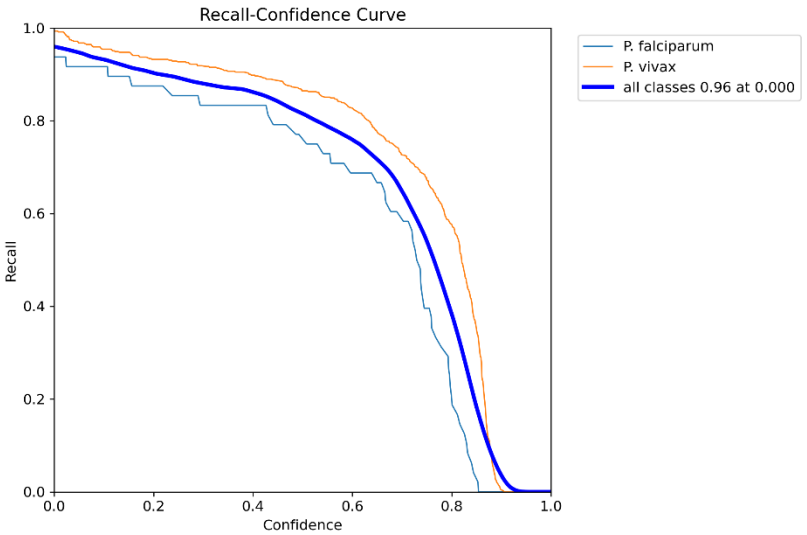
Gambar 4.5 Hasil Kurva F1-Confidence Skenario 1

Berdasarkan Gambar 4.5 kurva ini digunakan untuk menentukan titik keseimbangan optimal antara ketepatan deteksi (*Precision*), kepekaan model (*Recall*) dan tingkat *confidence*. Berdasarkan observasi grafik, garis biru tebal yang merepresentasikan rata-rata performa model secara global menyentuh titik puncak skor F1 sebesar 0,84 pada ambang batas keyakinan (*confidence threshold*) di angka 0,433. Capaian ini memberikan justifikasi bahwa sistem klasifikasi beroperasi pada performa maksimalnya ketika batas toleransi keraguan prediktif diatur pada kisaran 43% [113], [114]. Selain itu, fenomena di mana kurva untuk kelas *P. vivax* (oranye) lebih superior dibandingkan kurva *P. falciparum* (biru tipis) merupakan sebagai hasil yang sangat logis dan dapat dipertanggungjawabkan karena skenario eksperimen dirancang dengan distribusi rasio 1:2 yang secara natural memberikan porsi variasi fitur visual lebih besar pada kelas mayoritas. Di mana kinerja prediksi kelas ini di analisis lagi secara absolut melalui Matriks Kebingungan pada Gambar 4.8.



Gambar 4.6 Hasil Confusion Matrix Skenario 1

Berdasarkan gambar 4.6 hasil matriks ini menjadi esensial untuk melacak distribusi tebakan benar dan klasifikasi meleset yang dihasilkan oleh algoritma terhadap anotasi aktual sediaan darah. Pada sel di area tengah, model mampu melokalisasi 550 citra *P. vivax* dengan benar dan hanya salah mengklasifikasikan 1 citra sebagai kelas minoritas. Untuk kelas *P. falciparum*, model berhasil mengidentifikasi 41 citra secara tepat dengan 5 kesalahan prediksi (*false positive*) sebagai *P. vivax*. Tingkat kesalahan silang (*crossclass misclassification*) yang sangat minim ini menjadi bukti kuat bahwa sistem tidak mengalami kebingungan dalam membedakan morfologi biologis antara spesies parasit. Evaluasi juga menunjukkan bahwa sisa galat terbesar justru berada dari sel latar belakang (*background*), yang mencerminkan bias natural algoritma terhadap artefak mikroskop atau sisa zat pewarna Giemsa.

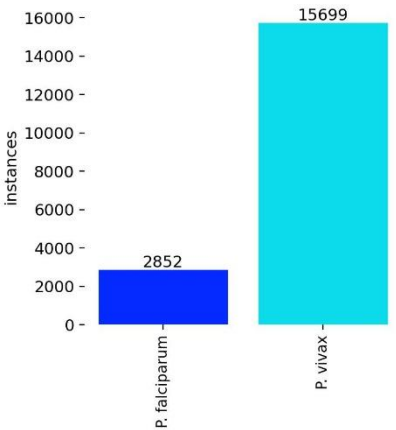


Gambar 4.7 Hasil Kurva Recall Skenario I

Berdasarkan dari Gambar 4.7 yang merupakan salah satu metrik evaluasi krusial dalam sistem diagnosis berbantuan komputer (*Computer-Aided Diagnosis*). Grafik ini mengukur kemampuan model mempertahankan presisi saat dituntut menjaring sebanyak mungkin sel yang terinfeksi (*Recall*). Garis biru tebal menunjukkan pencapaian nilai rata-rata presisi (mAP@50) global sebesar 0,895. Pada tingkat spesies, model mampu mendeteksi *P. falciparum* dengan nilai mAP sebesar 0,839. Tingkat akurasi di atas 80% ini dinilai sangat baik teringat juga parasit malaria memiliki ukuran yang sangat kecil dibandingkan dengan luas pandang mikroskop. Bentuk kurva yang stabil dan mendatar sebelum menurun curam membuktikan bahwa model ini memiliki tingkat deteksi positif palsu (*false positive*) yang rendah. Hal ini mengonfirmasi bahwa sistem layak dioperasikan secara *real-time* tanpa menghasilkan alarm kesalahan yang berlebihan[115].

4.3.2 Skenario II: Pelatihan Dengan *Global Augmentation*

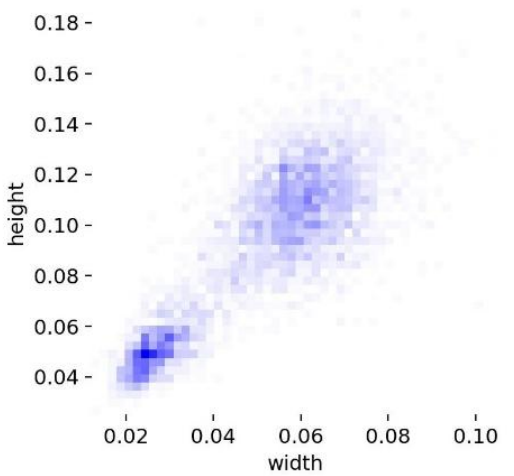
Dilanjutkan pada skenario II atau skenario kedua dengan melakuakn augmentasi data secara *global* atau melakuakan augmentasi data secara keseluruhan dengan metode augmentasi yang sama seperti sebelumnya. Strategi ini bertujuan untuk meningkatkan representasi spasial dari *ring-form Falciparum* dan juga menambahkan jumlah data training agar model tidak bias terhadap satu kelas dan juga membuat model mempelajari morfologi seluruh parasit baik *P.Vivax* atau *P.Falciparum*. Metode pelatihan ini menggunakan hyperparameter mutlak atau yang sama seperti skenario 1 dan juga 3. Proses augmentasi ini menghasilkan total jumlah label citra menjadi kurang lebih 1:3 dengan *P. Vivax* memiliki total jumlah 15699 label citra dan *P.Falci* memiliki jumlah total 2852 dengan total jumlah gambar keseluruhan menjadi 6900 dapat dilihat juga pada gambar 4.10.



Gambar 4.8 Hasil Pembagian Labels Dalam Training Skenario 2

Gambar 4.8 menampilkan jumlah data untuk masing-masing kelas setelah proses augmentasi (perbanyakan gambar) dilakukan pada seluruh dataset. Pendekatan ini membuat jumlah data menjadi sangat tidak seimbang. Kelas *P. vivax* melonjak drastis menjadi 15.699 kotak

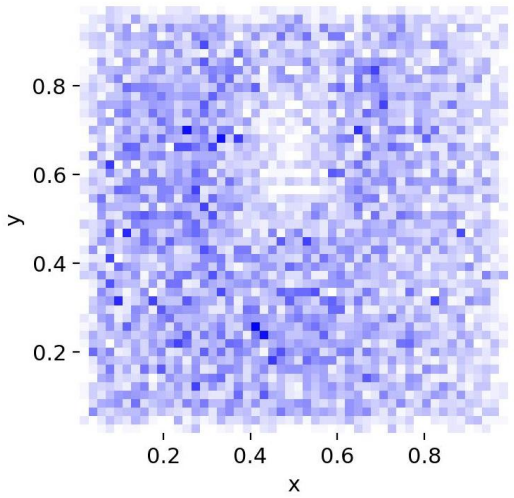
target, sedangkan *P. falciparum* hanya berjumlah 2.852 kotak target dengan total gambar mencapai gambar. Akibatnya, model kecerdasan buatan ini melihat terlalu banyak contoh gambar *P. vivax*, sehingga berisiko membuat model menjadi bias atau lebih memihak pada kelas mayoritas tersebut. Dampak buruk dari ketidakseimbangan ini dapat dilihat langsung pada perubahan ukuran parasit di Gambar 4.11.



Gambar 4.9 Hasil Scatter Plot Width vs Height Skenario 2

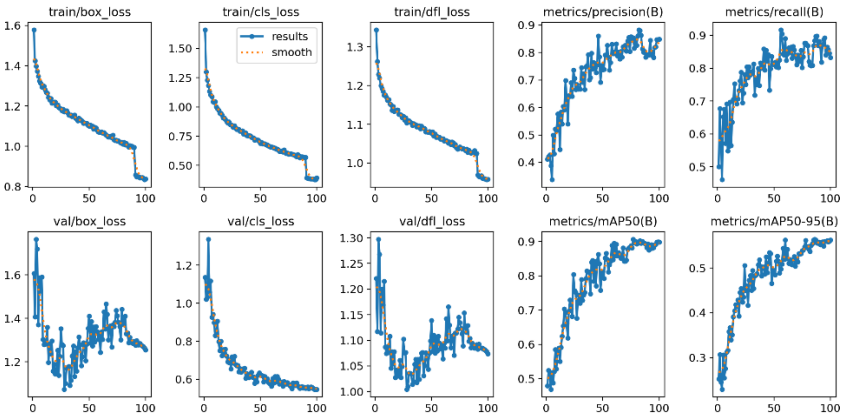
Gambar 4.9 menampilkan grafik perbandingan ukuran kotak pembatas parasit (*width vs height scatter plot*). Pada skenario pertama, titik-titik persebaran objek hanya terkumpul di pojok kiri bawah karena ukuran asli parasit memang sangat kecil. Namun pada Skenario II ini, muncul kelompok titik baru yang menyebar luas ke arah tengah grafik. Perubahan ini terjadi karena model mengaktifkan parameter augmentasi scale: 0.4046 (efek *zoom*) dan mosaic 1 (penggabungan beberapa gambar). Proses ini memutarbalikkan ukuran asli parasit menjadi tampak tidak wajar, baik menjadRi terlalu kecil maupun membesar[116]. Perubahan ukuran sintetik ini berpotensi membuat

model kebingungan, yang mana polanya juga memengaruhi letak posisi parasit pada Gambar 4.12



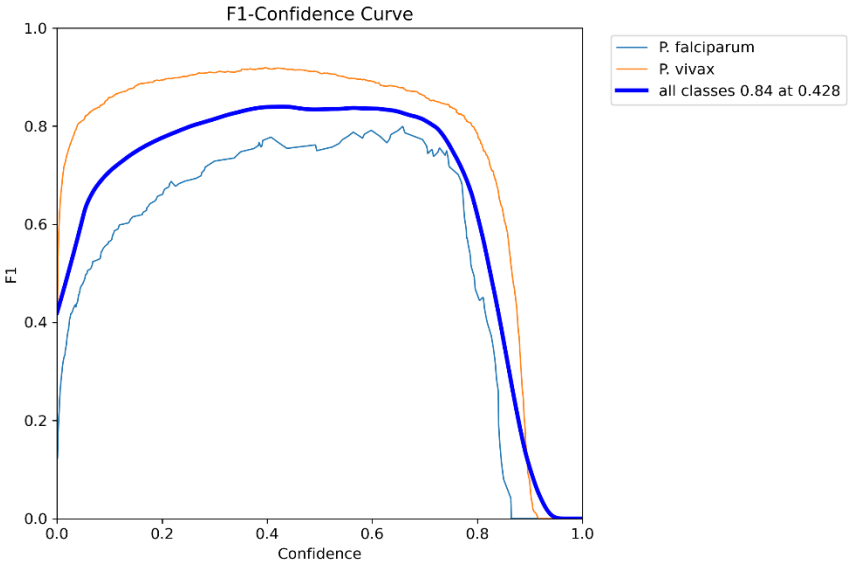
Gambar 4.10 Hasil Scatter Plot xy Skenario 2

Berdasarkan gambar 4.10 grafik persebaran posisi parasit di dalam citra (*x vs y scatter plot*). Titik-titik biru pada grafik ini terlihat jauh lebih pekat dan padat dibandingkan skenario sebelumnya. Kepadatan yang tidak beraturan ini dipicu oleh aktifnya parameter *translate* 0.0847 dan *mosaic* 1 yang mengacak posisi objek hingga saling bertumpuk di seluruh sudut gambar. Kondisi ruang yang terlalu padat ini memaksa model untuk mempelajari posisi objek buatan yang sebenarnya tidak akan pernah ditemui pada sampel darah asli di bawah mikroskop. Dampak buruk dari rekayasa data yang berlebihan ini langsung memengaruhi stabilitas proses belajar model pada Gambar 4.13.



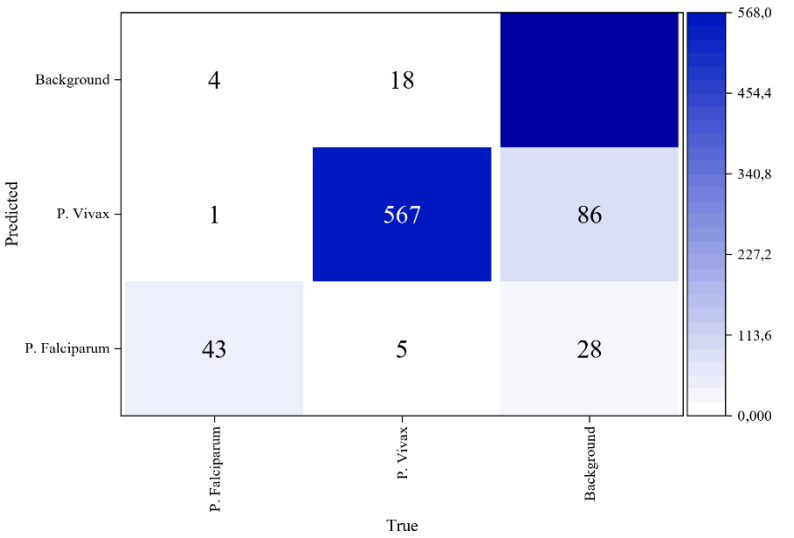
Gambar 4.11 Hasil Proses Training Model Skenario 2

Gambar 4.11 memberikan grafik hasil pelatihan dan validasi model selama 100 *epoch*. Akibat ukuran dan posisi data yang tidak wajar, model menunjukkan gejala *overfitting* yang parah. Hal ini terlihat jelas pada grafik *val/box_loss dan val/dfl_loss* (baris bawah), di mana garis kurva mengalami osilasi (naik-turun) secara tajam dan justru menaik setelah *epoch* ke-30. Kenaikan yang fluktuatif ini membuktikan bahwa penambahan gambar augmentasi secara berlebihan membuat model kehilangan arah. Model berhasil menghafal data latih, namun kehilangan ketepatan dalam menebak letak kotak parasit saat diuji menggunakan data baru[74]. Kegagalan ini kemudian menurunkan kualitas keseimbangan performa model pada Gambar 4.14.



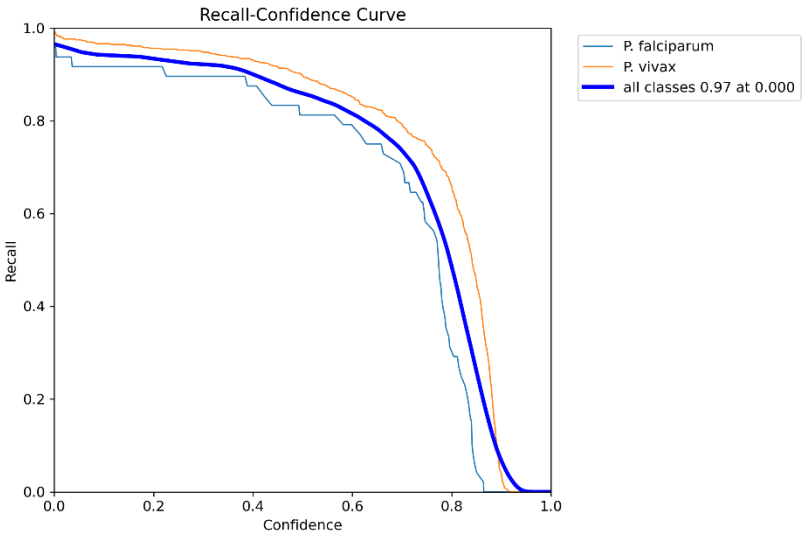
Gambar 4.12 Hasil Kurva Confidence F1 Curve Skenario 2

Berdasarkan gambar 4.12 kurva *F1-Confidence* yang berfungsi untuk menilai keseimbangan antara ketepatan (*Precision*) dan keberhasilan (*Recall*) model. Garis biru tebal menunjukkan nilai rata-rata keseluruhan sebesar 0,84 pada batas keyakinan 0,428. Walaupun angka rata-ratanya tinggi, terdapat jarak yang sangat jauh antara kurva oranye (*P. vivax*) dan kurva biru tipis (*P. falciparum*). Jarak kurva yang lebar ini menunjukkan bahwa tingginya nilai rata-rata model hanya berasal dari keberhasilan deteksi pada kelas *P. vivax*. Model menjadi bias terhadap data mayoritas sehingga kurang maksimal dalam mengenali kelas minoritas. Detail kesalahan tebakan akibat bias ini dapat dilihat lebih jelas pada Matriks Kebingungan di Gambar 4.15.



Gambar 4.13 Hasil Confusion Matriks Skenario 2

Berdasarkan hasil dari gambar 4.13 merinci jumlah prediksi model yang benar dan salah. Model berhasil menebak 567 gambar *P. vivax* dan 43 gambar *P. falciparum* dengan tepat. Namun, kelemahan utama dari skenario ini adalah tingginya angka deteksi positif palsu (*false positive*) dari area latar belakang (*background*). Model salah mengklasifikasikan 86 artefak kotoran sebagai *P. vivax* dan 28 artefak sebagai *P. falciparum*. Tingginya kesalahan ini didukung oleh fitur augmentasi *erasing* 0.4 dan *mixup* 0.2869 yang menumpuk kotoran buatan, sehingga model menjadi terlalu sensitif dan sering mengira sisa pewarna darah sebagai parasit[117]. Sensitivitas yang keliru ini diukur kembali pada Gambar 4.16.

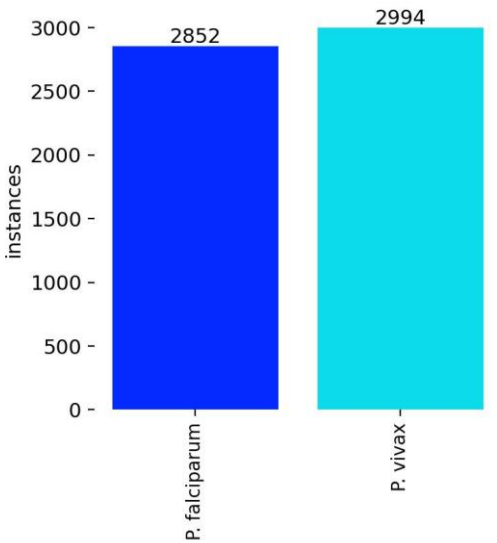


Gambar 4.14 Hasil Kurva Recall Confidence Skenario 2

Hasil gambar 4.14 menyajikan Kurva *Recall Confidence* yang berguna untuk mengukur kemampuan model dalam menangkap seluruh target parasit. Garis biru tebal memang menunjukkan tingkat penangkapan maksimal di angka 0,97 pada tingkat keyakinan terendah. Akan tetapi, kurva kelas *P. falciparum* (biru tipis) menurun jauh lebih curam dan cepat dibandingkan kelas *P. vivax* (oranye) seiring naiknya batas keyakinan model. Berdasarkan hasil evaluasi ini, dapat disimpulkan bahwa penerapan augmentasi secara menyeluruh dan agresif tidak efisien[116], [117]. Pendekatan ini merusak struktur alami objek mikroskopis, sehingga menghasilkan *overfitting* spasial dan menciptakan bias kelas yang berbahaya untuk diagnosis medis, sehingga membuktikan bahwa pengaturan pada Skenario I jauh lebih optimal.

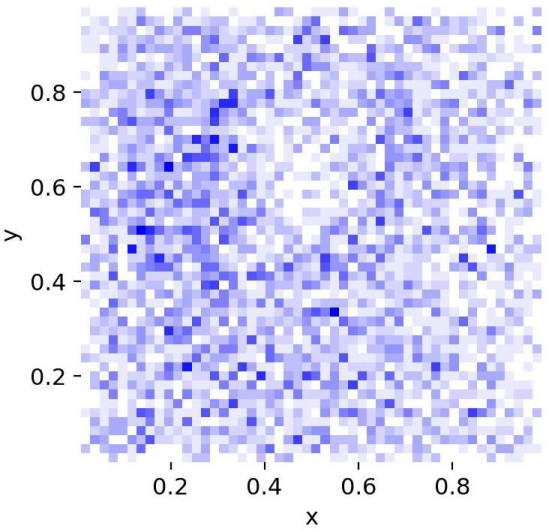
4.3.3 Skenario III: Pelatihan Dengan *Undersampling*

Evaluasi dilanjutkan pada skenario ketiga dengan menerapkan pendekatan keseimbangan data mutlak atau rasio 1:1 melalui metode *undersampling*. Strategi ini bertujuan untuk menguji performa model ketika dilatih menggunakan jumlah data target yang sama rata, dengan harapan dapat menghilangkan bias terhadap kelas mayoritas [118]. Sama seperti pengujian sebelumnya, metode pelatihan pada skenario ini tetap menggunakan nilai *hyperparameter* mutlak yang sama dengan Skenario I dan II untuk menjaga konsistensi eksperimen. Proses *undersampling* ini memangkas jumlah label citra kelas *P. vivax* secara acak agar sama persis dengan jumlah kelas *P. falciparum*. Hasilnya, kedua kelas memiliki perbandingan rasio kurang lebih 1:1 dengan *P. Falciparum* memiliki label sebanyak 2.852 label citra dan *P. Vivax* memiliki 2.994 label citra dengan total citra 1946 yang di dapatkan setelah augmentasi menjadi . Perubahan sebaran jumlah data untuk Skenario III ini dapat dilihat pada Gambar 4.15.



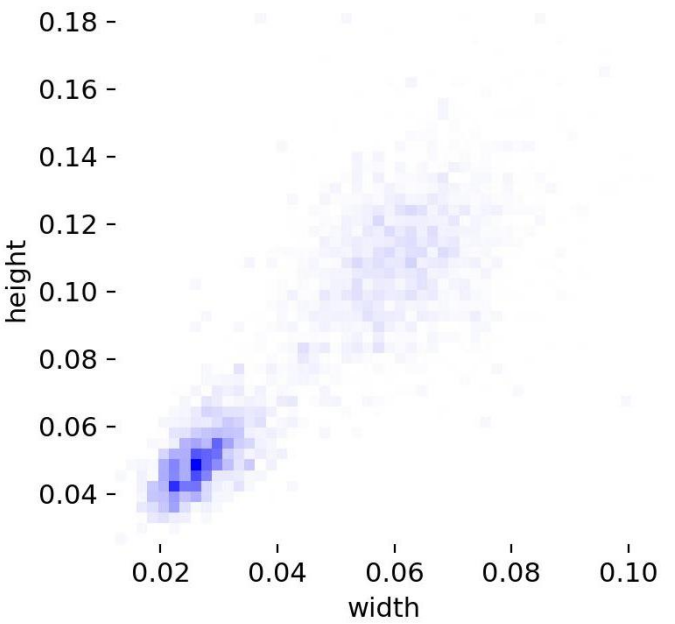
Gambar 4.15 Hasil Pembagian Data 1:1 Skenario 3

Gambar 4.15 menampilkan visualisasi distribusi data latih (*training set*) yang digunakan pada Skenario III setelah proses penyeimbangan kelas (*hybrid class balancing*) berhasil dilakukan. Berdasarkan grafik batang pada sudut kiri atas, terlihat bahwa ketimpangan jumlah target yang terjadi pada dataset mentah telah berhasil diatasi hingga mencapai rasio kurang lebih 1:1. Kelas *P. falciparum* memiliki total 2.852 kotak target (*bounding box*) sebagai hasil pemertahanan data augmentasi dari eksperimen sebelumnya. Di sisi lain, populasi kelas *P. vivax* yang semula dominan telah dipangkas (*undersampling*) secara acak hingga menyisakan 2.994 kotak target dengan total gambar dalam *train* 3276 gambar dalam folder *train*, 459 total gambar dalam folder *test*, dan total 460 gambar dalam folder *val*. Selisih nilai yang sangat tipis ini secara metodologis dapat dianggap sebagai rasio 1:1. Namun, konsekuensi komputasional dari pemangkasan ini adalah terbuangnya ribuan sampel *P. vivax* murni, yang secara teoritis berisiko mengeliminasi kekayaan variasi morfologi alami parasit di dalam memori pelatihan jaringan



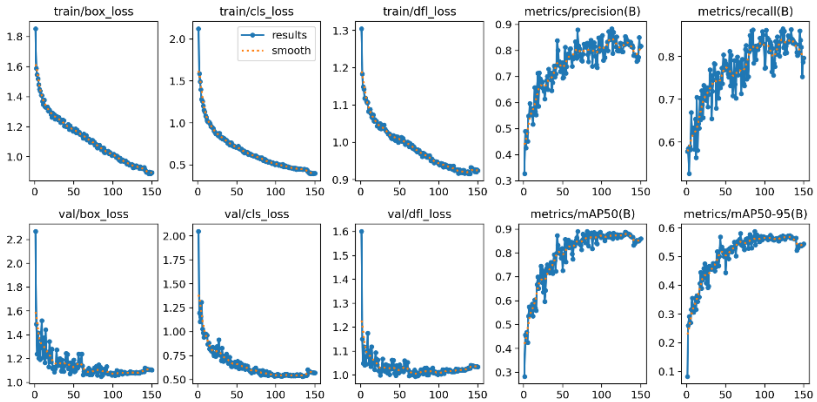
Gambar 4.16 Hasil Grafik Distribusi

Selain pembuktian keseimbangan jumlah kelas, Gambar 4.16 juga memvisualisasikan persebaran letak dan ukuran parasit di dalam citra. Pada grafik distribusi koordinat spasial (*x vs y scatterplot*) Gambar 4.18, titik-titik biru tersebar secara acak menutupi area sumbu X dan Y. Meskipun secara kasar sebaran ini tampak merata, densitas titik koordinat pada grafik ini menurun secara drastis jika dibandingkan dengan titik spasial pada Skenario I (Rasio 1:2). Penurunan kepadatan spasial ini menjadi indikator awal bahwa model berpotensi mengalami defisit referensi mengenai titik lokasi alami parasit[119]. Kehilangan referensi spasial yang esensial ini dapat memicu kebingungan jaringan arsitektur YOLOv8m dalam membedakan objek parasit dengan area kotoran di latar belakang (*background*) yang kosong.



Gambar 4.17 Hasil Grafik Height vs Width

Selanjutnya, grafik persebaran dimensi objek pada Gambar 4.17 menunjukkan pemusatan klaster biru yang tebal pada area nilai ukuran (*width* dan *height*) yang sangat kecil. Kondisi ini dapat diartikan bahwa secara umum karakteristik ukuran bintik mikroskopis parasit tetap konsisten di dalam dataset Skenario III. Akan tetapi, akibat hilangnya ribuan data *P. vivax*, luas sebaran klaster dimensi ini menjadi lebih sempit (*sparse*). Penyempitan variasi ukuran kotak target ini membatasi kemampuan lapisan konvolusi dalam mengenali fase ameboid parasit yang wujudnya sangat dinamis, di mana dampak fatal dari pembatasan fitur ini akan terkonfirmasi secara langsung pada grafik evaluasi pelatihan model.



Gambar 4.18 Hasil Training Model Skenario 3

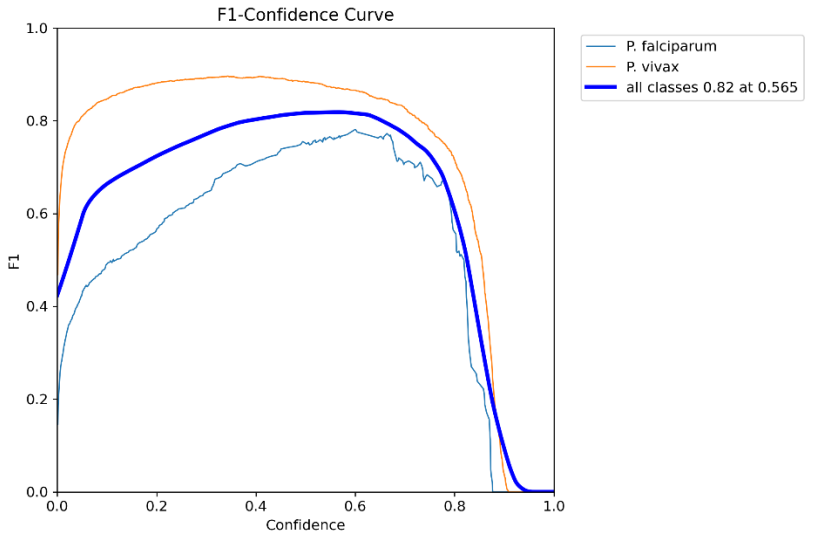
Gambar 4.18 memberikan rekam jejak performa pelatihan dan validasi arsitektur YOLOv8m pada Skenario III yang menggunakan keseimbangan data rasio 1:1 selama 150 *epoch*. Secara keseluruhan, grafik ini memperlihatkan fenomena pembelajaran mesin yang berhasil melakukan konvergensi, namun mengalami stagnasi akibat hilangnya kekayaan variasi data. Pada tiga metrik kerugian pelatihan atau *training loss* (*train/box_loss*, *train/cls_loss*, dan *train/dfl_loss*), kurva menunjukkan penurunan yang sangat mulus dan konsisten mendekati angka nol. Hal ini membuktikan bahwa arsitektur dasar model berfungsi dengan baik dan mampu mengenali serta menghafal pola data latih yang diberikan.

Namun, indikasi permasalahan generalisasi data mulai terlihat jelas pada kurva kerugian validasi (*validation loss*). Pada grafik *val/box_loss* dan *val/dfl_loss* (baris bawah), kurva mengalami penurunan di awal pelatihan tetapi kemudian tertahan atau mendatar (*plateau*) sejak *epoch* ke-50 hingga akhir pelatihan di *epoch* 150. Garis validasi tersebut bahkan menunjukkan sedikit fluktuasi (bergelombang) di kisaran angka 1.1 hingga 1.2 dan tidak mampu

turun lebih jauh. Kondisi ini merupakan gejala awal dari *overfitting*, di mana model menjadi sangat pintar menghafal data latih, tetapi kesulitan untuk menerapkan pengetahuannya pada data baru yang belum pernah dilihat sebelumnya. Stagnasi ini adalah konsekuensi langsung dari penerapan metode *undersampling*, di mana pembuangan ribuan data *P. vivax* secara paksa membuat model kehilangan banyak memori tentang variasi morfologi alami parasit.

Dampak dari berkurangnya variasi data tersebut juga terekam pada metrik evaluasi performa utama model. Grafik tingkat akurasi rata-rata atau mAP50 melesat di awal pelatihan, namun menabrak "batas atas" dan stagnan di kisaran angka 0,86 hingga 0,88 (86% - 88%). Angka ini tertahan secara konstan hingga *epoch* terakhir tanpa ada perbaikan yang signifikan. Begitu pula pada grafik ketepatan tebakan (*precision*) dan kepekaan penemuan target (*recall*) yang berfluktuasi cukup tajam di rentang 0,80 hingga 0,85[73].

Hasil evaluasi pada Skenario III ini memberikan kesimpulan yang sangat penting bagi pengembangan sistem deteksi. Pemaksaan keseimbangan kuantitas kelas agar menjadi rasio 1:1 absolut melalui metode *undersampling* terbukti merugikan kapabilitas arsitektur dalam mendeteksi objek. Meskipun data menjadi seimbang secara matematis, pembuangan data medis minor menyebabkan sistem kehilangan informasi fitur visual yang penting, sehingga akurasi tertahan dan tidak mampu menyamakan tingkat kecerdasan model pada skenario rasio 1:2.



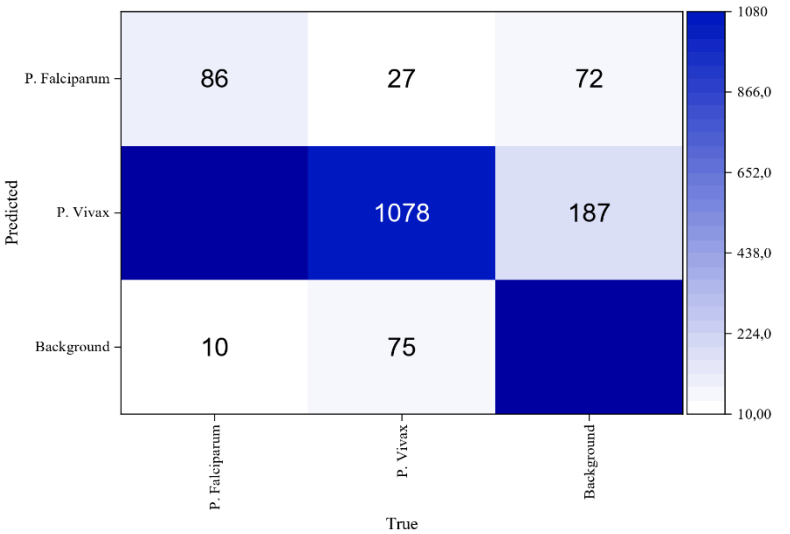
Gambar 4.19 Grafik F1-Curve Skenario 3

Gambar 4.19 memberikan Kurva F1-Confidence yang berfungsi untuk mengukur keseimbangan harmonis antara tingkat ketepatan prediksi (*precision*) dan kepekaan penemuan target (*recall*) dari arsitektur model pada Skenario III. Nilai F1-Score merupakan metrik yang sangat krusial dalam sistem skrining medis karena merepresentasikan keandalan model dalam meminimalisir kasus positif palsu (salah deteksi) maupun negatif palsu (parasit yang terlewat). Berdasarkan grafik tersebut, garis biru tebal yang mewakili rata-rata performa keseluruhan kelas mencapai nilai puncak F1-Score sebesar 0,82 pada ambang batas keyakinan (*confidence threshold*) 0,565.

Meskipun model pada skenario ini dilatih menggunakan dataset dengan rasio kelas yang seimbang mutlak (1:1), grafik memperlihatkan ketimpangan performa yang masih terjadi secara signifikan di antara kedua spesies. Garis oranye yang mewakili kelas *P. vivax* tetap mendominasi unjuk kerja dengan nilai F1-Score yang sangat tinggi

(mendekati 0,90) dan stabil pada rentang ambang batas keyakinan yang lebar. Sebaliknya, garis biru tipis yang mewakili kelas *P. falciparum* masih tertinggal cukup jauh, di mana nilai puncaknya hanya mampu menyentuh kisaran angka 0,78. Selain itu, kurva *P. falciparum* juga terlihat lebih berosilasi atau tidak stabil dibandingkan kelas *P. vivax*.

Hasil ini memberikan pembuktian yang sangat penting bagi pengembangan model. Kesenjangan kurva yang lebar antara kedua kelas membuktikan bahwa sekadar menyamakan kuantitas data target (jumlah *bounding box* rasio 1:1) tidak secara otomatis menyetarakan tingkat kesulitan model dalam mengenali fitur visual objek. Kelas *P. vivax* tetap lebih mudah dideteksi karena sisa data latih yang digunakan bersifat murni (tanpa augmentasi) sehingga memiliki struktur morfologi alami yang kuat. Di sisi lain, kelas *P. falciparum* tetap lebih sulit diklasifikasikan meskipun jumlah datanya sudah diperbanyak melalui augmentasi. Selanjutnya, pencapaian batas maksimal F1-Score di angka 0,82 ini memberikan konfirmasi bahwa metode pemotongan data ekstrem (*undersampling*) yang diterapkan pada Skenario III justru menurunkan potensi model untuk deteksi. Kehilangan ribuan data variasi alami *P. vivax* menyebabkan sistem gagal mencapai harmoni prediksi yang lebih optimal seperti yang ditunjukkan pada eksperimen rasio 1:2.



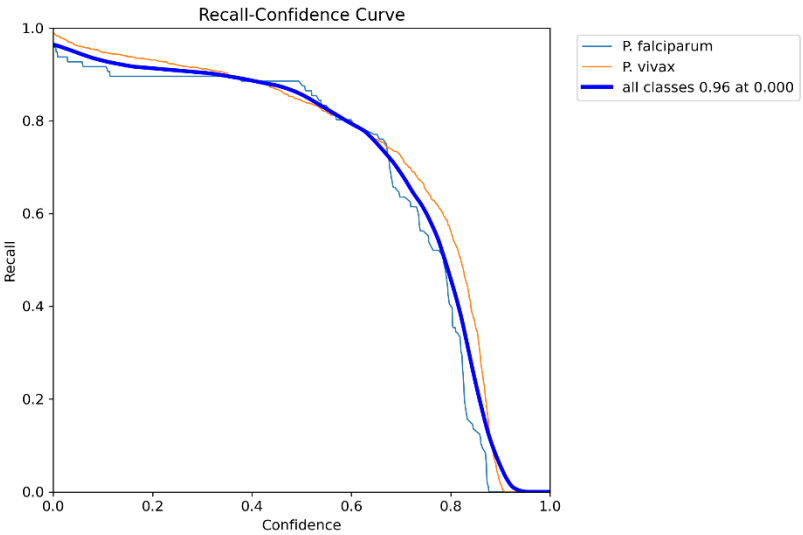
Gambar 4.20 Confusion Matrix Skenario 3

Gambar 4.20 menampilkan Matriks Kebingungan (*Confusion Matrix*) yang merekam rincian ketepatan prediksi model pada dataset validasi untuk Skenario III. Pada skenario keseimbangan rasio 1:1 ini, model menunjukkan kemampuan yang cukup baik dalam mengenali kelas dominan pada data uji, terbukti dari keberhasilannya memprediksi 1.078 target *P. vivax* secara tepat (*True Positive*). Selain itu, model juga berhasil mengidentifikasi 86 target *P. falciparum* dengan benar. Meskipun model mampu mendeteksi keberadaan target secara umum, matriks ini menangkap kelemahan akibat penerapan metode pemangkasan data latih (*undersampling*).

Kelemahan utama dari skenario ini terlihat pada tingginya angka positif palsu (*False Positive*) yang dihasilkan oleh sistem. Model melakukan kesalahan berat dengan memprediksi area latar belakang (*background*) yang kosong seperti sisa kotoran darah atau sel darah merah yang sehat sebagai parasit. Berdasarkan Gambar 4.21 sebanyak

187 area latar belakang salah dikenali sebagai *P. vivax*, dan 72 area latar belakang lainnya dikira sebagai *P. falciparum*. Kenaikan kesalahan tebakan terhadap latar belakang ini merupakan efek dari proses *undersampling*. Saat ribuan citra *P. vivax* dibuang secara paksa untuk menyeimbangkan rasio target, model yang kehilangan ribuan contoh informasi visual mengenai apa yang "bukan parasit" (*negative samples*). Akibat kekurangan referensi visual terhadap variasi kotoran latar belakang, arsitektur YOLOv8 menjadi lebih sensitif dan rentan salah melakukan deteksi[120].

Selain kesalahan terhadap latar belakang, matriks ini juga mencatat terjadinya kebingungan antar-kelas dan negatif palsu (*False Negative*). Terdapat 27 target *P. vivax* yang bentuknya menyerupai *ring-form* sehingga keliru diprediksi sebagai *P. falciparum*. Di sisi lain, model juga gagal mengenali sama sekali 75 target *P. vivax* dan 10 target *P. falciparum*. Kegagalan deteksi serta tingginya angka salah tebak (*False Positive*) pada Skenario III ini memberikan kesimpulan yang sangat kuat terkhususinya pada hasil akhirnya. Pemaksaan rasio keseimbangan 1:1 dengan memotong porsi besar dari data medis asli tidak direkomendasikan, karena selain mereduksi memori model terhadap keragaman morfologi parasit, hal tersebut juga menghancurkan ketahanan model terhadap gangguan visual (*noise*) di latar belakang kaca preparat mikroskopis[12], [120], [121].



Gambar 4.21 Hasil Curva Recall Skenario 3

Gambar 4.21 memberikan Kurva *Recall Confidence* yang mengevaluasi tingkat sensitivitas arsitektur YOLOv8m pada Skenario III terhadap perubahan batas atas keyakinan (*confidence threshold*). Metrik *Recall* (sensitivitas) merupakan indikator yang sangat penting dalam sistem diagnostik medis, karena metrik ini mengukur seberapa tangguh model dalam menemukan seluruh target parasit yang ada di kaca preparat tanpa melewatkannya (*False Negative*). Berdasarkan grafik tersebut, garis biru tebal yang merepresentasikan rata-rata keseluruhan kelas menunjukkan bahwa model mampu mencapai nilai *Recall* maksimal sebesar 0,96 pada ambang batas terendah (0). Hal ini berarti arsitektur CNN pada dasarnya memiliki kapasitas untuk menemukan 96% dari total populasi parasit secara keseluruhan.

Hasil paling besar dari grafik ini terletak pada jarak antara kurva kelas *P. falciparum* (garis biru tipis) dan *P. vivax* (garis oranye). Berbeda dengan Kurva F1-Score di mana kedua kelas memiliki

perbedaannya performa yang sangat lebar, pada Kurva Recall ini, kedua garis terlihat bergerak beriringan dengan jarak yang sangat rapat. Bahkan, pada rentang batas atas keyakinan kritis (0,4 hingga 0,6), garis *P. falciparum* mampu mengimbangi dan sesekali menyentuh garis *P. vivax*. Fenomena pergerakan kurva yang harmonis ini membuktikan bahwa penyeimbangan dataset secara matematis menjadi rasio 1:1 berhasil menyetarakan sensitivitas model[103]. Arsitektur jaringan tidak lagi menunjukkan bias preferensial terhadap kelas mayoritas, tatapi memberikan beban perhatian yang sama besarnya dalam melakukan pencarian terhadap kelas *P. falciparum* maupun *P. vivax*.

Meskipun model terbukti memiliki tingkat sensitivitas pencarian yang seimbang dan tinggi, hasil ini harus dievaluasi secara komprehensif bersama dengan matriks presisi sebelumnya. Tingginya angka *Recall* pada Skenario III ini digantikan dengan turunnya kemampuan model dalam menyaring objek bukan sasaran (*background/noise*). Karena model dilatih dengan jumlah data yang dipangkas secara drastis (*undersampling* pada *P. vivax*), model menjadi terlalu agresif dan reaktif dalam menebak objek demi mempertahankan nilai *Recall* yang tinggi untuk kedua kelas. Hasil ini yang memicu lonjakan angka positif palsu (*False Positive*) pada matriks kebingungan. Oleh karena itu, dapat disimpulkan bahwa memaksakan keseimbangan rasio 1:1 memang berhasil meratakan sensitivitas deteksi, namun mengorbankan ketajaman diskriminasi fitur visual yang justru lebih fundamental dalam deteksi mikroskopis malaria.

4.4 Evaluasi Performa Sistem Deteksi Model

Berikutnya melakukan penlaian evaluasi performa sistem deteksi model terhadap keandalan arsitektur YOLOv8m yang telah melalui proses *fine-tuning*, dilakukan analisis komparatif menyeluruh terhadap hasil pengujian dari ketiga skenario manipulasi dataset. Pengujian ini dievaluasi secara ketat pada data uji (*test set*) yang sepenuhnya terisolasi sebesar 10% dari total populasi citra. Isolasi ini diterapkan untuk menjamin objektivitas evaluasi dan menghindari fenomena kebocoran data (*data leakage*), sehingga metrik yang dihasilkan murni merepresentasikan kemampuan generalisasi sistem di dunia nyata. Rekap kuantitatif dari metrik performa final seluruh skenario dapat dilihat pada Tabel 4.7.

Tabel 4.7 Rekap Hasil Model Skenario

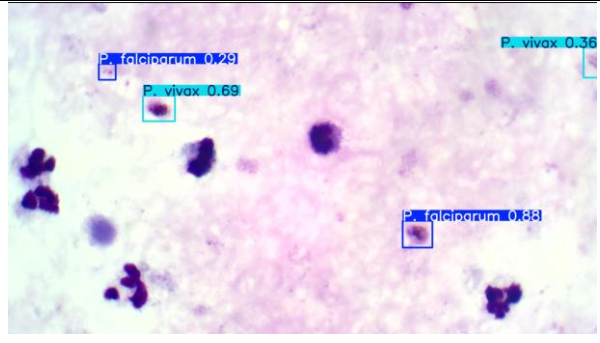
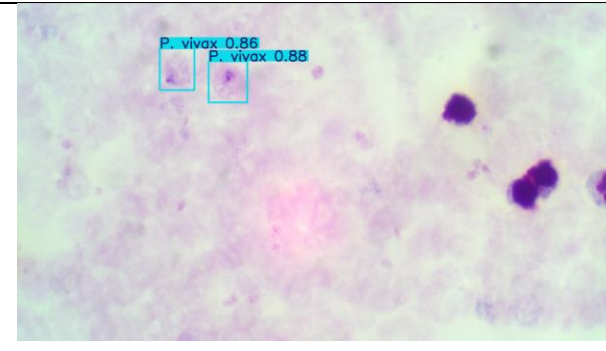
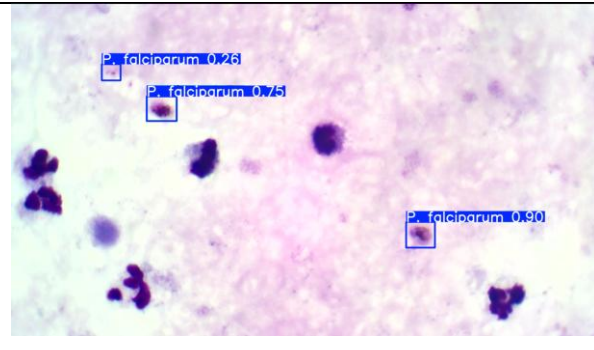
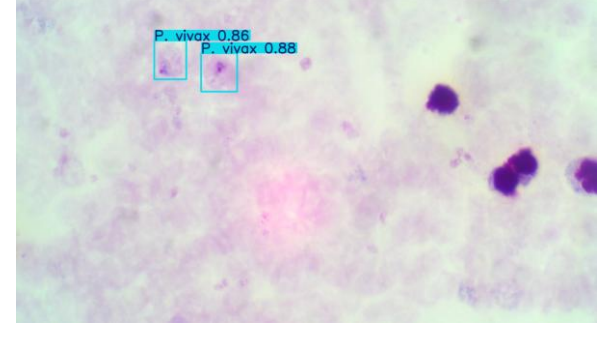
Skenario Eksperimen Data	***Precision***	***Recall***	***F1-Score***	***mAP@50***	***mAP@50-95***
Skenario I (Oversampling 1:2)	86%	83%	84%	91%	59%
Skenario II (Global Augmentasi)	84%	85%	84%	89.84%	56%
Skenario III (Undersampling 1:1)	81%	82%	82%	87%	55%

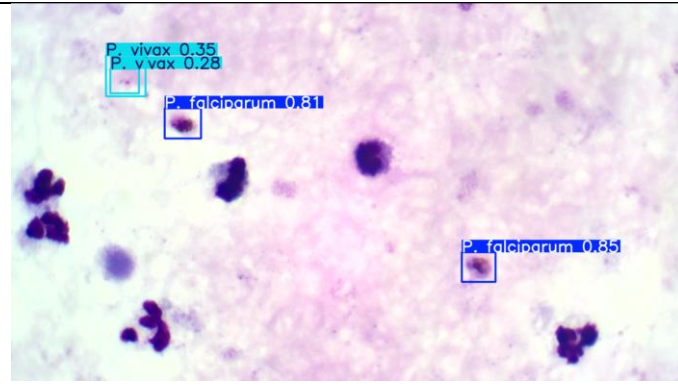
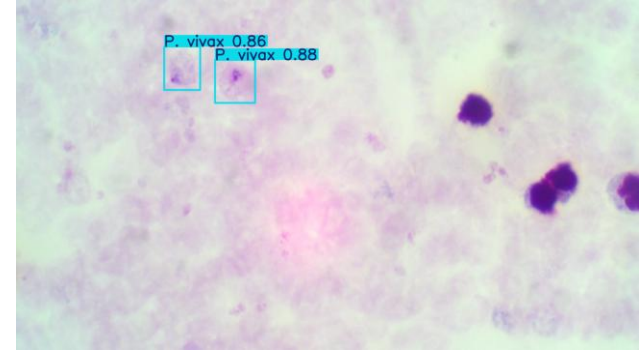
Kolom karakteristik hasil komputasional pada Tabel 4.6 memaparkan status konvergensi pembelajaran algoritma dari ketiga metode penanganan data. Skenario I mencatatkan karakteristik *Best Fitting*, sebuah kondisi komputasional paling ideal di mana arsitektur klasifikasi CNN berhasil mengoptimalkan pembobotan deteksi tanpa kehilangan kemampuan generalisasi. Pada kondisi ini, jaringan konvolusi mampu mengambil fitur morfologis parasit secara proporsional. Sebaliknya, Skenario II menghasilkan anomali *Overfitting* Spasial. Intervensi augmentasi global yang terlalu besar memenuhi ruang pelatihan dengan artefak sintetik, memaksa lapisan tersembunyi (*hidden layers*) untuk menghafal pola derau pewarnaan *Giemsa* sehingga sistem menjadi sangat sensitif saat menganalisis sediaan darah baru. Sementara itu, Skenario III justru mengalami Stagnasi Dini (*Plateau Curve*). Metode pemangkasan data (*undersampling*) yang diimplementasikan secara ekstrem mereduksi perbendaharaan fitur visual alami parasit secara drastis, sehingga laju pembelajaran model tertahan secara prematur sebelum mampu mencapai tingkat akurasi klasifikasi spasial yang komprehensif.

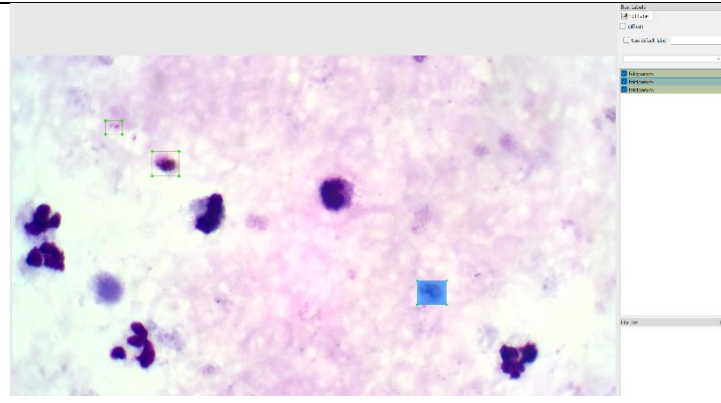
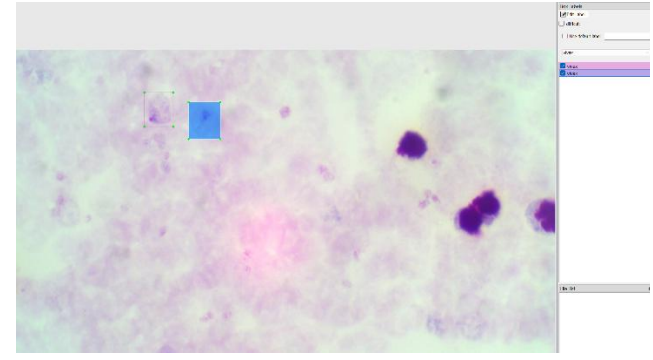
Untuk menarik kesimpulan teoritis dan praktis yang valid mengenai dampak rekayasa dataset terhadap kecerdasan arsitektur *deep learning*, dilakukan analisis komparatif menyeluruh lintas skenario pelatihan. Hambatan berupa ketidakseimbangan kelas (*class imbalance*) dan variasi morfologi mikro parasit diselesaikan melalui pengujian performa matriks Skenario I (*Oversampling* Terkontrol 1:2), Skenario II (*Global Augmentation*), dan Skenario III (*Undersampling* Ekstrem 1:1). Pembuktian kualitas komputasional ketiga skenario ini dievaluasi secara ketat pada data uji (*test set*) sebesar 10% dari total populasi citra yang telah diisolasi secara mutlak sejak awal pembagian

data. Isolasi ini merupakan parameter metodologis yang sangat krusial guna menghindari risiko kebocoran data (*data leakage*), sehingga metrik yang terekam murni merepresentasikan kemampuan generalisasi sistem saat dikonfrontasikan dengan citra klinis baru di dunia nyata. Rekapitulasi kuantitatif dari metrik performa final seluruh skenario eksperimen dirangkum secara terstruktur menggunakan *test set* yang tidak masuk ke dalam proses training sama sekali pada Tabel 4.7.

Tabel 4.8 Hasil Evaluasi Dengan Test Set Serta Validasi

Skenario	Hasil Falciparum	Hasil Vivax
Augmentasi Semua		
Augmentasi 1:2		

Skenario	Hasil Falciparum	Hasil Vivax
Augmentasi 1:1		

Skenario	Hasil Falciparum	Hasil Vivax
Validasi		

Proses evaluasi berikut dapat di buktikan hasilnya dengan menggunakan *LabelImg* dengan file atau gambar yang sama dan labeling yang dilakukan oleh tenaga kerja kesehatan yang ada di puskesmas Hanura secara langsung pada Tabel 4.8.

Kolom karakteristik hasil komputasional pada Tabel 4.7 memberikan hasil pembelajaran algoritma dari ketiga metode penanganan data. Skenario I (*Oversampling*) mencatatkan karakteristik *Best Fitting*, sebuah kondisi komputasional paling ideal di mana arsitektur klasifikasi CNN berhasil mengoptimalkan beban deteksi tanpa kehilangan kemampuan generalisasi. Pada kondisi ini, jaringan konvolusi mampu mengekstraksi fitur morfologis parasit secara proporsional. Sebaliknya, Skenario II (*Global Augmentation)* memanifestasikan anomali *Overfitting* Spasial dan Sensitivitas Derau. Intervensi augmentasi global yang terlalu masif membanjiri ruang pelatihan dengan artefak sintetik, memaksa lapisan tersembunyi (*hidden layers*) untuk menghafal pola derau pewarnaan *Giemsa* sehingga sistem menjadi sangat sensitif saat menganalisis sediaan darah baru. Sementara itu, Skenario III (*Undersampling*) justru mengalami Stagnasi Dini (*Plateau Curve*) [120]. Pemangkasan data (*undersampling*) yang berlebihan membuat model kehilangan banyak variasi bentuk dan karakteristik visual asli dari parasit, sehingga laju pembelajaran model tertahan secara prematur sebelum mampu mencapai tingkat akurasi klasifikasi spasial yang komprehensif [72], [120].

4.4.1 AnalisisAkurasi Spasial (mAP@50 Dan mAP@50-95)

Metrik mAP@50 dan mAP@50-95 merupakan instrumen pengukuran paling fundamental untuk mengevaluasi akurasi lokalisasi

geometri (*bounding box regression*) sekaligus ketepatan klasifikasi multi-skala pada arsitektur YOLOv8m. Berdasarkan hasil yang ada pada komparasi Tabel 4.7, Skenario I (Rasio 1:2) dan Skenario II sama-sama mencatatkan nilai rata-rata presisi tertinggi mAP@50 yang stabil di kisaran 90%, melebihi batas atas hipotesis awal penelitian. Maka oleh karean itu, determinasi kualitas model yang sesungguhnya teruji pada metrik mAP@50 dengan rentang ambang batas IoU ketat (0.50 hingga 0.95), di mana Skenario I unggul secara absolut dengan nilai 0,59, meninggalkan Skenario II (0,56) dan Skenario III (0,55).

Superioritas Skenario I pada rentang metrik yang lebih ketat ini membuktikan keberhasilan sinergi antara fungsi kerugian *Complete Intersection over Union* dan *Distribution Focal Loss* yang terkalibrasi secara sempurna oleh *optimizer* AdamW. Penggunaan laju pembelajaran awal *lr0* yang sangat kecil (0,000218) pada Skenario I memaksa lapisan konvolusi di dalam blok *Decoupled Head* untuk tidak mengabaikan fitur-fitur minor. Hasilnya, jaringan mampu melakukan estimasi batas kotak prediksi secara presisi tinggi, tepat membungkus tepi morfologi parasit tanpa banyak ruang kosong (*margin*).

Secara kontras, penerapan pemangkasan data murni (*undersampling*) yang ekstrem pada Skenario III menghasilkan penurunan yang drastis pada isi fitur spasial model. Hilangnya ribuan sampel *Plasmodium vivax* asli membuat sistem kekurangan referensi visual mengenai variasi bentuk parasit mengenai variasi bentuk *ameboid* parasit. Kurangnya informasi struktural ini memaksa proses *bounding box regression* menabrak batas atas kapasitas pembelajarannya, yang bermanifestasi sebagai stagnasi dini (*plateau*)

pada kurva validasi sejak *epoch* ke-50, serta tertahannya mAP@50 pada angka terendah yaitu 87%

4.4.2 Analisis Keseimbangan Diagnosis Klinis (*Precision, Recall,* dan *F1-Score*)

Dalam pengembangan sistem deteksi biomedis berbasis *Computer-Aided Diagnosis* (CAD), evaluasi metrik tidak sekadar diartikan sebagai deret angka komputasional, tetapi representasi langsung dari risiko klinis operasional di lapangan. Metrik *Recall* (sensitivitas) memiliki urgensi kasta tertinggi karena merepresentasikan kemampuan sistem meminimalisir angka negatif palsu (*False Negative*). Kegagalan melokalisasi parasit pada skrining darah akan berujung pada penundaan terapi *anti* malaria yang berpotensi fatal bagi keselamatan jiwa pasien. Dan juga, *Precision* yang tinggi juga diperlukan untuk memastikan model memiliki hasil spasial tinggi terhadap *noise*, sehingga analis tidak mengalami kelelahan operasional akibat gangguan alarm diagnosis palsu[122].

Ketidakseimbangan metrik ini terlihat secara langsung ketika bobot (*weights*) skenario model diuji secara independen menggunakan citra sediaan darah terbuka (*open source*). Skenario II mencatatkan nilai *Recall* semu tertinggi sebesar 85%. Namun, tingginya sensitivitas ini dihancurkan oleh hadirnya bias kelas mayoritas yang fatal. Ketika mengeksekusi inferensi pada citra uji klinis, model Skenario II terbukti gagal total dalam mengidentifikasi spesies *P. falciparum* sejati dan secara keliru mengklasifikasikannya (*crossclass misclassification*) sebagai *P. vivax* dengan tingkat kepercayaan mencapai 76%. Kesalahan klasifikasi spesies pada pengujian inferensi ini sangat berbahaya secara klinis dikarenakan *P. falciparum* memerlukan regimen terapi ACT

(*Artemisinin based Combination Therapy*) yang agresif, sementara *P. vivax* membutuhkan obat primakuin untuk membunuh parasit yang bersembunyi di dalam organ hati agar penyakit tidak kambuh kembali.

Sedangkan, apabila bobot Skenario III (1:1) dievaluasi pada dataset pengujian yang sama, pemotongan data melalui *undersampling* menyebabkan model kehilangan parameter pembanding tentang sampel negatif latar belakang. Akibatnya, saat dijalankan proses deteksi, arsitektur *Head* menjadi terlalu agresif dan reaktif, sehingga membanjiri area citra dengan puluhan kotak halusinasi positif palsu (*False Positive*) di atas area eritrosit sehat maupun sisa zat warna Giemsa. Kondisi ini sangat merugikan secara operasional karena sistem memicu alarm diagnosis palsu secara massal. Kemunculan kotak prediktif hantu yang berlebihan ini secara matematis menarik turun nilai *Precision* Skenario III ke angka terendah (81%), yang membuktikan bahwa model rasio 1:1 tidak aman untuk diimplementasikan pada diagnosis riil.

Skenario I (Rasio 1:2) tampil sebagai satu-satunya solusi algoritmik terbaik yang berhasil menaklukkan dilema diagnostik klinis ini. Dengan capaian *Precision* 86% dan *Recall* 83%, model mengukuhkan nilai *F1-Score* global tertinggi sebesar 84% pada ambang batas keyakinan optimal 0,433. Saat dihadapkan pada pengujian lintas-dataset (*crossdataset validation*), Skenario I membuktikan kapasitasnya sebagai arsitektur yang presisi dan memiliki *false positive detection* paling sedikit, sistem secara detail melokalisasi stadium cincin *P. falciparum* sub-piksel serta fase *ameboid P. vivax*, tanpa mudah terkecoh oleh runtuhan matriks sel darah yang lisis ataupun distraksi warna pekat dari inti sel darah putih (*leukosit*).

Berdasarkan pembuktian keandalan performa inferensi dan minimnya tingkat kesalahan ini, model Skenario I secara mutlak ditetapkan sebagai model terbaik. Hasil model dari Skenario I inilah yang kemudian dipilih untuk diintegrasikan dan dideploy secara fungsional ke dalam Antarmuka Pengguna Grafis (GUI) guna mendukung digitalisasi skrining malaria secara otomatis dan luring di Puskesmas Hanura[12], [90], [119], [122].

Untuk memposisikan capaian penelitian ini dalam konteks perkembangan riset deteksi parasit malaria berbasis *deep learning*, hasil model Skenario I (mAP@50 = 91%) dibandingkan dengan penelitian-penelitian relevan pada Tabel 2.7. Dibandingkan dengan Ju dan Cai yang menerapkan YOLOv8 pada domain deteksi fraktur tulang (mAP50 = 63,8%), penelitian ini menunjukkan performa yang jauh lebih superior, yang mengindikasikan bahwa karakteristik visual parasit malaria pada citra mikroskopis meski berukuran kecil memiliki pola morfologi yang lebih konsisten untuk dipelajari model dibandingkan variasi bentuk fraktur tulang yang sangat heterogen antar-pasien.

Sementara itu, dibandingkan dengan Mura dkk. yang mengembangkan arsitektur khusus YOLO-Tryppa untuk deteksi parasit *Trypanosoma* berukuran mikro (mAP50 = 71,3%), penelitian ini justru mencatatkan mAP@50 yang lebih tinggi (91%) meskipun tidak melakukan modifikasi arsitektur khusus, melainkan murni melalui strategi *fine-tuning* dan penyeimbangan kelas (*oversampling*). Hal ini mengindikasikan bahwa untuk kasus deteksi *P. falciparum* dan *P. vivax* pada penelitian ini, penanganan *class imbalance* memberikan kontribusi yang sepadan dengan modifikasi arsitektur yang lebih kompleks.

Perbandingan dengan Widayani dkk, yang melaporkan *precision* di atas 92% pada penerapan YOLOv8 untuk berbagai modalitas citra medis umum, menunjukkan bahwa nilai *precision* penelitian ini (86%) masih berada sedikit di bawah rentang tersebut. Kesenjangan ini konsisten dengan temuan pada analisis Skenario II, di mana model menunjukkan kerentanan terhadap kesalahan klasifikasi akibat kemiripan visual antara morfologi parasit stadium awal dengan artefak pewarnaan darah sebuah tantangan spesifik pada citra hematologi yang tidak selalu dijumpai pada modalitas citra medis lain seperti X-Ray atau CT-Scan.

4.5 Implementasi Perancangan Antarmuka Pengguna (GUI)

Deksripsikan bahwa GUI dibangun menggunakan *Python* dengan *library Tkinter* sebagai *framework*nya, *OpenCV* untuk akusisi kamera, *Pillow* (PIL) dengan tujuan untuk melakukan manipulasi citra dan *Ultralystics* untuk integrasi model YOLOv8m. Ukuran window utama di tetapkan pada resolusi 3024x 4032 piksel. Dapat dilihat pada Gambar 4.22.



Gambar 4.22 GUI Antarmuka Pengguna

Pada Gambar 4.22, GUI antarmuka pengguna memiliki berbagai fungsi dan fitur di dalam GUI tersebut untuk mempermudah proses diagnosis dari tenaga kesehatan. Dimulai dari pemilihan model, dimana tenaga kesehatan bisa memilih model terlebih dahulu lalu dilanjutkan dengan bagian berikutnya berupa *camera,* dimana pada bagian ini pengguna dapat memulai camera, *stop* camera, *switch* camera, *take image*, dan check camera. Memulai camera dan *stop* camera dibuat dengan tujuan untuk menghentikan proses diagnosis disaat perlu, terkhususnya apabila suhu perangkat sudah meningkat melewati batas tahannya. *Take image* dibuat untuk mengambil gambar dari gambar yang sudah ditunjukkan dari *camera* dan di simpan untuk di kirimkan kepada tenaga kesehatan lainnya. Terakhir, *check camera* dibuat untuk melakukan evaluasi terhadap *camera* apakah sudah terpasang dengan benar atau terdapat masalah pada *camera*nya itu sendiri.

Berikutnya, terdapat fitur *flip*, *zoom*, dan *export image*, masing-masing ini memiliki tujuannya sendiri, untuk *flip* dan *zoom* dibuat untuk memutarkan camera agar tenaga kesehatan dapat identifikasikan bentuk virusnya serta jenisnya dikarenakan bentuk virus yang tidak menetap, lalu untuk *export image*, dibuat dengan tujuan untuk mengubah hasil gambar yang di tangkap menjadi, *pdf, jpg, jpeg, png*, dst.

BAB V
KESIMPULAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang dilakukan dalam tugas akhir berjudul *"Fine-Tuning Model You Only Look Once V8M untuk Deteksi Parasit Malaria pada Citra Mikroskopis Sediaan Smear Darah"*, maka dapat diperoleh kesimpulan sebagai berikut:

1. Dataset citra mikroskopis sediaan darah tebal (*thick smear*) yang diperoleh dari Puskesmas Hanura berjumlah 2.300 citra dengan distribusi kelas yang sangat tidak seimbang, yaitu 217 citra *P. falciparum* (218 *bounding box*) dan 2.083 citra *P. vivax* (4.282 *bounding box*). Proses *cutting* dan *resizing* citra dari resolusi 3.024×4.032 piksel menjadi empat kuadran berukuran 640×640 piksel terbukti efektif dalam mengoptimalkan beban memori GPU tanpa mengorbankan detail morfologis parasit berskala mikro. Penerapan augmentasi spasial berupa operasi *flip* dan rotasi 90° pada kelas minoritas berhasil memperkaya variasi fitur visual parasit sehingga mencegah model menghafal posisi statis objek selama proses pelatihan. Pembagian dataset menggunakan metode *Hold-Out Validation* dengan rasio 80:10:10 (*training*:*validation*:*test*) menjamin bahwa data uji (*test set*) terisolasi sepenuhnya dari siklus pelatihan untuk mencegah *data leakage*, sehingga metrik evaluasi akhir benar-benar merepresentasikan kemampuan generalisasi sistem pada citra sediaan darah baru yang belum pernah dilihat sebelumnya.

2. Proses *fine-tuning* arsitektur YOLOv8m dilaksanakan dengan pendekatan *transfer learning* dari bobot pra-latih *yolov8m.pt*

(COCO) menggunakan optimasi *hyperparameter* otomatis berbasis algoritma *Optuna* sebanyak 153 *trial*. Konfigurasi *hyperparameter* terbaik ditemukan pada *Trial* 141 dengan penetapan *lr0* = 0,000218, *momentum* = 0,8652, dan *weight decay* = $8{,}35\times10^{-5}$ menggunakan *optimizer* AdamW. Eksplorasi tiga skenario distribusi dan augmentasi dataset memperlihatkan perbedaan karakteristik konvergensi yang signifikan: Skenario I (*Oversampling* Terkontrol 1:2) mencapai kondisi *Best Fitting* dengan konvergensi yang paling stabil; Skenario II (*Global Augmentation*) menyebabkan *overfitting* spasial akibat dominasi data sintetis yang distortif; dan Skenario III (*Undersampling* 1:1) mengalami stagnasi dini (*plateau*) yang membatasi kapasitas ekstraksi fitur model akibat hilangnya kekayaan variasi morfologi alami *P. vivax*.

3. Evaluasi performa sistem pada data uji yang terisolasi secara penuh membuktikan bahwa Skenario I (*Oversampling* 1:2) merupakan konfigurasi eksperimen terbaik dengan capaian mAP@50 sebesar 91%, mAP@50-95 sebesar 59%, *F1-Score* sebesar 84%, *Precision* sebesar 86%, dan *Recall* sebesar 83%, sehingga target hipotesis penelitian pada metrik mAP@50 (>90%), *F1-Score* berhasil terlampaui. Meskipun memang untuk mAP@50-95 , *Precision*, dan *Recall* tidak melampaui target, namun hasil yang sudah didapatkan berdasarkan evaluasi yang dilakukan sudah dapat dianggap sebagai model yang dapat digunakan secara langsung pada lapangan. Validasi *cross-dataset* lebih lanjut membuktikan bahwa hanya model Skenario I yang mampu membedakan spesies *P. falciparum* dan *P. vivax* secara benar tanpa misklasifikasi lintas kelas yang berbahaya; model Skenario II terbukti gagal dengan

mengklasifikasikan *P. falciparum* sebagai *P. vivax* pada tingkat kepercayaan 76%, sebuah kesalahan yang berpotensi fatal secara klinis mengingat kedua spesies memerlukan regimen terapi yang berbeda (*Artemisinin-based Combination Therapy* versus primakuin). Temuan ini menegaskan bahwa strategi penanganan ketidakseimbangan kelas bukan hanya berdampak pada angka metrik komputasional, tetapi juga menentukan keandalan klinis dan keamanan diagnostik sistem di lapangan.

4. Model Skenario I yang telah divalidasi diintegrasikan ke dalam Antarmuka Pengguna Grafis (GUI) berbasis *Python* dengan pustaka *OpenCV* dan *PyTorch* untuk mendukung operasi deteksi secara *real-time* melalui kamera yang terpasang pada mikroskop konvensional. GUI yang dikembangkan dilengkapi empat modul fitur utama, yaitu *Camera* (*start*, *stop*, *take image*, dan *check camera*), *Flip Control* (rotasi 90°/180°/270° dengan *slider* kustom hingga 360°), *Zoom Control* (pembesaran bertahap ±10% dengan *reset*), dan *Export Image* ke direktori pilihan pengguna. Sistem ini dapat dioperasikan pada komputer atau laptop standar di lingkungan Puskesmas tanpa memerlukan perangkat keras tambahan yang mahal, sehingga menjadi solusi yang terjangkau dalam mendukung digitalisasi skrining malaria di daerah endemis dengan keterbatasan sumber daya.

5.2 Saran

1. Penelitian lanjutan disarankan untuk memperluas dataset dengan melibatkan citra mikroskopis dari berbagai fasilitas pelayanan kesehatan, variasi kualitas preparat, serta kondisi akuisisi citra yang berbeda. Penggunaan dataset yang lebih beragam diharapkan

mampu meningkatkan kemampuan generalisasi model terhadap variasi pencahayaan, kualitas pewarnaan Giemsa, tingkat kepadatan parasit, dan karakteristik mikroskop yang berbeda, sehingga performa sistem menjadi lebih stabil ketika diterapkan pada kondisi nyata.

2. Penelitian lanjutan perlu melakukan evaluasi terhadap arsitektur deteksi objek lainnya, seperti YOLOv11, RT-DETR, EfficientDet, maupun Faster R-CNN, dengan menggunakan dataset dan parameter evaluasi yang sama. Perbandingan tersebut bertujuan untuk memperoleh gambaran yang lebih komprehensif mengenai performa masing-masing arsitektur dalam mendeteksi parasit malaria pada citra mikroskopis, sehingga dapat ditentukan model yang paling sesuai untuk implementasi di bidang diagnostik medis.
3. Penelitian selanjutnya disarankan untuk mengembangkan sistem agar mampu mendeteksi lebih banyak spesies Plasmodium selain Plasmodium falciparum dan Plasmodium vivax, seperti Plasmodium malariae, Plasmodium ovale, dan Plasmodium knowlesi. Pengembangan tersebut diharapkan dapat meningkatkan cakupan diagnostik sistem sehingga lebih sesuai dengan variasi kasus malaria yang ditemukan di berbagai wilayah endemis.
4. Penelitian lanjutan perlu mengoptimalkan implementasi sistem ke dalam perangkat dengan spesifikasi komputasi yang lebih rendah.
5. Penelitian selanjutnya disarankan untuk mengembangkan antarmuka pengguna (GUI) dengan menambahkan fitur pendukung, seperti penyimpanan riwayat pemeriksaan, pembuatan laporan otomatis, penghitungan jumlah parasit yang terdeteksi, serta visualisasi hasil deteksi secara lebih informatif. Pengembangan tersebut diharapkan dapat meningkatkan

kemudahan penggunaan sistem sekaligus mendukung proses dokumentasi pemeriksaan di fasilitas pelayanan kesehatan.

DAFTAR PUSTAKA

[1] H. Mayasari, "Eliminasi Malaria Di Berbagai Negara: Literature Review," *Journal of Nursing and Public Health*, vol. 11, no. 1, pp. 73–83, 2023.

[2] Kemenkes, "Buku Saku Pengobatan Malaria," 2023.

[3] I. Lusi and M. Usman, "Pemetaan Persebaran Penyakit Malaria di Kecamatan Punduh Pidada, Kabupaten Pesawaran, Provinsi LampungMapping the Distribution of Malaria in Punduh Pidada District, Pesawaran Regency, Lampung Province," *Spatial: Wahana Komunikasu dan Informasi Geografi*, no. 1, pp. 85–94, 2023.

[4] Nani Sri, "*Environmental Factors to Malaria Incidence : A Literature Review*," *Journal of Community Medicine and Public Health Research*, vol. 5, no. 2, pp. 197–207, 2024.

[5] R. Varo, N. Balanza, A. Mayor, and Q. Bassat, "*Diagnosis of clinical malaria in endemic settings*," *Expert Rev. Anti. Infect. Ther.*, vol. 19, no. 1, pp. 79–92, 2021.

[6] N. Kumar, "*Evaluation of malaria diagnostic methods as a key for successful control and elimination programs*," *Trop. Med. Infect. Dis.*, vol. 5, no. 2, 2020.

[7] Oyegoke, L. Maharaj, Akoniyon, I. Kwoji, A. T. Roux, T. S. Adewumi, R. Maharaj, B. T. Oyebola, M. A. Adeleke, and M. Okpeku, "*Malaria diagnostic methods with the elimination goal in view*," *Parasitol. Res.*, vol. 121, no. 7, pp. 1867–1885, 2022.

[8] J, Sam., "Should Deep-Sequenced Amplicons Become the New Gold Standard for Analyzing Malaria Drug Clinical Trials?," *Antimicrobial Chemotherapy*, vol. 65, pp. 3–18, 2021.

[9] A. Amir, F. W. Cheong, J. R. De Silva, and Y. L. Lau, "*Diagnostic tools in childhood malaria*," *Parasit. Vectors*, vol. 11, no. 1, pp. 1–12, 2018.

[10] A. Blaine., "Update on Malaria Diagnostics and Test Utilization," *J. Clin. Microbiol.*, vol. 55, no. 7, pp. 3–46, 2017.

[11] K. Tam, D. Eaton, A. Mayo, A. James, C. Tefertiller, K. C. Stenson, C. Curtin, D. Ota, F. Laurent, M. J. Berger, J. Dengler, and I. K. Fox, "*Health Care Utilization in Veterans With Tetraplegia in the First Year After Cervical Spinal Cord Injury: Identifying Opportunities for Dissemination of Treatment Information*," *Arch. Phys. Med. Rehabil.*, Aug. 2025.

[12] A. Widayani, A. M. Putra, A. R. Maghriebi, D. Z. C. Adi, and Moh. H. F. Ridho, "*Review of Application YOLOv8 in Medical Imaging*," *Indonesian Applied Physics Letters*, vol. 5, no. 1, pp. 23–33, 2024.

[13] L. Ezzeddini, J. Ktari, T. Frikha, N. Alsharabi, A. Alayba, A. J. Alzahrani, A. Jadi, A. Alkholidi, and H. Hamam, "*Analysis of the performance of Faster R-CNN and YOLOv8 in detecting fishing vessels and fishes in real time*," *PeerJ Comput. Sci.*, vol. 10, pp. 1–15, 2024.

[14] M. Peckham, "*What is a microscope? How the microscope has evolved over three hundred and fifty years*," *J. Phys. Conf. Ser.*, vol. 2877, no. 1, 2024.

[15] H. Lee and I. J. Rhyu, "*Antonie van Leeuwenhoek and the dawn of microscopic observation: a narrative review from Delft's lens to the modern microscope*," *Applied Microscopy*, vol. 56, no. 1. Springer, 01-Dec-2026.

[16] Prestel C, "*Malaria Diagnostic Practices in U.S. Laboratories*," *J. Clin. Microbiol.*, vol. 56, no. 8, 2017.

[17] Y. Wang, X. Zhang, J. Xu, X. Sun, X. Zhao, H. Li, Y. Liu, J. Tian, X. Hao, X. Kong, Z. Wang, J. Yang, and Y. Su, "*The Development of Microscopic Imaging*

Technology and its Application in Micro- and Nanotechnology," *Frontiers in Chemistry*, vol. 10. Frontiers Media SA, 05-Jul-2022.

[18] M. Weber and J. Huisken, "*Multidisciplinarity Is Critical to Unlock the Full Potential of Modern Light Microscopy*," *Front. Cell Dev. Biol.*, vol. 9, Oct. 2021.

[19] A. J. M. Wollman, R. Nudd, E. G. Hedlund, M. C. Leake, and M. C. Leake, "*IX. An account of Mr. Leeuwenhoek's microscopes*," *Philos. Trans. R. Soc. Lond.*, vol. 41, no. 458, pp. 503–519, 1740.

[20] S. Iyer, "*Watching the embryo: Evolution of the microscope for the study of embryogenesis*," *BioEssays*, 2021.

[21] L. E. Franken, K. Grünewald, E. J. Boekema, and M. C. A. Stuart, "*A Technical Introduction to Transmission Electron Microscopy fsor Soft-Matter: Imaging, Possibilities, Choices, and Technical Developments*," *Small*, vol. 16, no. 14. Wiley-VCH Verlag, 01-Apr-2020.

[22] W. H. Organization, *World malaria report 2024*. Geneva: Global Malaria Programme (GMP), 2024.

[23] Caitlin A, "*The history of the microscope reflects advances in science and medicine*," *Semin. Diagn. Pathol.*, vol. 42, no. 2, pp. 74–257, 2025.

[24] Mijithra Ganesan, "*Foldscope microscope, an inexpensive alternative tool to conventional microscopy Applications in research and education: A review*," *Microsc Res Tech*, vol. 85, no. 11, pp. 3484–3494, 2022.

[25] Suman, "*Microscope In Dentistry: A Review Article*," *Innovare Journal of Medical Sciences*, vol. 9, no. 2, pp. 15–21, 2021.

[26] T. ARAKI, "*The history of optical microscope," Mechanical Engineering Reviews*, vol. 4, no. 1, pp. 16-00242-16–00242, 2017.

[27] W. Wimmer, “Carl Zeiss, Ernst Abbe*, and Advances in the Light Microscope*,” *Micros. Today*, vol. 25, no. 4, pp. 50–57, 2017.

[28] Prestel C, “*Malaria Diagnostic Practices in U.S. Laboratories*,” *J. Clin. Microbiol.*, vol. 56, no. 8, 2017.

[29] N. J. White, “*Severe malaria*,” *Malar. J.*, pp. 1–17, 2022.

[30] A. Chakraborty, “*NU Understanding the biology of the Plasmodium*,” *Life Sci.*, 2016.

[31] B. Dinko and G. Pradel, “*Immune Evasion by Plasmodium falciparum Parasites : Converting a Host Protection Mechanism for the Parasite’s Benefit*,” no. June, pp. 82–95, 2016.

[32] M. P. Jessica Molina-Franky, M. Patarroyo, M. Kalkum, “*The Cellular and Molecular Interaction Between Erythrocytes and Plasmodium falciparum Merozoites*,” *Front. Cell. Infect. Microbiol.*, vol. 12, 2022.

[33] M. Poostchi, K. Silamut, R. J. Maude, S. Jaeger, and G. Thoma, “*Image analysis and machine learning for detecting malaria*,” *Translational Research*, vol. 194. Mosby Inc., pp. 36–55, 01-Apr-2018.

[34] M. Fikadu and E. Ashenafi, “*Malaria: An Overview*,” *Infection and Drug Resistance*, vol. 16. Dove Medical Press Ltd, pp. 3339–3347, 2023.

[35] Dr. N. Saxena, Dr. S. C. Meena, and Dr. S. S. Shekhawat, “*Malaria: A backyard enemy*,” *Pharma Innov.*, vol. 12, no. 3, pp. 489–496, Jan. 2023.

[36] J. R. Poespoprodjo, N. M. Douglas, D. Ansong, S. Kho, and N. M. Anstey, “*Malaria,*” *The Lancet*, vol. 402, no. 10419, pp. 2328–2345, Dec. 2023.

[37] J. M. Roth, D. A. Korevaar, M. M. G. Leeflang, and P. F. Mens, “*Molecular malaria diagnostics: A systematic review and meta-analysis*,” *Critical Reviews in Clinical*

Laboratory Sciences, vol. 53, no. 2. Taylor and Francis Ltd, pp. 87–105, 03-Mar-2016.

[38] M. Rana and M. Bhushan, "*Machine learning and deep learning approach for medical image analysis: diagnosis to detection*," *Multimed. Tools Appl.*, vol. 82, no. 17, pp. 26731–26769, 2023.

[39] Ms. Aayushi, "*A Systematic Review on Data Scarcity Problem in Deep Learning: Solution and Applications*," *Association for Computing Machinery*, vol. 54, no. 10, pp. 300–360, 2022.

[40] D. Muchlinski, "*Machine learning and deep learning*," *Elgar Encyclopedia of Technology and Politics*, pp. 114–118, 2022.

[41] C. Janiesch, P. Zschech, and K. Heinrich, "*Machine learning and deep learning*," no. 31, pp. 685–695, 2021.

[42] Dr. Sheshang Degadwala and Dhairya Vyas, "*Systematic Analysis of Deep Learning Models vs. Machine Learning*," *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, vol. 10, no. 4, pp. 60–70, 2024.

[43] G. B. Goh, N. O. Hodas, and A. Vishnu, "*Deep Learning For Computational Chemistry*," *J. Comput. Chem.*, vol. 38, no. 16, pp. 1291–1307, 2017.

[44] O. Y. Al-jarrah, P. D. Yoo, S. Muhaidat, G. K. Karagiannidis, and K. Taha, "*Efficient Machine Learning for Big Data : A Review*," pp. 1–8.

[45] N. K. C. and K. Singh, "*A Review on Conventional Machine Learning vs Deep Learning*," *2018 International Conference on Computing, Power and Communication Technologies (GUCON), Greater Noida, India,* pp. 347–352, 2018.

[46] S. S. Pramila P. Shinde, "*A Review of Machine Learning and Deep Learning Applications*," *2018 Fourth*

International Conference on Computing Communication Control and Automation (ICCUBEA), 2018.

[47] S. Razavi, "*Deep learning, explained: Fundamentals, explainability, and bridgeability to process-based modelling*," *Environmental Modelling & Software*, vol. 144, 2021.

[48] A. Mosso Vázquez, D. Juárez-Romero, J. A. Hernández-Pérez, D. Echeverría Sosa, J. E. Loría Yah, R. J. González Horta, G. I. de A. Pech Carveo, and C. A. Decena Chan, "*Una Revisión de los Fundamentos de Aprendizaje Profundo El Modelo de Red Neuronal XOR*," *Programación Matemática y Software*, vol. 15, no. 1, 2023.

[49] M. M. Taye, "*Theoretical Understanding of Convolutional Neural Network: Concepts, Architectures, Applications, Future Directions*," *Computation*, vol. 11, no. 3. MDPI, 01-Mar-2023.

[50] Purwono, A. Ma'arif, W. Rahmaniar, H. I. K. Fathurrahman, A. Z. K. Frisky, and Q. M. U. Haq, "*Understanding of Convolutional Neural Network* (CNN): *A Review*," *International Journal of Robotics and Control Systems*, vol. 2, no. 4, pp. 739–748, 2022.

[51] A. Upreti, "*Convolutional Neural Network* (CNN): *A comprehensive overview*," vol. 3, no. 4, pp. 488–493.

[52] G. W. Lindsay, "*Convolutional Neural Networks as a Model of the Visual System: Past, Present, and Future*," 2018.

[53] Teguh Wahyono, "*Python for Machine Learning* (Dasar-dasar Pemrograman Python untuk Machine Learning dan Kecerdasan Buatan)," 2013.

[54] S. Tiwari, G. Jain, D. K. Shetty, M. Sudhi, J. M. Balakrishnan, and S. R. Bhatta, "*A Comprehensive Review on the Application of 3D Convolutional Neural*

Networks in Medical Imaging," *Engineering Proceedings*, vol. 59, no. 1, 2023.

[55] F. H. A. M. R. J. M. F. R. Mohammad Gouse Galety, "*Deep Neural Network Concepts for Classification using Convolutional Neural Network: A Systematic Review and Evaluation*," 2021.

[56] Y. Lee, "*The* CNN: *The Architecture Behind Artificial Intelligence Development*," no. 4, pp. 4–12, 2023.

[57] T. A. M. Saad Albawi, "*2017 International Conference on Engineering and Technology*," vol. 3, no. 8, pp. 19–49, 2017.

[58] R. Sarno, S. Sabila, M. Malikhah, D. Purbawa, and M. S. Ardani, *Machine Learning dan Deep Learning-Konsep dan Pemrograman Python*. 2022.

[59] B.-S. Wang, J.-W. Hsieh, M.-C. Chang, P.-Y. Chen, L. Ke, and S. Lyu, "*Learnable Discrete Wavelet Pooling* (LDW-Pooling) *For Convolutional Networks*," Oct. 2021.

[60] A. Zafar, N. Saba, A. Arshad, A. Alabrah, S. Riaz, M. Suleman, S. Zafar, and M. Nadeem, "*Convolutional Neural Networks: A Comprehensive Evaluation and Benchmarking of Pooling Layer Variants*," *Symmetry (Basel).*, vol. 16, no. 11, Nov. 2024.

[61] N. I. Galanis, P. Vafiadis, K. G. Mirzaev, and G. A. Papakostas, "*Convolutional Neural Networks: A Roundup and Benchmark of Their Pooling Layer Variants*," *Algorithms*, vol. 15, no. 11, Nov. 2022.

[62] X. Zhao, L. Wang, Y. Zhang, X. Han, M. Deveci, and M. Parmar, "*A review of convolutional neural networks in computer vision*," *Artif. Intell. Rev.*, vol. 57, no. 4, Apr. 2024.

[63] Zewen Li, "*Survey of Convolutional Neural Networks Analysis, Applications, and Prospect*," vol. 7, no. 4, pp. 1–21, 2020.

[64] H. Yingge, I. Ali, and K. Y. Lee, "*Deep neural networks on chip - A survey*," in *Proceedings - 2020 IEEE International Conference on Big Data and Smart Computing, BigComp 2020*, 2020, pp. 589–592.

[65] N. Bilous, V. Malko, M. Frohme, and A. Nechyporenko, "*Comparison of* CNN-*Based Architectures for Detection of Different Object Classes*," *AI (Switzerland)*, vol. 5, no. 4, pp. 2300–2320, Dec. 2024.

[66] S. Basha, S. R. Dubey, V. Pulabaigari, and S. Mukherjee, "*Impact of fully connected layers on performance of convolutional neural networks for image classification*," *Neurocomputing*, vol. 378, pp. 112–119, Feb. 2020.

[67] P. Kocsis, P. Súkeník, G. Brasó, M. Nießner, L. Leal-Taixé, and I. Elezi, "*The Unreasonable Effectiveness of Fully-Connected Layers for Low-Data Regimes*," Oct. 2022.

[68] C. Yeh, M. Lin, P. Chang, and L. W. Kang, "*Enhanced visual attention-guided deep neural networks for image classification*," *IEEE Access*, vol. 8, pp. 163447–163457, 2020.

[69] B. Zhang, Q. Zhao, W. Feng, and S. Lyu, "*AlphaMEX: A smarter global pooling method for convolutional neural networks*," *Neurocomputing*, vol. 321, pp. 36–48, Dec. 2018.

[70] H. H. Chen, B. J. Hwang, J. S. Wu, and P. T. Liu, "*The effect of different deep network architectures upon CNN-based gaze tracking*," *Algorithms*, vol. 13, no. 5, May 2020.

[71] W. Wang, J. Tian, C. Zhang, Y. Luo, X. Wang, and J. Li, "*An improved deep learning approach and its applications on colonic polyp images detection*," *BMC Med. Imaging*, vol. 20, no. 1, Jul. 2020.

[72] S. Y. Ali and H. Maseeh, "*Dropout: An Effective Approach to Prevent Neural Networks from Overfitting*,"

Asian Journal of Research in Computer Science, vol. 18, no. 2, pp. 163–185, Feb. 2025.

[73] Olivia Harris and Michael Andrews, "*Effects and results of dropout layer in reducing overfitting with convolutional Neural Networks (CNN)," World Journal of Advanced Engineering Technology and Sciences*, vol. 13, no. 2, pp. 836–853, Dec. 2024.

[74] M. Xiao, Y. Wu, G. Zuo, S. Fan, H. Yu, Z. A. Shaikh, and Z. Wen, "*Addressing Overfitting Problem in Deep Learning-Based Solutions for Next Generation Data-Driven Networks*," *Wirel. Commun. Mob. Comput.*, vol. 4, no. 6, pp. 1–10, 2021.

[75] H. Hu, "*Galaxy classification based on convolutional neural networks with dropout technique*," *Applied and Computational Engineering*, vol. 22, no. 1, pp. 42–52, Oct. 2023.

[76] Y. Zeng, T. Dai, B. Chen, S. T. Xia, and J. Lu, "*Correlation-based structural dropout for convolutional neural networks*," *Pattern Recognit.*, vol. 120, no. 10, Dec. 2021.

[77] F. Sultana, A. Sufian, and P. Dutta, "*A Review of Object Detection Models based on Convolutional Neural Network*," vol. 5, no. 6, Oct. 2019.

[78] S. Reddy, N. Pillay, and N. Singh, "*Comparative Evaluation of Convolutional Neural Network Object Detection Algorithms for Vehicle Detection*," *J. Imaging*, vol. 10, no. 7, Jul. 2024.

[79] T. Diwan, G. Anirudh, and J. V. Tembhurne, "*Object detection using YOLO: challenges, architectural successors, datasets and applications*," *Multimed. Tools Appl.*, vol. 82, no. 6, pp. 9243–9275, Mar. 2023.

[80] Y. Wang, "*Comparative Analysis of Object Detection Architectures for Enhanced Performance and*

Application Suitability," *Applied and Computational Engineering*, vol. 166, no. 1, pp. 70–77, Jun. 2025.

[81] "*A Comparative Study Of Various Object Detection Algorithms*," *International Research Journal of Modernization in Engineering Technology and Science*, no. 6, pp. 1–8, Jun. 2024.

[82] X. Pan, Z. Luo, and L. Zhou, "*Comprehensive Survey of State-of-the-Art Convolutional Neural Network Architectures and Their Applications in Image Classification*," *Innovations in Applied Engineering and Technology*, pp. 1–16, Mar. 2022.

[83] Dr. S. Gothane, "*A Practice for Object Detection Using YOLO Algorithm,*" *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, pp. 268–272, Apr. 2021.

[84] S. Bhattacharjee, "*A Literature-based Performance Assessment of the YOLO (You Only Look Once) CNN Approach for Real-time Object Detection*," *Computology: Journal of Applied Computer Science and Intelligent Technologies*, vol. 4, no. 2, pp. 18–40, Apr. 2025.

[85] S. Patil, A. Kharade, A. M. Kesarkar, U. D. Bankarmali, and N. Magdum, "*Object Detection Using YOLO*," vol. 7.

[86] G. Lavanya and S. D. Pande, "*Enhancing Real-time Object Detection with YOLO Algorithm*," *EAI Endorsed Transactions on Internet of Things*, vol. 10, 2024.

[87] Thrupthi C P, Dr. Chitra K, and Mrs Harilakshmi V M, "*Object Detection for Autonomous Vehicles Using YOLO Algorithm*," *International Journal of Advanced Research in Science, Communication and Technology*, pp. 180–184, Nov. 2024.

[88] R. Ju and W. Cai, "*Fracture detection in pediatric wrist trauma X-ray images using YOLOv8 algorithm*," *Sci. Rep.*, vol. 13, no. 1, Dec. 2023.

[89] Mr. J. Rajasekhar, "*Understanding Yolo: Real-Time Object Detection Explained*," *Interantional Journal Of Scientific Research In Engineering And Management*, vol. 08, no. 07, pp. 1–9, Jul. 2024.

[90] N. Jegham, C. Y. Koh, M. Abdelatti, and A. Hendawi, "*YOLO Evolution: A Comprehensive Benchmark and Architectural Review of YOLOv12, YOLO11, and Their Previous Versions*," vol. 14, no. 3, Mar. 2025.

[91] M. Yaseen, "*What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detecto*r," vol. 10, no. 6, Aug. 2024.

[92] M. Talib, A. H. Y. Al-Noori, and J. Suad, "*YOLOv8-CAB: Improved YOLOv8 for Real-time Object Detection*," *Karbala International Journal of Modern Science*, vol. 10, no. 1, pp. 56–68, 2024.

[93] L. Zedda, A. Loddo, and C. Di Ruberto, "*A deep architecture based on attention mechanisms for effective end-to-end detection of early and mature malaria parasites in a realistic scenario*," *Comput. Biol. Med.*, vol. 186, Mar. 2025.

[94] A. M. B. R. C. Andrzej D. Dobrzycki, *An Analysis of Layer-Freezing Strategies for Enhanced Transfer Learning in YOLO Architectures*, vol. 13. IEEE, 2015.

[95] S. Selvakumari and M. Durairaj, "*Indian Journal Of Science And Technology A Comparative Study Of Optimization Techniques In Deep Learning Using The Mnist Dataset*," 2025.

[96] H. Rezatofighi, N. Tsoi, J. Gwak, A. Sadeghian, I. Reid, and S. Savarese, "*Generalized Intersection over Union: A Metric and A Loss for Bounding Box Regression*," 2019.

[97] D. A. Mura, L. Zedda, A. Loddo, and C. Di Ruberto, "*YOLO-Tryppa: A Novel YOLO-Based Approach for Rapid and Accurate Detection of Small Trypanosoma Parasites*," *J. Imaging*, vol. 11, no. 4, Apr. 2025.

[98] R. I. A. S. Zahra Nematzadeh, "*Comparative Studies on Breast Cancer Classifications with K-Fold Cross Validations Using Machine Learning Techniques*," *UTM*, vol. 1, no. 3, pp. 1–6, 2015.

[99] E. Mutiara Hoy Yuliana, Y. Sundara Mulia, I. Kurniati, and P. Kemenkes Bandung, "*Perbandingan Kualitas Preparat Malaria Yang Digenangi Dengan Direndam Dalam Larutan Giemsa Comparison Of The Quality Of Malaria Preparations Flooded With Soaked In Giemsa Solution*," *JMLS) Journal of Medical Laboratory and Science*, vol. 5, no. 1, 2025.

[100] K. M. Naing, S. Boonsang, S. Chuwongin, V. Kittichai, T. Tongloy, S. Prommongkol, P. Dekumyoy, and D. Watthanakulpanich, "*Automatic recognition of parasitic products in stool examination using object detection approach*," *PeerJ Comput. Sci.*, vol. 8, 2022.

[101] H. SKom, Mk. Pembimbing, C. Dewi SKom MCsphD Pembimbing, H. Dwi Purnomo, T. Wahyono, and D. RWidiasari, "*Yolov8 Analysis for vehicle classification Under various*."

[102] R. B. D. Figueiredo and H. A. Mendes, "*Analyzing Information Leakage on Video Object Detection Datasets by Splitting Images into Clusters with High Spatiotemporal Correlation*," vol. 11, 2023.

[103] M. Chitra and C. Shanmuganathan, "*Robust Object Detection in Jam-Packed Scenes Through Enhanced YOLOv8: A Deep Learning Method*," in *2024 5th International Conference on Smart Electronics and Communication (ICOSEC)*, 2024, pp. 1707–1711.

[104] N. Sabrina, Luqman, I. Ahmad, S. M. Mohamad Maharum, Z. Mansor, B. Wei, and V. Kumar, "*Precision*

Detection of Small Brown Planthoppers in Agriculture via YOLOv8 Fine-Tuning," in *2025 IEEE 11th International Conference on Smart Instrumentation, Measurement and Applications (ICSIMA)*, 2025, pp. 171–176.

[105] J. Leonardy, M. R. Salim, R. E. Putra, A. Virgono, U. A. Ahmad, M. K. Delimayanti, and W. P. Tresna, "*Optimizing Convolutional Layer in YOLOv8: Enhancing Accuracy and Efficiency for Camouflaged Object Detection in Complex Environments*," in *2025 IEEE 8th International Conference on Electrical, Control and Computer Engineering (InECCE)*, 2025, pp. 543–546.

[106] J. Tiong, K. Hasikin, R. Ngui, P. C. S. Divis, C. K. Loo, K. W. Lai, F. W. Cheong, and W. Y. Wan Sulaiman, "*Insights into AI-Driven malaria diagnosis: A systematic review with implications for Plasmodium knowlesi*," *Acta Trop.*, vol. 271, p. 107842, Nov. 2025.

[107] B. Yilmaz and U. Kutbay, "*YOLOv8-Based Drone Detection: Performance Analysis and Optimization*," *Computers*, vol. 13, no. 9, Sep. 2024.

[108] Y. Lee, M. P. Patil, J. G. Kim, Y. B. Seo, D. H. Ahn, and G. Do Kim, "*Hyperparameter optimization of apple leaf dataset for the disease recognition based on the YOLOv8*," *J. Agric. Food Res.*, vol. 21, Jun. 2025.

[109] I. G. A. A. B. D. Ratih and D. R. Wijaya, "*Object Detection Model for Student and Lecturer Classification Using YOLOv8 and Optuna*," in *2025 IEEE International Conference on Industry 4.0, Artificial Intelligence, and Communications Technology (IAICT)*, 2025, pp. 654–659.

[110] L. Fan, S. Tang, M. K. A. b. M. Ariffin, M. I. S. Ismail, and X. Wang, "*Impact of Image Preprocessing and Crack Type Distribution on YOLOv8-Based Road Crack Detection*," *Sensors*, vol. 25, no. 7, Apr. 2025.

[111] M. F. Tariq and M. A. Javed, "*Small Object Detection with YOLO: A Performance Analysis Across Model Versions and Hardware*," Apr. 2025.

[112] A. Degale Desta and C. Jian, "*Enhancing YOLOv8 for Vehicle Detection in Intelligent Traffic Management*."

[113] E. Ariyanda, M. Sarosa, S. Wibowo, W. N. Hidayat, Y. M. Azis, and I. Mahfudi, "*Performance Evaluation of YOLOv8 for Automatic Bullet Impact Detection and Scoring on Shooting Targets*," in *2026 International Conference on Current Research in Artificial Intelligence and Data Science (ICCRAIDS)*, 2026, vol. 1, pp. 1–7.

[114] A. H. Sodhro, S. Kannam, and M. Jensen, "*Real-time efficiency of YOLOv5 and YOLOv8 in human intrusion detection across diverse environments and recommendation*," *Internet of Things (The Netherlands)*, vol. 33, Sep. 2025.

[115] A. S. Mekled, S. Abdennadher, and O. M. Shehata, "*Performance Evaluation of YOLO Models in Varying Conditions*: A Study on Object Detection and Tracking," in *2024 International Conference on Computer and Applications (ICCA)*, 2024, pp. 1–6.

[116] Y. Lin, "*Research on small object detection method based on YOLOv8:Application of high-resolution detection layer and Mosaic data augmentation*," 2025.

[117] X. Dai, X. Zhao, F. Cen, and F. Zhu, "*Data Augmentation Using Mixup and Random Erasing,*" in *2022 IEEE International Conference on Networking, Sensing and Control (ICNSC)*, 2022, pp. 1–6.

[118] S. Jindal, "*Evaluating the Impact of Dataset Resampling: A Comparative Analysis of VGG-16, ResNet50, and YOLO v11*," *International Journal of High School Research*, vol. 7, no. 11, pp. 124–131, Nov. 2025.

[119] B. Gašparović, G. Mauša, J. Rukavina, and J. Lerga, "*Comparative Analysis of YOLOv7 with Modified Mosaic Augmentation Against YOLOv8-11 for Object Detection in Unbalanced Datasets*," in *2025 10th International Conference on Smart and Sustainable Technologies (SpliTech)*, 2025, pp. 1–4.

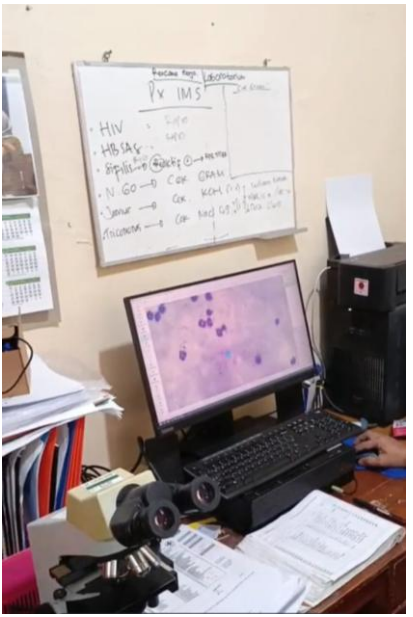
[120] A. Dal Pozzolo, O. Caelen, R. A. Johnson, and G. Bontempi, "*Calibrating Probability with Undersampling for Unbalanced Classification*." *2025 10th International Conference on Smart and Sustainable Technologies (SpliTech)*, 2025, pp. 5-19.

[121] A. Mbanefo and N. Kumar, "*Evaluation of malaria diagnostic methods as a key for successful control and elimination programs*," *Trop. Med. Infect. Dis.*, vol. 5, no. 2, 2020.

[122] O. K. Sahingoz, G. Karatas Baydogmus, and E. Kugu, "*A Systematic Literature Review of You Only Look Once Architectures (v1–v12) in Healthcare Systems*," *Diagnostics*, vol. 16, no. 6. Multidisciplinary Digital Publishing Institute (MDPI), 01-Mar-2026.

LAMPIRAN

Lampiran 1. Dokumentasi Pengambilan Dataset Desa Hanura



Lampiran 1.1 Dokumentasi Preparat Parasit



Lampiran 2. Dokumentasi *Source Code*

Lampiran 2.1 *Source Code Pre-processing Dataset*

```
base_path = r"C:\Users\Ivan\OneDrive\Documents\Skripsi_Malaria\dataset_final_malaria"
images_dir = os.path.join(base_path, "images", "train")
labels_dir = os.path.join(base_path, "labels", "train")

TARGET_CLASS = 0

def add_noise(image):
    """Menambahkan efek bintik-bintik (Noise)"""
    row, col, ch = image.shape
    mean = 0
    var = 0.5
    sigma = var**0.5
    gauss = np.random.normal(mean, sigma, (row, col, ch))
    gauss = gauss.reshape(row, col, ch)
    noisy = image + gauss * 20
    return np.clip(noisy, 0, 255).astype(np.uint8)

def adjust_brightness(image):
    """Menggelapkan atau mencerahkan gambar secara acak"""
    factor = random.uniform(0.6, 1.4)
    hsv = cv2.cvtColor(image, cv2.COLOR_BGR2HSV)
    hsv[:, :, 2] = np.clip(hsv[:, :, 2] * factor, 0, 255)
    return cv2.cvtColor(hsv, cv2.COLOR_HSV2BGR)

def augment_data():
    print("🚀 MEMULAI AUGMENTASI CERDAS (VARIASI GAMBAR)...")

    files = [f for f in os.listdir(images_dir) if f.endswith(('.jpg', '.png', '.bmp'))]
    falciparum_files = []

    for f in files:
        label_path = os.path.join(labels_dir, os.path.splitext(f)[0] + ".txt")
        if not os.path.exists(label_path): label_path = os.path.join(labels_dir, os.path.splitext(f)[0] + ".TXT")

        if os.path.exists(label_path):
            with open(label_path, 'r') as file:
                content = file.read()
                if f"{TARGET_CLASS} " in content:
                    falciparum_files.append((f, label_path))

    print(f"   Ditemukan {len(falciparum_files)} gambar Falciparum asli.")
    print("   Sedang membuat variasi: Noise, Brightness, & Flip...")

    count = 0
    for img_name, lbl_path in tqdm(falciparum_files):
        img_path = os.path.join(images_dir, img_name)
        image = cv2.imread(img_path)
```

Lampiran 2.2 *Source Code* Proses *Training* Model

```
dataset_path = r"C:\Users\Ivan\OneDrive\Documents\Skripsi_Malaria\datasets\mmalaria"
project_save_path = r"D:\Skripsi_Malaria_Output"
yaml_path = os.path.join(dataset_path, "malaria.yaml")

# ==============================
# MAIN TRAINING FUNCTION
# ==============================
def run_training():

    print("🚀 MENJALANKAN TRAINING ULANG (RESEP TRIAL 20 - mAP 88.95%)...")

    # Buat YAML dataset
    yaml_content = {
        'path': dataset_path,
        'train': 'images/train',
        'val': 'images/val',
        'names': {0: 'P.falciparum', 1: 'P.vivax'}
    }

    with open(yaml_path, 'w') as f:
        yaml.dump(yaml_content, f, default_flow_style=False)

    # Load model pretrained
    model = YOLO("yolov8m.pt")

    # Training dengan Hyperparameter Trial 20
    model.train(
        data=yaml_path,
        epochs=100,           # Dikembalikan ke 100 sesuai ARGS Trial 20
        imgsz=640,
        batch=16,
        device=0,
        workers=6,
        optimizer="AdamW",

        # --- RESEP TRIAL 20 ---
        lr0=0.0021464035477145866,
        lrf=0.004268368324226795,
        momentum=0.937,
        weight_decay=3.5299987701933912e-06,
        warmup_epochs=6.6902538291572045,
        warmup_momentum=0.94220796847618,
        degrees=114.0,
        translate=0.1,
        scale=0.4694983607092159,
        hsv_s=0.7,
        hsv_v=0.4,
        mosaic=1.0,
        erasing=0.3691005300778975,
```

Lampiran 2.3 *Source Code* Pencarian *Best* Hyperparameter Model

```python
def run_optuna_training():

    print("🚀 MENJALANKAN OPTUNA HYPERPARAMETER SEARCH...")

    # Buat YAML dataset
    yaml_content = {
        'path': dataset_path,
        'train': 'images/train',
        'val': 'images/val',
        'names': {0: 'P.falciparum', 1: 'P.vivax'}
    }

    with open(yaml_path, 'w') as f:
        yaml.dump(yaml_content, f, default_flow_style=False)

    # Persistent study
    sampler = optuna.samplers.TPESampler(seed=42)

    study = optuna.create_study(
        study_name="malaria_yolo_study",
        direction="maximize",
        storage="sqlite:///malaria_yolo_study.db",
        load_if_exists=True,
        sampler=sampler
    )
```

Lampiran 2.4 *Source Code Split Dataset*

```python
# --- 3. PEMBAGIAN 80:10:10 ---
train_idx = int(total_files * 0.8)
val_idx = int(total_files * 0.9)  # 80% + 10%

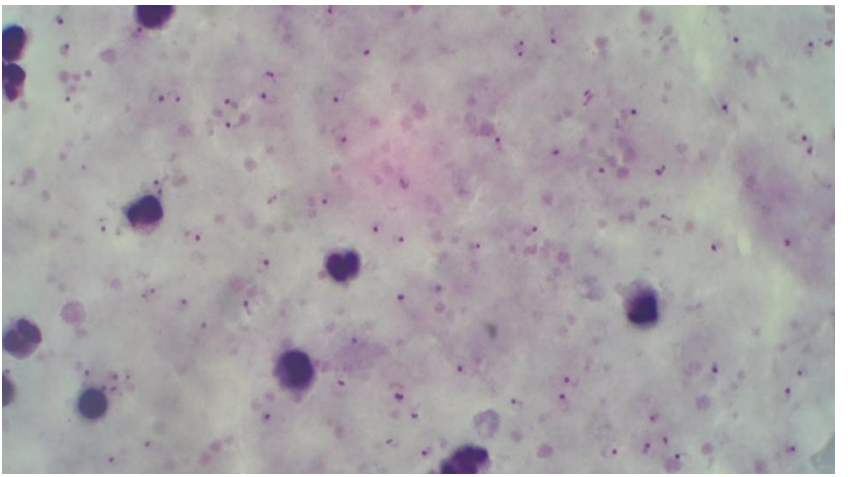
train_set = data_pairs[:train_idx]
val_set = data_pairs[train_idx:val_idx]
test_set = data_pairs[val_idx:]

print(f"✅ Training Set (80%)  : {len(train_set)} file")
print(f"✅ Validation Set (10%): {len(val_set)} file")
print(f"✅ Test Set (10%)      : {len(test_set)} file")

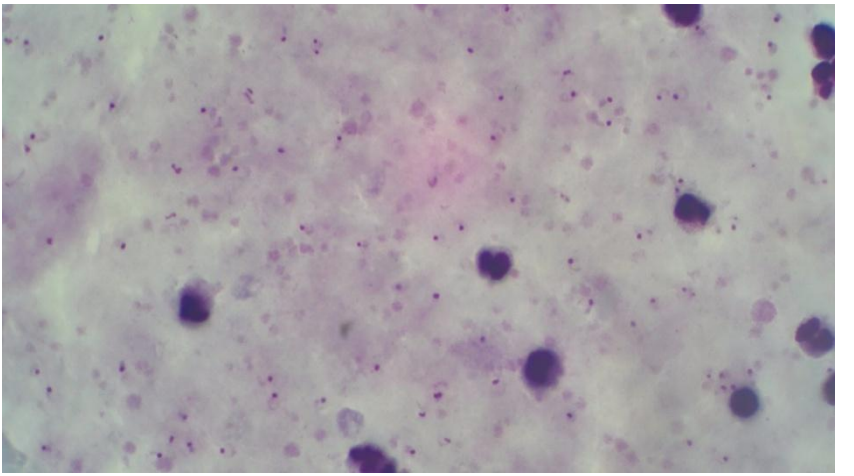
# --- 4. PEMBUATAN FOLDER ---
for split in ['train', 'val', 'test']:
    os.makedirs(os.path.join(dataset_dest, 'images', split), exist_ok=True)
    os.makedirs(os.path.join(dataset_dest, 'labels', split), exist_ok=True)
```

Lampiran 3. Sampel *Dataset* Penelitian

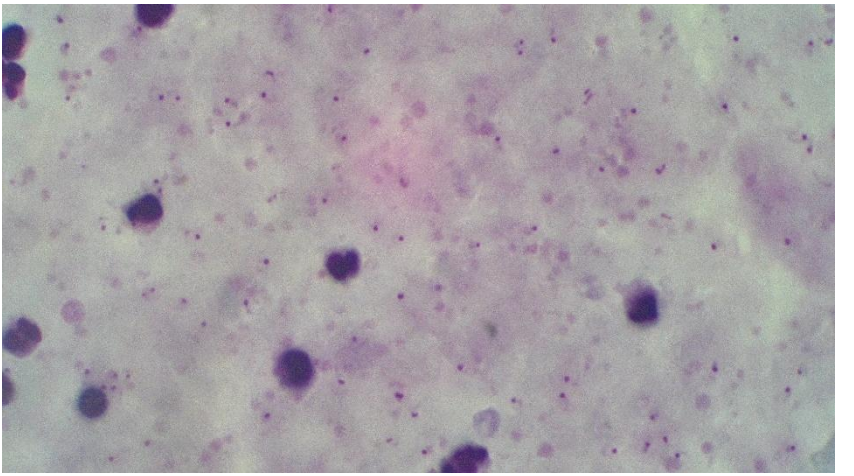
Lampiran 3.1 Dataset *RAW*



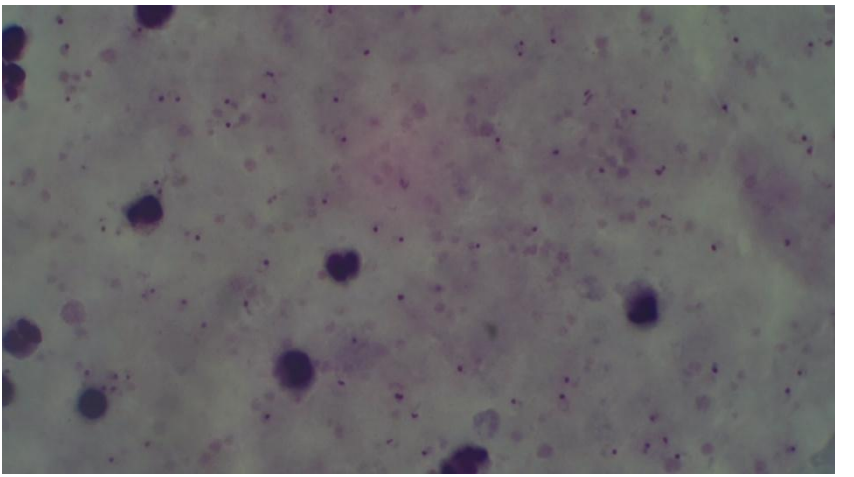
Lampiran 3.2 Dataset Augmentasi *Flip*



Lampiran 3.3 Dataset Augmentasi *Noise*



Lampiran 3.4 Dataset Augmentasi *Brightness*



Lampiran 4.

4.1 Jumlah Proses Trial

