FINE-TUNING MODEL *YOU ONLY LOOK ONCE* V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN *SMEAR* DARAH

LAPORAN TUGAS AKHIR

IVAN FULVIAN PITOYO

122430064



PROGRAM STUDI TEKNIK BIOMEDIS

JURUSAN TEKNOLOGI PRODUKSI DAN INDUSTRI

INSTITUT TEKNOLOGI SUMTERA

2025

FINE-TUNING MODEL *YOU ONLY LOOK ONCE* V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN SMEAR DARAH

LAPORAN TUGAS AKHIR

IVAN FULVIAN PITOYO

122430064



PROGRAM STUDI TEKNIK BIOMEDIS

JURUSAN TEKNOLOGI PRODUKSI DAN INDUSTRI

INSTITUT TEKNOLOGI SUMTERA

2025

LEMBAR PENGESAHAN

Laporan Tugas Akhir dengan judul "*FINE-TUNING* MODEL *YOU ONLY LOOK ONCE* V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN *SMEAR* DARAH" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan di serahkan sebelumnya, baik sebagian atau seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 3 Mei 2026
Penulis,
Ivan Fulvian Pitoyo
122430064

Diperiksa dan disetujui oleh,

Pembimbing I	Pembimbing II
Martin Clinton Tosima Manullang, Ph.D.	I Gde Eka Dirgayussa, M.Si
NIP.199301092019031017	NIP. 198905032024061001

Disahkan oleh,
Koordinator Program Studi Teknik Biomedis
Fakultas Teknik Industri
Institut Teknologi Sumatera

Rudi Setiawan, S.T., M.T.
NIP. 199306032022031008

HALAMAN PERNYATAAN ORISINALITAS

Tugas akhir ini adalah karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan benar.

Nama	**:** Ivan Fulvian Pitoyo
NIM	**:** 122430064
Tanda Tangan	**:**
Tanggal	**:** 3 Mei 2026

ABSTRAK

FINE-TUNING MODEL YOU ONLY LOOK ONCE V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN SMEAR DARAH

Ivan Fulvian Pitoyo (122430064)

Pembimbing: Martin Clinton Tosima Manullang, Ph.D, I Gde Eka Dirgayussa, M.Si

RINGKASAN

Diagnosis malaria *gold standard* melalui mikroskop konvensional seringkali terkendala oleh faktor kelelahan visual tenaga medis dan subjektivitas interpretasi yang memicu kesalahan deteksi, khususnya pada daerah endemik dengan sumber daya terbatas. Penelitian ini bertujuan untuk mengembangkan dan melakukan *fine-tuning* pada arsitektur *deep learning* YOLOv8m (*You Only Look Once* versi *medium*) guna mendeteksi serta membedakan *Plasmodium falciparum* dan *Plasmodium vivax* secara otomatis pada citra mikroskopis. Manfaat dari sistem ini adalah mengurangi beban kerja analis kesehatan serta meningkatkan akurasi deteksi parasit secara komputasional. Ruang lingkup penelitian difokuskan pada sediaan darah tepi dengan menggunakan dataset primer dari Puskesmas Hanura yang telah divalidasi. Metodologi yang digunakan mencakup pra-pemrosesan citra, pelatihan model dengan *optimizer* AdamW untuk mencari parameter optimal, serta pengujian menggunakan metode *Hold-Out Validation* dengan rasio pembagian 80:20 untuk mencegah *overfitting* sekaligus menjaga efisiensi komputasi memori GPU. Evaluasi data diinterpretasikan melalui metrik *precision*, *recall*, F1-Score, dan mAP@50 untuk memastikan model dapat mengenali objek parasit

berskala mikro dengan presisi tinggi dan tidak bias terhadap kelas mayoritas.

Kata kunci: *Deep Learning*, Malaria, Mikroskop, *Object Detection*, YOLOv8m

ABSTRACT

FINE-TUNING OF YOU ONLY LOOK ONCE V8 MODEL FOR MALARIA PARASITE DETECTION IN MICROSCOPIC BLOOD SMEAR IMAGES

Ivan Fulvian Pitoyo (122430064)

Supervisor(s): Martin Clinton Tosima Manullang, Ph.D, I Gde Eka Dirgayussa, M.Si

SUMMARY

The gold standard malaria diagnosis via conventional microscopy is often constrained by medical personnel's visual fatigue and interpretation subjectivity, leading to detection errors, particularly in resource-limited endemic areas. This study aims to develop and fine-tune the YOLOv8m (You Only Look Once medium) deep learning architecture to automatically detect and differentiate Plasmodium falciparum and Plasmodium vivax in microscopic images. The benefit of this system is to reduce the workload of health analysts and improve computational parasite detection accuracy. The scope is focused on peripheral blood smears using a validated primary dataset from the Hanura Public Health Center. The methodology encompasses image pre-processing (geometric augmentation and visual adjustment), model training using the AdamW optimizer to find optimal parameters, and testing using the Hold-Out Validation method with an 80:20 split ratio to prevent overfitting while maintaining GPU memory computational efficiency. Data evaluation was interpreted through precision, recall, F1-Score, and mAP@50 metrics to ensure the model can recognize micro-scale parasite objects with high precision and avoids majority class bias.

Keywords: Deep Learning, Malaria, Microscope, Object Detection, YOLOv8

KATA PENGANTAR

Puji syukur senantiasa penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia yang diberikan, sehingga penyusunan Laporan Tugas Akhir yang berjudul *"FINE-TUNING MODEL YOU ONLY LOOK ONCE V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN SMEAR DARAH"* dapat diselesaikan dengan baik. Laporan Tugas Akhir ini dimaksudkan untuk memenuhi salah satu persyaratan kelulusan dalam meraih gelar Sarjana Teknik pada Program Studi Teknik Biomedis, Jurusan Teknologi Produksi dan Industri, Institut Teknologi Sumatera. Penulis menyadari bahwa penyusunan Tugas Akhir ini, mulai dari tahap rekayasa pra-pemrosesan citra medis hingga evaluasi kinerja algoritma kecerdasan buatan, tidak akan dapat diselesaikan tanpa bimbingan, arahan, dan dukungan fasilitas dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Bapak Prof. Dr. I Nyoman Pugeg Aryantha, selaku Rektor Institut Teknologi Sumatera.
2. Bapak Hadi Teguh Yudistira S.T., Ph.D., selaku Dekan Fakultas Teknik Industri Institut Teknologi Sumatera.
3. Bapak Rudi Setiawan, S.T., M.T., selaku Koordinator Program Studi Teknik Biomedis Institut Teknologi Sumatera.
4. Bapak Martin Clinton Tosima Manullang, Ph.D., selaku Dosen Pembimbing I, yang telah meluangkan waktu dan pikiran untuk membimbing, memberikan masukan analitis yang

komprehensif, serta memvalidasi rekayasa sistem kecerdasan buatan dalam penelitian ini.

5. Bapak I Gde Eka Dirgayussa, M.Si., selaku Dosen Pembimbing II, atas saran konstruktif terkait pengolahan citra medis dan ketelitian dalam mengarahkan fundamental metodologi penelitian.
6. Institut Teknologi Sumatera, yang telah memberikan izin dan akses terhadap dataset primer citra sediaan darah mikroskopis yang menjadi subjek utama penelitian ini.
7. Terima kasih kepada LPDP atas dukungan pendanaan yang diberikan sehingga penelitian operasional komputasional ini dapat berjalan lancar.

Penulis menyadari bahwa sistem deteksi dan Laporan Tugas Akhir ini masih memiliki berbagai keterbatasan. Oleh karena itu, segala bentuk kritik dan saran yang bersifat membangun sangat diharapkan. Akhir kata, semoga Tugas Akhir ini dapat memberikan kontribusi secara ilmiah bagi pengembangan rekayasa teknologi medis di masa depan.

Tempat penyusunan TA, 24 April 2026

Penulis,

Ivan Fulvian Pitoyo

PERSEMBAHAN

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala Rahmat dan karunia sehingga saya dapat menyelesaikan lembar demi lembar perjalanan panjang ini. Dengan segala kerendahan hati, karya kecil ini saya persembahkan kepada:

1. Tuhan Yang Maha Esa Sumber segala ilmu pengetahuan, ketenangan, dan kekuatan. Terima kasih atas petunjuk, perlindungan, dan kemudahan yang tiada henti, terutama di saat-saat paling buntu dalam menyelesaikan penelitian ini. Semua pencapaian ini pada akhirnya hanyalah titipan darinya.

2. Ayah dan Ibu Tercinta Dua sosok paling berjasa dan tak tergantikan dalam hidup saya. Terima kasih atas peluh, keringat, kasih sayang, dan doa-doanya yang selalu mengudara tanpa henti. Setiap baris kalimat dalam skripsi ini tidak akan pernah cukup untuk membalas pengorbanan kalian. Karya ini adalah bentuk bakti dan hadiah kecil untuk mengukir senyum bangga di wajah kalian.

3. Saudara dan Keluarga Besar Terima kasih atas segala bentuk dukungan moral, perhatian, dan semangat yang selalu diberikan dari rumah. Terima kasih telah selalu mengingatkan saya bahwa selalu ada tempat yang hangat untuk kembali setelah lelah berjuang.

MOTTO

“Menjembatani batas laboratorium dengan dunia nyata dengan tujuan untuk menyelamatkan kehidupan”

DAFTAR ISI

FINE-TUNING **MODEL *YOU ONLY LOOK ONCE* V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN SMEAR DARAH** ii

LEMBAR PENGESAHAN iii

HALAMAN PERNYATAAN ORISINALITAS iv

ABSTRAK v

ABSTRACT vii

KATA PENGANTAR ix

PERSEMBAHAN xi

MOTTO xii

DAFTAR ISI xiii

DAFTAR GAMBAR xvi

DAFTAR TABEL xvii

BAB I 1

1.1 Latar Belakang 1

1.2 Perumusan Masalah 5

1.3 Tujuan Penelitian 5

1.4 Hipotesis 6

1.5 Ruang Lingkup Penelitian 6

1.6 Sistematika Penulisan 7

BAB II 8

2.1 Mikroskop 8

2.2 Malaria 11
2.3 Deep Learning 19
2.4 Convolutional Neural Network (CNN) 21
2.4.1 Convolutional Layer 22
2.4.2 Pooling Layer 25
2.4.3 Fully Connected Layer 27
2.4.4 Arsitektur CNN 30
2.5 Algoritma YOLO (*You Only Look Once*) 34
2.6 *Hyperparameter* 45
2.7 *State Of The Art* 48
BAB III 60
3.1 Jenis Penelitian 60
3.2 Waktu dan Tempat Pelaksanaan 60
3.3 Alat dan Bahan 61
3.3.1 Alat 61
3.3.2 Bahan 66
3.4 Metode dan Persamaan yang Digunakan 66
3.4.1 Fungsi Kerugian (*Loss Function*) 66
3.4.2 Parameter Optimasi (AdamW) 68
3.4.2 Metrik Evaluasi Kinerja Sistem 68
3.5 Diagram Alir Penelitian 70
3.5.1 Studi Literatur 71

3.5.2 Pengumpulan Dataset 71
3.5.3 Pre-Processing Data..... 71
3.5.4 Training Model 72
3.5.5 Evaluasi Matriks 72
3.5.6 Pembuatan GUI 73
3.5.7 Analisis Data 73
3.6 Langkah Penelitian secara Spesifik 73
3.6.1 Proses Training Model..... 78
3.6.2 Proses Training 81
3.6.3 Integrasi *Hardware* dan *Software* 84
3.6.4 Uji Implementasi 88
3.7 Interpretasi Data/Analisis Data..... 88
DAFTAR PUSTAKA 90

DAFTAR GAMBAR

Gambar 2.1 Jenis Tipe Mikroskop Berdiri Pertama Kali 9
Gambar 2.2 Skematik *Electron Microscope*..... 10
Gambar 2.3 Arsitektur CNN..... 22
Gambar 2.4 Proses Komputasi *Convolutional Layer*. 23
Gambar 2.5 Proses Perhitungan *Pooling Layer*..... 26
Gambar 2.6 Proses Flattening dan Koneksi pada F*ully Connected Layer*..... 28
Gambar 2.7 Ilustrasi Hasil Deteksi YOLO..... 36
Gambar 2.8 Perbandingan YOLOv8 Dengan Versi-Versi Sebelumnya 37
Gambar 2.9 Arsitektur YOLOv8 38
Gambar 3.1 Diagram Alir Penelitian..... 70
Gambar 3.2 Diagram Alir Penelitian Spesifik..... 74
Gambar 3.3 Hasil Data *Cutting Dan Resizing*..... 76
Gambar 3.4 Hasil Data *Gaussian Nosie***Error! Bookmark not defined.**
Gambar 3.5 Hasil Perbandingan Data Filtering**Error! Bookmark not defined.**
Gambar 3.6 Perbandingan Hasil Image Augmentasi..... 77
Gambar 3.7 Tahap *Training Model* 80
Gambar 3.8 Design GUI..... 85
Gambar 3.9 Lokasi Penyimpanan File 87

DAFTAR TABEL

Tabel 2.1 Citra dan Karakteristik Fase Parasit *Falciparum* 13
Tabel 2.2 Citra Dan Karakteristik Parasit *Vivax* 16
Tabel 2.3 Rangkuman Performa Metrik Arsitektur 31
Tabel 2.4 Rata-rata Kecepatan Pemrosesan Arsitektur 32
Tabel 2.5 Analisis Persentase Error Deteksi 33
Tabel 2.6 Detail Fungsi Blok Komponen Arsitektur YOLOv8 42
Tabel 2.7 *State Of The Art* 48
Tabel 3.1 Spesifikasi Alat Software dan Hardware 62
Tabel 3.2 Daftar Bahan Penelitian 66
Tabel 3.3 Rangkuman Jumlah Komposisi dan Label Dataset 75
Tabel 3.4 Tabel Pembagian Data 77

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penyakit Malaria menjadi salah satu penyakit yang sangat menlar secara global, terutama di negara-negara tropis seperti di Indonesia. World Health Organization (WHO) menyatakan bahwa pada tahun 2023 sendiri terdapat 263 juta kasus malaria dan 597.000 yang meninggal dikarenakan malaria[1]. Di dalam Indonesia sendiri pada tahun 2024 kasus malaria sudah mencapai 443.530 kasus dengan kasus positif malaria mencapai 89% di Provinsi Papua[2]. Pada tahun 2019 sampai tahun 2020, terdapat total 403 kasus di lampung, pada rentang umur 15-64 tahun, tempat yang menjadi titik paling utama terkenai penyakit malaria di lampung terdapat di desa pesawaran, dimana parasit yang umum terkenai para warga adalah *plasmodium vivax*[3]. Diagnosis secara dini dan akurat menjadi salah satu hal yang sangat penting dalam penanganannya, hal ini dikarenakan dengan diagnosis secara cepat pasien dapat mendapatkan pengobatan yang sesuai, sehingga menurunkan tingkat resiko komplikasi serius hingga kematian pada pasien.

Metode diagnosis malaria yang menjadi gold standard sampai sekarang adalah pemeriksaan darah pasien menggunakan mikroskopis pada sediaan darah tepi (*thick smear* dan *thin smear*)[4]. Selain pemeriksaan mikroskopis, terdapat juga beberapa metode lainnya, seperti teknologi konvensional sampai molekuler, dimana masing-masing memiliki keunggulan dan kekurangan masing-masing[5]. Salah satu alternatif yang dapat digunakan adalah *Rapid Diagnostic Test*

(RDTs). Metode ini menawarkan solusi yang cepat dan terjangkau, sehingga sangat berguna di daerah endemis. RDTs mudah digunakan dan memberikan hasil dalam waktu singkat, meskipun memiliki kelemahan berupa potensi hasil negatif palsu (*false-negative*), tanpa memberikan gambaran secara kuantitatif. Selain itu, terdapat juga beberapa metode lainnya yang memberikan tingkat sensitivitas yang tinggi seperti *Polymerase Chain Reaction* (PCR), dimana metode PCR ini menggunakan sensor untuk mendeteksi DNA yang terdapat dalam parasit dengan sensitivitas 98-100% dan memiliki spesifitas 84-94%[6]. Selain itu, terdapat juga beberapa metode lainnya seperti *Loop-Mediated Isothermal Amplification* (LAMP) yang menunjukkan potensi besar untuk digunakan sebagai alat testing di tempat langsung[7]. Meskipun seperti itu, metode mikroskopis ini termasuk dalam metode konvensional namun dianggap sebagai *gold standard* dalam dunia kesehatan untuk melakukan pendeteksi penyakit malaria[8]. Hal ini dikarenakan kemampuannya yang unik dalam memberikan informasi diagnostik yang komprehensif dan tidak tertandingi oleh metode lain [5]. Metode ini tidak hanya memungkinkan identifikasi definitif kelima spesies *Plasmodium* pada manusia, tetapi juga mampu melakukan kuantifikasi jumlah parasit (*parasitemia*) secara akurat. Hal ini termasuk sangat penting untuk manajemen klinis dan pemantauan respons pengobatan[9]. Hal ini juga didukung dengan visualisasi secara langsung parasit, dimana yang sering terlewatkan oleh proses diagnosis oleh metode lain[6][9]. Namun, proses identifikasi parasit malaria masih sangat bergantung pada tenaga medis atau analis yang bersedia di lokasi. Keterbatasan ini sering menimbulkan subjektivitas, kelahan visual dan memungkinkan kesalahan deteksi, terutama pada kasus dengan parasitemia rendah[10].

Efektivitas penggunaan mikroskopi sebagai metode *gold standard* sudah menunjukkan variabilitas yang sangat signifikan di lapangan dengan kekurangan dan kelebihan yang sangat jelas. Keunggulan metode ini terletak pada kemampuannya untuk memberikan informasi diagnostik yang komprehensif dengan meliputi berbagai spesies dan dapat mengkuantifikasikan parasitemia untuk memandu intensitas pengobatan, dan indikator keparahan penyakit [6]. Meskipun begitu, performa yang menghasilkan nilai yang lebih rendah. Berdasarkan studi yang dilakukan oleh A. Amir,dkk menyatakan bahwa tingkat sensitivitas pada metode mikroskop ini hanya 74.5% dan spesifitas 59%[9]. Keterbatasan ini sangat bergantung pada keahlian teknisi, dimana mereka secara minimum dapat mendeteksi serendahnya 5 parasit/µL darah, dibandingkan dengan tenaga medis biasa dapat mencapai 50 – 100 parasit/µL [9][6]. Proses ini juga memerlukan waktu yang cukup lama antara 20 sampai dengan 40 menit, tergantung dengan kualitas preparat, mikroskop, dan juga keterampilan tenaga medis. Terutama apabila hasil yang di keluarkan berupa negatif, maka hasil tersebut harus di lakukan evaluasi ulang setelah 12 sampai 24 jam kemudian[11]. Ketergantungan terhadap hal ini yang dapat membuka jalan untuk adanya potensi kesalahan, terutama pada daerah yang memiliki sumber daya manusia dan alat yang memadai.

Setelah melakukan *literature review* terkait malaria di Puskesmas Hanura Daerah Provinsi Lampung juga menunjukkan bahwa dalam proses praktik lapangan, proses deteksi malaria masih sangat bergantung kepada metode mirkoskopis secara manual yang dilakukan oleh satu tenaga kerja medis, hal ini juga menjadi tantangan bagi mereka dikarenakan kelelahan mata yang dialami oleh tenaga medis dikarenakan melakukan observasi secara *non-stop* untuk jangka

waktu yang lama. Selain itu, berdasarkan penelitian yang dilakukan oleh Dinas Kesehatan Provinsi Lampung, upaya pengendalian penyakit malaria di Lampung diperlukannya dukungan dan inovasi terbaru secara teknologi untuk proses deteksi secara cepat dan akurat dengan mengingat keterbatasannya tenaga medis dan besarnya beban kerja di lapangan langsung.

Dalam hal ini, dengan perkembangan teknologi digital dapat membuka peluang besar untuk meningkatkan kapabilitas mikroskop konvensional dan cara kerjanya. Beberapa studi sudah menunjukkan bahwa integrasi modul kamera dan model YOLOv8 untuk proses deteksi dapat digunakan dalam praktik pada berbagai bidang. Dalam studi yang dilakukan oleh Aisyah Widayani, dkk. pada tahun 2024 menyatakan bahwa metode YOLOv8 berhasil dalam melakukan deteksi untuk tumor otak, deteksi kanker payudara, dan juga melakukan analisis radiografi gigi dengan tingkat akurasi validasi dan akurasi pelatihan mencapai 95%[12]. Pada bidang arsitektur dan mesin, Ezzedini, dkk. pada tahun 2024 membuktikan bahwa model YOLOv8 memberikan hasil yang sangat baik dalam proses mendeteksi *locomotive* dan kapal yang ada di area lautan beserta ikan-ikannya, dimana tingkat akurasi yang di berikan mencapai 76%[13]. Meskipun begitu, penerapan teknologi tersebut dalam proses deteksi malaria secara *real-time* pada citra mikroskopis masih sangat terbatas. Maka oleh karena itu, penelitian ini dilakukan dengan fokus kepada pembuatan sistem untuk melakukan proses diagnosis secara *real-time* dengan kamera yang terpasang pada mikrsokop secara langsung dengan metode YOLOv8 dengan tujuan untuk mengidentifikasi *plasmodium vivax* dan *plasmodium falciparum*.

Dengan penelitian tersebut, diharapkan hasil yang dikeluarkan dapat menjadi solusi untuk proses deteksi dengan metode mikroskopis konvensional dan menjawab kebutuhan dari pihak puskesmas hanura yang disebabkan oleh lama proses waktu pemeriksaan, ketergantungan kepada tenaga medis, kekurangannya tenaga medis, dan menurunkan resiko kesalahan diagnosis. Dengan pelatihan model YOLOv8 kepada citra darah yang telah melalui tahap isolasi dan juga pemrosesan, sistem akan dirancang untuk membedakan *P.Falciparum, P.Vivax*, dalam dataset yang didapatkan di pesawaran[7].

1.2 Perumusan Masalah

Berdasarkan latar belakang yang ada, permasalahan yang dapat diangkat adalah :

1. Bagaimana merancang sistem deteksi malaria berbasis YOLOv8 pada citra mikroskopis sediaan darah tebal?
2. Bagaimana mengolah dan mempersiapkan dataset citra sediaan darah mikroskopis untuk melatih dan *fine-tuning* model YOLOv8 agar mampu mengenali parasit malaria secara akurat?
3. Bagaimana hal uji performa sistem deteksi malaria berbasis YOLOv8 dalam hal akurasi dan presisi?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang di ambil, adapun tujuan dalam melakukan penelitian ini adalah :

1. Menyusun dan mengolah dataset citra mikroskopis sediaan darah tebal sebagai data pelatihan dan pengujian model YOLOv8.

2. Melakukan *fine-tuning* sistem berbasis YOLOv8 untuk deteksi penyakit malaria pada mikroskop dengan smear darah tebal.
3. Mengevaluasi performa sistem deteksi malaria berbasis YOLOv8 menggunakan parameter akurasi dan presisi.

1.4 Hipotesis

Sistem deteksi malaria berbasis YOLOv8 pada citra mikroskopis dengan sediaan darah tebal dan atau tipis dapat mengenali parasit malaria dengan tingkat akurasi dan sediaan darah tepi yang cukup tinggi. Diharapkan sistem ini dapat memberikan sistem deteksi yang konsisten serta dapat mengurangi tingkat subjektivitas dan kesalahan dalam melakukan identifikasi pada pemeriksaan mikroskopis konvensional berdasarkan dataset yang bagus dan mencukupi.

1.5 Ruang Lingkup Penelitian

Penelitian ini dibatasi pada pengembangan sistem deteksi malaria berbasis YOLOv8 secara mikroskopis menggunakan mikroskop pada sediaan darah tepi, baik *smear* tebal maupun tipis. Dikarenakan adanya keterbatasan pada data dan dana, maka penelitan ini memanfaatkan dataset citra mikroskopis malaria yang disediakan oleh sumber terbuka dan hasil kerjasama dengan pihak tenaga kesehatan untuk mengambil data primer.

Sistem yang dikembangkan dengan melakukan implementasi kepada perangkat lunak dengan menggunakan komputer dan atau laptop yang ada. Oleh karena itu, dikarenakan tidak akan ada pembahasan secara klinis terhadap cara pengobatan, maka penelitian ini hanya berfokus pada sistem atau proses deteksi malaria parasit dalam citra mikroskopis.

Performa YOLOv8 dilakukan dengan parameter seperti akurasi dan persisi, terbatas pada dataset yang digunakan. Penelitian ini dilakukan dengan uji validasi klini dengan bantuan tenaga medis melakukan klarifikasi dan validasi terhadap hasil yang sudah dilakukan.

1.6 Sistematika Penulisan

Secara keseluruhan, penyusunan laporan Tugas Akhir ini mengikuti standar format penulisan akademik yang telah ditetapkan, yaitu menggunakan jenis huruf *Times New Roman* dengan ukuran 12 pt dan jarak baris 1,5 spasi. Penggunaan tanda desimal dalam laporan ini disimbolkan dengan tanda koma (,), sedangkan pemisah ribuan disimbolkan dengan tanda titik (.). Untuk memberikan gambaran yang komprehensif dan terstruktur mengenai alur penelitian, sistematika penulisan laporan ini dibagi ke dalam lima bab utama yang saling berkesinambungan, dengan rincian sebagai berikut:

BAB II
TINJAUAN PUSTAKA

2.1 Mikroskop

Sejarah perkembangan teknologi observasi mikroskopis berawal pada abad ke-13 ketika Salvino D'Armate merancang prototipe kacamata pertama. Alat sederhana ini menggunakan prinsip pembiasan cahaya untuk menghasilkan perbesaran visual sebesar 6x hingga 10x pada satu mata, yang saat itu umum digunakan untuk mengamati detail objek kecil seperti serangga atau struktur tanaman. Selanjutnya, pada akhir abad ke-16, Zacharias Jansen bersama ayahnya di Belanda menguji coba penggabungan beberapa lensa ke dalam sebuah tabung. Eksperimen inilah yang kelak menjadi cikal bakal terciptanya instrumen optik modern seperti mikroskop dan teleskop[14].

Meskipun Jansen berhasil menciptakan perangkat pembesar, mikroskop generasi awal tersebut masih memiliki banyak kelemahan. Dengan tingkat perbesaran yang masih rendah serta kualitas resolusi gambar yang buruk, alat tersebut belum memenuhi standar presisi untuk observasi ilmiah yang mendalam. Terobosan besar kemudian dicapai oleh ilmuwan Belanda, Antonie van Leeuwenhoek. Ia merancang mikroskop sederhana berlensa tunggal yang tingkat distorsinya jauh lebih rendah dibandingkan mikroskop majemuk di eranya, bahkan mampu menembus perbesaran hingga lebih dari 200 kali[15]. Berkat instrumen buatannya ini, Leeuwenhoek berhasil mengamati berbagai spesimen biologis secara detail, mulai dari sel darah merah (eritrosit), bakteri, hingga spermatozoa. Kualitas visual yang revolusioner ini

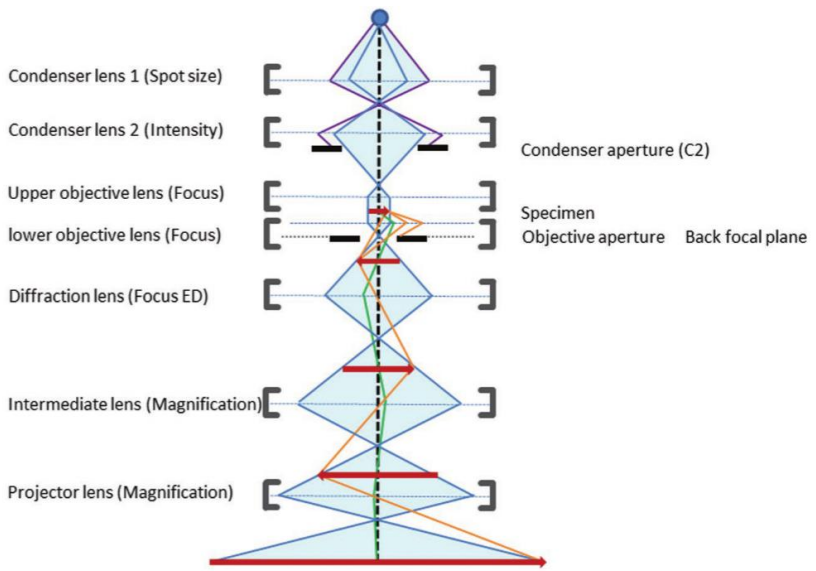
membuat desain mikroskop Leeuwenhoek diadaptasi sebagai standar utama dalam dunia mikroskopi selama puluhan tahun[16].



Gambar 2.1 Jenis Tipe Mikroskop Berdiri Pertama Kali [17].

Memasuki abad ke-19, perkembangan mikroskop mengalami lompatan yang sangat signifikan melalui kolaborasi Carl Zeiss, Ernst Abbe, dan Otto Schott. Mereka berhasil merancang mikroskop modern tipe berdiri yang dilengkapi dengan lensa apokromatik. Inovasi ini sangat krusial karena mampu mengoreksi aberasi sferis maupun kromatik, sehingga menghasilkan citra yang jauh lebih tajam dengan resolusi spasial mencapai 0,2 μm[18]. Pencapaian ini sekaligus menjadi tonggak awal standardisasi dan reproduktifitas manufaktur instrumen optik. Walaupun demikian, inovasi ini juga secara tidak langsung memperlihatkan batas fisik fundamental dari cahaya tampak. Ernst Abbe merumuskan sebuah teori yang dikenal sebagai "Batas Abbe" (*Abbe limit*), yang membuktikan bahwa mikroskop optik konvensional difraksi cahaya tidak akan mampu membedakan dua titik yang jaraknya lebih kecil dari setengah panjang gelombang cahaya yang digunakan (sekitar 200 nm)[19]. Keterbatasan fisik ini menjadi kendala utama

dalam mengobservasi objek berskala nanometer, seperti struktur internal virus maupun detail organel sel [14]. Untuk menembus batas difraksi cahaya tersebut, Ernst Ruska, Max Knoll, dan Bodo von Borries merintis penemuan mikroskop elektron pada dekade 1930-an. Dengan memanfaatkan berkas electron yang memiliki panjang gelombang jauh lebih pendek dibandingkan foton Cahaya instrumen seperti *Transmission Electron Microscope* (TEM) dan *Scanning Electron Microscope* (SEM) mampu menghasilkan tingkat perbesaran hingga jutaan kali lipat. Penemuan revolusioner ini membuka lembaran baru yang mengubah lanskap penelitian di bidang ilmu material dan biologi sel[20].



Gambar 2.2 Skematik Electron Microscope [21].

Berdasarkan rekam jejak evolusi tersebut, mikroskop secara etimologi yang diserap dari bahasa Yunani *mikrós* (kecil) dan *skopeîn* (melihat) dapat didefinisikan sebagai instrumen esensial untuk memvisualisasikan objek renik yang tak kasat mata [19]. Meskipun

purwarupa pertamanya telah berusia lebih dari 350 tahun [22], mikroskop modern terus berkembang pesat dengan mengintegrasikan berbagai prinsip pencitraan mutakhir, mulai dari sistem optik, elektron, hingga *scanning probe* demi menghasilkan visualisasi beresolusi sangat tinggi[23], Pada era kontemporer, lompatan teknologi telah melahirkan teknik-teknik canggih seperti *super-resolution fluorescence microscopy* dan *confocal laser scanning microscopy*, yang memungkinkan analisis presisi pada skala seluler maupun sub-seluler [24]. Pada era kontemporer, lompatan teknologi telah melahirkan teknik-teknik canggih seperti *super-resolution fluorescence microscopy* dan *confocal laser scanning microscopy*, yang memungkinkan analisis presisi pada skala seluler maupun sub-seluler. Rangkaian inovasi ini mengukuhkan posisi mikroskop sebagai instrumen fundamental yang menggerakkan kemajuan sains dan kedokteran masa kini, dengan peran krusial di berbagai disiplin ilmu seperti *life sciences*, nanoteknologi, ilmu material, sampai kedokteran gigi [25],[26],[27].

2.2 Malaria

Malaria adalah penyakit menular yang ditularkan melalui vektor (*vector-borne*) yang disebabkan oleh parasit protozoa dari genus *Plasmodium*, yang ditransmisikan ke manusia melalui gigitan nyamuk *Anopheles* betina yang terinfeksi. Dari berbagai spesies yang ada, lima di antaranya menginfeksi manusia *P. falciparum, P. vivax, P. malariae, P. ovale*, dan *P. knowlesi* dengan *P. falciparum* bertanggung jawab atas sebagian besar kasus yang parah dan fatal. Penyakit ini merupakan masalah kesehatan masyarakat global yang utama, dengan sekitar setengah populasi dunia berisiko pada tahun 2020. Beban penyakit ini

tetap signifikan, dengan perkiraan 247 juta kasus di seluruh dunia pada tahun 2023 menurut WHO, dan telah menyebabkan 409.000 kematian pada tahun 2019, terutama berdampak pada anak-anak di bawah usia lima tahun. Penyakit ini endemik di negara-negara tropis dan subtropis, di mana faktor lingkungan seperti keberadaan tempat perkembangbiakan nyamuk memainkan peran penting dalam penularannya. Upaya pengendalian bergantung pada diagnosis dini melalui mikroskopi darah, pengobatan tepat waktu, dan manajemen vektor yang kuat, meskipun tantangan terus berlanjut karena siklus hidup parasit yang kompleks dan penyebaran resistensi obat[28].

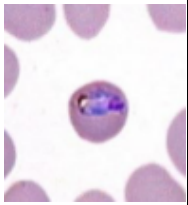
Jenis *Plasmodium* yang sering menyerang manusia adalah *Plasmodium Falciparum* dan *Plasmodium Vivax* pada area asia tenggara sendiri sampai jenis *P. falciparum* memiliki jenis penyakitnya sendiri apabila sudah mencapaitingkat keparahan yang tinggi, yaitu *Severe falciparum Malaria*[29]. Kedua jenis ini, memiliki penjelasan dan citra masing-masing dapat dilihat pada gambar 2.1 yang dapat membantu dalam proses pembuatan tugas akhir ini yang di ambil dari beberapa jurnal.

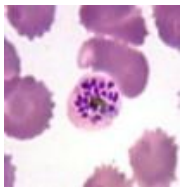
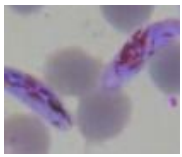
1. *Plasmodium falciparum*

P. falciparum merupakan jenis parasit orgaisme interselular yang menjadi penyebab terjadinya malaria pada daerah tropik atau malaria tropika, bentuk malaria yang paling bahaya untuk manusia[30][31]. *P. falciparum* termasuk sebagai parasit apicomplexan yang membutuhkan manusia atau inang serta vektro berupa nyamuk *anopheles* untuk membantu dalam menyebarkan dirinya serta menyelesaikan siklus hidupnya[30]. Parasit ini memiliki beberapa fase dalam siklus hidupnya, salah satunya termasuk sebagai fase darah dalam inang manusia, dimana parasit ini akan menginvasi eritrosit dan

menjalani siklus replikasi aseksual yang berulang setiap 48 jam, melewati tahap cincin, *trofozoit* dan *skizon.* Selama siklus eritrositik ini, sebagian kecil merozoit yang sedang berkembang tidak melanjutkan replikasi aseksual, tetapi berdefiriansi menjadi gametosit jantan dan betina yang termasuk sebagai tahap seksual yang esensial untuk transmisi kembali kepada nyamuk [32]. Hal ini dapat dilihat tahap perkembangannya dan karakteristik setiap fasenya pada tabel 2.1. Parasit *P. falciparum* sudah memiliki resistansi yang tinggi terhadap beberapa obat, seperti klorokuin dan artemisinin.

Tabel 2.1 Citra dan Karakteristik Fase *Parasit falciparum*[33]

Spesies	Stadium	Citra Gambar	Karakteristik
P. falciparum	Ring		Sitoplasma tipis dan halus dengan satu atau dua titik kromatin kecil. Eritrosit (RBC) yang terinfeksi tidak membesar. Infeksi ganda dalam satu RBC sering terjadi.
	Trophzoite		Jarang terlihat dalam sediaan darah perifer Merupakan perkembangan

Spesies	Stadium	Citra Gambar	Karakteristik
			dari stadium ring dengan sitoplasma lebih padat.
	Schizont		Jarang ditemukan di darah perifer. Mengandung sekitar 8–24 merozoit kecil. Pigmen gelap.
	Gametocyte		Berbentuk sabit atau seperti sosis, khas untuk P. falciparum. Kromatin berbentuk massa tunggal pada makrogametosit (betina) dan lebih menyebar pada mikrogametosit (jantan)

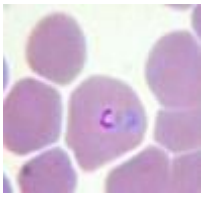
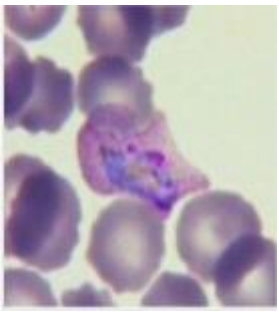
2. *Plasmodium Vivax*:

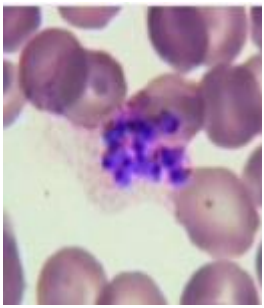
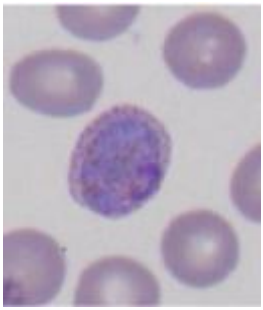
Plasmodium vivax termasuk dalam subgenus Plasmodium dan merupakan salah satu penyebab malaria tertiana, yaitu malaria dengan pola demam setiap 48 jam. Salah satu karakteristik biologis

terpentingnya adalah kemampuannya membentuk hipnozoit, yaitu bentuk dorman di dalam hepatosit (sel hati) yang dapat bertahan dalam waktu lama dan menyebabkan relaps (kekambuhan) meskipun parasit sudah tidak terdeteksi lagi di darah perifer[34]. Karena itu, terapi infeksi P. vivax tidak hanya menargetkan stadium eritrositik, tetapi juga harus mencakup eradikasi stadium hati. Dalam siklus intra-eritrositnya, P. vivax cenderung menginfeksi eritrosit muda (retikulosit), yang berkontribusi pada pembesaran sel darah merah yang terinfeksi. Parasit ini juga mulai memproduksi gametosit relatif lebih awal selama perkembangan dalam darah, sehingga potensi penularan ke nyamuk Anopheles dapat terjadi bahkan pada fase awal infeksi[34], [35].

Secara epidemiologis, infeksi *P. vivax* sangat berkaitan dengan keberadaan antigen Duffy (Duffy antigen receptor for chemokines/DARC) pada permukaan eritrosit. Individu dengan fenotipe Duffy-negatif memiliki resistensi alami terhadap sebagian besar strain P. vivax karena parasit kesulitan memasuki eritrosit tanpa reseptor tersebut[34]. Hal ini menjelaskan mengapa P. vivax jarang ditemukan di Afrika Tengah dan Afrika Barat, wilayah dengan prevalensi tinggi populasi Duffy-negatif. Secara morfologis, P. vivax memiliki ciri khas berupa pembesaran eritrosit yang terinfeksi, bentuk trofozoit yang amoeboid, serta adanya bintik Schüffner pada pewarnaan Giemsa[36]. Bentuk-bentuk perkembangan parasit dalam darah perifer meliputi stadium ring, trofozoit, skizon, dan gametosit ditampilkan pada Tabel 2.2 berikut.

Tabel 2.2 Citra Dan Karakteristik Parasit *Vivax[33]*

Spesies	Stadium	Citra Gambar	Karakteristik
P.vivax	Ring		Memiliki titik kromatin yang relatif besar. Sitoplasma dapat berkembang menjadi bentuk amoeboid seiring maturase.
	Trophozoite		Sitoplasma jelas bersifat amoeboid dengan titik kromatin besar. Tampak pigmen halus berwarna kuning kecokelatan (hemozoin).

Spesies	Stadium	Citra Gambar	Karakteristik
	Schizont		Berukuran besar dan dapat hampir memenuhi seluruh RBC yang terinfeksi. Mengandung sekitar 12–24 merozoit.
	Gametocyte		Berbentuk bulat hingga oval. Memiliki pigmen cokelat yang tersebar. Dapat hampir memenuhi RBC yang terinfeksi.

Diagnosis malaria dapat ditegakkan melalui evaluasi klinis berdasarkan tanda dan gejala seperti demam periodik, menggigil, sakit kepala, anemia, dan splenomegali. Namun, pendekatan klinis saja memiliki tingkat akurasi yang terbatas karena gejalanya sering menyerupai penyakit tropis lain, seperti demam tifoid, dengue, atau infeksi virus lainnya, serta adanya kemungkinan koinfeksi yang dapat memperburuk gambaran klinis. Oleh karena itu, konfirmasi laboratorium sangat diperlukan untuk memastikan diagnosis.

Salah satu metode diagnostik utama adalah pemeriksaan mikroskopis sediaan darah tepi, baik apus darah tipis maupun apus darah tebal. Pemeriksaan ini memungkinkan identifikasi spesies Plasmodium, penentuan stadium perkembangan parasit (ring, trofozoit, skizon, gametosit), serta estimasi tingkat parasitemi. Citra mikroskopis yang dihasilkan menjadi dasar dalam membedakan karakteristik morfologis seperti yang telah dijelaskan sebelumnya pada P. falciparum dan P. vivax.

Selain mikroskopi, tersedia juga rapid diagnostic test (RDT) berbasis deteksi antigen. Metode ini bekerja secara imunokromatografi dengan mendeteksi antigen spesifik malaria dalam sampel darah dalam jumlah kecil. Antigen yang umum ditargetkan antara lain histidine-rich protein 2 (HRP-2) yang spesifik untuk P. falciparum, serta enzim seperti parasite lactate dehydrogenase (pLDH) dan aldolase yang dapat ditemukan pada berbagai spesies Plasmodium. RDT memberikan hasil yang relatif cepat dan praktis, terutama di daerah dengan keterbatasan fasilitas laboratorium, meskipun sensitivitas dan spesifisitasnya dapat bervariasi tergantung kepadatan parasit dan variasi genetik parasit (seperti delesi gen HRP-2).

Meskipun pemeriksaan mikroskopis masih dianggap sebagai gold standard karena kemampuannya mengidentifikasi spesies dan menghitung parasitemia secara langsung, metode ini memiliki beberapa keterbatasan. Proses pemeriksaan membutuhkan waktu, ketelitian tinggi, serta tenaga analis yang terlatih, dan hasilnya dapat bersifat subjektif tergantung pengalaman pemeriksa. Variasi kualitas preparat dan pewarnaan juga dapat memengaruhi akurasi[37].

Untuk mengatasi keterbatasan tersebut, berbagai pendekatan berbasis kecerdasan buatan telah dikembangkan dalam beberapa tahun

terakhir. Algoritma ini umumnya memanfaatkan teknik pengolahan citra dan pembelajaran mesin, termasuk deep learning, untuk mengenali pola morfologis khas dari parasit P. falciparum dan P. vivax pada citra mikroskopis. Dengan sistem otomatisasi ini, proses deteksi dan klasifikasi dapat dilakukan lebih cepat, konsisten, dan berpotensi mengurangi ketergantungan pada interpretasi subjektif, sehingga mendukung peningkatan efisiensi dan akurasi diagnosis malaria di fasilitas pelayanan kesehatan.

2.3 Deep Learning

Deep learning merupakan sub-bidang khusus dari *machine learning* yang didefinisikan sebagai konsep pembelajaran mesin berbasis jaringan saraf tiruan (*artificial neural networks*)[38], [39]. Metode ini terinspirasi dari struktur dan fungsi otak manusia, menggunakan arsitektur jaringan saraf dengan banyak lapisan (*multi-layered*) untuk mempelajari pola dan representasi kompleks secara otomatis dari kumpulan data dalam skala besar[40][41].

Perbedaan mendasar antara *deep learning* dengan *machine learning* konvensional terletak pada pendekatan ekstraksi fitur. Algoritma *machine learning* dasar seringkali memiliki keterbatasan dalam menangani tugas kompleks yang melibatkan data tidak terstruktur seperti gambar, suara, dan video. Hal ini karena *machine learning* konvensional sangat bergantung pada proses rekayasa fitur (*feature engineering*) secara manual, di mana seorang ahli harus merancang dan mengekstrak fitur relevan dari data mentah sebuah proses yang memakan waktu dan tenaga[40][42]. Sebaliknya, kemampuan fundamental *deep learning* adalah secara otomatis

menemukan dan mengekstrak fitur-fitur yang dibutuhkan langsung dari data mentah, sehingga meminimalisir intervensi manusia[43].

Konsep “deep” atau "dalam" pada *deep learning* merujuk pada keberadaan banyak lapisan tersembunyi (*hidden layers*) di antara lapisan input dan output. Jaringan saraf tiruan ini terdiri dari komponen inti berupa neuron yang saling terhubung. Setiap lapisan dirancang untuk mempelajari fitur secara hierarkis: lapisan awal mungkin hanya akan mendeteksi fitur sederhana seperti tepi atau warna pada sebuah gambar, sementara lapisan yang lebih dalam akan mampu mengenali bentuk, tekstur, hingga objek yang utuh[41], [44]. Kemampuan untuk memproses informasi secara non-linear melalui banyak lapisan inilah yang memungkinkan *deep learning* unggul dalam ekstraksi fitur, identifikasi pola, dan klasifikasi[40][45].

Beberapa arsitektur model *deep learning* yang paling dikenal antara lain:

1. *Convolutional Neural Network* (CNN): Dirancang khusus untuk memproses data berbentuk grid seperti gambar. CNN sangat efektif untuk tugas-tugas visi komputer, termasuk klasifikasi dan deteksi objek.

2. *Recurrent Neural Network* (RNN): Didesain untuk data sekuensial atau data deret waktu, seperti teks atau suara. RNN memiliki "memori" untuk memproses informasi dari input sebelumnya.

3. *Transformers*: Arsitektur modern yang menggunakan mekanisme *self-attention* dan telah menjadi standar untuk

tugas-tugas pemrosesan bahasa alami (*Natural Language Processing*) yang canggih[40][46].

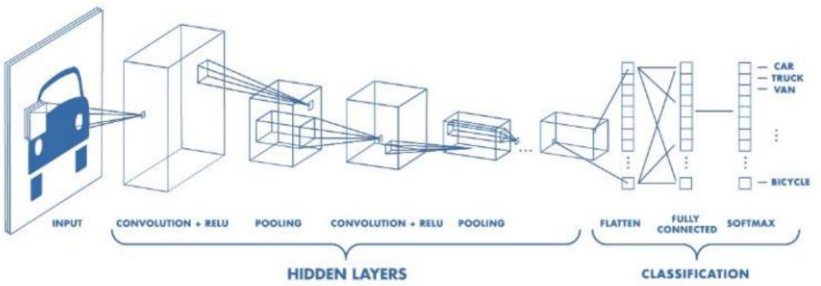
Untuk menjalankan tugasnya, *deep learning* membutuhkan data dengan volume yang sangat besar guna membangun model dengan tingkat akurasi yang tinggi. Selain itu, eksekusi pelatihan model *deep learning* juga menuntut daya komputasi yang besar. Oleh karena itu, penggunaan *Graphics Processing Unit* (GPU) menjadi sangat penting, karena GPU telah dioptimalkan secara khusus untuk mempercepat proses pelatihan model secara signifikan[47][40]. Meskipun unggul dalam performa pada data kompleks, model *deep learning* sering dianggap sebagai *"black box"* karena proses pengambilan keputusannya yang sulit ditelusuri, berbeda dengan algoritma *machine learning* tradisional yang seringkali lebih mudah diinterpretasikan[48].

2.4 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah salah satu arsitektur *deep learning* berbasis jaringan saraf tiruan (JST) yang dirancang secara khusus untuk memproses data berstruktur grid, seperti citra visual dua dimensi. Keunggulan utama CNN dibandingkan jaringan saraf konvensional (*Multi-Layer Perceptron*) terletak pada kemampuannya untuk mengekstraksi dan mempelajari representasi fitur spasial secara otomatis dan hierarkis tanpa memerlukan ekstraksi fitur manual. Berkat kemampuan ini, CNN secara luas diimplementasikan dalam berbagai tugas *computer vision*, mulai dari klasifikasi citra, segmentasi semantik, hingga deteksi objek yang kompleks [49].

Secara arsitektural, CNN dibangun oleh serangkaian lapisan (*layers*) yang saling terhubung dan terbagi menjadi dua blok fungsi

utama: *Feature Extraction Layer* (Lapisan Ekstraksi Fitur) dan *Classification Layer* (Lapisan Klasifikasi). Blok ekstraksi fitur utamanya terdiri dari *Convolutional Layer* dan *Pooling Layer* yang bertugas mengubah citra mentah menjadi peta fitur (*feature maps*). Sementara itu, blok klasifikasi umumnya terdiri dari *Fully Connected Layer* yang bertugas mengolah kumpulan fitur berdimensi tinggi tersebut menjadi probabilitas kelas keluaran.



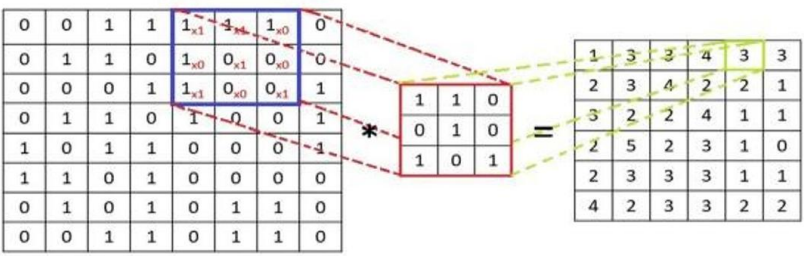
Gambar 2.3 Arsitektur CNN[50].

2.4.1 Convolutional Layer

Convolutional Layer merupakan fondasi komputasi utama dari arsitektur CNN yang bertanggung jawab untuk melakukan operasi ekstraksi fitur dari citra masukan. Lapisan ini beroperasi dengan menggeserkan sejumlah matriks filter (*kernel*) di seluruh area citra masukan untuk melakukan operasi matematika perkalian matriks secara berulang (dot product). Proses ini menghasilkan feature map yang merepresentasikan pola-pola visual tertentu, seperti garis tepi (edges), gradien warna, hingga bentuk objek yang kompleks, sambil tetap mempertahankan struktur tata letak spasial dari citra asli[49], [50].

Setiap filter di dalam *convolutional layer* hanya berinteraksi dengan sebagian kecil area dari citra pada satu waktu, yang dikenal

dengan istilah *local receptive field*. Konsep ini memungkinkan model untuk melakukan pembagian bobot (*parameter sharing*), di mana satu filter yang sama digunakan secara berulang di seluruh area gambar. Mekanisme ini tidak hanya mengurangi jumlah parameter komputasi secara drastis sehingga model menjadi lebih efisien, tetapi juga menciptakan sifat translasi invarian (*spatial invariance*). Sifat ini sangat penting dalam analisis citra mikroskopis karena memungkinkan model untuk mengenali parasit malaria terlepas dari posisinya pada kaca preparat[49], [51]. Secara matematis, lapisan konvolusi beroperasi menggunakan sebuah matriks filter (sering juga disebut sebagai *kernel*) untuk menghitung nilai konvolusi dari citra masukan dan mengekstrak fitur-fitur fundamentalnya. Filter ini memiliki dimensi yang lebih kecil dibandingkan citra asli, namun memuat parameter bobot (*weights*) yang akan terus diperbarui selama proses pelatihan. Untuk memahami bagaimana ekstraksi fitur ini terjadi secara spasial, ilustrasi komputasi sederhana dari operasi konvolusi dapat dilihat pada Gambar 2.4.



Gambar 2.4 Proses Komputasi Convolutional Layer[50].

Berdasarkan Gambar 2.4, mekanisme ekstraksi fitur dimulai ketika matriks filter meluncur (*sliding*) setahap demi setahap melintasi matriks piksel citra masukan. Pada setiap pergeserannya, jaringan menghitung perkalian titik (*dot product*) antara nilai bobot pada filter

dengan nilai intensitas piksel citra yang berada tepat di bawahnya, kemudian menjumlahkannya. Rangkaian proses matematis ini menghasilkan sebuah matriks dua dimensi baru yang dikenal sebagai *Activation Map* atau peta aktivasi. Hasil dari operasi konvolusi selanjutnya dilewatkan ke dalam sebuah fungsi aktivasi non-linier untuk menentukan apakah informasi fitur tersebut cukup kuat untuk diteruskan ke lapisan berikutnya[52]–[54]. Salah satu fungsi aktivasi yang paling dominan digunakan adalah *Rectified Linear Unit* (ReLU). ReLU sangat populer karena struktur matematisnya yang sederhana, yaitu mengubah semua nilai input negatif menjadi nol dan membiarkan nilai positif tetap sama (Persamaan 2.1). Hal ini membuat waktu komputasi menjadi sangat cepat dan membantu mempercepat konvergensi gradien selama proses pelatihan [53], [55].

$$\psi(x) = \begin{cases} 0 & \text{if } x < 0, \\ x & \text{if } x \geq 0 \end{cases} \qquad (2.1)$$

Dalam praktiknya, ketika operasi konvolusi diterapkan pada citra, ukuran dimensi spasial dari *feature map* yang dihasilkan cenderung akan menyusut secara bertahap. Hal ini dapat menyebabkan hilangnya informasi spasial penting yang berada di tepi gambar (piksel perbatasan). Untuk menanggulangi masalah ini, CNN menerapkan teknik *padding*, yaitu penambahan deretan piksel semu (biasanya bernilai nol, atau *zero-padding*) di sekeliling batas luar citra masukan sebelum operasi konvolusi dilakukan. Teknik ini memastikan bahwa setiap piksel, termasuk yang berada di tepi, mendapatkan kesempatan komputasi yang sama[56], [57], [58].

2.4.2 Pooling Layer

Pooling Layer atau lapisan *subsampling*, umumnya disisipkan di antara dua *convolutional layer* yang berurutan. Lapisan ini berfungsi untuk mereduksi dimensi spasial (tinggi dan lebar) dari peta fitur secara progresif, tanpa mengubah kedalaman (jumlah saluran/filter) dari peta fitur tersebut[59]. Reduksi ini krusial untuk menekan jumlah parameter dan beban komputasi secara keseluruhan, sekaligus mencegah terjadinya *overfitting*, yaitu suatu kondisi di mana model menghafal data latih namun gagal berkinerja baik pada data baru[60], [61]. Peta fitur (*feature map*) yang dihasilkan oleh *convolutional layer* seringkali masih memiliki sensitivitas yang tinggi terhadap lokasi persis dari sebuah fitur di dalam citra. Untuk mengatasi sensitivitas tersebut dan mengurangi beban komputasi, arsitektur CNN umumnya menyisipkan *Pooling Layer* untuk melakukan *downsampling* (pengurangan dimensi spasial tinggi dan lebar). Berbeda dengan lapisan konvolusi, operasi pada *pooling layer* murni menggunakan fungsi matematika sederhana dan sama sekali tidak melibatkan parameter bobot yang dapat dipelajari (*learnable weights*).

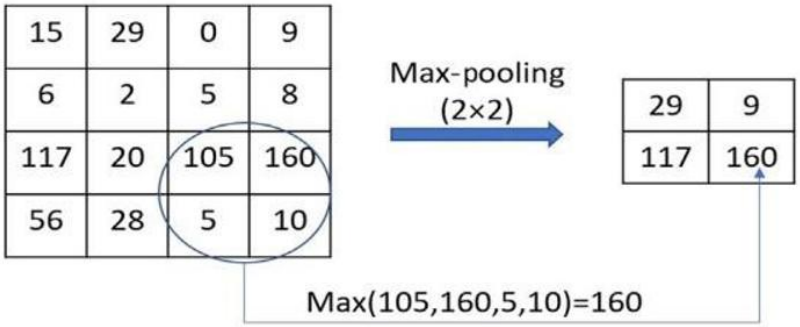
Secara teknis, operasi *downsampling* di dalam lapisan ini diatur oleh dua parameter utama, yaitu:

1. Filter Size (Ukuran Kernel): Menentukan seberapa luas area spasial pada peta fitur (misalnya matriks berukuran 2x2 piksel) yang akan diringkas atau disederhanakan menjadi satu nilai representasi tunggal.

2. Stride (Langkah Geser): Menentukan jarak pergeseran kernel saat memindai area peta fitur. Penggunaan matriks 2x2 dengan *stride* bernilai 2 akan menghasilkan area pemindaian yang

saling tidak tumpang tindih (*nonoverlapping*), sehingga dimensi citra akan menyusut tepat menjadi setengah dari ukuran aslinya[50], [62], [63].

Dua operasi matematis yang paling umum digunakan dalam proses *pooling* adalah *Max Pooling* (mengambil nilai tertinggi) dan *Average Pooling* (mengambil nilai rata-rata), seperti yang diilustrasikan pada Gambar 2.5.



Gambar 2.5 Proses Perhitungan Pooling Layer

Berdasarkan visualisasi komputasi pada Gambar 2.5, pada operasi Max Pooling, filter mengevaluasi sekumpulan piksel dalam area cakupannya dan hanya mengekstrak nilai piksel yang paling tinggi. Dalam konteks deteksi citra mikroskopis malaria, *Max Pooling* sangat direkomendasikan karena kemampuannya dalam menonjolkan fitur-fitur yang paling tajam dan dominan, seperti bercak kromatin pekat pada *Plasmodium* atau batas tepi dinding sel darah, sambil mengabaikan *noise* di latar belakang. Sebaliknya, operasi Average Pooling menghitung nilai rata-rata dari seluruh piksel dalam area cakupan, yang menghasilkan representasi fitur yang secara visual lebih halus (*smooth*)[50], [64]

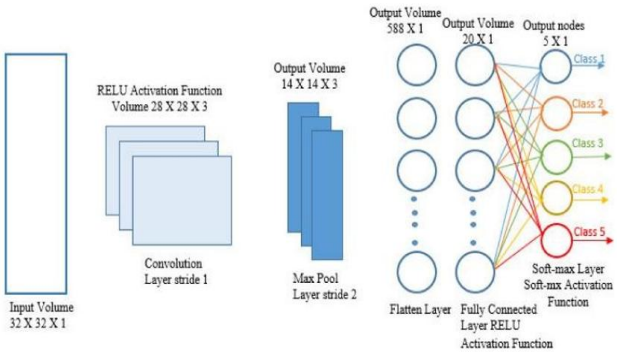
Penyusutan dimensi spasial melalui *pooling layer* ini memberikan dampak yang sangat signifikan terhadap ketahanan (*robustness*) model. Dalam dimensi peta fitur yang lebih kecil dan padat, lokasi fitur parasit cenderung menjadi tetap dan stabil (*translation invariance*) meskipun posisi objek parasit tersebut bergeser, terputar, atau sedikit berbeda orientasinya pada citra masukan. Lebih lanjut, peta fitur yang telah mengalami proses *pooling* (sering disebut *pooled feature map*) memiliki karakteristik yang identik dengan peta konvolusi, yaitu tersusun atas neuron-neuron. Namun, karena lapisan ini tidak dilengkapi dengan fungsi aktivasi (seperti ReLU), nilai matematis hasil ekstraksi *Max* atau *Average* secara otomatis dan langsung merepresentasikan nilai keluaran (*output*) dari neuron pada *pooling layer* tersebut untuk diteruskan ke tahap klasifikasi[52], [61], [65].

2.4.3 Fully Connected Layer

Setelah citra masukan melewati serangkaian *Convolutional Layer* dan *Pooling Layer*, arsitektur CNN pada umumnya akan diakhiri dengan satu atau lebih *Fully Connected Layer* (FC Layer)[49], [51]. Jika lapisan-lapisan sebelumnya bertindak sebagai ekstraktor fitur hierarkis yang mengidentifikasi pola visual secara spasial, maka FC Layer berfungsi sebagai unit penalaran (*reasoning unit*) dan pengambil keputusan akhir. Dinamakan "terhubung penuh" karena setiap neuron pada lapisan ini memiliki koneksi langsung yang berbobot (*weighted connection*) dengan seluruh neuron yang ada pada lapisan sebelumnya, mengadopsi struktur jaringan saraf tiruan tradisional (*Multi-Layer Perceptron*)[66].

1. Transisi Dimensi (*Flattening*)

Sebelum data dapat diproses oleh FC Layer, terdapat sebuah proses transisi krusial yang disebut *flattening*. Peta fitur keluaran dari *pooling layer* terakhir masih berupa matriks tiga dimensi (tinggi x lebar x kedalaman saluran). Proses *flattening* meruntuhkan struktur spasial tersebut dan meratakannya menjadi sebuah susunan vektor fitur satu dimensi (1D).



Gambar 2.6 Proses Flattening dan Koneksi pada Fully Connected Layer[50].

Sebagaimana diilustrasikan pada Gambar 2.6, sebelum dapat diproses oleh *Fully Connected Layer*, peta fitur (*feature map*) keluaran dari *pooling layer* terakhir yang masih berupa matriks tiga dimensi harus diruntuhkan struktur spasialnya. Melalui proses *flattening*, nilai-nilai tersebut diratakan menjadi sebuah susunan vektor fitur satu dimensi (1D)[67]. Vektor 1D hasil *flattening* ini tidak lagi merepresentasikan piksel di koordinat X dan Y, melainkan telah menjadi representasi abstrak matematis tingkat tinggi yang siap dikalikan dengan bobot (*weights*) jaringan untuk dievaluasi probabilitas kelasnya[66][68].

2. Komputasi Matematis dan Probabilitas Kelas

Di dalam FC Layer, operasi matematis yang terjadi adalah perkalian titik (*dot product*) antara vektor input dengan matriks bobot jaringan, ditambahkan dengan nilai bias, lalu dilewatkan pada fungsi aktivasi akhir. Untuk tugas klasifikasi multikelas (misalnya membedakan *Plasmodium falciparum*, *Plasmodium vivax*, atau sel sehat), lapisan *output* paling ujung biasanya menggunakan fungsi aktivasi *Softmax*[69]. Fungsi Softmax bertugas mengonversi nilai numerik mentah (*logits*) dari neuron menjadi distribusi probabilitas dengan rentang nilai 0 hingga 1, di mana total seluruh probabilitas kelas akan berjumlah 1 (100%). Hal ini memungkinkan model untuk memberikan prediksi yang dapat diinterpretasikan secara statistik, misalnya: model yakin 88% bahwa objek yang terdeteksi adalah *P. vivax* dan 12% kemungkinan berupa artefak[70], [71].

3. Kompleksitas Parameter dan Teknik Regularisasi (*Dropout*)

Salah satu kelemahan fundamental dari *Fully Connected Layer* (FC Layer) adalah beban komputasi yang sangat ekstrem akibat kuantitas parameter yang masif. Sebagai ilustrasi, apabila peta fitur terakhir memiliki dimensi spasial 7 x 7 x 512, proses *flattening* akan mengonversinya menjadi sebuah vektor berukuran 25.088 elemen[72]. Jika FC Layer pertama dirancang memiliki 4.096 neuron, maka model harus menghitung lebih dari 102 juta koneksi bobot (*weights*) hanya pada satu lapisan tersebut[73]. Meskipun kapasitas parameter yang besar ini memungkinkan model untuk mempelajari detail fitur mikroskopis sel darah yang sangat kompleks, kondisi ini juga memicu kerentanan jaringan terhadap *overfitting*. *Overfitting* merupakan suatu anomali di mana model kehilangan kemampuan generalisasinya karena

hanya "menghafal" data latih, sehingga akurasinya akan menurun drastis saat dihadapkan pada citra baru[74].

Untuk memitigasi risiko tersebut, teknik regularisasi seperti *Dropout* secara lazim diterapkan pada FC Layer. Mekanisme *Dropout* beroperasi dengan cara menonaktifkan (memutus koneksi) sejumlah neuron secara acak pada persentase tertentu misalnya 50% di setiap siklus iterasi pelatihan[75]. Pendekatan ini mencegah jaringan saraf agar tidak terlalu bergantung pada satu atau dua jalur koneksi spesifik tertentu, serta memaksa model untuk mendistribusikan pembelajarannya secara merata ke seluruh neuron. Hasilnya, model deteksi menjadi jauh lebih tangguh (*robust*) dan tetap akurat ketika diuji menggunakan data citra sediaan darah baru yang belum pernah diobservasi sebelumnya[68], [73], [76].

2.4.4 Arsitektur CNN

Convolutional Neural Network telah menjadi landasan struktural yang mendorong evolusi berbagai algoritma pendeteksi objek modern. Dalam perkembangannya, arsitektur dasar CNN telah dimodifikasi dan dikembangkan menjadi berbagai model mutakhir yang dirancang untuk menyeimbangkan antara tingkat akurasi dan efisiensi komputasinya [77][78].

Secara umum, arsitektur pendeteksi objek berbasis CNN terbagi menjadi dua kategori utama: model *two-stage detector* seperti Faster R-CNN yang memisahkan proses pencarian lokasi objek dan klasifikasi, serta model *one-stage detector* seperti YOLO (*You Only Look Once*), SSD (*Single Shot MultiBox Detector*), dan *EfficientDet* yang melakukan lokalisasi dan klasifikasi secara simultan dalam satu jaringan utuh[79].

Perbedaan pendekatan arsitektural ini menghasilkan karakteristik kinerja yang bervariasi ketika diuji pada dataset citra beresolusi tinggi, termasuk dalam tugas analisis citra medis mikroskopis. Beberapa studi komparatif terkini (2020-2026) yang mengkaji performa berbagai arsitektur deteksi objek mulai dari generasi awal hingga literasi paling mutakhir seperti YOLOv11 dan YOLOv12 menunjukkan pola perbandingan metrik evaluasi seperti yang dirangkum pada Tabel 2.3 [80], [81].

Tabel 2.3 Rangkuman Performa Metrik Arsitektur

Arsitektur	Precision	Recall	mAP@0.5
YOLOv4	0.82	0.81	0.82
YOLOv5	0.85	0.84	0.86
YOLOv7	0.87	0.86	0.87
YOLOv8	0.89	0.88	0.89
YOLOv11	0.91	0.90	0.91
YOLOv12	0.93	0.91	0.92
Faster R-CNN	0.88	0.85	0.86
SSD	0.78	0.75	0.76
EfficientDet	0.84	0.82	0.83

Berdasarkan Tabel 2.3, dapat diamati bahwa keluarga arsitektur YOLO secara konsisten menunjukkan peningkatan performa dari generasi ke generasi. Varian *state of the art* terbaru seperti YOLOv11

dan YOLOv12 mencatatkan tingkat akurasi puncak melampaui 90%, yang didorong oleh optimasi modul *attention* tingkat lanjut dan efisiensi *parameter sharing*. Kendati demikian, YOLOv8 tetap mempertahankan posisinya sebagai *milestone* yang paling signifikan dalam arsitektur deteksi objek. Dengan adopsi *anchotr free detection* dan nilai mAP mencapai 0.89, YOLOv8 dinilai sebagai arsitektur yang paling teruji validitas dan stabilitasnya secara luas untuk berbagai implementasi sistem medis nyata, jika dibandingkan dengan versi-versi eksperimental terbarunya [62],[82].

Selain akurasi, elemen fundamental lain yang menjadi tolok ukur implementasi sistem deteksi terutama untuk kebutuhan diagnosis klinis yang bersifat *real time* adalah kecepatan pemrosesan model atau *Frame Per Second* (FPS). Perbandingan efisiensi komputasi dari masing-masing arsitektur disajikan pada Tabel 2.4.

Tabel 2.4 Rata-rata Kecepatan Pemrosesan Arsitektur

Arsitektur	Rata-rata FPS
YOLOv4	45
YOLOv5	60
YOLOv7	55
YOLOv8	65
YOLOv11	72
YOLOv12	78
Faster R-CNN	12

SSD	38

Data kecepatan komputasi pada Tabel 2.2 menegaskan kelemahan utama dari arsitektur *two-stage* seperti Faster R-CNN, yang hanya mencatatkan 12 FPS sehingga kurang ideal untuk analisis *real-time*. Di sisi lain, generasi YOLOv8 hingga YOLOv12 mendominasi ranah inferensi berkecepatan tinggi. Rentang kecepatan 65 hingga 78 FPS membuktikan bahwa pembaruan pada blok konvolusi internal YOLO sukses menyeimbangkan antara tingginya akurasi diagnosis medis dengan rendahnya latensi inferensi [62].

Untuk memberikan analisis yang lebih komprehensif, performa sebuah arsitektur juga harus ditinjau dari profil kesalahan (*error profile*) yang dihasilkannya selama proses deteksi objek. Tabel 2.3 membedah tingkat persentase kegagalan model dalam tiga kategori utama: *Partially Detected*,*Misclassified*, dan *Missed*.

Tabel 2.5 Analisis Persentase *Error* Deteksi

Arsitektur	**Partially Detected**	**Misclassified**	**Missed**
YOLOv4	12%	8%	9%
YOLOv5	10%	6%	7%
YOLOv7	8%	5%	6%
YOLOv8	5%	3%	4%
YOLOv11	4%	2%	3%

YOLOv12	3%	2%	2%
Faster R-CNN	7%	4%	8%
SSD	15%	11%	10%
EfficientDet	11%	8%	8%

Objek parasit mikroskopis seperti *Plasmodium* sangat rentan mengalami klasifikasi silang (*misclassification*) dengan artefak kotoran pada kaca preparat. Merujuk pada Tabel 2.3, seri arsitektur YOLO terbaru sukses menekan angka *missed detection* hingga di bawah 5%. Hal ini sangatlah krusial, karena metrik *False Negative* yang rendah merupakan syarat mutlak agar sebuah sistem dapat digunakan untuk memvalidasi tingkat kepadatan parasit pasien di puskesmas atau laboratorium klinik.

Secara keseluruhan, komparasi ini memperkuat justifikasi bahwa keluarga arsitektur YOLO (khususnya YOLOv8 yang telah sangat stabil dan tervalidasi luas) merupakan landasan algoritma yang paling rasional dan andal untuk dikembangkan dalam sistem diagnosis otomatis sediaan darah malaria [12], [62], [82].

2.5 Algoritma YOLO (*You Only Look Once*)

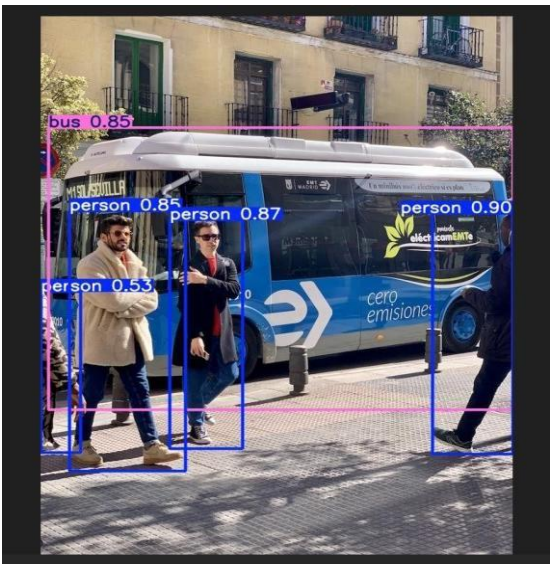
Algoritma *You Only Look Once* (YOLO) termasuk sebagai salah satu algoritma yang sangat populer dalam mendeteksi objek, gambar, serta visi komputer. Kemampuan YOLO dalam melakukan deteksi objek atau gambar secara *real-time* memiliki tingkat akurasi yang tinggi. Maka oleh karena itu, penggunaan YOLO menjadi pilihan utama untuk mayoritas dalam berbagai aplikasi modern. YOLO sendiri

sudah mengeluarkan berbagai versi dimulai dengan YOLOv1 hingga YOLOv12. Setiap versi YOLO membawa peningkatan yang signifikan dalam kecepatan, akurasi, serta efisiensi dalam proses training, tentu juga memberikan berbagai fitur tambahan dalam proses deteksi objek[83], [84].

Penggunaan YOLO dapat menghasilkan bounding box yang dapat memperkirakan keberadaan objek secara kotak, kecuali YOLO versi awal. Hal ini diikuti oleh klarifikasi dengan CNN untuk menentukkan keberadaan objek dalam *bounding box* tersebut. YOLO sendiri menggunakan pendekatan berbeda, yaitu hanya menggunakan CNN hanya satu kali untuk memprediksi semua jenis objek yang ada dalam *bounding box* tersebut dan membagikan gambar menjadi grid S x S, Dimana setiap sel bertanggung jawab dalam memprediksi *bounding boxes*, tingkat *confidence* dari masing-masing sel dan probabilitas kelas serta ukuran grid (S) dari gambar tersebut [12], [85].

Mekanisme kerja YOLO dalam mendeteksi objek atau gambar dimulai dengan gambar *input* dibagi menjadi *grid* S x S. Setiap sel *grid* memiliki tanggung jawab untuk memprediksi objek yang pusatnya jatuh dalam sel tersebut. Dalam proses deteksi YOLO area atau *box* yang lebih terang pada gambar *input* memiliki tingkat probabilitas deteksi yang lebih tinggi untuk menentukkan objek kelas yang sesuai. Benda yang berada dalam sel tersebut akan menghasilkan *heatbox* dari area Lokasi objek. Setelah memprediksi *bounding box* dan *confident score*, YOLO menghasilkan banyak kotak dengan tingkat *overlapping* yang tinggi. NMS (*Non-Maximum Suppresion*) menghasilkan kotak yang *overlapping* atau tumpeng tinggi dengan memilih kotak skor kepercayaan tinggi. Dalam Gambar 2. (Isi) terlihat berbagai kotak

warna-warni atau prediksi awal YOLO yang difilter menjadi lebih sedikit. Akhirnya, algoritm menghasilkan deteksi final berupa bounding box dengan skor kepercayaan tinggi yang lolos proses NMS[86], [87].

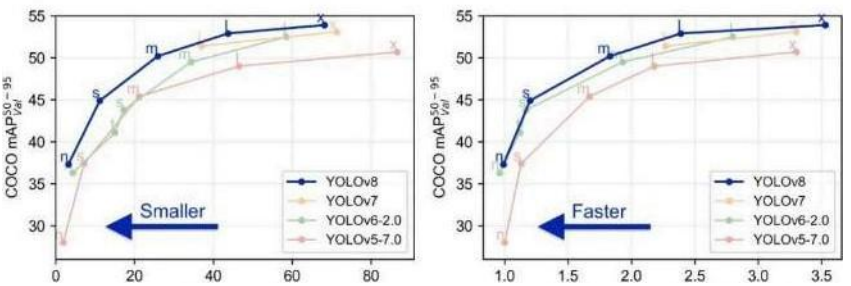


Gambar 2.7 Ilustrasi Hasil Deteksi YOLO [87].

Dalam konteks Gambar 2.7 terlihat berbagai kotak warna-warni yang merupakan prediksi awal di filter menjadi sedikit. Yang dimana akhirnya algoritma akan menentukkan deteksi final berupa bounding box dengan tingkat kepercayaan terhadap hasil gambar.

Model YOLOv8 masih termasuk sebagai model evolusi yang baru dari algoritma deteksi objek *You Only Look Once*, model YOLO ini memberikan kemampuan untuk mendeteksi virus-virus yang ada dalam *slide* darah merah tebal. Dengan memberikan arsitektur yang lebih efisien dan akurat dibandingkan model-model YOLO sebelumnya, YOLOv8 dapat mendeteksi perbedaan antara virus *falciparum* dan virus *vivax* dalam *slide* darah merah tebal, sel darah

merah, dan sel darah putih. Kemampuan model ini dalam mendeteksi virus memungkinkan pengamatan secara lanjut atas perbedaan bentuk-bentuk virus yang mungkin tidak dapat terdeteksi oleh manusia secara langsung dan membantu dalam proses deteksi secara langsung atau *real-time*[87].



Gambar 2.8 Perbandingan YOLOv8 Dengan Versi-Versi Sebelumnya[88].

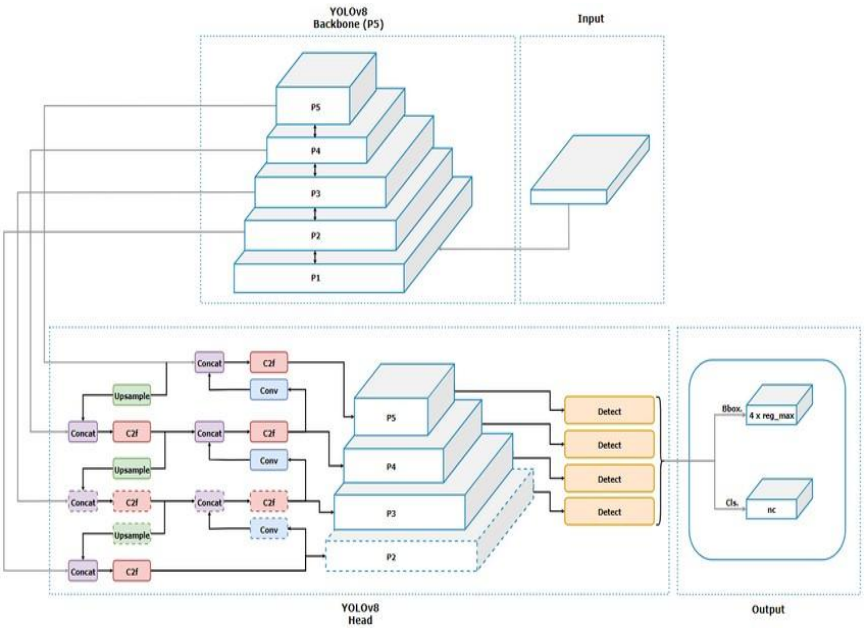
Gambar 2.8 menunjukkan perbedaan efektivitas YOLOv8 dengan yang sebelumnya (YOLOv7, YOLOv6, dan YOLOv5) yang dilatih semua pada gambar resolusi 640, dimana berdasarkan gambar itu menjelaskan bahwa YOLOv8 memberikan hasil yang lebih akurat dan memberikan persisi yang lebih baik daripada yang sebelumnya menggunakan parameter-parameter yang sama. Di dalam YOLOv8 ada beberapa fitur yang baru dan lebih baik dibandingkan YOLO versi sebelumnya:

1. Meningkatnya akurasi serta kecepatan dibandingkan dengan versi YOLO sebelumnya.

2. *Backbone* yang telah diperbarui dengan perubahan modul C3 menjadi C2f (*Cross Stage Partial Bottleneck* dengan 2 konvolusi). Modul ini menggantikan modul C3 dengan mengoptimalisasikan aliran gradien dan menangkap fitur tingkat tinggi secara lebih efisien.

3. Menambah modul fusi fitur (*Neck)* yang di optimalkan untuk integrasi informasi atau data spasial dalam berbagai dimensi.

4. Melakukan transisi terhadap sistem deteksi *Anchor-free* (tanpa kotak jangkar) sehingga dapat membuat model menjadi lebih fleksibel dalam proses memprediksi pusat objek dengan berbagai ukuran[84], [89].



Gambar 2.9 Arsitektur YOLOv8 [90].

Berdasarkan Gambar 2.9, arsitektur YOLOv8 secara fundamental dibangun atas tiga komponen utama, yaitu *Backbone*, *Neck*, dan *Head*. Masing-masing komponen memiliki peran spesifik dalam memproses citra masukan hingga menghasilkan prediksi deteksi akhir yang akurat. Berikut adalah rincian dari masing-masing komponen:

a. Backbone

Backbone merupakan bagian awal dari arsitektur yang bertugas sebagai pengekstraksi fitur (*feature extractor*) dari citra *input* sediaan darah mikroskopis. Berbeda dengan versi sebelumnya, YOLOv8 memodifikasi arsitektur CSPDarknet dengan memperkenalkan modul C2f (*Cross Stage Partial Bottleneck with 2 convolutions*).

1. Modul C2f

Modul ini menggantikan modul C3 pada YOLOv5, yang dirancang untuk memperkaya aliran informasi gradien (*gradient flow*) sekaligus menjaga agar komputasi tetap ringan.

2. SPPF (*Spatial Pyramid Pooling Fast)*

SPPF berada di bagian belakang dari backbone, dimana modul ini berfungsi untuk mengumpulkan fitur atau *pooling* spasial dari berbagai ukuran dan menghubungkannya agar model mampu mengenali objek tanpa dipengaruhi oleh variasi ukuran citra yang digunakan atau data yang digunakan.

b. Neck

Bagian tengah arsitektur YOLOv8, yang secara teknis disebut sebagai *Neck*, berfungsi sebagai jembatan integrasi fitur antara *Backbone* dan *Head*. Struktur *Neck* pada YOLOv8 mengadopsi evolusi dari konsep FPN (*Feature Pyramid Network*) dan PANet (*Path Aggregation Network*) yang bertujuan untuk melakukan ekstraksi fitur secara multi-skala. Bagian ini sangat krusial dalam deteksi parasit malaria karena objek target memiliki variasi ukuran yang signifikan, mulai dari stadium *ring* yang sangat kecil hingga gametosit yang lebih besar [84], [91].

Proses Integrasi fitur pada *neck* YOLOv8 dilakukan dengan melalui 2 aliran informasi utama, yaitu:

1. Jalur *Top Down*

Aliran *Top-Down* bertujuan untuk menyebarkan informasi semantik tingkat tinggi (fitur abstrak) dari lapisan *Backbone* yang lebih dalam ke peta fitur (*feature maps*) yang memiliki resolusi spasial lebih tinggi. Proses ini melibatkan operasi *upsampling* untuk menyamakan dimensi spasial peta fitur. Melalui jalur ini, detail visual pada citra sediaan darah diperkaya dengan pemahaman kontekstual mengenai karakteristik morfologi parasit, sehingga model dapat membedakan antara artefak kotoran mikroskopis dengan parasit yang sesungguhnya [80], [91].

2. Jalur *Bottom Up*

Sedangkan, jalur *bottom up* memperkuat pelokalan objek dengan membawa informasi spasial yang memiliki tingkat persisi yang tinggi. Proses integrasi ini dilakukan dengan operasi *concatenation* (*Concat*), dimana fitur dari *backbone* digabungkan secara langsung dengan fitur *upscaling*. Penggabungan ini bertujuan untuk memastikan informasi tekstur halus dari membran sel darah dan parasite tetap terjaga meskipun melewati banyak lapisan konvolusi [91], [92].

3. Peran Modul C2f dalam *Neck*

Pada YOLOv8, efisiensi fusi fitur ditingkatkan melalui penggunaan modul C2f (*Cross Stage Partial Bottleneck with 2 convolutions*). Di bagian *Neck*, modul C2f dikonfigurasi dengan parameter *shortcut = false*. Penghapusan koneksi *shortcut* pada bagian ini bertujuan untuk menyaring informasi dan mengurangi redundansi

data sebelum diteruskan ke bagian *Head*. Implementasi modul C2f dengan nilai kedalaman (*n*) yang bervariasi memungkinkan jaringan untuk melakukan pengolahan fitur secara non-linear tanpa menambah beban komputasi yang berlebihan, yang sangat penting untuk mempertahankan kecepatan inferensi [12], [80].

c. *Head*

Komponen terakhir pada sisi kanan Gambar 2. adalah *Head*, yang memiliki peran vital dalam merumuskan hasil akhir deteksi. YOLOv8 menerapkan struktur *Decoupled Head*, yang memisahkan tugas prediksi menjadi dua cabang paralel: cabang klasifikasi dan cabang regresi kotak pembatas atau *bounding box*. Pemisahan ini dilakukan untuk meminimalisir konflik antara tugas klasifikasi objek dan penentuan lokasi presisi, yang terbukti meningkatkan akurasi deteksi pada objek medis yang padat [91].

Blok *Detect* pada bagian *Head* beroperasi pada tiga skala resolusi yang berbeda guna menjamin fleksibilitas deteksi terhadap variasi ukuran parasit:

1. Skala P3 (80×80×256) : Digunakan untuk mendeteksi objek berukuran kecil (*small objects*) melalui resolusi spasial yang tinggi.
2. Skala P4 (40×40×512) : Digunakan untuk deteksi objek berukuran sedang (*medium objects*).
3. Skala P5 (20×20×512) : Digunakan untuk deteksi objek berukuran besar (*large objects*) dengan fitur semantik yang lebih kuat [12], [92].

Lebih jauh lagi, secara arsitektural meskipun tidak dijabarkan secara rinci pada diagram tingkat tinggi tersebut kinerja YOLOv8 ditopang oleh beberapa modul pemrosesan internal yang menjadi fondasi jaringannya. Berdasarkan literatur resmi Ultralytics, arsitektur ini dibangun berdasarkan referensi [12],[91] :

a. Modul *Conv*: Terdiri dari operasi konvolusi standar yang diikuti oleh *Batch Normalization* dan aktivasi *SiLU* untuk menstabilkan ekstraksi fitur sel darah.

b. Modul *Bottleneck*: Menerapkan struktur residual dengan koneksi *skip* untuk menjaga integritas informasi spasial parasit pada lapisan yang sangat dalam.

c. Modul SPPF (*Spatial Pyramid Pooling - Fast*): Berfungsi mengekstraksi fitur multi-skala secara efisien sebelum aliran data masuk ke bagian *Neck.*

d. Modul C2f (*Cross Stage Partial Fusion*): Evolusi dari modul terdahulu yang secara strategis menggabungkan *bottleneck* untuk menciptakan representasi fitur malaria yang kaya namun tetap efisien secara komputasi sehingga memungkinkan deteksi secara *real-time*.

Tabel 2.6 Detail Fungsi Blok Komponen Arsitektur YOLOv8 [12], [80], [84], [91]–[93].

Blok Komponen	Keterangan
Backbone	Bagian dasar jaringan yang berfungsi sebagai pengekstraksi fitur (feature extractor) utama. Penggunaan modul C2f (Cross Stage Partial

Blok Komponen	Keterangan
	Bottleneck with 2 convolutions) memungkinkan model untuk menangkap informasi gradien yang lebih kaya dan detail morfologi parasit pada sediaan darah tanpa meningkatkan beban komputasi secara signifikan.
Spatial Pyramid Pooling - Fast	Lapisan yang berfungsi mengumpulkan fitur spasial dari berbagai ukuran (*receptive fields*) melalui operasi pooling yang cepat. Komponen ini memastikan model memiliki pemahaman konteks global terhadap citra mikroskopis sebelum data diteruskan ke bagian fusi fitur.
Neck	Bertindak sebagai jembatan integrasi fitur yang menggabungkan informasi detail spasial tingkat rendah dengan informasi semantik tingkat tinggi melalui jalur *Top-Down* dan *Bottom-Up*. Struktur ini sangat krusial untuk mempertahankan eksistensi fitur parasit yang berukuran sangat kecil.
Upsample & *Concat*	Operasi untuk meningkatkan resolusi spasial (*Upsampling*) dan menggabungkan peta fitur dari lapisan berbeda (*Concatenation*). Hal ini membantu menjaga resolusi detail visual agar parasit stadium ring atau titik kecil lainnya tidak terabaikan selama proses konvolusi yang dalam.

Blok Komponen	Keterangan
Decoupled Head	Bagian akhir jaringan yang memisahkan tugas prediksi menjadi dua cabang paralel: klasifikasi (cls) untuk menentukan jenis parasit dan regresi (bbox) untuk menentukan posisi kotak pembatas. Pemisahan ini meningkatkan akurasi karena setiap tugas dapat dioptimalkan secara mandiri.
Anchor Free Mechanism	Metode deteksi objek yang memprediksi pusat parasit secara langsung tanpa menggunakan kotak jangkar (*anchor boxes*) yang kaku. Pendekatan ini membuat model lebih fleksibel dalam mengenali berbagai bentuk dinamis parasit malaria, terutama pada stadium amoeboid.
Loss Function	Komponen penghitung galat yang terdiri dari *Binary Cross Entropy* untuk akurasi kelas, *Complete IoU* untuk presisi geometri kotak pembatas, dan *Distribution Focal Loss* untuk memperhalus estimasi batas objek, terutama pada area parasit yang padat atau saling tumpang tindih.

Dalam proses penlaian keberhasilan deteksi untuk YOLOv8 dilakukan dengan menentukkan beberapa metrics penting yang dapat menjadi tolak ukur keberhasilan kinerja model. Berikut ada beberapa parameter atau *metrics* yang harus diperhatikan :

1. mAP (*mean Average Precision)* tinggi

mAP merupakan metrik evaluasi paling komprehensif untuk mengukur performa model deteksi objek. Metrik ini mengkalkulasi area di bawah kurva *Precision-Recall* pada nilai ambang batas *Intersection over Union* (IoU) tertentu. Ada mAP@0.5 (mAP50): Mengukur akurasi deteksi dengan syarat *bounding box* prediksi memiliki tumpeng tindih seminimalnya 50% dengan *ground truth*. Untuk deteksi sel darah dan parasite malaria mikroskopis, pencapaian mAP50% diatas 85% sampai dengan 90% sudah dapat dianggap sebagai standar kinerja yang bagus dan siap untuk diuji lapangan atau klinis[84]. Lalu ada mAP@0.5:0.95: mAP ini mengukur rata-rata persisi dari ambang batas IoU 50% sampai dengan 95% dengan interval 5%. Metrik ini bertujuan untuk menunjukkan seberapa persisi model membingkai bentuk parasit yang tidak beraturan secara geometris [91]

2. Analisis *Confussion metrics* tinggi

Berbeda dengan deteksi objek umum, deteksi parasit malaria menuntut keseimbangan yang ketat untuk meminimalisir kesalahan diagnosis (*misdiagnosis*). Kinerja ini diukur melalui *precision, recall,* dan *F1-Score* menunjukkan bahwa model memiliki kemampuan yang baik dalam proses deteksi dan mengklarifikasikan objek yang benar. Nilai akurasi dan *F1-Score* diatas 80% dianggap menunjukkan performa yang sangat baik [92], [93].

2.6 *Hyperparameter*

Hyperparameter merupakan variabel konfigurasi eksternal yang nilainya ditentukan secara manual sebelum proses pelatihan (*training*) dimulai. Berbeda dengan parameter internal, seperti bobot dan bias, yang diperbarui secara otomatis oleh jaringan selama pelatihan, *hyperparameter* berfungsi untuk mengontrol perilaku

keseluruhan algoritma pembelajaran. Dalam arsitektur YOLOv8, pemilihan kombinasi *hyperparameter* yang tepat sangat krusial untuk memastikan model mampu mengekstraksi fitur parasit malaria dengan tingkat presisi yang tinggi secara efisien [91].

Salah satu parameter paling esensial dalam proses optimasi ini adalah *initial learning rate* (lr0) yang bekerja beriringan dengan fungsi *optimizer*. *Learning rate* menentukan besarnya langkah pembaruan bobot model pada setiap iterasi berdasarkan gradien fungsi kerugian (*loss function*). Penggunaan *optimizer* AdamW (*Adam with Weight Decay Fix*) menuntut penentuan *learning rate* yang sangat presisi. Nilai *learning rate* yang terlalu tinggi dapat menyebabkan fluktuasi yang ekstrem sehingga model gagal mencapai konvergensi dan justru melewati titik minimum global. Sebaliknya, nilai yang terlalu rendah akan menyebabkan proses konvergensi berjalan sangat lambat dan rentan membuat model terjebak pada area minimum lokal [49], [96].

Selain *learning rate*, pengaturan *batch size* dan jumlah *epoch* juga memegang peranan penting dalam menyeimbangkan stabilitas dan efisiensi komputasi. *Batch size* menentukan jumlah sampel citra yang diproses ke dalam memori sebelum bobot model diperbarui. Pengaturan *batch size* yang lebih besar dapat menstabilkan estimasi gradien selama pelatihan, namun menuntut kapasitas memori GPU yang jauh lebih besar. Sementara itu, *epoch* merujuk pada satu siklus iterasi lengkap di mana seluruh dataset telah melewati jaringan saraf. Jumlah *epoch* yang optimal diperlukan agar model memiliki waktu yang cukup untuk mempelajari pola morfologi *Plasmodium*, tanpa berujung pada kondisi di mana model sekadar menghafal data dan kehilangan kemampuan generalisasinya [54], [84].

Tujuan utama dari penyesuaian *hyperparameter* ini adalah mencapai kondisi *best fitting*, yaitu titik keseimbangan ideal antara kompleksitas model dan kemampuan generalisasinya terhadap data baru. Ketidakseimbangan dalam proses ini dapat memicu dua fenomena kegagalan utama, yaitu *underfitting* dan *overfitting*. *Underfitting* terjadi jika model terlalu sederhana untuk menangkap pola kompleks pada data sediaan darah, yang ditandai dengan tingginya tingkat kesalahan baik pada tahap pelatihan maupun validasi. Sebaliknya, *overfitting* terjadi ketika model terlalu rumit sehingga cenderung "menghafal" detail dan *noise* pada data latih secara berlebihan. Kondisi *overfitting* ini menghasilkan akurasi yang terlihat sangat tinggi pada data latih, namun performanya akan menurun drastis saat diuji menggunakan citra darah baru yang belum pernah dilihat sebelumnya [73], [74].

Untuk memitigasi risiko *overfitting* dan memastikan model berhenti belajar pada titik akurasi puncaknya, penelitian ini menerapkan teknik *early stopping* beserta pengaturan *patience*. *Early stopping* merupakan mekanisme regulasi yang akan menghentikan proses pelatihan secara otomatis jika tidak ditemukan peningkatan performa pada data validasi setelah melewati sejumlah *epoch* tertentu. Batas toleransi inilah yang didefinisikan sebagai nilai *patience*. Pengaturan nilai *patience* yang terkalibrasi dengan baik memungkinkan model untuk mengakhiri pelatihan tepat sebelum kurva validasi menunjukkan tren penurunan, sehingga efisiensi waktu komputasi dapat tercapai tanpa mengorbankan akurasi deteksi penyakit[96].

2.7 *State Of The Art*

Tabel 2.7 *State Of The Art*

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
A Deep Architecture Based On Attention Mechanisms For Effective End-To-End Detection Of Early And Mature Malaria Parasites In A Realistic Scenario	2025	Zedda, L., Loddo, A., & Di Ruberto, C.	Pengembangan framework deteksi berbasis deep learning dengan mekanisme atensi, memperluas model YOLO-SPAM dan YOLO-PAM.	Menunjukkan akurasi tinggi dalam mendeteksi empat spesies malaria pada seluruh stadium infeksi (awal dan matang) dalam skenario realistik.
Review Of Application Yolov8 In Medical Imaging	2024	Widayani, A., Putra, A. M., Maghriebi, A.	Studi literatur sistematis mengevaluasi performa YOLOv8 pada berbagai	YOLOv8 mencapai performa tinggi pada tumor otak (*Precision* >0,92, mAP >0,93) dan

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
		R., & Ridho, M. H. F.	modalitas seperti (X-Ray, CT-Scan, dan MRI).	*Recall* (mAP 0,87) menggunakan optimizer SGD.
Yolov8-CAB: Improved Yolov8 For Real-Time Object Detection	2024	Talib, M., Al-Noori, A. H. Y., & Suad, J.	Integrasi Context Attention Block (CAB) dan modifikasi Spatial Attention (SA) untuk meningkatkan ekstraksi fitur pada blok C2f.	Peningkatan signifikan pada akurasi deteksi objek kecil dan kemampuan ekstraksi fitur lemah tanpa menambah kompleksitas model yang besar.
What Is Yolov8: An In-Depth Exploration Of The Internal Features	2024	Yaseen, M.	Analisis mendalam fitur internal YOLOv8 (CSPNet	Mengonfirmasi keunggulan YOLOv8 dalam hal presisi dan kemampuan real-time

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
			backbone, FPN+PAN neck, dan Anchor-free approach).	dibandingkan YOLOv5 pada benchmark COCO dan Roboflow 100.
Fracture Detection In Pediatric Wrist Trauma X-Ray Images Using Yolov8 Algorithm	2023	Ju, R. Y., & Cai, W.	Penggunaan algoritma YOLOv8 yang dikombinasikan dengan teknik augmentasi data intensif pada dataset GRAZPEDWRI-DX.	Mencapai nilai mAP50 sebesar 0,638, melampaui performa YOLOv7 dan model YOLOv8 orisinal dalam mendeteksi fraktur tulang anak.
Image Analysis And Machine Learning For Detecting Malaria	2018	Poostchi, M., Silamut, K., Maude, R. J.,	Tinjauan teknik pengolahan citra, cell segmentation, dan klasifikasi otomatis untuk sediaan darah tipis dan tebal.	Membuktikan Deep Learning mampu melakukan automatis diagnosis dengan

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
		Jaeger, S., & Thoma, G.		mengatasi variasi morfologi dan artefak.
YOLO-Tryppa: A Novel YOLO-Based Approach For Rapid And Accurate Detection Of Small Trypanosoma Parasites	2025	Mura, D. A., Zedda, L., Loddo, A., & Di Ruberto, C.	Modifikasi arsitektur YOLO khusus untuk parasit berukuran kecil (small objects) dengan mengeliminasi head P5 dan mengoptimalkan head P2 menggunakan ghost convolutions.	Menghasilkan AP50 sebesar 71,3%, mengatasi masalah hilangnya fitur pada deteksi parasit berukuran mikro dengan beban komputasi (GFLOPs) yang lebih rendah.
Automatic Patient-Level Recognition Of Four Plasmodium Species On Thin Blood	2024	Guemas, E., Routier, B., dkk.	Penggunaan algoritma Real-Time Detection Transformer (RT-DETR) untuk membedakan 4 spesies	RT-DETR mampu mencapai akurasi tingkat pasien yang tinggi (99,8%), membuktikan

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
Smear By A Real-Time Detection Transformer (RT-DETR) Object Detection Algorithm			Plasmodium pada citra sediaan darah tipis dengan dataset masif (24.720 citra).	bahwa arsitektur bebas-anchor (anchor-free) sangat superior untuk citra malaria.
Insights Into AI-Driven Malaria Diagnosis: A Systematic Review With Implications For Plasmodium Knowlesi	2025	Tiong, Jia Ying,	Tinjauan sistematis membandingkan CNN, Transfer Learning, dan YOLO/Faster R-CNN khusus untuk tahapan darah Plasmodium (termasuk knowlesi).	Menemukan bahwa tantangan terbesar saat ini adalah ketidakseimbangan kelas (class imbalance) dan kurangnya anotasidataset, yang mana metode seperti YOLO terbukti efektif jika dikombinasikan dengan adaptasi domain.

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
Automatic Recognition Of Parasitic Products In Stool Examination Using Object Detection Approach	2022	Naing, K. M., Boonsang, S., dkk.	Komparasi algoritma deteksi objek (YOLOv3, YOLOv4-Tiny, Faster R-CNN, SSD) untuk mendeteksi parasit pada sampel medis menggunakan Artificial Intelligence.	Arsitektur keluarga YOLO menunjukkan keseimbangan terbaik antara kecepatan (real-time) dan presisi pengenalan morfologi parasit dibandingkan SSD dan Faster R-CNN.

Penelitian yang dilakukan oleh Zedda, Loddo, dan Di Ruberto (2025) menunjukkan pendekatan yang komprehensif dalam pengenalan objek medis berskala mikro menggunakan arsitektur berbasis *Deep Learning*. Penelitian ini berjudul *"A deep architecture based on attention mechanisms for effective end-to-end detection of early and mature malaria parasites in a realistic scenario"*. Penelitian ini mengintegrasikan arsitektur keluarga YOLO dengan mekanisme atensi untuk mendeteksi parasit malaria secara *end-to-end* dari sediaan darah. Model berhasil mencapai akurasi yang tinggi dalam mengenali empat spesies *Plasmodium* yang berbeda pada seluruh stadium infeksi, baik pada fase awal maupun matang. Keberhasilan ini disebabkan oleh kemampuan mekanisme jaringan dalam mempertahankan fitur spasial dari parasit berukuran sangat kecil yang sering kali hilang pada lapisan konvolusi dalam. Penelitian ini membuktikan bahwa arsitektur bebas-jangkar (*anchor-free*) sangat tangguh dalam menangani variasi morfologi parasit di skenario klinis yang realistis. Keterkaitan penelitian ini dengan tugas akhir yang sedang dikembangkan adalah memberikan landasan arsitektural yang kuat bahwa penggunaan YOLOv8 yang secara bawaan telah mengadopsi sistem *anchor-free* dan *Decoupled Head* merupakan pilihan algoritma yang paling mutakhir dan tepat untuk mendeteksi stadium awal parasit pada citra mikroskopis.

Penelitian yang dilakukan oleh Tiong . (2025) memberikan perspektif yang sangat kritis terhadap tantangan implementasi kecerdasan buatan dalam diagnosis medis melalui tinjauan sistematis berjudul *"Insights into AI-Driven malaria diagnosis: A systematic review with implications for Plasmodium knowlesi"*. Penelitian yang dipublikasikan oleh Elsevier ini mengevaluasi berbagai teknik mulai

dari prapemrosesan hingga metode deteksi objek seperti YOLO dan Faster R-CNN dalam mendiagnosis tahapan darah parasit malaria. Hasil studi secara tegas menyoroti bahwa kendala paling persisten yang membatasi performa model AI saat ini adalah fenomena ketidakseimbangan kelas (*class imbalance*) pada *dataset* medis serta kurangnya anotasi yang berkualitas. Evaluasi ini membuktikan bahwa tanpa penanganan ketidakseimbangan data yang memadai, model cenderung mengalami bias terhadap kelas yang dominan. Keterkaitan penelitian ini dengan tugas akhir yang dilakukan adalah sebagai justifikasi utama atas penerapan strategi pembobotan kelas (*class weights* / image_weights). Strategi tersebut secara langsung menjawab kesenjangan riset yang disoroti oleh Tiong ., dengan memastikan model tidak bias meskipun jumlah *dataset* kelas *Vivax* jauh lebih mendominasi dibandingkan kelas *Falciparum*.

Penelitian yang dilakukan oleh Talib, Al-Noori, dan Suad (2024) berfokus pada inovasi efisiensi ekstraksi fitur melalui penelitian berjudul *"YOLOv8-CAB: Improved YOLOv8 for Real-time object detection"*. Penelitian ini memodifikasi struktur internal YOLOv8 dengan menambahkan *Context Attention Block* (CAB) dan mempertebal blok C2f (*Coarse-to-Fine*). Model yang dikembangkan berhasil mencapai peningkatan performa yang tajam dalam melokalisasi objek-objek berukuran kecil tanpa meningkatkan kompleksitas komputasi model secara berlebihan. Hal ini disebabkan oleh optimalisasi blok C2f yang mampu mengekstraksi fitur lemah (*weak features*) pada latar belakang gambar yang bervariasi. Penelitian ini secara empiris membuktikan bahwa kedalaman blok C2f memainkan peran paling vital dalam menjaga kualitas representasi visual dari objek kecil hingga ke tahap prediksi akhir. Keterkaitan

penelitian ini dengan tugas akhir yang diusulkan adalah memperkuat argumen teoritis bahwa struktur blok C2f pada YOLOv8 memiliki peran yang signifikan dalam menjaga detail tepi parasit agar tidak mengalami *vanishing gradient*, sehingga deteksi dapat tetap presisi pada perbesaran mikroskopis tertentu.

Penelitian yang dilakukan oleh Widayani . (2024) memberikan wawasan spesifik mengenai penerapan varian YOLO pada berbagai modalitas citra klinis dalam artikel berjudul *"Review of Application YOLOv8 in Medical Imaging"*. Penelitian ini mengevaluasi kinerja YOLOv8 dalam deteksi lesi dan klasifikasi penyakit pada pencitraan seperti X-Ray, CT-Scan, dan MRI. Model ini secara konsisten mencetak nilai *mean Average Precision* (mAP) yang tinggi, termasuk pada deteksi kanker payudara dengan rata-rata mAP 0,87. Keberhasilan ini sangat dipengaruhi oleh konfigurasi parameter pelatihan, di mana penggunaan fungsi optimasi algoritma yang tepat secara langsung menentukan akurasi klasifikasi. Keterkaitan penelitian ini dengan penelitian peneliti adalah memberikan pijakan ilmiah untuk melakukan eksperimen *hyperparameter tuning* secara komprehensif. Berdasarkan temuan tersebut, tugas akhir ini memodifikasi parameter fundamental (seperti *learning rate*, momentum, dan *weight decay*) untuk memastikan model YOLOv8 mencapai titik konvergensi terbaik pada citra sediaan darah.

Penelitian oleh Mura, Zedda, Loddo, dan Di Ruberto (2025) berjudul *"YOLO-Tryppa: A Novel YOLO-Based Approach for Rapid and Accurate Detection of Small Trypanosoma Parasites"* memperkenalkan modifikasi khusus untuk parasit renik. Penelitian ini mengusulkan model YOLO-Tryppa yang mengeliminasi *head* prediksi

P5 dan mengoptimalkan *head* P2 untuk meningkatkan lokalisasi objek kecil. Hasilnya menunjukkan pencapaian nilai AP50 sebesar 71,3%, yang membuktikan bahwa penyesuaian pada skala prediksi sangat krusial untuk objek yang hanya mencakup beberapa piksel dalam citra mikroskopis. Keterkaitan penelitian ini dengan tugas akhir adalah memberikan bukti bahwa untuk parasit darah, fokus deteksi pada skala spasial yang lebih halus (seperti P3 pada YOLOv8 standar) adalah kunci utama. Hal ini mendukung eksperimen tugas akhir dalam mempertahankan resolusi *input* yang tinggi (640 piksel) agar fitur parasit stadium *ring* tetap dapat terdeteksi oleh jaringan.

Penelitian yang dilakukan oleh Guemas . (2024) berjudul *"Automatic patient-level recognition of four Plasmodium species on thin blood smear by a real-time detection transformer (RT-DETR) object detection algorithm"* mengeksplorasi penggunaan algoritma berbasis *Transformer*. Penelitian ini menggunakan *dataset* masif sebanyak 24.720 citra untuk melatih model RT-DETR dalam membedakan empat spesies malaria. Model ini mampu mencapai akurasi tingkat pasien hingga 99,8%, yang menunjukkan bahwa pendekatan berbasis *real-time transformer* dapat menyaingi model konvensional. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai pembanding teknologi deteksi objek terkini. Meskipun RT-DETR menunjukkan akurasi yang luar biasa, penggunaan YOLOv8 dalam tugas akhir ini dipilih karena efisiensi beban komputasinya (GFLOPs) yang lebih rendah, sehingga lebih memungkinkan untuk diimplementasikan pada perangkat mikroskop digital dengan spesifikasi perangkat keras menengah di daerah endemik.

Penelitian oleh Naing . (2022) berjudul *"Automatic recognition of parasitic products in stool examination using object detection approach"* membandingkan performa berbagai algoritma deteksi seperti YOLOv3, YOLOv4-Tiny, Faster R-CNN, dan SSD. Hasil penelitian menunjukkan bahwa arsitektur keluarga YOLO memberikan keseimbangan paling optimal antara kecepatan pemrosesan (*real-time*) dan presisi pengenalan morfologi parasit dibandingkan model SSD. Model YOLO mampu mengenali detail tekstur parasit pada sampel medis secara konsisten. Keterkaitan penelitian ini dengan tugas akhir yang disusun adalah mengonfirmasi bahwa pemilihan keluarga YOLO (dalam hal ini versi terbaru, YOLOv8) adalah langkah yang tepat secara teknis untuk mencapai target sistem deteksi yang tidak hanya akurat secara medis, tetapi juga efisien secara waktu untuk kebutuhan diagnosis massal.

Penelitian yang dipresentasikan oleh Yaseen (2024) melalui artikel *"WHAT IS YOLOV8: AN IN-DEPTH EXPLORATION OF THE INTERNAL FEATURES OF THE NEXT-GENERATION OBJECT DETECTOR"* melakukan analisis mendalam terhadap inovasi arsitektur YOLOv8. Penelitian ini membedah keunggulan integrasi *CSPNet backbone*, *FPN+PAN neck*, serta transisi menuju sistem *anchor-free*. Hasil analisis menunjukkan peningkatan signifikan pada *benchmark* Microsoft COCO dibandingkan versi YOLOv5. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai sumber referensi teknis utama dalam Bab 2 Tinjauan Pustaka. Penjelasan Yaseen mengenai bagaimana modul C2f dan *Decoupled Head* bekerja menjadi landasan teori dasar bagi tugas akhir ini dalam menjelaskan mengapa YOLOv8 memiliki kapabilitas ekstraksi fitur yang lebih kuat untuk objek kecil seperti parasit malaria dibandingkan pendahulunya.

Penelitian oleh Ju dan Cai (2023) berjudul *"Fracture detection in pediatric wrist trauma X-ray images using YOLOv8 algorithm"* menyoroti pentingnya teknik augmentasi data dalam pencitraan medis. Penelitian ini menggunakan algoritma YOLOv8 untuk mendeteksi fraktur tulang pada anak dan berhasil mencapai nilai mAP50 sebesar 0,638. Keberhasilan ini didorong oleh penerapan berbagai teknik augmentasi citra yang mampu menangkap variasi data yang terbatas. Keterkaitan penelitian ini dengan tugas akhir Ivan adalah memperkuat metodologi pada Bab 3 terkait penggunaan augmentasi spasial dan warna. Sebagaimana riset Ju dan Cai, tugas akhir ini memanfaatkan augmentasi untuk memperluas variasi citra sediaan darah, sehingga model menjadi lebih tangguh terhadap perbedaan pencahayaan mikroskop dan kualitas pewarnaan Giemsa.

Penelitian fundamental oleh Poostchi . (2018) berjudul *"Image analysis and machine learning for detecting malaria"* memberikan gambaran historis dan perkembangan teknik diagnosis malaria otomatis. Penelitian ini meninjau transisi dari pengolahan citra klasik menuju era *Deep Learning* untuk mengatasi tantangan variasi morfologi parasit dan artefak sediaan. Kesimpulan penelitian menekankan bahwa *Deep Learning* adalah solusi masa depan untuk diagnosis malaria yang andal. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai fondasi latar belakang masalah. Dengan merujuk pada tinjauan Poostchi, tugas akhir ini memposisikan diri untuk menjawab tantangan otomatisasi diagnosis tersebut melalui penggunaan YOLOv8 yang merupakan representasi teknologi *Deep Learning* paling mutakhir saat ini.

BAB III
METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini merupakan jenis penelitian kuantitatif yang dirancang dengan pendekatan penelitian terapan (*applied research*) dalam area pemrosesan citra medis dan kecerdasan buatan. Pendekatan kuantitatif digunakan karena proses evaluasi kinerja model deteksi parasit malaria diukur secara objektif menggunakan parameter matematis dan metrik statistik, seperti *Mean Average Precision* (mAP), presisi (*precision*), sensitivitas (*recall*), dan *F1-Score*, yang diekstraksi secara komputasional.

Sifat terapan dalam penelitian ini dititikberatkan pada tahap pengembangan dan optimasi sistem. Proses ini mencakup *fine-tuning* arsitektur *You Only Look Once* versi 8 (YOLOv8) melalui penyesuaian iteratif pada *hyperparameter* fundamental yaitu *learning rate*, momentum, dan *weight decay* menggunakan *optimizer* AdamW. Selain itu, penelitian ini juga menerapkan teknik pembobotan kelas (*class weights*) sebagai bentuk rekayasa komputasional untuk menguji ketangguhan model dalam menangani kondisi ketidakseimbangan data (*class imbalance*) antara kelas *Plasmodium falciparum* dan *Plasmodium vivax* pada sediaan mikroskopis.

3.2 Waktu dan Tempat Pelaksanaan

Penelitian ini dilaksanakan sekitar sembilan bulan, dimulai dari bulan Agustus 2025 sampai April 2026 yang dilaksanakan di Insitut Teknologi Sumatera, Lampung Selatan untuk perancangan pengintegrasian modul kamera, mikroskop, dan juga pengambilan data primer secara langsung dengan preparat.

3.3 Alat dan Bahan

Adapun alat dan bahan yang diperlukan dalam penelitian ini akan dijelaskan dalam beberapa poin berikut.

3.3.1 Alat

Berikut ini adalah daftar alat yang digunakan dalam penelitian ini, beserta spesifikasi, jumlah dan fungsinya, sebagaimana tercantum pada Tabel 3.1.

Tabel 3.1 Spesifikasi Alat Software dan Hardware

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
Hardware	Laptop ASUS TUF GAMING A16	• AMD Ryzen 7 260 w/ Radeon 780M Graphics, 3800 Mhz, 8 Core(s), 16 Logical Processor(s) • 16 GB RAM • NVIDIA GFORCE RTX 5060 8GB • 1 TB SSD • Windows 11 Home 64-bit	1 Buah	Sebagai pusat komputasi, digunakan untuk menjalankan *software* pengolahaan citra dan model YOLO

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
Hardware	Mikroskop	• Lensa okuler Monokuler, Perbesaran 10x • Lensa objektif 4x-100x	1 Buah	Berfungsi sebagai pembesaran sampel darah sehingga parasite dapat terlihat dalam mikroskop secara detail
	Modul Kamera	• Resolusi 4K • *Output* : HDMI / *Type-C*	1 Buah	Berfungsi untuk menangkap citra mikroskopis melalui lensa mikroskop
Software	Visual Studio Code	• Versi 1.115 • *Virtual Enviroment* (*venv*) • *Pytorch* • Python 3.12.3	-	Berperan sebagai wadah pembuatan model YOLO serta *Training Data*

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
		• *Pylabs, .Net Install Tool, Rainbow CSV,* dan pustaka pendukung lainnya • *Ultralystics* untuk YOLOv8		
	LabelImg	• *Operating System* : Windows 10 atau lebih • *Python requirments* : Minimum *Python* 2.6 • CPU : 2 x 64-bit, 2.8 GHz atau lebih	-	Berperan dalam membantu proses membuat dan mengambil *dataset* parasit malaria menggunakan format *labelimg* YOLO agar setiap gambar memiliki *bounding box* dan file teks berisi dengan informasi *bounding box tersebut.*

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
		• *Memory* : 16 GB RAM minimum, dengan 1600 MHz DDR3		

3.3.2 Bahan

Berikut adalah beberapa bahan yang digunakan dan diperlukan selama melakukan penelitian ini, lengkap dengan jumlah dan fungsinya, sebagaimana di tampilkan dalam Tabel 3.2.

Tabel 3.2 Daftar Bahan Penelitian

Nama Bahan	Jumlah	Kegunaan
Data Set Citra Mikroskopis Smear Darah Tipis	2 Dataset (2 kelas/2300Citra)	Berfungsi sebagai bahan latihan dan ujian bagi *Deep Learning Model* YOLOv8

3.4 Metode dan Persamaan yang Digunakan

Pengembangan sistem deteksi parasit malaria dalam penelitian ini didasarkan pada arsitektur *Deep Learning* YOLOv8 yang mengintegrasikan mekanisme ekstraksi fitur, lokalisasi objek, dan klasifikasi dalam satu jaringan saraf konvolusional terpadu. Untuk memandu proses pelatihan (*training*) agar mencapai konvergensi optimal, digunakan serangkaian persamaan matematis yang mencakup fungsi kerugian dan metrik evaluasi sebagai berikut.

3.4.1 Fungsi Kerugian (*Loss Function*)

Model YOLOv8 dioptimalkan menggunakan fungsi kerugian total (L_{total}) yang menggunakan tiga jenis perhitungan untuk memastikan presisi geometris dan akurasi klasifikasi. Komponen tersebut meliputi :

1. *Classification Loss* (BCE)

Classification Loss dalam penelitian ini digunakan untuk mengukur kesalahan model dalam membedakan antara kelas *Plasmodium falciparum* dan *Plasmodium vivax*. Persamaan ini di dasarkan pada *Binary Cross-Entropy* (BCE) yang menghitung perbedaan antara probabilitas prediksi dan label aktual:

$$Lcls = -\frac{1}{N}\sum_{i=1}^{N}[Yi\log(Pi) + (1 - Yi)\log(1 - Pi)]$$

Dimana N termasuk sebagai jumlah sampel, Yi Adalah label biner (0 atau 1), dan Pi adalah skor probabilitas yang dihasilkan model[90].

2. *Bounding Box Regression Loss* (CloU)

Untuk meningkatkan akurasi pelokalan koordinat parasit yang berukuran kecil pada sediaan darah, penelitian ini menggunakan metode *Complete Intersection over Union* (CloU). CloU sendiri mempertimbangkan tumpeng tindih area, jarak pusat kota, dan konsistensi ratio aspek kotak pembatas itu sendiri :

$$LCIoU = 1 - IoU + \frac{p^2(b, b^{gt})}{c^2} + av$$

Dalam konteks pencitraan medis dan penelitian ini, penggunaan CloU menjadi sangat krusial dalam meminimalisir deviasi posisi kotak merah pada objek mikroskopis [91].

3. *Distribution Focal Loss* (DFL)

DFL dalam penelitian ini berfungsi untuk memperhalus estimasi batas kotak pembatas pada kondisi di mana batas objek parasit tidak terlalu jelas atau saling tumpeng tindih dengan sel darah merah lainnya.

3.4.2 Parameter Optimasi (AdamW)

Proses pembaruan bobot jaringan saraf dalam penelitian ini dikendalikan oleh *optimizer* AdamW (*Adam with Weight Decay Fix*). Algoritma ini dilih oleh peneliti karena kemampuannya dalam memisahkan penanganan peluruhan bobot (*Weight Decay*) dari pembaruan gradien utama, hal ini dapat menghilangkan kejadiannya *overfitting* pada *dataset* malaria yang memiliki ketimpangan kelas yang besar. Persamaan pembaruan bobot w pada langkah waktu t :

$$w_{t+1} = wt - n_t \left(\frac{\widehat{m_t}}{\sqrt{\widehat{v_t} + \epsilon}} + \lambda w_t \right)$$

Dimana n mempresentasikan learning rate, $\widehat{m_t}$dan $\widehat{v_t}$ adalah estimasi momen gradien, sementara λ adalah parameter tingkat *weight decay* sebesar 0.005 yang di terapkan dalam penelitian ini.

3.4.2 Metrik Evaluasi Kinerja Sistem

Keberhasilan sistem yang mengendali morfologi parasit diukur secara kuantitatif melalui metrik statistic yang dihitung berdasarkan nilai hasil *confusion matrix*. Parameter ini mencakup berbagai hal dari *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), *False Negative* (FN) :

1. Akurasi (*Accuracy*)

Akurasi mempresentasikan presentase total prediksi benar dibandingkan keseluruhan data:

$$Accuracy = \frac{TP + TN}{TP + TN + FN + FP}$$

2. Sensitivitas (*Recall*)

Sensitivitas atau *recall* untuk mengukur model dalam menemukan kembali seluruh parasit malaria yang ada di dalam citra:

$$Recall = \frac{TP}{TP + FN}$$ [93]

3. Presisi (*Precision*)

Presisi atau *precision* mengukur tingkat keandalan model dalam memprediksi parasite tanpa terdistraksi oleh artefak atau kotoran:

$$Precision = \frac{TP}{TP + FP}$$

4. F1-*Score*

F1-*score* digunakan sebagai indikator keseimbangan antara persisi dan sensitivitas dalam klarifikasi diagnosis medis:

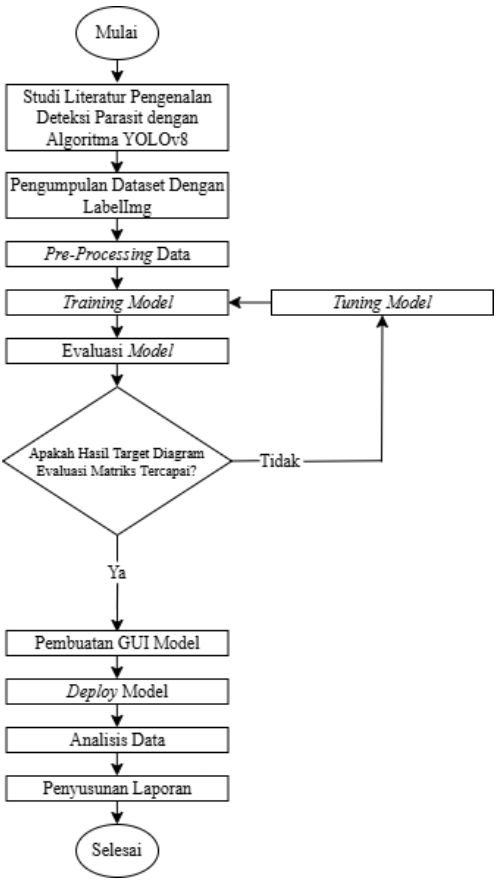
$$F1 - score = 2\ x\ \frac{precision\ x\ recall}{precision + recall}$$ [93]

Dalam konteks diagnosis medis seperti malaria, parameter Sensitivitas (*Recall*) memiliki prioritas tertinggi karena kesalahan sistem dalam melewatkan sel yang terinfeksi (*False Negative*) dapat berakibat fatal bagi pasien. Oleh karena itu, metrik ini dievaluasi secara ketat bersama dengan F1-Score untuk memastikan keandalan model pada kondisi sediaan darah yang realistis [93].

5. *Mean Average Precision* (mAP@50)

Metrik ini digunakan sebagai tolak ukur utama dalam deteksi objek yang menghitung rata-rata presisi pada berbagai tingkat sensitivitas dengan ambang batas IoU 0,5. Pencapaian nilai mAP@50 sebesar 87,89% menunjukkan efektivitas penggunaan persamaan-persamaan di atas dalam memandu konvergensi model YOLOv8 [92], [97].

3.5 Diagram Alir Penelitian



Gambar 3.1 Diagram Alir Penelitian

Sesuai dengan diagram alir 3.1 tahapan penelitian ini terbagi menjadi secara keseluruhan 4 tahap utama, dimulai dengan *image*

processing, *pre-processing* data, *training data,* dan integrasi model YOLOv8 dengan modul kamera yang ada. Tahapan penelitian ini akan dijelaskan dalam beberapa sub bab berikut.

3.5.1 Studi Literatur

Langkah pertama diawali dengan tahap Studi Literatur Pengenalan Deteksi Parasit dengan Algoritma YOLOv8. Pada fase esensial ini, dilakukan kajian komprehensif terhadap berbagai literatur dan publikasi ilmiah terkini yang relevan. Hal ini difokuskan pada karakteristik morfologi citra mikroskopis parasit malaria, penanganan data tidak seimbang (*class imbalance*), serta bedah arsitektur mutakhir YOLOv8 seperti mekanisme ekstraksi fitur pada modul C2f dan sistem pelokalan *anchor-free*. Pemahaman teoritis ini menjadi pijakan fundamental sebelum memulai perancangan sistem secara teknis.

3.5.2 Pengumpulan Dataset

Langkah selanjutnya adalah, tahap Pengumpulan Dataset Dengan LabelImg. Tahap ini melibatkan akuisisi citra primer sediaan darah dari lapangan (puskesmas) yang telah dikurasi oleh pakar. Citra-citra mentah tersebut kemudian diproses menggunakan perangkat lunak LabelImg untuk melakukan anotasi secara manual. Proses anotasi ini bertujuan untuk membuat kotak pembatas (*bounding box*) pada objek target dan memberikan label kelas spesifik (seperti *Plasmodium falciparum* atau *Plasmodium vivax*), yang kelak berfungsi sebagai data kebenaran dasar (*ground truth*) bagi model.

3.5.3 Pre-Processing Data

Dataset berlabel kemudian dialirkan ke dalam tahapan Pre-Processing Data. Tahapan ini sangat krusial untuk menormalisasi variasi data dan membersihkan gangguan visual yang tidak diinginkan.

Proses pra-pemrosesan mencakup penyesuaian resolusi citra menjadi ukuran standar masukan YOLOv8 (640x640 piksel), penyesuaian kontras pencahayaan mikroskop, serta augmentasi data spasial. Tindakan manipulasi ini bertujuan untuk memperkaya variabilitas fitur agar model memiliki ketahanan (*robustness*) yang tinggi saat mengenali parasit dengan orientasi yang berbeda-beda.

3.5.4 Training Model

Dataset yang telah diolah, selanjutnya digunakan pada tahap Training Model. Pada fase ini, arsitektur YOLOv8 dilatih secara komputasional untuk mengenali pola parasit berdasarkan dataset latih. Setelah serangkaian iterasi (*epoch*) selesai, alur berlanjut ke tahap Evaluasi Model, di mana performa jaringan diuji menggunakan dataset validasi. Kinerja model dikuantifikasi menggunakan parameter metrik evaluasi standar seperti *Confusion Matrix*, presisi, *recall*, dan tingkat *Mean Average Precision* (mAP@50) untuk menilai kemampuan generalisasinya terhadap citra baru.

3.5.5 Evaluasi Matriks

Hasil evaluasi tersebut kemudian bermuara pada titik keputusan (*decision node*). Apabila hasil evaluasi (seperti nilai mAP atau keseimbangan F1-Score) dirasa belum memenuhi target atau terindikasi mengalami *overfitting/underfitting*, maka alur akan berbelok ke tahap Tuning Model. Pada proses iteratif ini, dilakukan penyesuaian ulang terhadap nilai *hyperparameter* (seperti *learning rate*, *optimizer* AdamW, atau pembobotan fungsi kerugian) sebelum sistem dikembalikan ke tahap pelatihan. Siklus ini akan terus berulang hingga model berhasil mencapai konvergensi dan tingkat akurasi yang diharapkan.

3.5.6 Pembuatan GUI

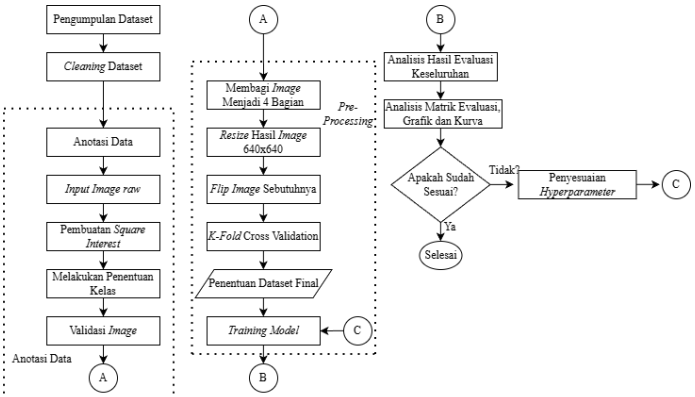
Jika model dinyatakan telah memenuhi atau melampaui target matriks evaluasi dengan menyatakan Ya, langkah selanjutnya adalah Pembuatan GUI Model. Tahap ini bertujuan untuk mengemas arsitektur *Deep Learning* yang kompleks ke dalam Antarmuka Pengguna Grafis (*Graphical User Interface*). Setelah antarmuka selesai dibangun, tahapan Deploy Model dilakukan guna mengimplementasikan sistem secara fungsional. Proses *deployment* ini memungkinkan model beroperasi secara *real-time* atau luring untuk menganalisis citra mikroskopis di lingkungan operasional yang sebenarnya.

3.5.7 Analisis Data

Pasca implementasi, dilakukan Analisis Data secara mendalam terhadap keluaran sistem. Analisis ini meninjau perbandingan hasil deteksi prediktif model terhadap hasil observasi manual oleh tenaga medis, guna mengidentifikasi margin galat yang mungkin timbul saat sistem dihadapkan pada sediaan darah baru. Keseluruhan alur metodologi penelitian ini akhirnya dirangkum secara formal dalam tahap Penyusunan Laporan Tugas Akhir, sebelum keseluruhan rangkaian eksperimen dan pengembangan sistem dinyatakan Selesai.

3.6 Langkah Penelitian secara Spesifik

Langkah Penelitian dimulai dengan pengumpulan dataset dengan labelimg memiliki proses yang cukup panjang, proses tersebut dapat dilihat pada Gambar 3.2.



Gambar 3.2 Diagram Alir Penelitian Spesifik

1) Persiapan Dataset

Proses dimulai dari pengecekan terhadap dataset. Penelitian ini menggunakan dataset yang terdiri diri dari citra mikroskopis sediaan darah total yang sudah di anotasikan, yang dikumpulkan secara langsung pada desa hanura, lampung selatan. Citra-citra tersebut diambil melalui lensa okuler mikroskop dengan pembesaran 100x menggunakan kamera ponsel. Semua citra disimpan dalam ruang warna RGB dengan resolusi 3.024×4.032 piksel. Dataset ini dikategorikan ke dalam dua kelas: sediaan darah yang terinfeksi P. *falciparum*, sediaan darah yang terinfeksi P.*vivax*. Secara keseluruhan, dataset ini mencakup 2404 citra sediaan darah tebal (pada tingkat mikroskop) yang diperoleh dari berbagai pasien, baik yang terinfeksi maupun yang terasumsi terinfeksi. Status infeksi semua pasien dikonfirmasi menggunakan metode gold standard, yaitu pemeriksaan mikroskopis sediaan darah tebal dan tipis.

Citra pada tingkat mikroskop ini kemudian diproses lebih lanjut untuk menghasilkan 2300 citra berlabel secara individual pada tingkat seluler (Tabel 3.3). Proses anotasi dataset dilakukan oleh seorang ahli

mikroskopis dari Puskesmas Hanura di Hanura, yang memverifikasi keberadaan infeksi, mengidentifikasi spesies parasit, serta secara manual memberi label pada setiap citra untuk menandai parasit dan sel darah putih.

Tabel 3.3 Rangkuman Jumlah Komposisi dan Label Dataset

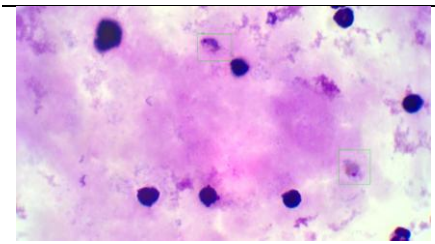
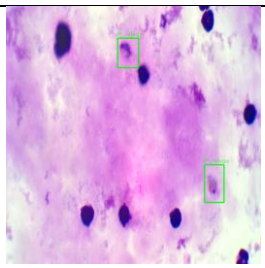
Subset	Jumlah Citra	Parasit Berlabel
P.falciparum	217	218
P.Vivax	2083	4282
Total	2300	4500

Citra-citra yang telah dianotasi ini kemudian dikatalogkan dan disimpan dalam Google *Drive*. Dataset ini sebelumnya telah divalidasi, dianalisis, dan dipublikasikan oleh tim penelitian yang sama, sehingga dapat dijadikan acuan yang kredibel dalam penelitian ini. Mengingat keterbatasan waktu pelatihan dan kapasitas komputasi, penelitian ini hanya menggunakan citra dari total dataset yang tersedia. Pemilihan subset dilakukan secara acak dan merata dari tiap kelas, serta diatur langsung melalui skrip pemrograman pada tahap pemuatan data, guna memastikan efisienso proses tanpa mengganggu distribusi label pada dataset.

2) *Cutting & Resizing Citra Dataset*

Setelah melakukan persiapan dataset, tahap selanjutkan dilakukan dengan *cutting* dataset. Hal ini bertujuan untuk melakukan pemfokusan kepada parasit yang ada, memisahkan elemen-elemen yang penting dan tidak penting dan menghindari *overfitting* dalam data.

Citra mikroskopis dari dataset original yang beresolusi 3024x 4032 piksel akan di-*cut* menjadi 4 bagian dengan tujuan untuk membesarkan gambar citra parasit tanpa mengubah piksel citra berdasarkan koordinat bounding box dari meta data dataset yang berukuran 640 x 640 piksel. Setelah cropping, citra disimpan ke dalam drive sesuai dengan kelasnya (falciparum, vivax.) Hasil *cutting* dapat dilihat pada Gambar 3.3

Sebelum	Sesudah
	

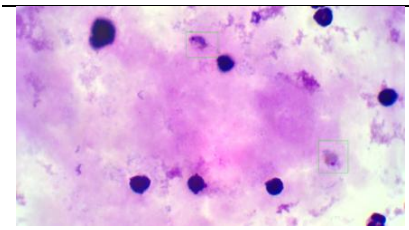
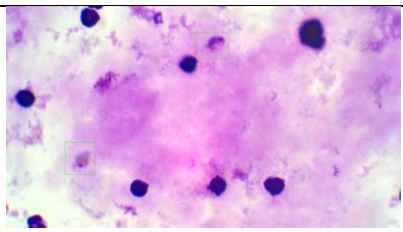
Gambar 3.3 Hasil Data Cutting Dan Resizing

3) *Pre-processing*

Dataset harus diamati apakah kondisinya sudah cukup baik atau masih kurang. Jika kurang baik, maka perlu dilakukan *pre-processing*. Tahap ini sangat penting untuk menghilangkan noise atau gangguan yang dapat mengaburkan informasi dalam gambar, serta membuang bagian-bagian yang tidak diperlukan agar hasil pengolahan selanjutnya lebih akurat. Berikut ini adalah teknik *pre-processing* yang akan dilakukan, seluruh citra yang ditampilkan diambil dari jurnal karya Briceno, dkk. yang berjudul "*Deep Learning-Based Malaria Parasite Detection: You Only Live Once Model for Accurate Species Identification of Plasmodium Falciparum and Plasmodium Vivax"* dan juga metode yang diajukan sendiri dalam pembuatan sistem ini.

a) Augmentasi Data

Dalam dataset yang diambil terdapat beberapa tantangan dalam *image* hal ini berupa *image* citra yang di ambil, bentuk parasit yang bervariasi sehingga pada proses training dapat menurunkan tingkat akurasi hasil akhir. Untuk mengatasi itu dilakukan proses augmentasi data, Dimana dilakukan *flip* atau rotasi secara 90° untuk menyesuaikan dengan *image* yang lainnya. Hasil gambar yang sudah dilakukan augmentasi dapat dilihat pada Gambar 3.4.

Sebelum	Sesudah
	

Gambar 3.4 Perbandingan Hasil Image Augmentasi

4) Pembagian Dataset (*Hold Out Validation*)

Dataset yang telah melalui tahap pra-pemrosesan kemudian dibagi ke dalam dua subset utama, yaitu data *training* (pelatihan) dan data *validation* (validasi). Pada penelitian ini, metode evaluasi yang digunakan adalah *Hold-Out Validation* dengan rasio pembagian statis sebesar 80:20. Artinya, 80% dari total citra digunakan untuk melatih model agar mampu mengenali dan mengekstraksi fitur parasit secara mendalam, sedangkan 20% sisanya digunakan secara eksklusif untuk memvalidasi performa model dan mendeteksi terjadinya *overfitting* selama proses pelatihan.

Tabel 3.4 Tabel Pembagian Data

No	Data *Training*	Data *Validation*
1	80%	20%

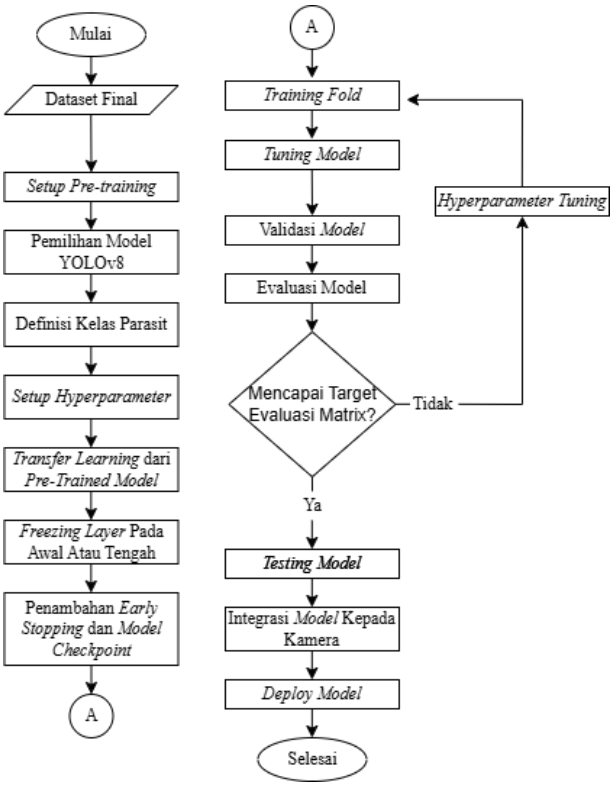
Penggunaan metode *Hold-Out Validation* dengan rasio 80:20 dipilih sebagai pengganti *K-Fold Cross Validation* dengan beberapa justifikasi ilmiah dan teknis. Pertama, pelatihan arsitektur *deep learning* mutakhir seperti YOLOv8 untuk deteksi objek beresolusi tinggi menuntut beban komputasi memori GPU dan waktu yang sangat massif [95]. Menggunakan K-Fold (misalnya 5-fold) berarti mengulang proses training penuh sebanyak 5 kali yang dinilai tidak efisien secara komputasional. Kedua, dataset telah diacak (shuffle) secara terstruktur sebelum dibagi (menggunakan konfigurasi random seed yang statis) untuk memastikan distribusi kelas P. falciparum dan P. vivax tersebar secara proporsional. Dengan ukuran dataset yang ada, rasio 80% data latih dan 20% data validasi telah terbukti secara empiris cukup stabil untuk menghasilkan model dengan tingkat generalisasi dan Mean Average Precision (mAP) yang tinggi tanpa mengalami bias data [96].

3.6.1 Proses Training Model

Pada proses *training model* disesuaikan dengan kebutuhan sistem pemantauan secara terus menerus atau berkelanjutan. Model dilatih dengan *dataset* yang ada dimana menjawab dan mencerminkan kondisi deteksi nyata. Pada tahapan ini difokuskan kepada kemampuan model untuk mengenali dan mempelajari berbagai parasite yang ada dalam malaria dan mempertahankan akurasi dan persisi selama periode deteksi yang lama. Peneliti menerapkan algoritma YOLOv8 yang melibatkan desain jaringan neural baru yang dikembangkan untuk disesuaikan kepada bentuk parasit dan berbagai macam parasit yang ada

dalam malaria dengan tujuan untuk meningkatkan performa, akurasi, persisi, dan mengurangi beban kerja tenaga medis yang ada di Desa Hanura. Proses *training* model meliputi beberapa tahapan seperti, *pre-training setup*, *training process*, *validation model*, dan *testing model*. Seperti yang diberikan pada Gambar 3.1.

Peneliti menggunakan YOLOv8 yang pada dasarnya sudah terancang untuk mendeteksi objek dengan akurasi tinggi dan kecepatan yang lebih cepat dibandingkan dengan pembuatan model dari nol, namun YOLOv8 pada dasarnya hanya akan mendeteksi beberapa *class* dasar saja, seperti anjing, kucing, dan manusia. Peneliti melakukan *transfer learning, fine tuning* dan *pre-trained weight*, dimana menggunakan model yang dilakukan untuk deteksi *class* lainnya, namun dilakukan *training* dengan *dataset* baru untuk membuat model baru. Hal ini memungkinkan model YOLOv8 untuk memanfaatkan pengetahuan yang sudah ada dengan membekkukan sebagian *layer* untuk mempercepat proses pelatihan dan meningkatkan akurasi deteksi parasit malaria.



Gambar 3.5 Tahap Training Model

Berdasarkan Gambar 3.7 peneliti akan menentukkan dataset final, menentukkan parameter-parameter untuk dimasukkan dan digunakan dalam proses *training*. Selanjutnya peneliti akan menentukkan *base model* YOLOv8 yang akan digunakan, dalam kasus ini peneliti memilih *base model* YOLOv8m, lalu menentukkan pengaturan lingkungan pengembangan, dan instansi *library* yang mendukung peneliti dalam proses pelatihan model.

Konfigurasi pelatihan model diimplementasikan menggunakan berkas berekstensi YAML (*Yet Another Markup Language*) yang berfungsi sebagai cetak biru utama sistem. Berkas ini memuat

spesifikasi teknis yang krusial, meliputi jalur direktori dataset (*directory paths*), definisi arsitektur jaringan, dan skema augmentasi data. Pendefinisian jumlah dan nama kelas dalam konfigurasi ini sangat vital agar model dapat membedakan morfologi spesifik antar spesies parasit malaria. Selain itu, berkas ini juga mengatur *hyperparameter* pelatihan esensial seperti *batch size*, *learning rate*, dan jenis *optimizer* untuk memastikan stabilitas proses pembelajaran model.

Peneliti menggunakan metode *transfer learning*, hal ini dikarenakan menjadi salah satu metode yang sangat berguna dan bagus bagi peneliti untuk memungkinkan membuat model baru untuk belajar tanpa harus membuat model dari nol. Proses *transfer learning* dapat menghemat waktu peneliti dalam proses model untuk belajar, terutama apabila data pembelajaran tidak banyak (2500 dataset). Dimana, peneliti menggunakan *callback*, *weight decay*, pengubahan *learning rate*, dan *logging*.

3.6.2 Proses Training

Setelah melakukan *pre-training setup*, peneliti mulai melakukan proses *training* yang dimulai dengan melakukan konfigurasi umum yang telah di tentukan sebelumnya. Hal ini dilakukan dengan tujuan untuk mengetahui dan memberikan pengetahuan dasar kepada model untuk melakukan pelatihan. Model dilatih dengan menggunakan *Visual Studio Code* yang memberikan setting *hyperparameter* yang cukup konsisten, hal ini termasuk *learning rate, batch size, epoch,* dan *optimizer*. Hal ini dilakukan untuk memberikan konsistensi yang pas dan sesuai untuk membandingkan antara masing-masing *fold* dan juga menghindari adanya bias.

Berikutnya peneliti melakukan berbagai perbandingan *hyperparameter* yang dilakukan atau dicoba untuk menemukan konfigurasi model yang paling bagus dan cocok untuk melakukan penelitian, seperti *learning rate, batch size, epoch,* pemilihan *optimizer*, *weight decay*, dan *callback*. Peneliti juga melakukan *review* terhadap kinerja model dan juga arsitektur model untuk menemukan hasil yang optimal.

Proses pelatihan menggunakan *optimizer AdamW* dengan menggunakan fungsi kerugian *Cross-Entropy Loss*, yang efektif untuk klasifikasi multi-kelas. *Hyperparameter* ditetapkan berdasarkan kombinasi yang stabil, dengan konfigurasi sebagai berikut :

- *Batch Size* : *16*
- *Epoch* : 50 - 100
- *Learning Rate0* : 0.0001 – 0.00001
- *Learning RateF* : 0.01 – 0.001
- *Weight Decay* : 1 – 2
- *Warmup Epoch* : 5 – 10
- *Warmup momentum* : 0.1 – 1
- *Warumup bias lr* : 0.1

Konfigurasi ini dipilih untuk menjaga keseimbangan antara kecepatan konvergensi dan stabilitas pelatihan. Dengan pendekatan ini, diharapkan model mampu mempelajari fitur morfologis khas dari citra sel darah terinfeksi malaria secara akurat dan konsisten pada setiap fold pelatihan.

Setiap fold yang telah dilatih dievaluasi secara terpisah menggunakan metrik seperti akurasi, precision, recall, dan F1-score.

Kurva lossdan akurasi per *epoch* divisualisasikan untuk memantau dinamika pelatihan sekaligus mendeteksi potensi overfitting atau underfitting. Hasil evaluasi model ini berupa berbagai macam metrikseperti accuracy, recall, precision, f1-score, dan loss. Metrik-metrik ini dihitung berdasarkan nilai yang diperoleh dari confusion matrix, yang mencakup *True Positives*(TP), *True Negatives*(TN), *False Positives*(FP), dan *False Negatives*(FN).

a) *Accuracy*

Menghitung jumlah prediksi yang benar dibandingkan jumlah total prediksi yang dibuat. Nilai *accuracy* dapat dihitung menggunakan persamaan berikut:

$$Accuracy = \frac{TP+TN}{TP+TN+FN+FP} \quad (3.1)$$

b) *Recall*

Recall dikenal sebagai actual positive rate yang berarti jumlah data positif yang diklaim model dibandingkan dengan jumlah data positif sebenarnya yang ada di seluruh data. Nilai *recall* untuk satu kelas tunggal diberikan dalam persamaan berikut:

$$Recall = \frac{TP}{TP+FN} \quad (3.2)$$

c) *Precision*

Precision menunjukkan seberapa banyak prediksi positif yang benar dibandingkan total prediksi positif. Persamaan yang digunakan untuk menghitung precisionadalah sebagai berikut:

$$Precision = \frac{TP}{TP+FP} \quad (3.3)$$

d) F1 – *Score*

F1-Score merupakan metrik evaluasi kinerja model klasifikasi yang mempertimbangkan keseimbangan antara Precision dan RecallNilai F1-Score dapat ditentukan menggunakan persamaan berikut:

$$F1 - score = 2x\frac{precision\ x\ recall}{precision+recall} \quad (3.4)$$

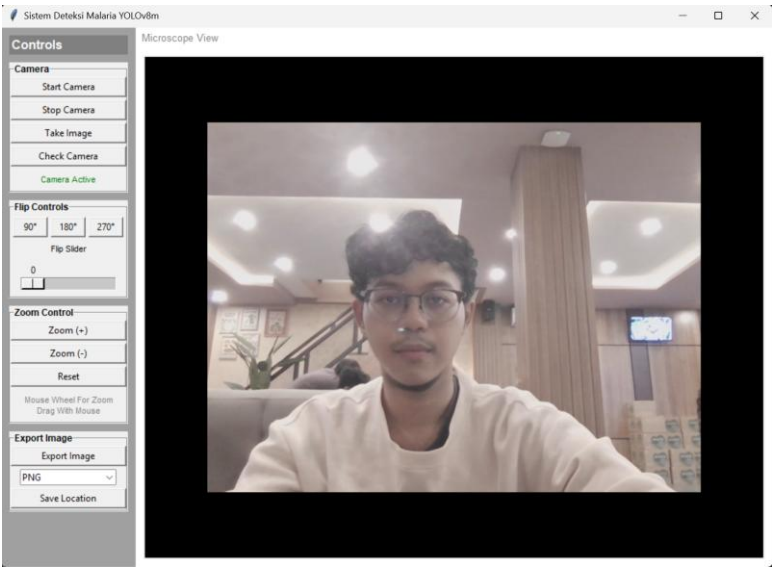
Setelah pelatihan, evaluasi keseluruhan dilakukan untuk memperoleh gambaran performa model secara agregat. Hasil evaluasi mencakup perhitungan rata-rata akurasi pada seluruh fold, serta analisis distribusi kesalahan melalui confusion matrix. Visualisasi tambahan berupa kurva ROC-AUC keseluruhan juga digunakan untuk menilai kemampuan diskriminasi antar kelas. Analisis ini memungkinkan identifikasi fold terbaik dengan mempertimbangkan tidak hanya akurasi, tetapi juga kestabilan loss, distribusi kesalahan, dan generalisasi model terhadap variasi data.

Proses pelatihan ini dilakukan dengan jalan *code* yang disertakan dalam *google collab* :
https://colab.research.google.com/drive/1jE_qdPLLZKu7ZeH2YIsxp8s2T5yAPHXa?usp=sharing

3.6.3 Integrasi *Hardware* dan *Software*

Tahap ini berfokus pada integrasi *webcam* atau *eyepiece camera* sebagai modul akuisisi citra dengan mikroskop konvensional, serta model YOLOv8 yang telah dilatih untuk mengklasifikasikan parasit malaria pada sel darah merah. Kamera digunakan untuk menangkap citra mikroskopis secara *real-time*, kemudian citra tersebut dialirkan untuk diproses secara digital menggunakan bahasa pemrograman *Python* dengan bantuan pustaka *OpenCV*.

Proses *pre-processing* pada tahap integrasi meliputi penyesuaian resolusi, peningkatan kontras, dan normalisasi warna agar citra memenuhi syarat standar masukan model. Setelah citra siap, proses analisis dilakukan menggunakan bobot model terbaik (*best.pt*) melalui *framework PyTorch* dan pustaka *ultralytics*. Hasil inferensi yang dihasilkan berupa identifikasi spesies parasit, apakah terinfeksi *Plasmodium falciparum* atau *Plasmodium vivax*, yang kemudian ditampilkan secara visual melalui antarmuka pengguna grafis (GUI). Untuk mengoptimalkan kecepatan deteksi pada perangkat dengan daya komputasi terbatas, penelitian ini juga mempertimbangkan teknik optimasi seperti kuantisasi model atau konversi ke format yang lebih ringan hal ini juga untuk memastikan sistem dapat beroperasi dengan latensi yang sangat rendah. Hasil visual melalui antarmuka pengguna grafis atau GUI dapat dilihat pada Gambar 3.8.



Gambar 3.6 Design GUI

Pada gambar ini terlihat baseline atau kerangka awal dari GUI, dimana di dalam GUI ini sendiri memiliki beberapa kategori fitur dimulai dari *camera*, *flip control*, *zoom control*, dan *export image*.

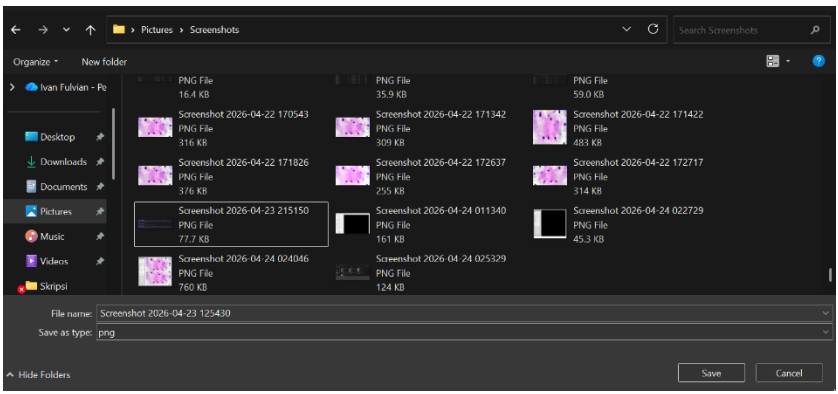
Di dalam masing-masing kategori fitur memiliki beberapa tombol atau fitur sendiri, dimulai dengan *camera* di dalam kategori fitur *camera* memiliki tombol *start camera* hal ini berfungsi untuk memulai proses atau model untuk model mulai melakukan identifikasi terhadap gambar yang diberi. Sedangkan, penggunaan *stop camera* berfungsi untuk menghentikan proses deteksi model yang sedang dilakukan atau mematikan kamera yang digunakan agar berhenti untuk mendeteksi hal ini akan menyebabkan area yang sebelumnya terdapat gambar dari parasit akan menghasilkan warna hitam. Berikutnya ada *take image* hal ini bertujuan untuk mengambil gambar dari hasil deteksi yang sudah dilakukan. Lalu, terdapat *check camera* tombol ini berfungsi untuk memberitahu pengguna terkait terdeteksinya *camera* atau tidak di dalam GUInya, apabila tidak terdeteksi maka akan memberikan teks "*camera not detected* " atau "*camera detected* " dalam warna merah.

Berikutnya terdapat fitur *flip controls*, fitur ini memiliki tujuan untuk melakukan rotasi terhadap gambar yang sudah diberi dengan harapan dapat meningkatkan tingkat akurasi atau mempermudah pengguna dalam melakukan pendeteksian secara manual apabila perlu. Di dalam fitur *flip controls* terdapat beberapa tombol lagi dimulai dengan 90°, 180°, 270°. Dengan adanya slider untuk melakukan rotasi secara *custom* atau sesuai kebutuhan pengguna dengan maskimum slider 360°.

Lalu, terdapat fitur *zoom control,* fitur ini memberikan pengguna kemampuan untuk melakukan pembesaran gambar sesuai

kebutuhan dari pengguna dengan harapan dapat meningkatkan akurasi dari model atau mempermudah pengguna dalam melihat parasit. Di dalam fitur *zoom control* ini memiliki beberapa tombol lainnya, dimulai dengan *zoom* (+), fitur ini memberikan kemampuan pengguna untuk melakukan pembesaran gambar secara bertahap dengan tingkat pembesaran 10%. Lalu, terdapat fitur *zoom* (-) dengan kemampuan kebalikannya dari *zoom* (+) yang memberikan kemampuan kepada pengguna untuk melakukan memperkecilkan ukuran gambar. Berikutnya, terdapat fitur *reset* hal ini bertujuan untuk melakukan *reset* terhadap peningkatan atau penurunan *zoom* yang telah dilakukan oleh pengguna.

Berikutnya terdapat fitur *export image* hal ini memberikan kemampuan kepada pengguna untuk menyimpan hasil gambar dari GUI langsung ke dalam *folder* atau *file* yang ada di dalam perangkat pengguna, dengan memberikan tempat penyimpanan yang *custom* atau menyesuaikan dengan kebutuhan pengguna. Contoh tempat penyimpanan gambar dapat dilihat pada gambar 3.9.



Gambar 3.7 Lokasi Penyimpanan File

Tempat penyimpanan gambar dapat disimpan di dalam *folder* tertentu atau pengguna dapat membuat *folder* baru khusus untuk gambar-gambar yang sudah atau akan di ambil.

3.6.4 Uji Implementasi

Setelah proses integrasi berhasil diselesaikan, langkah berikutnya adalah melakukan uji implementasi. Tahap ini bertujuan untuk menguji implementasi sistem yang telah dikembangkan, dengan fokus pada integrasi model YOLO dengan mikroskop konvensional melalui modul kamera digital. Uji implementasi dilakukan dengan dataset digital, dimana pada tahap ini, model YOLO yang telah dilatih diuji menggunakan *slide* preparate sel darah tipis untuk memastikan akurasi deteksi P.falciparum, P.vivax.

3.7 Interpretasi Data/Analisis Data

Tahap interpertasi data termasuk sebagai langkah yang sangat krusial dalam penelitian ini, hal ini berfungsi sebagai evaluasi kinerja sistem deteksi malaria berbasis YOLOv8 yang telah di kembangkan. Setelah proses pengujian model selesai dilakukan, hasil inferensi tidak hanya dilihat dari sebatas angka metrik komputasional saja, namun juga diinterpertasikan relevansinya terhadap standar atau *gold standard* diagnosis klinis. Analisis ini bertujuan untuk mengonfirmasi apakah sistem yang dirancang telah mampu mengenali dan membedakan kelas *plasmodium falciparum* dan *plasmodium vivax* pada citra mikroskopis sediaan darah secara akurat, persisi dan sesuai dengan hipotesis awal penelitian.

Secara kuantitatif, cara melakukan interpretasi data adalah dengan mengevaluasi performa algoritmik model berdasarkan parameter statistik yang diturunkan dari *Confusion Matrix*, yaitu

Akurasi, Presisi, *Recall*, *F1-Score*, dan *Mean Average Precision* (mAP@50). Teori dan asumsi yang dipakai dalam analisis ini adalah bahwa untuk sistem deteksi pencitraan medis penyakit menular seperti malaria, nilai sensitivitas (*Recall*) memiliki tingkat prioritas yang sangat krusial. Hal ini dilandaskan pada asumsi klinis bahwa meminimalkan *False Negative* (sistem gagal mendeteksi parasit yang sebenarnya ada di darah pasien) jauh lebih penting dibandingkan menekan *False Positive* (sistem mendeteksi artefak kotoran sebagai parasit), karena kesalahan melewatkan sel yang terinfeksi dapat berakibat fatal bagi penanganan pengobatan pasien. Pencapaian target evaluasi seperti mAP50% yang tinggi akan menjadi indikator utama bahwa model telah mengekstraksi fitur dengan baik dan layak untuk tahap implementasi.

Selanjutnya, secara kualitatif, data hasil deteksi berupa pelokalan kotak pembatas (*bounding box*) dari model YOLOv8 akan divalidasi melalui metode komparatif. Data yang digunakan sebagai pembanding mutlak (*ground truth*) dalam penelitian ini adalah hasil diagnosis dan anotasi manual yang telah dikonfirmasi oleh ahli mikroskopis dari Puskesmas Desa Hanura, yang bertindak sebagai representasi metode *gold standard*. Apabila ditemukan anomali atau kesalahan deteksi (*misclassification*), maka analisis data akan dilanjutkan untuk mengidentifikasi faktor penyebabnya secara visual, seperti pengaruh kualitas sediaan preparat, penumpukan sel darah putih, atau munculnya artefak *vignetting* akibat keterbatasan *Field of View* (FoV) dari lensa mikroskop. Melalui perbandingan klinis ini, hasil interpretasi pada akhirnya dapat membuktikan seberapa andal dan konsisten sistem yang dibangun dalam mendampingi serta mengurangi beban kerja tenaga medis di lapangan.

DAFTAR PUSTAKA

[1] Hilma Mayasari, "Eliminasi Malaria Di Berbagai Negara: Literature Review," *Journal of Nursing and Public Health*, vol. 11, no. 1, pp. 73–83, 2023.

[2] Kemenkes, "Buku Saku Pengobatan Malaria," 2023.

[3] I. Lusi and M. Usman, "Pemetaan Persebaran Penyakit Malaria di Kecamatan Punduh Pidada, Kabupaten Pesawaran, Provinsi LampungMapping the Distribution of Malaria in Punduh Pidada District, Pesawaran Regency, Lampung Province," *Spatial: Wahana Komunikasu dan Informasi Geografi*, no. 1, pp. 85–94, 2023.

[4] Nani Sri, "*Environmental Factors to Malaria Incidence: A Literature Review*," *Journal of Community Medicine and Public Health Research*, vol. 5, no. 2, pp. 197–207, 2024.

[5] R. Varo, N. Balanza, A. Mayor, and Q. Bassat, "*Diagnosis of clinical malaria in endemic settings*," *Expert Rev. Anti. Infect. Ther.*, vol. 19, no. 1, pp. 79–92, 2021.

[6] A. Mbanefo and N. Kumar, "*Evaluation of malaria diagnostic methods as a key for successful control and elimination programs,*" *Trop. Med. Infect. Dis.*, vol. 5, no. 2, 2020.

[7] O. Oyegoke, L. Maharaj, O. P. Akoniyon, I. Kwoji, A. T. Roux, T. S. Adewumi, R. Maharaj, B. T. Oyebola, M. A. Adeleke, and M. Okpeku, "*Malaria diagnostic methods with the elimination goal in view*," *Parasitol. Res.*, vol. 121, no. 7, pp. 1867–1885, 2022.

[8] J, Sam., "*Should Deep-Sequenced Amplicons Become the New Gold Standard for Analyzing Malaria Drug Clinical Trials?*" *Antimicrobial Chemotherapy*, vol. 65, pp. 3–18, 2021.

[9] A. Amir, F. W. Cheong, J. R. De Silva, and Y. L. Lau, "*Diagnostic tools in childhood malaria*," *Parasit. Vectors*, vol. 11, no. 1, pp. 1–12, 2018.

[10] Blaine A., "*Update on Malaria Diagnostics and Test Utilization*," *J. Clin. Microbiol.*, vol. 55, no. 7, pp. 3–46, 2017.

[11] K. Tam, D. Eaton, A. Mayo, A. James, C. Tefertiller, K. C. Stenson, C. Curtin, D. Ota, F. Laurent, M. J. Berger, J. Dengler, and I. K. Fox, "*Health Care Utilization in Veterans With Tetraplegia in the First Year After Cervical Spinal Cord Injury: Identifying Opportunities for Dissemination of Treatment Information*," *Arch. Phys. Med. Rehabil.*, Aug. 2025.

[12] A. Widayani, A. M. Putra, A. R. Maghriebi, D. Z. C. Adi, and Moh. H. F. Ridho, "Review of Application YOLOv8 in Medical Imaging," *Indonesian Applied Physics Letters*, vol. 5, no. 1, pp. 23–33, 2024.

[13] L. Ezzeddini, J. Ktari, T. Frikha, N. Alsharabi, A. Alayba, A. J. Alzahrani, A. Jadi, A. Alkholidi, and H. Hamam, "Analysis of the performance of Faster R-CNN and YOLOv8 in detecting fishing vessels and fishes in real time," *PeerJ Comput. Sci.*, vol. 10, pp. 1–15, 2024.

[14] M. Peckham, "*What is a microscope? How the microscope has evolved over three hundred and fifty years*," *J. Phys. Conf. Ser.*, vol. 2877, no. 1, 2024.

[15] H. Lee and I. J. Rhyu, "*Antonie van Leeuwenhoek and the dawn of microscopic observation: a narrative review from Delft's lens to the modern microscope*," *Applied Microscopy*, vol. 56, no. 1. Springer, 01-Dec-2026.

[16] Prestel C, "Malaria Diagnostic Practices in U.S. Laboratories," *J. Clin. Microbiol.*, vol. 56, no. 8, 2017.

[17] Y. Wang, X. Zhang, J. Xu, X. Sun, X. Zhao, H. Li, Y. Liu, J. Tian, X. Hao, X. Kong, Z. Wang, J. Yang, and Y. Su, "*The Development of Microscopic Imaging Technology and its Application in Micro- and Nanotechnology*," *Frontiers in Chemistry*, vol. 10. Frontiers Media SA, 05-Jul-2022.

[18] M. Weber and J. Huisken, "*Multidisciplinarity Is Critical to Unlock the Full Potential of Modern Light Microscopy*," *Front. Cell Dev. Biol.*, vol. 9, Oct. 2021.

[19] A. J. M. Wollman, R. Nudd, E. G. Hedlund, M. C. Leake, and M. C. Leake, "*IX. An account of Mr. Leeuwenhoek's microscopes*," *Philos. Trans. R. Soc. Lond.*, vol. 41, no. 458, pp. 503–519, 1740.

[20] S. Iyer, "*Watching The Embryo: Evolution Of The Microscope For The Study Of Embryogenesis*," *BioEssays*, 2021.

[21] L. E. Franken, K. Grünewald, E. J. Boekema, and M. C. A. Stuart, "*A Technical Introduction to Transmission Electron Microscopy for Soft-Matter: Imaging, Possibilities, Choices, and Technical Developments*," *Small*, vol. 16, no. 14. Wiley-VCH Verlag, 01-Apr-2020.

[22] *World Health Organization*, *World malaria report 2024*. Geneva: Global Malaria Programme (GMP), 2024.

[23] Caitlin A, "*The History Of The Microscope Reflects Advances In Science And Medicine*," *Semin. Diagn. Pathol.*, vol. 42, no. 2, pp. 74–257, 2025.

[24] Mijithra Ganesan, "*Foldscope Microscope, An Inexpensive Alternative Tool To Conventional Microscopy—Applications In Research And Education: A Review*," *Microsc Res Tech*, vol. 85, no. 11, pp. 3484–3494, 2022.

[25] Suman, "*Microscope In Dentistry: A Review Article*," *Innovare Journal of Medical Sciences*, vol. 9, no. 2, pp. 15–21, 2021.

[26] Araki, "*The History Of Optical Microscope*," *Mechanical Engineering Reviews*, vol. 4, no. 1, pp. 16-00242-16–00242, 2017.

[27] W. Wimmer, "*Carl Zeiss, Ernst Abbe, And Advances In The Light Microscope*," *Micros. Today*, vol. 25, no. 4, pp. 50–57, 2017.

[28] Prestel C, "*Malaria Diagnostic Practices in U.S. Laboratories*," *J. Clin. Microbiol.*, vol. 56, no. 8, 2017.

[29] N. J. White, "*Severe malaria*," *Malar. J.*, pp. 1–17, 2022.

[30] A. Chakraborty, "*NU Understanding the biology of the Plasmodium*," *Life Sci.*, 2016.

[31] B. Dinko and G. Pradel, "*Immune Evasion by Plasmodium falciparum Parasites: Converting a Host Protection Mechanism for the Parasite's Benefit*," no. June, pp. 82–95, 2016.

[32] M. P. Jessica Molina-Franky, M. Patarroyo, M. Kalkum, "*The Cellular And Molecular Interaction Between Erythrocytes And Plasmodium Falciparum Merozoites*," *Front. Cell. Infect. Microbiol.*, vol. 12, 2022.

[33] M. Poostchi, K. Silamut, R. J. Maude, S. Jaeger, and G. Thoma, "*Image Analysis And Machine Learning For Detecting Malaria*," *Translational Research*, vol. 194. Mosby Inc., pp. 36–55, 01-Apr-2018.

[34] M. Fikadu and E. Ashenafi, "*Malaria: An Overview*," *Infection and Drug Resistance*, vol. 16. Dove Medical Press Ltd, pp. 3339–3347, 2023.

[35] Dr. N. Saxena, Dr. S. C. Meena, and Dr. S. S. Shekhawat, "*Malaria: A Backyard Enemy*," *Pharma Innov.*, vol. 12, no. 3, pp. 489–496, Jan. 2023.

[36] J. R. Poespoprodjo, N. M. Douglas, D. Ansong, S. Kho, and N. M. Anstey, "*Malaria*," *The Lancet*, vol. 402, no. 10419, pp. 2328–2345, Dec. 2023.

[37] J. M. Roth, D. A. Korevaar, M. M. G. Leeflang, and P. F. Mens, "*Molecular Malaria Diagnostics: A Systematic Review And Meta-Analysis*," *Critical Reviews in Clinical Laboratory Sciences*, vol. 53, no. 2. Taylor and Francis Ltd, pp. 87–105, 03-Mar-2016.

[38] M. Rana and M. Bhushan, "*Machine Learning And Deep Learning Approach For Medical Image Analysis: Diagnosis To Detection*," *Multimed. Tools Appl.*, vol. 82, no. 17, pp. 26731–26769, 2023.

[39] Ms. Aayushi, "*A Systematic Review On Data Scarcity Problem In Deep Learning: Solution And Applications*," *Association for Computing Machinery*, vol. 54, no. 10, pp. 300–360, 2022.

[40] D. Muchlinski, "*Machine Learning And Deep Learning*," *Elgar Encyclopedia of Technology and Politics*, pp. 114–118, 2022.

[41] C. Janiesch, P. Zschech, and K. Heinrich, "*Machine Learning And Deep Learning*," no. 31, pp. 685–695, 2021.

[42] Dr. Sheshang Degadwala and Dhairya Vyas, "*Systematic Analysis of Deep Learning Models vs. Machine Learning*," *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, vol. 10, no. 4, pp. 60–70, 2024.

[43] G. B. Goh, N. O. Hodas, and A. Vishnu, "*Deep Learning For Computational Chemistry*," *J. Comput. Chem.*, vol. 38, no. 16, pp. 1291–1307, 2017.

[44] O. Y. Al-jarrah, P. D. Yoo, S. Muhaidat, G. K. Karagiannidis, and K. Taha, "*Efficient Machine Learning For Big Data : A Review*," pp. 1–8.

[45] N. K. C. and K. Singh, "*A Review On Conventional Machine Learning Vs Deep Learning*," *2018 International Conference on Computing, Power and Communication Technologies (GUCON), Greater Noida, India,* pp. 347–352, 2018.

[46] S. S. Pramila P. Shinde, "*A Review Of Machine Learning And Deep Learning Applications*," *2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBEA)*, 2018.

[47] S. Razavi, "*Deep Learning, Explained: Fundamentals, Explainability, And Bridgeability To Process-Based Modelling*," *Environmental Modelling & Software*, vol. 144, 2021.

[48] A. Mosso Vázquez, D. Juárez-Romero, J. A. Hernández-Pérez, D. Echeverría Sosa, J. E. Loría Yah, R. J. González Horta, G. I. de A. Pech Carveo, and C. A. Decena Chan, "*Una Revisión De Los Fundamentos De Aprendizaje Profundo – El Modelo De Red Neuronal XOR*," *Programación Matemática y Software*, vol. 15, no. 1, 2023.

[49] M. M. Taye, "*Theoretical Understanding Of Convolutional Neural Network: Concepts, Architectures, Applications, Future Directions*," *Computation*, vol. 11, no. 3. MDPI, 01-Mar-2023.

[50] Purwono, A. Ma'arif, W. Rahmaniar, H. I. K. Fathurrahman, A. Z. K. Frisky, and Q. M. U. Haq, "*Understanding of Convolutional Neural Network (CNN): A Review*," *International Journal of Robotics and Control Systems*, vol. 2, no. 4, pp. 739–748, 2022.

[51] A. Upreti, "*Convolutional Neural Network (CNN): A Comprehensive Overview*," vol. 3, no. 4, pp. 488–493.

[52] G. W. Lindsay, "Convolutional Neural Networks as a Model of the Visual System: Past, Present, and Future," 2018.

[53] Teguh Wahyono, "*Python for Machine Learning* (Dasar-dasar Pemrograman *Python* untuk *Machine Learning* dan Kecerdasan Buatan)," 2013.

[54] S. Tiwari, G. Jain, D. K. Shetty, M. Sudhi, J. M. Balakrishnan, and S. R. Bhatta, "*A Comprehensive Review on the Application of 3D Convolutional Neural Networks in Medical Imaging*," *Engineering Proceedings*, vol. 59, no. 1, 2023.

[55] Mohammad Gouse Galety, "*Deep Neural Network Concepts for Classification using Convolutional Neural Network: A Systematic Review and Evaluation*," 2021.

[56] Y. Lee, "*The CNN: The Architecture Behind Artificial Intelligence Development*," no. 4, pp. 4–12, 2023.

[57] T. A. M. Saad Albawi, "2017 International Conference on Engineering and Technology," vol. 3, no. 8, pp. 19–49, 2017.

[58] R. Sarno, S. Sabila, M. Malikhah, D. Purbawa, and M. S. Ardani, *Machine Learning dan Deep Learning-Konsep dan Pemrograman Python*. 2022.

[59] B.-S. Wang, J.-W. Hsieh, M.-C. Chang, P.-Y. Chen, L. Ke, and S. Lyu, "*Learnable Discrete Wavelet Pooling (LDW-Pooling) For Convolutional Networks*," Oct. 2021.

[60] A. Zafar, N. Saba, A. Arshad, A. Alabrah, S. Riaz, M. Suleman, S. Zafar, and M. Nadeem, "*Convolutional Neural Networks: A Comprehensive Evaluation and Benchmarking of Pooling Layer Variants*," *Symmetry (Basel).*, vol. 16, no. 11, Nov. 2024.

[61] N. I. Galanis, P. Vafiadis, K. G. Mirzaev, and G. A. Papakostas, "*Convolutional Neural Networks: A Roundup and Benchmark of Their Pooling Layer Variants*," *Algorithms*, vol. 15, no. 11, Nov. 2022.

[62] X. Zhao, L. Wang, Y. Zhang, X. Han, M. Deveci, and M. Parmar, "*A Review Of Convolutional Neural Networks In Computer Vision*," *Artif. Intell. Rev.*, vol. 57, no. 4, Apr. 2024.

[63] Zewen Li, "*Survey of Convolutional Neural Networks Analysis, Applications, and Prospect*," vol. 7, no. 4, pp. 1–21, 2020.

[64] H. Yingge, I. Ali, and K. Y. Lee, "*Deep Neural Networks On Chip - A Survey*," in *Proceedings - 2020 IEEE International Conference on Big Data and Smart Computing, BigComp 2020*, 2020, pp. 589–592.

[65] N. Bilous, V. Malko, M. Frohme, and A. Nechyporenko, "*Comparison Of CNN-Based Architectures For Detection Of Different Object Classes*," *AI (Switzerland)*, vol. 5, no. 4, pp. 2300–2320, Dec. 2024.

[66] S. H. S. Basha, S. R. Dubey, V. Pulabaigari, and S. Mukherjee, "*Impact Of Fully Connected Layers On Performance Of Convolutional Neural Networks For Image Classification*," *Neurocomputing*, vol. 378, pp. 112–119, Feb. 2020.

[67] P. Kocsis, P. Súkeník, G. Brasó, M. Nießner, L. Leal-Taixé, and I. Elezi, "*The Unreasonable Effectiveness Of Fully-Connected Layers For Low-Data Regimes*," Oct. 2022.

[68] C. H. Yeh, M. H. Lin, P. C. Chang, and L. W. Kang, "*Enhanced Visual Attention-Guided Deep Neural Networks For Image Classification*," *IEEE Access*, vol. 8, pp. 163447–163457, 2020.

[69] B. Zhang, Q. Zhao, W. Feng, and S. Lyu, "AlphaMEX: *A Smarter Global Pooling Method For Convolutional Neural Networks*," *Neurocomputing*, vol. 321, pp. 36–48, Dec. 2018.

[70] H. H. Chen, B. J. Hwang, J. S. Wu, and P. T. Liu, "*The Effect Of Different Deep Network Architectures Upon CNN-Based Gaze Tracking*," *Algorithms*, vol. 13, no. 5, May 2020.

[71] W. Wang, J. Tian, C. Zhang, Y. Luo, X. Wang, and J. Li, "*An Improved Deep Learning Approach And Its Applications On Colonic Polyp Images Detection*," *BMC Med. Imaging*, vol. 20, no. 1, Jul. 2020.

[72] S. Y. Ali and H. Maseeh, "*Dropout: An Effective Approach to Prevent Neural Networks from Overfitting*," *Asian Journal of Research in Computer Science*, vol. 18, no. 2, pp. 163–185, Feb. 2025.

[73] Olivia Harris and Michael Andrews, "*Effects And Results Of Dropout Layer In Reducing Overfitting With Convolutional Neural Networks* (CNN)," *World Journal of Advanced Engineering Technology and Sciences*, vol. 13, no. 2, pp. 836–853, Dec. 2024.

[74] M. Xiao, Y. Wu, G. Zuo, S. Fan, H. Yu, Z. A. Shaikh, and Z. Wen, "*Addressing Overfitting Problem in Deep Learning-Based Solutions for Next Generation Data-Driven Networks*," *Wirel. Commun. Mob. Comput.*, vol. 4, no. 6, pp. 1–10, 2021.

[75] H. Hu, "*Galaxy Classification Based On Convolutional Neural Networks With Dropout Technique*," *Applied and Computational Engineering*, vol. 22, no. 1, pp. 42–52, Oct. 2023.

[76] Y. Zeng, T. Dai, B. Chen, S. T. Xia, and J. Lu, "*Correlation-Based Structural Dropout For Convolutional Neural Networks*," *Pattern Recognit.*, vol. 120, no. 10, Dec. 2021.

[77] F. Sultana, A. Sufian, and P. Dutta, "*A Review of Object Detection Models based on Convolutional Neural Network*," vol. 5, no. 6, Oct. 2019.

[78] S. Reddy, N. Pillay, and N. Singh, "*Comparative Evaluation of Convolutional Neural Network Object Detection Algorithms for Vehicle Detection*," *J. Imaging*, vol. 10, no. 7, Jul. 2024.

[79] T. Diwan, G. Anirudh, and J. V. Tembhurne, "*Object Detection Using YOLO: Challenges, Architectural Successors, Datasets And Applications*," *Multimed. Tools Appl.*, vol. 82, no. 6, pp. 9243–9275, Mar. 2023.

[80] Y. Wang, "*Comparative Analysis of Object Detection Architectures for Enhanced Performance and Application Suitability*," *Applied and Computational Engineering*, vol. 166, no. 1, pp. 70–77, Jun. 2025.

[81] A. Mukhriddin "*A Comparative Study Of Various Object Detection Algorithms*," *International Research Journal of Modernization in Engineering Technology and Science*, no. 6, pp. 1–8, Jun. 2024.

[82] X. Pan, Z. Luo, and L. Zhou, "*Comprehensive Survey of State-of-the-Art Convolutional Neural Network Architectures and Their Applications in Image Classification*," *Innovations in Applied Engineering and Technology*, pp. 1–16, Mar. 2022.

[83] Dr. S. Gothane, "*A Practice for Object Detection Using YOLO Algorithm*," *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, pp. 268–272, Apr. 2021.

[84] S. Bhattacharjee, "*A Literature-based Performance Assessment of the* YOLO (You Only Look Once) CNN *Approach for Real-time Object Detection*," *Computology: Journal of Applied Computer Science and Intelligent Technologies*, vol. 4, no. 2, pp. 18–40, Apr. 2025.

[85] S. K. Patil, A. N. Kharade, A. M. Kesarkar, U. D. Bankarmali, and N. Magdum, "*Object Detection Using YOLO*," vol. 7, no 3, pp 1-4, June 2025

[86] G. Lavanya and S. D. Pande, "*Enhancing Real-time Object Detection with YOLO Algorithm*," *EAI Endorsed Transactions on Internet of Things*, vol. 10, 2024.

[87] Thrupthi C P, Dr. Chitra K, and Mrs Harilakshmi V M, "*Object Detection for Autonomous Vehicles Using YOLO Algorithm*," *International Journal of Advanced Research in Science, Communication and Technology*, pp. 180–184, Nov. 2024.

[88] R. Y. Ju and W. Cai, "*Fracture detection in pediatric wrist trauma X-ray images using YOLOv8 algorithm*," *Sci. Rep.*, vol. 13, no. 1, Dec. 2023.

[89] Mr. J. Rajasekhar, "*Understanding Yolo: Real-Time Object Detection Explained*," *INTERANTIONAL JOURNAL OF SCIENTIFIC RESEARCH IN ENGINEERING AND MANAGEMENT*, vol. 08, no. 07, pp. 1–9, Jul. 2024.

[90] N. Jegham, C. Y. Koh, M. Abdelatti, and A. Hendawi, "YOLO *Evolution: A Comprehensive Benchmark and Architectural Review of* YOLOv12, YOLO11, *and Their Previous Versions*," vol. 14, no. 3, Mar. 2025.

[91] M. Yaseen, "*What is* YOLOv8: *An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*," vol. 10, no. 6, Aug. 2024.

[92] M. Talib, A. H. Y. Al-Noori, and J. Suad, "YOLOv8-CAB: *Improved* YOLOv8 *for Real-time Object Detection*," *Karbala International Journal of Modern Science*, vol. 10, no. 1, pp. 56–68, 2024.

[93] L. Zedda, A. Loddo, and C. Di Ruberto, "*A Deep Architecture Based On Attention Mechanisms For Effective End-To-End Detection Of Early And Mature Malaria Parasites In A Realistic Scenario*," *Comput. Biol. Med.*, vol. 186, Mar. 2025.

[94] N. Kriegeskorte, "*Crossvalidation in Brain Imaging Analysis*," vol. 9, no. 6, pp. 1–7, Apr. 2015.

[95] R. I. A. S. Zahra Nematzadeh, "*Comparative Studies on Breast Cancer Classifications with K-Fold Cross Validations Using Machine Learning Techniques*," vol. 1, 2015.

[96] C. Andrzej D. Dobrzycki, "*An Analysis of Layer-Freezing Strategies for Enhanced Transfer Learning in YOLO Architectures"*, vol. 13. IEEE, 2015.

[97] D. A. Mura, L. Zedda, A. Loddo, and C. Di Ruberto, "*YOLO-Tryppa: A Novel YOLO-Based Approach for Rapid and Accurate Detection of Small Trypanosoma Parasites*," *J. Imaging*, vol. 11, no. 4, Apr. 2025.