FINE-TUNING MODEL *YOU ONLY LOOK ONCE* V8M UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN *SMEAR* DARAH

TUGAS AKHIR

IVAN FULVIAN PITOYO

122430064



PROGRAM STUDI TEKNIK BIOMEDIS

FAKULTAS TEKNOLOGI INDUSTRI

INSTITUT TEKNOLOGI SUMATERA

2026

FINE-TUNING MODEL *YOU ONLY LOOK ONCE* V8M UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN *SMEAR* DARAH

TUGAS AKHIR

IVAN FULVIAN PITOYO

122430064



PROGRAM STUDI TEKNIK BIOMEDIS

FAKULTAS TEKNOLOGI INDUSTRI

INSTITUT TEKNOLOGI SUMATERA

2026

LEMBAR PENGESAHAN

Laporan Tugas Akhir dengan judul "*FINE-TUNING* MODEL *YOU ONLY LOOK ONCE* V8 UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN *SMEAR* DARAH" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan di serahkan sebelumnya, baik sebagian atau seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.



Lampung Selatan, 11 Agustus 2026
Penulis,
Ivan Fulvian Pitoyo
122430064

Diperiksa dan disetujui oleh,

Pembimbing I	Pembimbing II
Martin Clinton Tosima Manullang, Ph.D.	I Gde Eka Dirgayussa, M.Si
NIP.199301092019031017	NIP. 198905032024061001

Disahkan oleh,
Koordinator Program Studi Teknik Biomedis
Fakultas Teknik Industri
Institut Teknologi Sumatera

Rudi Setiawan, S.T., M.T.
NIP. 199306032022031008

HALAMAN PERNYATAAN ORISINALITAS

Tugas akhir ini adalah karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan benar.

Nama	**:** Ivan Fulvian Pitoyo
NIM	**:** 122430064
Tanda Tangan	**:**
Tanggal	**:** 11 Agustus 2026

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik eInstitut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : Ivan Fulvian Pitoyo

NIM : 122430064

Program Studi : Teknik Biomedis

Fakultas : Fakultas Teknologi Industri

Jenis karya : Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Sumatera **Hak Bebas Royalti Noneksklusif (Non- exclusive Royalty Free Right)** atas karya ilmiah saya yang berjudul:

Fine-Tuning Model You Only Look Once V8m Untuk Deteksi Parasit Malaria Pada Citra Mikroskopis Sediaan Smear Darah

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (database), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta. Demikian pernyataan ini saya buat dengan sebenarnya

Dibuat di: Lampung Selatan

Pada tanggal: 11 Agustus 2026

Yang Menyatakan (Ivan Fulvian Pitoyo)

ABSTRAK

FINE-TUNING MODEL *YOU ONLY LOOK ONCE* V8M UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN SMEAR DARAH

Ivan Fulvian Pitoyo (122430064)

Pembimbing: Martin Clinton Tosima Manullang, Ph.D, I Gde Eka Dirgayussa, M.Si

RINGKASAN

Malaria masih menjadi tantangan kesehatan yang signifikan di Indonesia, khususnya di wilayah endemis seperti Lampung. Diagnosis konvensional melalui pemeriksaan mikroskopis manual masih bergantung pada ketelitian tenaga medis dalam mengamati citra secara berulang, sehingga berpotensi menimbulkan kelelahan visual dan memengaruhi konsistensi pengamatan. Penelitian ini bertujuan untuk mengembangkan sistem deteksi otomatis parasit malaria spesies *Plasmodium falciparum* dan *Plasmodium vivax* pada citra mikroskopis sediaan smear darah menggunakan pendekatan *fine-tuning* model *You Only Look Once* (YOLO)v8m yang telah di*pre-training* menggunakan *dataset* COCO. Dataset citra mikroskopis dari Puskesmas Hanura mengalami ketidakseimbangan kelas, sehingga diterapkan augmentasi data berupa *noise*, *brightness*, dan *flip* serta tiga skenario penanganan imbalance, yaitu oversampling dengan rasio 1:2, *global augmentation*, dan *undersampling* dengan rasio 1:1. Optimasi hyperparameter dilakukan menggunakan algoritma Optuna sebanyak 153 trial untuk memperoleh kombinasi learning rate, momentum, dan weight decay terbaik. Berdasarkan evaluasi keseluruhan, skenario *oversampling* menghasilkan performa terbaik dibandingkan *global augmentation* dan *undersampling*, dengan mAP@50 sebesar 91%, mAP@50-95 sebesar 59%, Precision sebesar 86%, Recall sebesar 83%, dan F1-Score sebesar 84%. Sementara itu, *global augmentation* dan *undersampling* menghasilkan false positive yang lebih tinggi, yang menunjukkan bahwa kedua strategi tersebut belum mampu menangani ketidakseimbangan kelas secara optimal. Model terbaik kemudian diintegrasikan ke dalam GUI berbasis Python dan OpenCV yang terhubung dengan kamera mikroskop untuk mendukung skrining malaria secara real-time. Penelitian ini menunjukkan bahwa strategi *oversampling* lebih efektif dibandingkan *global augmentation* dan *undersampling* dalam menangani ketidakseimbangan kelas pada sistem deteksi parasit malaria berbasis deep learning.

Kata kunci: *Deep Learning*, Malaria, Mikroskop, *Object Detection*, YOLOv8

ABSTRACT

FINE-TUNING OF YOU ONLY LOOK ONCE V8 MODEL FOR MALARIA PARASITE DETECTION IN MICROSCOPIC BLOOD SMEAR IMAGES

Ivan Fulvian Pitoyo (122430064)

Supervisor(s): Martin Clinton Tosima Manullang, Ph.D, I Gde Eka Dirgayussa, M.Si

SUMMARY

Malaria remains a significant health challenge in Indonesia, particularly in endemic areas such as Lampung. Conventional diagnosis through manual microscopic examination still relies on the accuracy of medical personnel in repeatedly observing microscopic images, which may lead to visual fatigue and affect observation consistency. This study aims to develop an automated detection system for malaria parasites of the species Plasmodium falciparum and Plasmodium vivax in microscopic images of blood smear preparations using a fine-tuning approach with the You Only Look Once (YOLO)v8m model, which was pretrained on the COCO dataset. The microscopic image dataset obtained from Puskesmas Hanura was affected by class imbalance; therefore, data augmentation techniques, including noise, brightness, and flip, were applied along with three imbalance-handling scenarios: oversampling with a 1:2 ratio, global augmentation, and undersampling with a 1:1 ratio. Hyperparameter optimization was performed using the Optuna algorithm with 153 trials to obtain the optimal combination of learning rate, momentum, and weight decay. Based on the overall evaluation, the oversampling scenario achieved the best performance compared with global augmentation and undersampling, with an mAP@50 of 91%, mAP@50-95 of 59%, Precision of 86%, Recall of 83%, and F1-Score of 84%. Meanwhile, global augmentation and undersampling resulted in higher false positives, indicating that these two strategies were not able to address the class imbalance optimally. The best-performing model was then integrated into a graphical user interface (GUI) based on Python and OpenCV and connected to a microscope camera to support real-time malaria screening. This study demonstrates that the oversampling strategy is more effective than global augmentation and undersampling in addressing class imbalance in a deep learning-based malaria parasite detection system.

Keywords: Deep Learning, Malaria, Microscope, Object Detection, YOLOv8

KATA PENGANTAR

Puji syukur senantiasa penulis panjatkan kehadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia yang diberikan, sehingga penyusunan Laporan Tugas Akhir yang berjudul *"FINE-TUNING* MODEL *YOU ONLY LOOK ONCE V8* UNTUK DETEKSI PARASIT MALARIA PADA CITRA MIKROSKOPIS SEDIAAN *SMEAR* DARAH″ dapat diselesaikan dengan baik. Laporan Tugas Akhir ini dimaksudkan untuk memenuhi salah satu persyaratan kelulusan dalam meraih gelar Sarjana Teknik pada Program Studi Teknik Biomedis, Jurusan Teknologi Produksi dan Industri, Institut Teknologi Sumatera. Penulis menyadari bahwa penyusunan Tugas Akhir ini, mulai dari tahap rekayasa pra-pemrosesan citra medis hingga evaluasi kinerja algoritma kecerdasan buatan, tidak akan dapat diselesaikan tanpa bimbingan, arahan, dan dukungan fasilitas dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Bapak Prof. Dr. I Nyoman Pugeg Aryantha, selaku Rektor Institut Teknologi Sumatera.
2. Bapak Hadi Teguh Yudistira S.T., Ph.D., selaku Dekan Fakultas Teknik Industri Institut Teknologi Sumatera.
3. Bapak Rudi Setiawan, S.T., M.T., selaku Koordinator Program Studi Teknik Biomedis Institut Teknologi Sumatera.
4. Bapak Martin Clinton Tosima Manullang, Ph.D., selaku Dosen Pembimbing I, yang telah meluangkan waktu dan pikiran untuk membimbing, memberikan masukan analitis yang

komprehensif, serta memvalidasi rekayasa sistem kecerdasan buatan dalam penelitian ini.

5. Bapak I Gde Eka Dirgayussa, M.Si., selaku Dosen Pembimbing II, atas saran konstruktif terkait pengolahan citra medis dan ketelitian dalam mengarahkan fundamental metodologi penelitian.
6. Institut Teknologi Sumatera, yang telah memberikan izin dan akses terhadap dataset primer citra sediaan darah mikroskopis yang menjadi subjek utama penelitian ini.
7. Terima kasih kepada LPDP atas dukungan pendanaan yang diberikan sehingga penelitian operasional komputasional ini dapat berjalan lancar.

Penulis menyadari bahwa sistem deteksi dan Laporan Tugas Akhir ini masih memiliki berbagai keterbatasan. Oleh karena itu, segala bentuk kritik dan saran yang bersifat membangun sangat diharapkan. Akhir kata, semoga Tugas Akhir ini dapat memberikan kontribusi secara ilmiah bagi pengembangan rekayasa teknologi medis di masa depan.

Tempat penyusunan TA, 30 Juli 2026

Penulis,

Ivan Fulvian Pitoyo

PERSEMBAHAN

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala Rahmat dan karunia sehingga saya dapat menyelesaikan lembar demi lembar perjalanan panjang ini. Dengan segala kerendahan hati, karya kecil ini saya persembahkan kepada:

1. Tuhan Yang Maha Esa Sumber segala ilmu pengetahuan, etenangan, dan kekuatan. Terima kasih atas petunjuk, perlindungan, dan kemudahan yang tiada henti, terutama di saat-saat paling buntu dalam menyelesaikan penelitian ini. Semua pencapaian ini pada akhirnya hanyalah titipan darinya.

2. Ayah dan Ibu Tercinta Dua sosok paling berjasa dan tak tergantikan dalam hidup saya. Terima kasih atas peluh, keringat, kasih sayang, dan doa-doanya yang selalu mengudara tanpa henti. Setiap baris kalimat dalam skripsi ini tidak akan pernah cukup untuk membalas pengorbanan kalian. Karya ini adalah bentuk bakti dan hadiah kecil untuk mengukir senyum bangga di wajah kalian.

3. Saudara dan Keluarga Besar Terima kasih atas segala bentuk dukungan moral, perhatian, dan semangat yang selalu diberikan dari rumah. Terima kasih telah selalu mengingatkan saya bahwa selalu ada tempat yang hangat untuk kembali setelah lelah berjuang.

MOTTO

"*Even if, you're tired, do it tired. Even if, you're about to cry, do it crying. Even if, the world is moving faster than you thought, just keep moving forward*"

DAFTAR ISI

LEMBAR PENGESAHAN ..... **iii**

HALAMAN PERNYATAAN ORISINALITAS ..... **iv**

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS ..... **v**

ABSTRAK ..... **vi**

ABSTRACT ..... **vii**

KATA PENGANTAR ..... **viii**

PERSEMBAHAN ..... **x**

MOTTO ..... **xi**

DAFTAR ISI ..... **xii**

DAFTAR TABEL ..... **xvi**

DAFTAR GAMBAR ..... **xvii**

BAB I PENDAHULUAN **19**

1.1 Latar Belakang 19

1.2 Perumusan Masalah 23

1.3 Tujuan Penelitian 23

1.4 Hipotesis 24

1.5 Ruang Lingkup Penelitian 25

1.6 Sistematika Penulisan 25

BAB II TINJAUAN PUSTAKA **28**

2.1 Mikroskop 28

2.2 Malaria 31
2.3 Deep Learning 39
2.4 Convolutional Neural Network (CNN) 41
2.4.1 Convolutional Layer 43
2.4.2 Pooling Layer 45
2.4.3 Fully Connected Layer 48
2.4.4 Arsitektur CNN 51
2.5 Algoritma YOLO (*You Only Look Once*) 55
2.6 *Hyperparameter* 67
2.7 *State of The Art* 70
BAB III METODOLOGI PENELITIAN 81
3.1 Jenis Penelitian 81
3.2 Waktu dan Tempat Pelaksanaan 82
3.3 Alat dan Bahan 82
3.3.1 Alat 82
3.3.2 Bahan 85
3.4 Metode dan Persamaan yang Digunakan 85
3.4.1 Fungsi Kerugian (*Loss Function*) 85
3.4.2 Parameter Optimasi (AdamW) 87
3.4.3 Metrik Evaluasi Kinerja Sistem 87
3.5 Diagram Alir Penelitian 90
3.5.1 Studi Literatur 91

3.5.2 Pengumpulan Dataset 91
3.5.3 Pre-Processing Data..... 91
3.5.4 Training Model..... 92
3.5.5 Evaluasi Model..... 92
3.5.6 Pembuatan GUI 93
3.5.7 Analisis Data 93
3.6 Langkah Penelitian secara Spesifik 93
3.6.1 Proses Training Model..... 98
3.6.2 Proses Training..... 100
3.6.3 Integrasi *Hardware* dan *Software*..... 102
3.6.4 Uji Implementasi 106
3.7 Interpretasi Data/Analisis Data..... 107
BAB IV HASIL DAN PEMBAHASAN 109
4.1 Pengolahan Dataset Citra Mikroskopis 109
4.1.1 Penyesuaian Resolusi 109
4.1.2 Implementasi Augmentasi Data..... 110
4.1.3 Pembagian Dataset 112
4.2 Fine-Tuning Model YOLOv8m..... 112
4.3 Analisis Pengaruh Distribusi dan Augmentasi Dataset 117
4.3.1 Skenario I: Pelatihan dengan *Oversampling*..... 117
4.3.2 Skenario II: Pelatihan Dengan *Global Augmentation* 125
4.3.3 Skenario III: Pelatihan Dengan *Undersampling*..... 132

4.4 Evaluasi Performa Sistem Deteksi Model 142
4.4.1 AnalisisAkurasi Spasial (mAP@50 Dan mAP@50-95) . 149
4.4.2 Analisis Keseimbangan Diagnosis Klinis (*Precision, Recall,* dan *F1-Score*) 150
4.5 Implementasi Perancangan Antarmuka Pengguna (GUI)..... 153
BAB V KESIMPULAN **155**
5.1 Kesimpulan..... 155
5.2 Saran 157
DAFTAR PUSTAKA **159**
LAMPIRAN **179**

DAFTAR TABEL

Tabel 2.1 Citra dan Karakteristik Fase Parasit falciparum 33
Tabel 2.2 Citra Dan Karakteristik Parasit Vivax 35
Tabel 2.3 Rangkuman Performa Metrik Arsitektur 52
Tabel 2.4 Rata-rata Kecepatan Pemrosesan Arsitektur..... 53
Tabel 2.5 Analisis Persentase Error Deteksi..... 54
Tabel 2.6 Detail Fungsi Blok Komponen Arsitektur YOLOv8. 64
Tabel 2.7 State Of The Art..... 70
Tabel 3.1 Spesifikasi Alat Software dan Hardware 83
Tabel 3.2 Daftar Bahan Penelitian 85
Tabel 3.3 Rangkuman Jumlah Komposisi dan Label Dataset 95
Tabel 3.4 Pembagian Data Final Training 97
Tabel 3.5 Konfigurasi *Hyperparameter*..... 101
Tabel 4.1 Hasil Data Resizing 110
Tabel 4.2 Hasil Augmentasi Data Yang Dilakukan..... 111
Tabel 4.3 Distribusi Pembagian Dataset Akhir Citra..... 112
Tabel 4.4 Hyperparameter Final 113
Tabel 4.5 Hyperparameter Test 115
Tabel 4.6 Hasil Eksperimen Hyperparameter..... 116
Tabel 4.7 Rekap Hasil Model Skenario 143
Tabel 4.8 Hasil Evaluasi Dengan Test Set Serta Validasi 145

DAFTAR GAMBAR

Gambar 2.1 Jenis Tipe Mikroskop Berdiri Pertama Kali..... 29
Gambar 2.2 Skematik Electron Microscope 30
Gambar 2.3 Arsitektur CNN 42
Gambar 2.4 Proses Komputasi Convolutional Layer..... 44
Gambar 2.5 Proses Perhitungan Pooling Layer 47
Gambar 2.6 Proses Flattening dan Koneksi. 49
Gambar 2.7 Ilustrasi Hasil Deteksi YOLO 57
Gambar 2.8 Perbandingan YOLOv8..... 58
Gambar 2.9 Arsitektur YOLOv8 59
Gambar 3.1 Diagram Alir Penelitian 90
Gambar 3.2 Diagram Alir Penelitian Spesifik 94
Gambar 3.3 Tahap Training Model..... 99
Gambar 3.4 Design GUI 104
Gambar 3.5 Lokasi Penyimpanan File..... 106
Gambar 4.1 Hasil Pembagian Labels Dalam Training Skenario 1 . 118
Gambar 4.2 Hasil Width vs Height Scatter Plot Skenario 1 119
Gambar 4.3 Hasil Grafik scatter plot Skenario 1 120
Gambar 4.4 Hasil Proses Training Skenario 1 121
Gambar 4.5 Hasil Kurva F1-Confidence Skenario 1 122
Gambar 4.6 Hasil Confusion Matrix Skenario 1..... 123
Gambar 4.7 Hasil Kurva Recall Skenario I..... 124
Gambar 4.8 Hasil Pembagian Labels Dalam Training Skenario 2 . 125
Gambar 4.9 Hasil Scatter Plot Width vs Height Skenario 2 126
Gambar 4.10 Hasil Scatter Plot xy Skenario 2..... 127
Gambar 4.11 Hasil Proses Training Model Skenario 2..... 128
Gambar 4.12 Hasil Kurva Confidence F1 Curve Skenario 2..... 129
Gambar 4.13 Hasil Confusion Matriks Skenario 2 130

Gambar 4.14 Hasil Kurva Recall Confidence Skenario 2 131
Gambar 4.15 Hasil Pembagian Data 1:1 Skenario 3 133
Gambar 4.16 Hasil Grafik Distribusi 134
Gambar 4.17 Hasil Grafik Height vs Width 135
Gambar 4.18 Hasil Training Model Skenario 3 136
Gambar 4.19 Grafik F1-Curve Skenario 3 138
Gambar 4.20 Confusion Matrix Skenario 3 139
Gambar 4.21 Hasil Curva Recall Skenario 3 141
Gambar 4.22 GUI Antarmuka Pengguna 153

BAB I
PENDAHULUAN

1.1 Latar Belakang

Malaria merupakan salah satu penyakit infeksi yang masih menjadi masalah kesehatan global, terutama di negara-negara tropis seperti Indonesia. World Health Organization (WHO) menyatakan bahwa pada tahun 2023 sendiri terdapat 263 juta kasus malaria dan 597.000 yang meninggal dikarenakan malaria [1]. Di dalam Indonesia sendiri pada tahun 2024 kasus malaria sudah mencapai 443.530 kasus dengan kasus positif malaria mencapai 89% di Provinsi Papua[2]. Pada tahun 2019–2020, tercatat 403 kasus malaria di Lampung pada kelompok usia 15–64 tahun, tempat yang menjadi titik paling utama terkenai penyakit malaria di lampung terdapat di desa pesawaran, dimana parasit yang umum terkenai para warga adalah *plasmodium vivax*[3]. Diagnosis secara dini dan akurat menjadi salah satu hal yang sangat penting dalam penanganannya, hal ini dikarenakan dengan diagnosis secara cepat pasien dapat mendapatkan pengobatan yang sesuai, sehingga menurunkan tingkat resiko komplikasi serius hingga kematian pada pasien.

Metode diagnosis malaria yang menjadi *gold standard* sampai sekarang adalah pemeriksaan darah pasien menggunakan mikroskopis konvensional, ada sediaan darah tepi dan tebal (*thick smear* dan *thin smear*)[4]. Selain pemeriksaan mikroskopis, terdapat juga beberapa metode lainnya, seperti teknologi konvensional sampai molekuler, dimana masing-masing memiliki keunggulan dan kekurangan masing-masing[5]. Salah satu alternatif yang dapat digunakan adalah *Rapid Diagnostic Test* (RDTs), metode ini menawarkan solusi yang cepat dan

terjangkau, sehingga sangat berguna di daerah endemis. RDTs mudah digunakan dan memberikan hasil dalam waktu singkat, meskipun memiliki kelemahan berupa potensi hasil negatif palsu (*false-negative*), tanpa memberikan gambaran secara kuantitatif. Selain itu, terdapat juga beberapa metode lainnya yang memberikan tingkat sensitivitas yang tinggi seperti *Polymerase Chain Reaction* (PCR), dimana metode PCR ini menggunakan sensor untuk mendeteksi DNA yang terdapat dalam parasit dengan sensitivitas 98-100% dan memiliki spesifitas 84-94%[6]. Selain metode PCR, terdapat juga metode lainnya seperti *Loop-Mediated Isothermal Amplification* (LAMP) yang menunjukkan potensi besar untuk digunakan sebagai alat testing di tempat secara langsung[7].

Meskipun demikian, metode mikroskopis ini termasuk dalam metode konvensional namun dianggap sebagai *gold standard* dalam dunia kesehatan, dikarenakan memiliki akurasi tertinggi dan terpercayai untuk melakukan pendeteksi penyakit malaria[8]. Hal ini dikarenakan kemampuannya yang unik dalam memberikan informasi diagnostik yang komprehensif dan tidak tertandingi oleh metode lain [5]. Metode ini tidak hanya memungkinkan identifikasi definitif kelima spesies *Plasmodium* pada manusia, tetapi juga mampu melakukan kuantifikasi jumlah parasit (*parasitemia*) secara akurat. Hal ini termasuk sangat penting untuk manajemen klinis dan pemantauan respons pengobatan[9]. Hal ini juga didukung dengan visualisasi secara langsung parasit, dimana yang sering terlewatkan oleh proses diagnosis oleh metode lain[6][9]. Namun, proses identifikasi parasit malaria masih sangat bergantung pada ketersediaan tenaga medis atau analis di lokasi. Keterbatasan ini sering menimbulkan subjektivitas, kelahan

visual dan memungkinkan kesalahan deteksi, terutama pada kasus dengan parasitemia rendah[10].

Efektivitas penggunaan mikroskopi sebagai metode *gold standard* sudah menunjukkan variabilitas yang sangat signifikan di lapangan, meskipun dengan kekurangan dan kelebihan yang sangat jelas. Seperti performa mikroskopi dapat bervariasi bergantung pada kualitas preparat dan keterampilan pemeriksa[6]. Berdasarkan studi yang dilakukan oleh A. Amir,dkk menyatakan bahwa tingkat sensitivitas pada metode mikroskop atau proses pendeteksian dengan *gold standard* ini hanya 74.5% dan spesifitas 59%[9]. Keterbatasan ini sangat bergantung pada keahlian teknisi, dimana mereka secara minimum dapat mendeteksi serendahnya 5 parasit/μL darah, dibandingkan dengan tenaga medis biasa dapat mencapai 50 – 100 parasit/μL [9][6]. Performa pemeriksaan mikroskopis bergantung pada keterampilan pemeriksa. Proses pemeriksaan juga membutuhkan waktu sekitar 20–40 menit, bergantung pada kualitas preparat dan keterampilan tenaga medis. Pada hasil negatif, pemeriksaan dapat memerlukan evaluasi ulang setelah 12–24 jam [11]. Ketergantungan terhadap hal ini yang dapat membuka jalan untuk adanya potensi kesalahan, terutama pada daerah yang memiliki sumber daya manusia dan alat yang tidak memadai.

Berdasarkan observasi di Puskesmas Hanura, proses deteksi malaria masih dilakukan melalui pemeriksaan mikroskopis manual. Kondisi tersebut menyebabkan tenaga medis melakukan pengamatan visual dalam durasi yang panjang dan berpotensi meningkatkan kelelahan visual. Selain itu, berdasarkan penelitian yang dilakukan oleh Dinas Kesehatan Provinsi Lampung, upaya pengendalian penyakit

malaria di Lampung diperlukannya dukungan dan inovasi terbaru secara teknologi untuk proses deteksi secara cepat dan akurat, dengan mengingat keterbatasannya tenaga medis dan besarnya beban kerja di lapangan langsung.

Dalam hal ini, dengan perkembangan teknologi digital dapat membuka peluang besar untuk meningkatkan kapabilitas mikroskop konvensional dan cara kerjanya. Beberapa studi sudah menunjukkan bahwa integrasi modul kamera dan model YOLOv8 untuk proses deteksi dapat digunakan dalam praktik pada berbagai bidang. Dalam studi yang dilakukan oleh Aisyah Widayani, dkk. pada tahun 2024 menyatakan bahwa metode YOLOv8 berhasil dalam melakukan deteksi untuk tumor otak, deteksi kanker payudara, dan juga melakukan analisis radiografi gigi dengan tingkat akurasi validasi dan akurasi pelatihan mencapai 95%[12]. Pada bidang arsitektur dan mesin, Ezzedini, dkk. pada tahun 2024 membuktikan bahwa model YOLOv8 memberikan hasil yang sangat baik dalam proses mendeteksi *locomotive* dan kapal yang ada di area lautan beserta ikan-ikannya, dimana tingkat akurasi yang di berikan mencapai 76%[13].

Meskipun begitu, penerapan teknologi tersebut dalam proses deteksi malaria secara *real-time* pada citra mikroskopis masih sangat terbatas. Oleh karena itu, penelitian ini dilakukan dengan fokus kepada pengembangan sistem untuk melakukan proses diagnosis malaria secara *real-time* dengan kamera yang terintegrasi pada mikrsokop secara langsung, dengan menggunakan model YOLOv8m dengan tujuan untuk mengidentifikasi *plasmodium vivax* dan *plasmodium falciparum*.

Dengan penelitian tersebut, diharapkan hasil yang dikeluarkan dapat menurunkan risiko kesalahan diagnosis untuk proses deteksi dengan metode mikroskopis konvensional dan menjawab kebutuhan dari pihak puskesmas hanura yang disebabkan oleh lama proses waktu pemeriksaan, ketergantungan kepada tenaga medis, kekurangannya tenaga medis, dan menurunkan resiko kesalahan diagnosis. Dengan pelatihan model YOLOv8 kepada citra darah yang telah melalui tahap isolasi dan juga pemrosesan, sistem akan dirancang untuk membedakan *P.Falciparum, P.Vivax*, dalam dataset yang didapatkan di pesawaran[7].

1.2 Perumusan Masalah

Berdasarkan latar belakang yang ada, permasalahan yang dapat diangkat adalah :

1. Bagaimana merancang sistem deteksi malaria berbasis YOLOv8m pada citra mikrosxkopis sediaan darah tebal?
2. Bagaimana mengevaluasi performa model yang telah dilatih menggunakan metrik standar (*mAP, Precision, Recall, F1-Score*) untuk memastikan keandalannya dalam mengatasi masalah ketidakseimbangan kelas?
3. Bagaimana mengimplementasikan model deteksi tersebut ke dalam sebuah Antarmuka Pengguna Grafis (GUI) agar dapat dioperasikan bersama mikroskop konvensional untuk skrining secara langsung?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang di ambil, adapun tujuan dalam melakukan penelitian ini adalah :

1. Menyusun dan mengolah dataset citra mikroskopis sediaan darah tebal sebagai data pelatihan dan pengujian model YOLOv8m.
2. Melakukan *fine-tuning* sistem berbasis YOLOv8m untuk deteksi penyakit malaria pada mikroskop dengan smear darah tebal.
3. Mengevaluasi performa sistem deteksi malaria berbasis YOLOv8m menggunakan parameter persisi, mAP50, mAP50-95, recall, F1-score.
4. Membuat antarmuka GUI yang secara *real-time*, dapat di install di dalam komputer puskesmas tanpa perlu merakit *hardware* mahal.

1.4 Hipotesis

Dalam penelitian ini, terdapat hipotesis yang diajukan yaitu sebagai berikut:

Hipotesis Nol (H_0):

H_{01} Sistem deteksi malaria berbasis model YOLOv8m yang dioptimasi pada citra mikroskopis sediaan darah tebal tidak mampu mengenali parasit malaria secara komputasional dan gagal mencapai target performa dengan nilai metrik $mAP_{50} \geq 90\%$, $mAP_{50-95} \geq 60\%$, *F1-Score* $\geq 70\%$, serta *recall*, *precision* $\geq 90\%$.

Hipotesis Alternatif (H_1):

H_{11} Sistem deteksi malaria berbasis model YOLOv8m yang dioptimasi pada citra mikroskopis sediaan darah tebal mampu mengenali parasit malaria secara komputasional dan berhasil mencapai target performa dengan nilai metrik $mAP_{50} \geq 90\%$,

$mAP_{50-95} \geq 60\%$, *F1-Score* $\geq 70\%$, serta *recall*, *precision* $\geq$ 90%.

1.5 Ruang Lingkup Penelitian

Penelitian ini dibatasi pada pengembangan sistem deteksi malaria berbasis YOLOv8 secara mikroskopis menggunakan mikroskop pada sediaan darah tebal. Dikarenakan adanya keterbatasan pada data, maka penelitan ini memanfaatkan dataset citra mikroskopis malaria yang di dapatkan dari Provinsi Lampung, Pesawaran, Desa Hanura dengan hasil kerjasama dengan pihak tenaga kesehatan untuk mengambil data primer.

Sistem yang dikembangkan dengan melakukan implementasi kepada perangkat lunak dengan menggunakan komputer dan atau laptop yang ada. Oleh karena itu, dikarenakan tidak akan ada pembahasan secara klinis terhadap cara pengobatan, maka penelitian ini hanya berfokus pada sistem atau proses deteksi malaria parasit dalam citra mikroskopis dan tidak melakukan deteksi terhadap sel darah merah yang utuh.

Performa YOLOv8m dilakukan dengan parameter seperti mAP-50, mAP 50-95, F1-Score, recall dan precision terbatas pada dataset yang digunakan. Evaluasi dilakukan dengan membandingkan hasil deteksi model terhadap anotasi ground truth pada test set untuk mengukur kemampuan model dalam mendeteksi objek secara kuantitatif. Hasil evaluasi tersebut digunakan untuk mengetahui performa YOLOv8m pada dataset yang digunakan dalam penelitian.

1.6 Sistematika Penulisan

Secara keseluruhan, penyusunan laporan Tugas Akhir ini mengikuti standar format penulisan akademik yang telah ditetapkan, yaitu menggunakan jenis huruf *Times New Roman* dengan ukuran 11 pt

dan jarak baris 1,5 spasi. Penggunaan tanda desimal dalam laporan ini disimbolkan dengan tanda koma (,), sedangkan pemisah ribuan disimbolkan dengan tanda titik (.). Untuk memberikan gambaran yang komprehensif dan terstruktur mengenai alur penelitian, sistematika penulisan laporan ini dibagi ke dalam lima bab utama yang saling berkesinambungan, dengan rincian sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan dasar dan arah pelaksanaan penelitian yang meliputi latar belakang masalah mengenai urgensi diagnosis malaria, perumusan masalah, tujuan penelitian, manfaat penelitian, ruang lingkup dan batasan masalah (terfokus pada spesies *Plasmodium falciparum* dan *Plasmodium vivax*), serta sistematika penulisan laporan.

BAB II TINJAUAN PUSTAKA

Bab ini membahas landasan teori dan kajian literatur yang mendasari penelitian, meliputi konsep dasar penyakit malaria, karakteristik morfologi parasit, prinsip sediaan darah mikroskopis, konsep dasar *Deep Learning* dan *Convolutional Neural Network* (CNN), arsitektur model *You Only Look Once* versi 8 (YOLOv8), teknik augmentasi data, metrik evaluasi kinerja arsitektur (seperti *Precision, Recall,* dan mAP), serta prinsip perancangan Antarmuka Pengguna Grafis (GUI).

BAB III METODE PENELITIAN

Bab ini menjelaskan secara rinci kerangka kerja dan prosedur operasional pelaksanaan penelitian. Pembahasan di dalamnya mencakup penentuan jenis penelitian, spesifikasi alat dan bahan (perangkat keras maupun lunak), serta langkah-langkah penelitian yang dimulai dari proses akuisisi dataset citra mikroskopis terbuka, prapemrosesan dan augmentasi data, perancangan skenario distribusi kelas data (*hybrid class balancing*), proses pelatihan model YOLOv8,

pencarian *hyperparameter*, prosedur evaluasi metrik, hingga tahap implementasi model ke dalam sistem GUI.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil penelitian beserta pembahasannya secara mendalam, meliputi pengolahan dataset citra mikroskopis (proses cutting, penyesuaian resolusi, augmentasi data, dan pembagian dataset), pelaksanaan fine-tuning model YOLOv8m melalui pencarian hyperparameter optimal menggunakan algoritma Optuna, analisis pengaruh distribusi dan augmentasi dataset yang dibandingkan melalui tiga skenario (oversampling, global augmentation, dan undersampling), evaluasi performa sistem deteksi menggunakan metrik Precision, Recall, F1-Score, mAP@50, dan mAP@50-95, serta implementasi model terbaik ke dalam rancangan Antarmuka Pengguna Grafis (GUI).

BAB V KESIMPULAN

Bab ini memaparkan kesimpulan akhir penelitian yang menjawab rumusan masalah, tujuan, dan hipotesis yang telah ditetapkan pada Bab I, mencakup ringkasan hasil pengolahan dataset, karakteristik konvergensi ketiga skenario fine-tuning, capaian performa terbaik model YOLOv8m, serta keberhasilan implementasinya ke dalam Antarmuka Pengguna Grafis (GUI). Selain itu, bab ini juga memuat saran bagi pengembangan penelitian selanjutnya, meliputi perluasan dataset, perbandingan dengan arsitektur deteksi objek lain, penambahan deteksi spesies Plasmodium lainnya, optimasi model untuk perangkat dengan sumber daya terbatas, serta pengembangan fitur tambahan pada GUI.

BAB II
TINJAUAN PUSTAKA

2.1 Mikroskop

Sejarah perkembangan teknologi observasi mikroskopis berawal pada abad ke-13 ketika Salvino D'Armate merancang prototipe kacamata pertama. Alat sederhana ini menggunakan prinsip pembiasan cahaya untuk menghasilkan perbesaran visual sebesar 6x hingga 10x pada satu mata, yang saat itu umum digunakan untuk mengamati detail objek kecil seperti serangga atau struktur tanaman. Selanjutnya, pada akhir abad ke-16, Zacharias Jansen bersama ayahnya di Belanda menguji coba penggabungan beberapa lensa ke dalam sebuah tabung. Eksperimen inilah yang kelak menjadi cikal bakal terciptanya instrumen optik modern seperti mikroskop dan teleskop[14].

Meskipun Jansen berhasil menciptakan perangkat pembesar, mikroskop generasi awal tersebut masih memiliki banyak kelemahan. Dengan tingkat perbesaran yang masih rendah serta kualitas resolusi gambar yang buruk, alat tersebut belum memenuhi standar presisi untuk observasi ilmiah yang mendalam. Berdasarkan inovasi tersebut, dilanjutkan oleh ilmuwan Belanda, Antonie van Leeuwenhoek. Ia merancang mikroskop sederhana berlensa tunggal yang tingkat distorsinya jauh lebih rendah dibandingkan mikroskop majemuk di eranya, bahkan mampu menembus perbesaran hingga lebih dari 200 kali[15]. Berkat instrumen buatannya ini, Leeuwenhoek berhasil mengamati berbagai spesimen biologis secara detail, mulai dari sel darah merah (eritrosit), bakteri, hingga spermatozoa. Perkembangan tersebut meningkatkan kemampuan mikroskop dalam menghasilkan citra dengan resolusi yang lebih tinggi. Dengan begitu, Leeuwenhoek

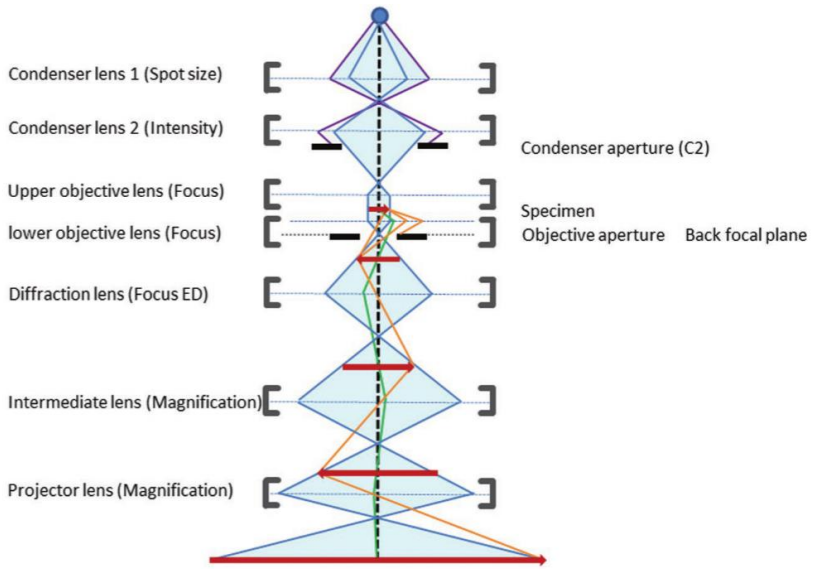
diadaptasi sebagai standar utama dalam dunia mikroskopi selama puluhan tahun[16].



Gambar 2.1 Jenis Tipe Mikroskop Berdiri Pertama Kali [17].

Memasuki abad ke-19, perkembangan mikroskop mengalami lompatan yang sangat signifikan melalui kolaborasi Carl Zeiss, Ernst Abbe, dan Otto Schott. Mereka berhasil merancang mikroskop modern tipe berdiri yang dilengkapi dengan lensa apokromatik, yang dapat dilihat pada gambar 2.1. Inovasi ini sangat krusial karena mampu mengoreksi aberasi sferis maupun kromatik, sehingga menghasilkan citra yang jauh lebih tajam dengan resolusi spasial mencapai 0,2 µm[18]. Pencapaian ini sekaligus menjadi tonggak awal standardisasi dan reproduktifitas manufaktur instrumen optik. Walaupun demikian, inovasi ini juga secara tidak langsung memperlihatkan batas fisik fundamental dari cahaya tampak. Ernst Abbe merumuskan sebuah teori yang dikenal sebagai "Batas Abbe" (*Abbe limit*), yang membuktikan bahwa mikroskop optik konvensional difraksi cahaya tidak akan mampu membedakan dua titik yang jaraknya lebih kecil dari setengah panjang gelombang cahaya yang digunakan (sekitar 200 nm)[19].

Keterbatasan fisik ini menjadi kendala utama dalam mengobservasi objek berskala nanometer, seperti struktur internal parasit maupun detail organel sel [14]. Untuk menembus batas difraksi cahaya tersebut, Ernst Ruska, Max Knoll, dan Bodo von Borries merintis penemuan mikroskop elektron pada dekade 1930-an. Dengan memanfaatkan berkas electron yang memiliki panjang gelombang jauh lebih pendek dibandingkan foton Cahaya instrumen seperti *Transmission Electron Microscope* (TEM) dan *Scanning Electron Microscope* (SEM) mampu menghasilkan tingkat perbesaran hingga jutaan kali lipat. Penemuan revolusioner ini membuka lembaran baru yang mengubah lanskap penelitian di bidang ilmu material dan biologi sel[20].



Gambar 2.2 Skematik Electron Microscope [21].

Merujuk pada skematik di Gambar 2.2, terlihat jelas perbedaan fundamental arsitektur mikroskop elektron dibandingkan dengan mikroskop optik konvensional. Mikroskop ini tidak lagi menggunakan lensa optik kaca, melainkan memanfaatkan rangkaian medan

elektromagnetik seperti *condenser lens*, *objective lens*, dan *projector lens* untuk memfokuskan tembakan sinar elektron secara terpusat melewati spesimen. Konfigurasi lintasan elektron inilah yang memungkinkan instrumen tersebut memecahkan batasan difraksi foton dan memproyeksikan struktur mikro dengan resolusi spasial berskala sub-nanometer.

Berdasarkan rekam jejak evolusi tersebut, mikroskop secara etimologi yang diserap dari bahasa Yunani *mikrós* (kecil) dan *skopeîn* (melihat) dapat didefinisikan sebagai instrumen esensial untuk memvisualisasikan objek renik [19]. Meskipun purwarupa pertamanya telah berusia lebih dari 350 tahun [22], mikroskop modern terus berkembang pesat dengan mengintegrasikan berbagai prinsip pencitraan, mulai dari sistem optik, elektron, hingga *scanning probe* untuk menghasilkan visualisasi beresolusi sangat tinggi[23][24]. Pada waktu yang sama, lompatan teknologi telah melahirkan teknik-teknik modern seperti *super-resolution fluorescence microscopy,* dan *confocal laser scanning microscopy*, yang memungkinkan analisis presisi pada skala seluler maupun sub-seluler. Rangkaian inovasi ini memperkuat posisi mikroskop sebagai instrumen fundamental yang menggerakkan kemajuan sains dan kedokteran masa kini, dengan peran krusial di berbagai disiplin ilmu seperti *life sciences*, *nano*teknologi, ilmu material, sampai kedokteran gigi [25],[26],[27].

2.2 Malaria

Malaria adalah penyakit menular yang disebabkan oleh parasit protozoa dari genus *Plasmodium*, yang ditransmisikan ke manusia melalui gigitan nyamuk *Anopheles* betina yang terinfeksi. Dari berbagai spesies yang ada, lima di antaranya menginfeksi manusia *P.*

Falciparum, P. Vivax, P. Malariae, P. Ovale, dan *P. Knowlesi* dengan *P. Falciparum* bertanggung jawab atas sebagian besar kasus yang fatal.

Penyakit ini merupakan masalah kesehatan masyarakat global yang utama, dengan sekitar setengah populasi dunia terinfeksi pada tahun 2020. Beban penyakit ini tetap signifikan, dengan perkiraan 247 juta kasus di seluruh dunia pada tahun 2023 menurut WHO, dan telah menyebabkan 409.000 kematian pada tahun 2019. Penyakit ini endemik di negara-negara tropis dan subtropis, dimana faktor lingkungan seperti keberadaan tempat perkembangbiakan nyamuk memainkan peran penting dalam penularannya. Upaya pengendalian bergantung pada diagnosis dini melalui mikroskopi darah, pengobatan tepat waktu, dan manajemen lingkungan yang kuat, meskipun tantangan tersebut terus berlanjut karena siklus hidup parasit yang kompleks [28].

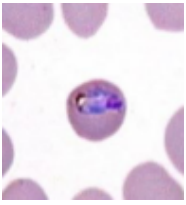
Jenis *Plasmodium* yang sering menyerang manusia adalah *Plasmodium Falciparum* dan *Plasmodium Vivax* pada area asia tenggara sendiri sampai jenis *P. falciparum* memiliki jenis penyakitnya sendiri apabila sudah mencapai tingkat fatal, yaitu *Severe falciparum Malaria*[29]. Kedua jenis ini, memiliki penjelasan dan citra masing-masing dapat dilihat pada gambar 2.1.

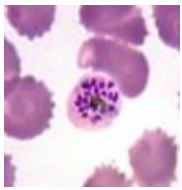
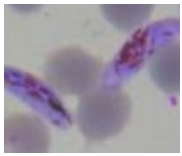
1. *Plasmodium Falciparum*

P. Falciparum merupakan jenis parasit organisme interselular yang menjadi penyebab terjadinya malaria pada daerah tropik atau malaria tropika, *P. Falciparum* termasuk bentuk malaria yang paling bahaya untuk manusia[30][31]. *P. Falciparum* termasuk sebagai parasit *apicomplexan* yang membutuhkan manusia atau inang serta vektor berupa nyamuk *anopheles* untuk membantu dalam menyebarkan dirinya serta menyelesaikan siklus hidupnya[30]. Parasit ini memiliki beberapa fase dalam siklus hidupnya, salah satunya termasuk sebagai

fase darah dalam inang manusia, dimana parasit ini akan menginvasi *eritrosit* dan menjalani siklus replikasi aseksual yang berulang setiap 48 jam, melewati tahap cincin, *trofozoit* dan *skizon.* Selama siklus eritrositik ini, sebagian kecil merozoit yang sedang berkembang tidak melanjutkan replikasi aseksual, tetapi berdefiriansi menjadi gametosit jantan dan betina yang termasuk sebagai tahap seksual yang esensial untuk transmisi kembali kepada nyamuk [32]. Hal ini dapat dilihat tahap perkembangannya dan karakteristik setiap fasenya pada tabel 2.1. Parasit *P. falciparum* sudah memiliki resistansi yang tinggi terhadap beberapa obat, seperti klorokuin dan artemisinin.

Tabel 2.1 Citra dan Karakteristik Fase *Parasit falciparum*[33]

Spesies	**Stadium**	**Citra Gambar**	**Karakteristik**
P. falciparum	*Ring*		Sitoplasma Tebal dan halus dengan satu atau dua titik kromatin kecil. Eritrosit (RBC) yang terinfeksi tidak membesar. Infeksi ganda dalam satu RBC sering terjadi.
	Trophzoite		Jarang terlihat dalam sediaan darah perifer Merupakan

Spesies	Stadium	Citra Gambar	Karakteristik
			perkembangan dari stadium ring dengan sitoplasma lebih padat.
	Schizont		Jarang ditemukan di darah perifer. Mengandung sekitar 8–24 merozoit kecil. Pigmen gelap.
	Gametocyte		Berbentuk sabit atau seperti sosis, khas untuk P. falciparum. Kromatin berbentuk massa tunggal pada makrogametosit (betina) dan lebih menyebar pada mikrogametosit (jantan)

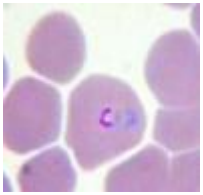
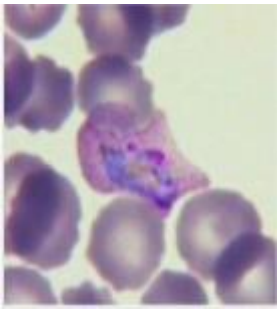
2. *Plasmodium Vivax*:

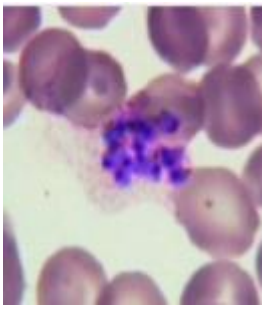
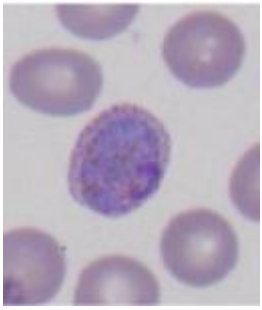
Plasmodium Vivax termasuk dalam subgenus Plasmodium dan merupakan salah satu penyebab malaria tertiana, yaitu malaria dengan

pola demam setiap 48 jam. Salah satu karakteristik biologis terpentingnya adalah kemampuannya untuk membentuk hipnozoit, yaitu bentuk dorman di dalam *hepatosit* (sel hati) yang dapat bertahan dalam waktu lama dan menyebabkan *relaps* (kekambuhan) meskipun parasit sudah tidak terdeteksi lagi di darah perifer[34]. Karena itu, terapi infeksi *P. Vivax* tidak hanya menargetkan stadium eritrosit, tetapi juga harus mencakup eradikasi stadium hati. Dalam siklus intra-eritrositnya, *P. Vivax* cenderung menginfeksi eritrosit muda (retikulosit), yang berkontribusi pada pembesaran sel darah merah yang terinfeksi. Parasit ini juga mulai memproduksi gametosit relatif lebih awal selama perkembangan dalam darah, sehingga potensi penularan ke nyamuk Anopheles dapat terjadi bahkan pada fase awal infeksi[34], [35].

Secara epidemiologis, infeksi *P. Vivax* sangat berkaitan dengan keberadaan antigen *Duffy* (*Duffy antigen receptor for chemokines/DARC*) pada permukaan *eritrosit*. Individu dengan fenotipe *Duffy*-negatif memiliki resistensi alami terhadap sebagian besar strain *P. Vivax,* karena parasit kesulitan memasuki eritrosit tanpa reseptor tersebut[34]. Hal ini menjelaskan mengapa *P. Vivax* jarang ditemukan di Afrika Tengah dan Afrika Barat, wilayah dengan prevalensi tinggi populasi *Duffy*-negatif. Secara morfologis*, P. Vivax* memiliki ciri khas berupa pembesaran *eritrosit* yang terinfeksi, bentuk *trofozoit* yang *amoeboid*, serta adanya bintik *Schüffner* pada pewarnaan *Giemsa*[36]. Bentuk-bentuk perkembangan parasit dalam darah perifer meliputi *stadium ring*, *trofozoit*, *skizon*, dan *gametosit* ditampilkan pada Tabel 2.2 berikut.

Tabel 2.2 Citra Dan Karakteristik Parasit *Vivax[33]*

Spesies	Stadium	Citra Gambar	Karakteristik
P.vivax	*Ring*		Memiliki titik kromatin yang relatif besar. Sitoplasma dapat berkembang menjadi bentuk amoeboid seiring maturase.
	Trophozoite		Sitoplasma jelas bersifat amoeboid dengan titik kromatin besar. Tampak pigmen halus berwarna kuning kecokelatan (hemozoin).

Spesies	Stadium	Citra Gambar	Karakteristik
	Schizont		Berukuran besar dan dapat hampir memenuhi seluruh sel darah merah yang terinfeksi. Mengandung sekitar 12–24 merozoit.
	Gametocyte		Berbentuk bulat hingga oval. Memiliki pigmen cokelat yang tersebar. Dapat hampir memenuhi RBC yang terinfeksi.

Diagnosis malaria dapat ditegakkan melalui evaluasi klinis berdasarkan tanda dan gejala seperti demam periodik, menggigil, sakit kepala, anemia, dan *splenomegali*. Namun, pendekatan klinis saja memiliki tingkat akurasi yang terbatas karena gejalanya sering menyerupai penyakit tropis lain, seperti demam *tifoid*, *dengue*, atau infeksi parasit lainnya, serta adanya kemungkinan koinfeksi yang dapat

memperburuk gambaran klinis. Oleh karena itu, konfirmasi laboratorium sangat diperlukan untuk memastikan diagnosis.

Salah satu metode diagnostik utama adalah pemeriksaan mikroskopis sediaan darah tepi dan darah tebal. Pemeriksaan ini memungkinkan identifikasi spesies *Plasmodium*, penentuan stadium perkembangan parasit (*ring*, *trofozoit*, *skizon*, *gametosit*), serta estimasi tingkat parasitemi. Citra mikroskopis yang dihasilkan menjadi dasar dalam membedakan karakteristik morfologis seperti yang telah dijelaskan sebelumnya pada *P. Falciparum* dan *P. Vivax.*

Selain mikroskopi, tersedia juga *Rapid Diagnostic Test* (RDT) berbasis deteksi antigen. Metode ini bekerja secara imunokromatografi dengan mendeteksi antigen spesifik malaria dalam sampel darah dalam jumlah kecil. Antigen yang umum ditargetkan antara lain *histidine-rich protein* 2 (HRP-2) yang spesifik untuk *P. Falciparum*, serta enzim seperti *parasite lactate dehydrogenase* (pLDH) dan *aldolase* yang dapat ditemukan pada berbagai spesies *Plasmodium*. RDT memberikan hasil yang relatif cepat dan praktis, terutama di daerah dengan keterbatasan fasilitas laboratorium, meskipun sensitivitas dan spesifisitasnya dapat bervariasi tergantung kepadatan parasit dan variasi genetik parasit (seperti HRP-2).

Meskipun, pemeriksaan mikroskopis masih dianggap sebagai *gold standard* karena kemampuannya mengidentifikasi spesies dan menghitung parasit secara langsung, metode ini memiliki beberapa keterbatasan. Proses pemeriksaan membutuhkan waktu, ketelitian tinggi, serta tenaga analis yang terlatih, dan hasilnya dapat bersifat subjektif tergantung pengalaman pemeriksa. Variasi kualitas preparat dan pewarnaan juga dapat memengaruhi akurasi[37]. Secara umum, terdapat dua jenis sediaan yang digunakan, yaitu sediaan darah tipis

(*thin smear*) dan sediaan darah tebal (*thick smear*). Sediaan darah tipis digunakan untuk mempertahankan morfologi sel darah merah secara utuh, sehingga sangat berguna untuk identifikasi spesies dan stadium parasit secara detail. Sebaliknya, sediaan darah tebal menampung volume darah yang lebih banyak dalam area yang lebih kecil, sehingga memiliki sensitivitas yang jauh lebih tinggi untuk melakukan skrining dan mendeteksi keberadaan parasit secara cepat. Pada proses pembuatan preparat sediaan darah tebal, darah tidak difiksasi menggunakan metanol sebelum pewarnaan. Hal ini menyebabkan sel darah merah mengalami lisis (pecah atau hancur) selama proses persiapan.

Untuk memperjelas objek di bawah mikroskop, preparat sediaan darah tebal diwarnai menggunakan pewarnaan *giemsa*. Pewarnaan Giemsa merupakan teknik pewarnaan standar yang memberikan kontras visual pada sel, di mana *kromatin* (inti) parasit malaria akan menyerap warna merah atau ungu kehitaman, sementara *sitoplasma* parasit akan berwarna biru. Pewarnaan ini sangat krusial untuk membedakan struktur parasit dari komponen darah lainnya.

2.3 Deep Learning

Deep learning merupakan salah *sub*-bidang khusus seperti *machine learning* yang didefinisikan sebagai konsep pembelajaran mesin berbasis jaringan saraf tiruan (*artificial neural networks*)[38], [39]. Metode ini terinspirasi dari struktur dan fungsi otak manusia, menggunakan arsitektur jaringan saraf dengan banyak lapisan (*multi-layered*) untuk mempelajari pola dan representasi kompleks secara otomatis dari kumpulan data dalam skala besar[40][41].

Perbedaan mendasar antara *deep learning* dengan *machine learning* konvensional terletak pada pendekatan ekstraksi fitur. Algoritma *machine learning* dasar seringkali memiliki keterbatasan dalam menangani tugas kompleks yang melibatkan data tidak terstruktur seperti, gambar, suara, dan video. Hal ini karena *machine learning* konvensional sangat bergantung pada proses rekayasa fitur (*feature engineering*) secara manual, di mana seorang ahli harus merancang dan mengekstrak fitur relevan dari data mentah, sebuah proses yang memakan waktu dan tenaga[40][42]. Sebaliknya, kemampuan fundamental *deep learning* adalah secara otomatis menemukan dan mengekstrak fitur-fitur yang dibutuhkan langsung dari data mentah, sehingga meminimalisir intervensi manusia[43].

Konsep "*deep*" atau "dalam" pada *deep learning* merujuk pada keberadaan banyak lapisan tersembunyi (*hidden layers*) di antara lapisan *input* dan *output*. Jaringan saraf tiruan ini terdiri dari komponen inti berupa neuron yang saling terhubung. Setiap lapisan dirancang untuk mempelajari fitur secara hierarkis: lapisan awal, hanya akan mendeteksi fitur sederhana seperti tepi atau warna pada sebuah gambar, sementara lapisan yang lebih dalam akan mampu mengenali bentuk, tekstur, hingga objek yang utuh[41],[44]. Kemampuan untuk memproses informasi secara non-linear melalui banyak lapisan inilah yang memungkinkan *deep learning* unggul dalam ekstraksi fitur, identifikasi pola, dan klasifikasi[40][45].

Beberapa arsitektur model *deep learning* yang paling dikenal antara lain:

1. *Convolutional Neural Network* (CNN): Dirancang khusus untuk memproses data berbentuk grid seperti gambar. CNN

sangat efektif untuk tugas-tugas visi komputer, termasuk klasifikasi dan deteksi objek.

2. *Recurrent Neural Network* (RNN): Didesain untuk data sekuensial atau data deret waktu, seperti teks atau suara. RNN memiliki "memori" untuk memproses informasi dari input sebelumnya.

3. *Transformers*: Arsitektur modern yang menggunakan mekanisme *self-attention* dan telah menjadi standar untuk tugas-tugas pemrosesan bahasa alami (*Natural Language Processing*) yang modern[40][46].

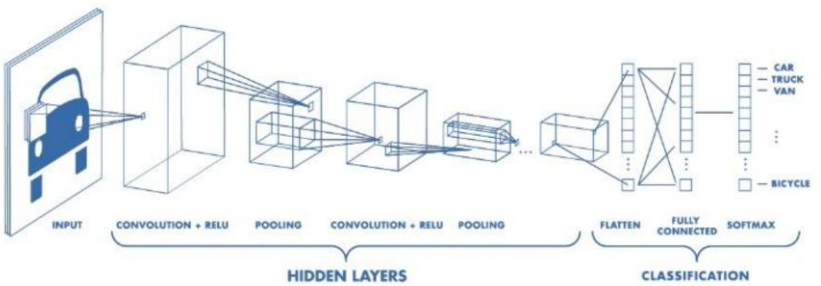
Untuk menjalankan tugasnya, Model *deep learning* umumnya membutuhkan data pelatihan yang memadai dan beragam untuk mempelajari representasi fitur secara optimal. Selain itu, eksekusi pelatihan model *deep learning* juga menuntut daya komputasi yang besar. Oleh karena itu, penggunaan *Graphics Processing Unit* (GPU) menjadi sangat penting, karena GPU telah dioptimalkan secara khusus untuk mempercepat proses pelatihan model secara signifikan[47][40]. Meskipun unggul dalam performa pada data kompleks, model *deep learning* sering disebut sebagai *black box* karena proses pengambilan keputusannya sulit diinterpretasikan. Sangat berbeda dengan algoritma *machine learning* tradisional yang seringkali lebih mudah diinterpretasikan[48].

2.4 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah salah satu arsitektur *deep learning* berbasis jaringan saraf tiruan (JST), yang dirancang secara khusus untuk memproses data berstruktur grid, seperti citra visual dua dimensi. Keunggulan utama CNN dibandingkan

jaringan saraf konvensional (*Multi-Layer Perceptron*), yang terletak pada kemampuannya untuk mengekstraksi dan mempelajari representasi fitur spasial secara otomatis dan hierarkis, hal ini dilakukan tanpa memerlukan ekstraksi fitur manual. Berkat kemampuan ini, CNN secara luas diimplementasikan dalam berbagai tugas *computer vision*, mulai dari klasifikasi citra, segmentasi semantik, hingga deteksi objek yang kompleks [49].

Secara arsitektural, CNN dibangun oleh serangkaian lapisan (*layers*) yang saling terhubung dan terbagi menjadi dua blok fungsi utama: *Feature Extraction Layer* (Lapisan Ekstraksi Fitur) dan *Classification Layer* (Lapisan Klasifikasi). Blok ekstraksi fitur utamanya terdiri dari *Convolutional Layer* dan *Pooling Layer* yang bertugas mengubah citra mentah menjadi peta fitur (*feature maps*). Sementara itu, blok klasifikasi umumnya terdiri dari *Fully Connected Layer* yang bertugas mengolah kumpulan fitur berdimensi tinggi menjadi probabilitas kelas keluaran.



Gambar 2.3 Arsitektur CNN[50].

Melalui ilustrasi Gambar 2.3, keseluruhan alur kerja dari arsitektur *Convolutional Neural Network* (CNN) dapat diamati secara terstruktur. Proses dimulai dari tahap penerimaan citra pada matriks

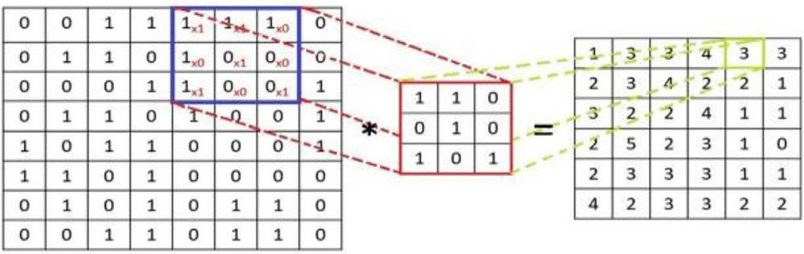
Input, yang kemudian diteruskan ke dalam blok *Hidden Layers* untuk mengalami proses ekstraksi fitur secara hierarkis melalui kombinasi operasi konvolusi, fungsi aktivasi non-linier, dan *pooling*. Setelah fitur-fitur spasial esensial berhasil diekstrak dan direduksi dimensinya, peta fitur tersebut diratakan (*flatten*) menjadi vektor satu dimensi agar dapat diproses oleh blok *Classification Layer* (*Fully Connected* dan *Softmax*) untuk menghasilkan probabilitas tebakan kelas akhir.

2.4.1 Convolutional Layer

Convolutional Layer merupakan fondasi komputasi utama dari arsitektur CNN, yang bertanggung jawab untuk melakukan operasi ekstraksi fitur dari citra masukan. Lapisan ini beroperasi dengan menggeserkan sejumlah matriks filter (*kernel*) di seluruh area citra masukan. Dengan tujuan untuk melakukan operasi matematika perkalian matriks secara berulang (dot product). Proses ini menghasilkan feature map yang merepresentasikan pola-pola visual tertentu, seperti garis tepi (edges), gradien warna, hingga bentuk objek yang kompleks, sambil tetap mempertahankan struktur tata letak spasial dari citra asli[49], [50].

Setiap filter di dalam *convolutional layer* hanya berinteraksi dengan sebagian kecil area dari citra pada satu waktu, yang dikenal dengan istilah *local receptive field*. Konsep ini memungkinkan model untuk melakukan pembagian bobot (*parameter sharing*), di mana satu filter yang sama digunakan secara berulang di seluruh area gambar. Mekanisme ini tidak hanya mengurangi jumlah parameter komputasi secara drastis sehingga model menjadi lebih efisien, tetapi juga menciptakan sifat translasi invarian (*spatial invariance*). Sifat ini sangat penting dalam analisis citra mikroskopis karena memungkinkan model

untuk mengenali parasit malaria terlepas dari posisinya pada kaca preparat[49], [51]. Secara matematis, lapisan konvolusi beroperasi menggunakan sebuah matriks filter (sering juga disebut sebagai *kernel*) untuk menghitung nilai konvolusi dari citra masukan dan mengekstrak fitur-fitur fundamentalnya. Filter ini memiliki dimensi yang lebih kecil dibandingkan citra asli, namun memuat parameter bobot (*weights*) yang akan terus diperbarui selama proses pelatihan. Untuk memahami bagaimana ekstraksi fitur ini terjadi secara spasial, ilustrasi komputasi sederhana dari operasi konvolusi dapat dilihat pada Gambar 2.4.



Gambar 2.4 Proses Komputasi Convolutional Layer[50].

Berdasarkan Gambar 2.4, mekanisme ekstraksi fitur dimulai ketika matriks filter meluncur (*sliding*) setahap demi setahap melintasi matriks piksel citra masukan. Pada setiap pergeserannya, jaringan menghitung perkalian titik (*dot product*) antara nilai bobot pada filter dengan nilai intensitas piksel citra yang berada tepat di bawahnya, kemudian menjumlahkannya. Rangkaian proses matematis ini menghasilkan sebuah matriks dua dimensi baru yang dikenal sebagai *Activation Map* atau peta aktivasi. Hasil dari operasi konvolusi selanjutnya dilewatkan ke dalam sebuah fungsi aktivasi non-linier untuk menentukan apakah informasi fitur tersebut cukup kuat untuk diteruskan ke lapisan berikutnya[52]–[54]. Salah satu fungsi aktivasi

yang paling dominan digunakan adalah *Rectified Linear Unit* (ReLU). ReLU sangat populer karena struktur matematisnya yang sederhana, yaitu mengubah semua nilai input negatif menjadi nol dan membiarkan nilai positif tetap sama (Persamaan 2.1). Hal ini membuat waktu komputasi menjadi sangat cepat dan membantu mempercepat konvergensi gradien selama proses pelatihan [53], [55].

$$\psi(x) = \begin{cases} 0 & \text{if } x < 0, \\ x & \text{if } x \geq 0 \end{cases} \qquad (2.1)$$

Dalam praktiknya, ketika operasi konvolusi diterapkan pada citra, ukuran dimensi spasial dari *feature map* yang dihasilkan cenderung akan menyusut secara bertahap. Hal ini dapat menyebabkan hilangnya informasi spasial penting yang berada di tepi gambar (piksel perbatasan). Untuk menanggulangi masalah ini, CNN menerapkan teknik *padding*, yaitu penambahan deretan piksel semu (biasanya bernilai nol, atau *zero-padding*) di sekeliling batas luar citra masukan sebelum operasi konvolusi dilakukan. Teknik ini memastikan bahwa setiap piksel, termasuk yang berada di tepi, mendapatkan kesempatan komputasi yang sama[56], [57], [58].

2.4.2 Pooling Layer

Pooling Layer atau lapisan *subsampling*, umumnya disisipkan di antara dua *convolutional layer* yang berurutan. Lapisan ini berfungsi untuk mereduksi dimensi spasial (tinggi dan lebar) dari peta fitur secara progresif, tanpa mengubah kedalaman (jumlah saluran/filter) dari peta fitur tersebut[59]. Reduksi ini krusial untuk menekan jumlah parameter dan beban komputasi secara keseluruhan, sekaligus mencegah

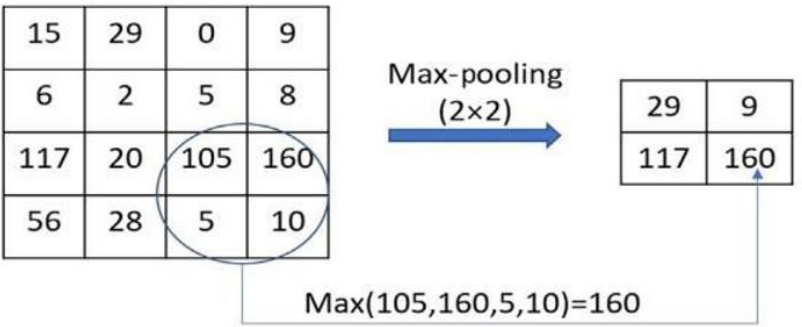
terjadinya *overfitting*, yaitu suatu kondisi di mana model menghafal data latih namun gagal berkinerja baik pada data baru[60], [61]. Peta fitur (*feature map*) yang dihasilkan oleh *convolutional layer* seringkali masih memiliki sensitivitas yang tinggi terhadap lokasi persis dari sebuah fitur di dalam citra. Untuk mengatasi sensitivitas tersebut dan mengurangi beban komputasi, arsitektur CNN umumnya menyisipkan *Pooling Layer* untuk melakukan *downsampling* (pengurangan dimensi spasial tinggi dan lebar). Berbeda dengan lapisan konvolusi, operasi pada *pooling layer* murni menggunakan fungsi matematika sederhana dan sama sekali tidak melibatkan parameter bobot yang dapat dipelajari (*learnable weights*).

Secara teknis, operasi *downsampling* di dalam lapisan ini diatur oleh dua parameter utama, yaitu:

1. Filter Size (Ukuran Kernel): Menentukan seberapa luas area spasial pada peta fitur (misalnya matriks berukuran 2x2 piksel) yang akan diringkas atau disederhanakan menjadi satu nilai representasi tunggal.

2. Stride (Langkah Geser): Menentukan jarak pergeseran kernel saat memindai area peta fitur. Penggunaan matriks 2x2 dengan *stride* bernilai 2 akan menghasilkan area pemindaian yang saling tidak tumpang tindih (*nonoverlapping*), sehingga dimensi citra akan menyusut tepat menjadi setengah dari ukuran aslinya[50], [62], [63].

Dua operasi matematis yang paling umum digunakan dalam proses *pooling* adalah *Max Pooling* (mengambil nilai tertinggi) dan *Average Pooling* (mengambil nilai rata-rata), seperti yang diilustrasikan pada Gambar 2.5.



Gambar 2.5 Proses Perhitungan Pooling Layer

Berdasarkan visualisasi komputasi pada Gambar 2.5, pada operasi Max Pooling, filter mengevaluasi sekumpulan piksel dalam area cakupannya dan hanya mengekstrak nilai piksel yang paling tinggi. Dalam konteks deteksi citra mikroskopis malaria, *Max Pooling* sangat direkomendasikan karena kemampuannya dalam menonjolkan fitur-fitur yang paling tajam dan dominan, seperti bercak kromatin pekat pada *Plasmodium* atau batas tepi dinding sel darah, sambil mengabaikan *noise* di latar belakang. Sebaliknya, operasi Average Pooling menghitung nilai rata-rata dari seluruh piksel dalam area cakupan, yang menghasilkan representasi fitur yang secara visual lebih halus (*smooth*)[50], [64]

Penyusutan dimensi spasial melalui *pooling layer* ini memberikan dampak yang sangat signifikan terhadap ketahanan (*robustness*) model. Dalam dimensi peta fitur yang lebih kecil dan padat, lokasi fitur parasit cenderung menjadi tetap dan stabil (*translation invariance*) meskipun posisi objek parasit tersebut bergeser, terputar, atau sedikit berbeda orientasinya pada citra masukan. Lebih lanjut, peta fitur yang telah mengalami proses *pooling* (sering disebut *pooled feature map*) memiliki karakteristik yang identik dengan

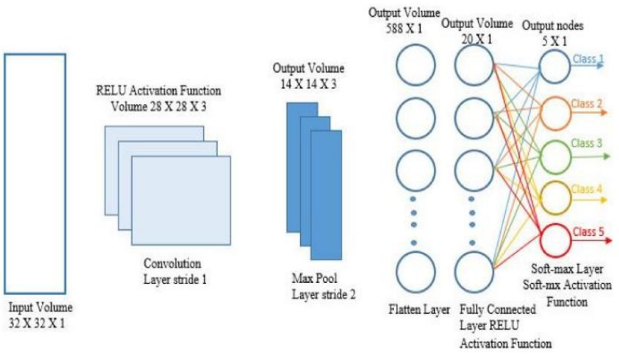
peta konvolusi, yaitu tersusun atas neuron-neuron. Namun, karena lapisan ini tidak dilengkapi dengan fungsi aktivasi (seperti ReLU), nilai matematis hasil ekstraksi *Max* atau *Average* secara otomatis dan langsung merepresentasikan nilai keluaran (*output*) dari neuron pada *pooling layer* tersebut untuk diteruskan ke tahap klasifikasi[52], [61], [65].

2.4.3 Fully Connected Layer

Setelah citra masukan melewati serangkaian *Convolutional Layer* dan *Pooling Layer*, arsitektur CNN pada umumnya akan diakhiri dengan satu atau lebih *Fully Connected Layer* (FC Layer)[49], [51]. Jika lapisan-lapisan sebelumnya bertindak sebagai ekstraktor fitur hierarkis yang mengidentifikasi pola visual secara spasial, maka FC Layer mengolah representasi fitur menjadi keluaran yang digunakan untuk proses klasifikasi. Dinamakan "terhubung penuh" karena setiap neuron pada lapisan ini memiliki koneksi langsung yang berbobot (*weighted connection*) dengan seluruh neuron yang ada pada lapisan sebelumnya, mengadopsi struktur jaringan saraf tiruan tradisional (*Multi-Layer Perceptron*)[66].

1. Transisi Dimensi (*Flattening*)

Sebelum data dapat diproses oleh FC Layer, terdapat sebuah proses transisi krusial yang disebut *flattening*. Peta fitur keluaran dari *pooling layer* terakhir masih berupa matriks tiga dimensi (tinggi x lebar x kedalaman saluran). Proses *flattening* meruntuhkan struktur spasial tersebut dan meratakannya menjadi sebuah susunan vektor fitur satu dimensi (1D).



Gambar 2.6 Proses Flattening dan Koneksi [50].

Sebagaimana diilustrasikan pada Gambar 2.6, sebelum dapat diproses oleh *Fully Connected Layer*, peta fitur (*feature map*) keluaran dari *pooling layer* terakhir yang masih berupa matriks tiga dimensi harus diruntuhkan struktur spasialnya. Melalui proses *flattening*, nilai-nilai tersebut diratakan menjadi sebuah susunan vektor fitur satu dimensi (1D) [67]. Vektor 1D hasil *flattening* ini tidak lagi merepresentasikan piksel di koordinat X dan Y, melainkan telah menjadi representasi abstrak matematis tingkat tinggi yang siap dikalikan dengan bobot (*weights*) jaringan untuk dievaluasi probabilitas kelasnya[66][68].

2. Komputasi Matematis dan Probabilitas Kelas

Di dalam FC Layer, operasi matematis yang terjadi adalah perkalian titik (*dot product*) antara vektor input dengan matriks bobot jaringan, ditambahkan dengan nilai bias, lalu dilewatkan pada fungsi aktivasi akhir. Untuk tugas klasifikasi multikelas (misalnya membedakan *Plasmodium falciparum*, *Plasmodium vivax*, atau sel sehat, lapisan *output* paling ujung biasanya menggunakan fungsi aktivasi *softmax*[69]. Fungsi *softmax* bertugas mengonversi nilai

numerik mentah (*logits*) dari neuron menjadi distribusi probabilitas dengan rentang nilai 0 hingga 1, dimana total seluruh probabilitas kelas akan berjumlah 1 (100%). Hal ini memungkinkan model untuk memberikan prediksi yang dapat diinterpretasikan secara statistik, misalnya: model yakin 88% bahwa objek yang terdeteksi adalah *P. vivax* dan 12% kemungkinan berupa artefak [70], [71].

3. Kompleksitas Parameter dan Teknik Regularisasi (*Dropout*)

Salah satu kelemahan fundamental dari *Fully Connected Layer* (FC *Layer*) adalah beban komputasi yang sangat ekstrem akibat kuantitas parameter yang besar. Sebagai ilustrasi, apabila peta fitur terakhir memiliki dimensi spasial 7 x 7 x 512, proses *flattening* akan mengonversinya menjadi sebuah vektor berukuran 25.088 elemen[72]. Jika FC *Layer* pertama dirancang memiliki 4.096 neuron, maka model harus menghitung lebih dari 102 juta koneksi bobot (*weights*) hanya pada satu lapisan tersebut[73]. Meskipun kapasitas parameter yang besar ini memungkinkan model untuk mempelajari detail fitur mikroskopis sel darah yang sangat kompleks, kondisi ini juga memicu kerentanan jaringan terhadap *overfitting*. *Overfitting* merupakan suatu anomali di mana model kehilangan kemampuan generalisasinya karena hanya "menghafal" data latih, sehingga akurasinya akan menurun drastis saat dihadapkan pada citra baru[74].

Untuk menghindari risiko tersebut, teknik regularisasi seperti *Dropout* secara wajib diterapkan pada FC Layer. Mekanisme *Dropout* beroperasi dengan cara menonaktifkan (memutus koneksi) sejumlah neuron secara acak pada persentase tertentu misalnya 50% di setiap siklus iterasi pelatihan[75]. Pendekatan ini mencegah jaringan saraf agar tidak terlalu bergantung pada satu atau dua jalur koneksi spesifik,

serta memaksa model untuk mendistribusikan pembelajarannya secara merata ke seluruh neuron. Hasilnya, model deteksi menjadi jauh lebih tangguh (*robust*) dan tetap akurat ketika diuji menggunakan data citra sediaan darah baru yang belum pernah diobservasi sebelumnya[68], [73], [76].

2.4.4 Arsitektur CNN

Convolutional Neural Network telah menjadi landasan struktural yang mendorong evolusi berbagai algoritma pendeteksi objek modern. Dalam perkembangannya, arsitektur dasar CNN telah dimodifikasi dan dikembangkan menjadi berbagai model mutakhir yang dirancang untuk menyeimbangkan antara tingkat akurasi dan efisiensi komputasinya [77][78].

Secara umum, arsitektur pendeteksi objek berbasis CNN terbagi menjadi dua kategori utama: model *two-stage detector* seperti Faster R-CNN yang memisahkan proses pencarian lokasi objek dan klasifikasi, serta model *one-stage detector* seperti YOLO (*You Only Look Once*), SSD (*Single Shot MultiBox Detector*), dan *EfficientDet* yang melakukan lokalisasi dan klasifikasi secara simultan dalam satu jaringan utuh[79].

Perbedaan pendekatan arsitektural ini menghasilkan karakteristik kinerja yang bervariasi ketika diuji pada dataset citra beresolusi tinggi, termasuk dalam tugas analisis citra medis mikroskopis. Beberapa studi komparatif terkini (2020-2026) yang mengkaji performa berbagai arsitektur deteksi objek mulai dari generasi awal seperti YOLOv11 dan YOLOv12 menunjukkan pola perbandingan metrik evaluasi seperti yang dirangkum pada Tabel 2.3 [80], [81].

Tabel 2.3 Rangkuman Performa Metrik Arsitektur

Arsitektur	Precision	Recall	mAP@0.5
YOLOv4	0.82	0.81	0.82
YOLOv5	0.85	0.84	0.86
YOLOv7	0.87	0.86	0.87
YOLOv8	0.89	0.88	0.89
YOLOv11	0.91	0.90	0.91
YOLOv12	0.93	0.91	0.92
Faster R-CNN	0.88	0.85	0.86
SSD	0.78	0.75	0.76
EfficientDet	0.84	0.82	0.83

Berdasarkan Tabel 2.3, dapat diamati bahwa keluarga arsitektur YOLO, secara konsisten menunjukkan peningkatan performa dari generasi ke generasi. Proses ini dilakukan dengan menggunakan dataset normal dari gambar 2.7. Varian *state of the art* terbaru seperti YOLOv11 dan YOLOv12 mencatatkan tingkat akurasi puncak melampaui 90%, yang didorong oleh optimasi modul *attention* tingkat lanjut dan efisiensi *parameter sharing*. Dengan demikian, YOLOv8 tetap mempertahankan posisinya sebagai *milestone* yang paling signifikan dalam arsitektur deteksi objek. Dengan adopsi *anchor free detection* dan nilai mAP mencapai 0.89, YOLOv8 dinilai sebagai arsitektur yang paling teruji validitas dan stabilitasnya secara luas untuk

berbagai implementasi sistem medis nyata, jika dibandingkan dengan versi-versi eksperimental terbarunya [62],[82].

Selain akurasi, elemen fundamental lain yang menjadi tolak ukur implementasi sistem deteksi untuk kebutuhan diagnosis klinis yang bersifat *real time,* adalah kecepatan pemrosesan model atau *Frame Per Second* (FPS). Perbandingan efisiensi komputasi dari masing-masing arsitektur disajikan pada Tabel 2.4.

Tabel 2.4 Rata-rata Kecepatan Pemrosesan Arsitektur[62]

Arsitektur	**Rata-rata FPS**
YOLOv4	45
YOLOv5	60
YOLOv7	55
YOLOv8	65
YOLOv11	72
YOLOv12	78
Faster R-CNN	12
SSD	38

Data kecepatan komputasi pada Tabel 2.4 menegaskan kelemahan utama dari arsitektur *two-stage* seperti Faster R-CNN, yang hanya mencatatkan 12 FPS, sehingga kurang ideal untuk analisis *real-time*. Di sisi lain, generasi YOLOv8 hingga YOLOv12 mendominasi ranah inferensi berkecepatan tinggi. Rentang kecepatan 65 hingga 78 FPS membuktikan bahwa pembaruan pada blok konvolusi internal

YOLO berhasil dalam menyeimbangkan antara tingginya akurasi diagnosis medis dengan rendahnya latensi inferensi [62].

Untuk memberikan analisis yang lebih komprehensif, performa sebuah arsitektur juga harus ditinjau dari profil kesalahan (*error profile*), yang dihasilkan selama proses deteksi objek. Tabel 2.5 membedah tingkat persentase kegagalan model dalam tiga kategori utama: *Partially Detected*,*Misclassified*, dan *Missed*.

Tabel 2.5 Analisis Persentase *Error* Deteksi[82]

Arsitektur	**Partially Detected**	**Misclassified**	**Missed**
YOLOv4	12%	8%	9%
YOLOv5	10%	6%	7%
YOLOv7	8%	5%	6%
YOLOv8	5%	3%	4%
YOLOv11	4%	2%	3%
YOLOv12	3%	2%	2%
Faster R-CNN	7%	4%	8%
SSD	15%	11%	10%
EfficientDet	11%	8%	8%

Objek parasit mikroskopis seperti *Plasmodium* sangat rentan mengalami klasifikasi silang (*misclassification*) dengan artefak kotoran pada kaca preparat. Berdasarkan pada Tabel 2.5, seri arsitektur YOLO terbaru sukses menekan angka *missed detection* hingga di bawah 5%.

Hal ini sangat krusial, karena metrik *False Negative* yang rendah merupakan syarat agar sebuah sistem dapat digunakan untuk memvalidasi tingkat kepadatan parasit dalam pasien.

Secara keseluruhan, komparasi ini memperkuat justifikasi bahwa keluarga arsitektur YOLO (khususnya YOLOv8 yang telah sangat stabil dan tervalidasi luas), merupakan landasan algoritma yang paling rasional dan andal untuk dikembangkan dalam sistem diagnosis otomatis sediaan darah malaria [12], [62], [82].

2.5 Algoritma YOLO (*You Only Look Once*)

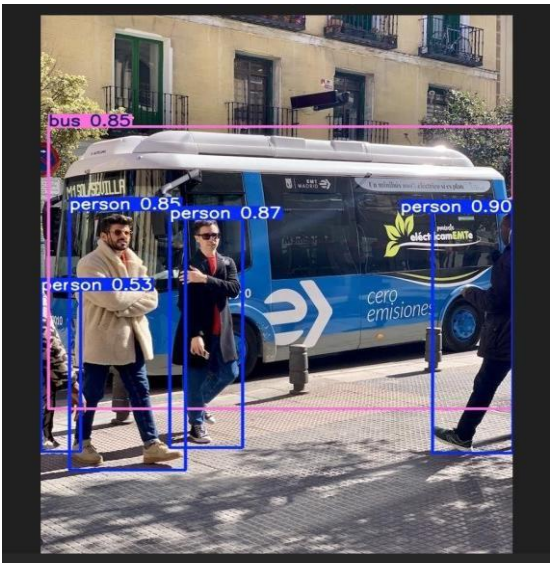
Algoritma *You Only Look Once* (YOLO) termasuk sebagai salah satu algoritma yang sangat populer dalam mendeteksi objek, gambar, serta visi komputer. Kemampuan YOLO dalam melakukan deteksi objek atau gambar secara *real-time* memiliki tingkat akurasi yang tinggi. YOLO banyak digunakan pada tugas deteksi objek yang membutuhkan keseimbangan antara akurasi dan kecepatan inferensi. YOLO sendiri sudah mengeluarkan berbagai versi dimulai dengan YOLOv1 hingga YOLOv12. Setiap versi YOLO membawa peningkatan yang signifikan dalam kecepatan, akurasi, serta efisiensi dalam proses training, tentu juga memberikan berbagai fitur tambahan dalam proses deteksi objek[83], [84].

Penggunaan YOLO dapat menghasilkan bounding box yang dapat memperkirakan keberadaan objek secara kotak, kecuali YOLO versi awal. Hal ini diikuti oleh klarifikasi dengan CNN untuk menentukkan keberadaan objek dalam *bounding box* tersebut. YOLO sendiri menggunakan pendekatan berbeda, yaitu hanya menggunakan CNN hanya satu kali untuk memprediksi semua jenis objek yang ada dalam *bounding box* tersebut, beserta membagikan gambar menjadi

grid S x S, dimana setiap sel bertanggung jawab dalam memprediksi *bounding box*, tingkat *confidence* dari masing-masing sel dan probabilitas kelas serta ukuran grid (S) dari gambar tersebut [12], [85].

Mekanisme kerja YOLO dalam mendeteksi objek atau gambar dimulai dengan gambar *input* dibagi menjadi *grid* S x S. Setiap sel *grid* memiliki tanggung jawab untuk memprediksi objek yang pusatnya jatuh dalam sel tersebut. Dalam proses deteksi YOLO, area atau *box* yang lebih terang pada gambar *input* memiliki tingkat probabilitas deteksi yang lebih tinggi untuk menentukkan objek kelas yang sesuai.

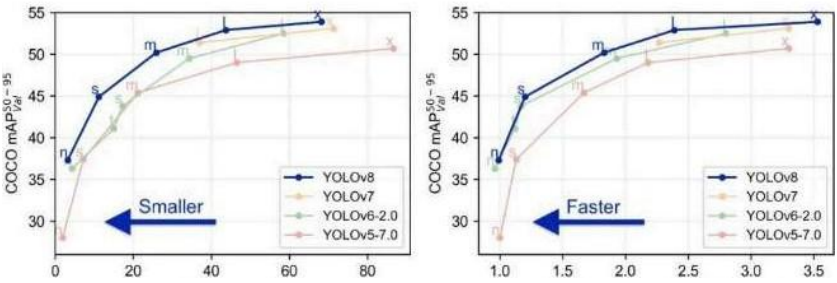
Benda yang berada dalam sel tersebut akan menghasilkan *bounding box* dari area lokasi objek. Setelah memprediksi *bounding box* dan *confident score*, YOLO menghasilkan banyak kotak dengan tingkat *overlapping* yang tinggi. NMS (*Non-Maximum Suppresion*) menghasilkan kotak yang *overlapping* atau tumpah tinggi dengan memilih kotak skor kepercayaan tinggi. Dalam Gambar 2.7 terlihat berbagai kotak warna-warni atau prediksi awal YOLO yang difilter menjadi lebih sedikit. Akhirnya, algoritm menghasilkan deteksi final berupa bounding box dengan skor kepercayaan tinggi yang lolos proses NMS[86], [87].



Gambar 2.7 Ilustrasi Hasil Deteksi YOLO[87].

Dalam konteks Gambar 2.7 terlihat berbagai kotak warna-warni yang merupakan prediksi awal di filter menjadi sedikit. Yang dimana akhirnya algoritma akan menentukkan deteksi final berupa bounding box dengan tingkat kepercayaan terhadap hasil gambar.

Model YOLOv8 masih termasuk sebagai model evolusi yang baru dari algoritma deteksi objek *You Only Look Once*. Dengan memberikan arsitektur yang lebih efisien dan akurat dibandingkan model-model YOLO sebelumnya, YOLOv8 dapat mendeteksi perbedaan antara parasit *falciparum* dan parasit *vivax* dalam *slide* preparat sel darah merah tebal. Teknik ini memperdalam analisis morfologi parasit yang sering terlewat dalam pengamatan visual langsung, sekaligus memfasilitasi deteksi cepat dan *real-time* [87].



Gambar 2.8 Perbandingan YOLOv8 [88].

Gambar 2.8 menunjukkan perbedaan efektivitas YOLOv8 dengan yang sebelumnya (YOLOv7, YOLOv6, dan YOLOv5) yang dilatih semua pada gambar resolusi 640, dimana berdasarkan gambar 2.8 menjelaskan bahwa YOLOv8 menunjukkan peningkatan performa pada benchmark yang dilaporkan, beserta memberikan persisi yang lebih baik dibandingkan yang sebelumnya menggunakan parameter-parameter yang sama. Di dalam YOLOv8 ada beberapa fitur yang baru dan lebih baik dibandingkan YOLO versi sebelumnya:

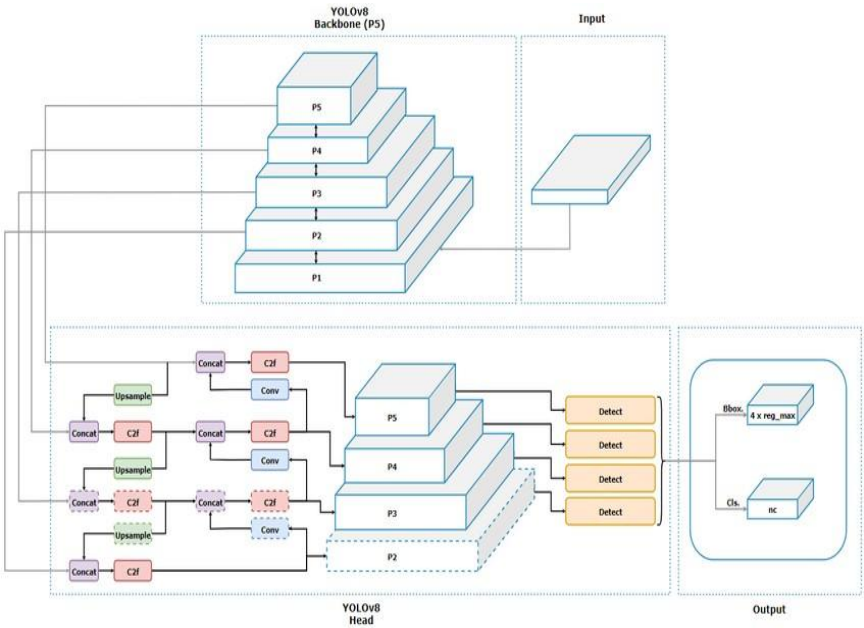
1. Meningkatnya akurasi serta kecepatan dibandingkan dengan versi YOLO sebelumnya.

2. *Backbone* yang telah diperbarui dengan perubahan modul C3 menjadi C2f (*Cross Stage Partial Bottleneck* dengan 2 konvolusi). Modul ini menggantikan modul C3 dengan mengoptimalisasikan aliran gradien dan menangkap fitur tingkat tinggi secara lebih efisien.

3. Menambah modul fusi fitur (*Neck)* yang di optimalkan untuk integrasi informasi atau data spasial dalam berbagai dimensi.

4. Melakukan transisi terhadap sistem deteksi *Anchor-free* (tanpa kotak jangkar) sehingga dapat membuat model menjadi lebih

fleksibel dalam proses memprediksi pusat objek dengan berbagai ukuran[84], [89].



Gambar 2.9 Arsitektur YOLOv8[90].

Berdasarkan Gambar 2.9, arsitektur YOLOv8 secara fundamental dibangun atas tiga komponen utama, yaitu *Backbone*, *Neck*, dan *Head*. Masing-masing komponen memiliki peran spesifik dalam memproses citra masukan hingga menghasilkan prediksi deteksi akhir yang akurat. Berikut adalah rincian dari masing-masing komponen:

a. Backbone

Backbone merupakan bagian awal dari arsitektur yang bertugas sebagai pengekstraksi fitur (*feature extractor*) dari citra *input* sediaan darah mikroskopis. Berbeda dengan versi sebelumnya, YOLOv8

memodifikasi arsitektur CSP*Darknet* dengan memperkenalkan modul C2f (*Cross Stage Partial Bottleneck with 2 convolutions*).

1. Modul C2f

Modul ini menggantikan modul C3 pada YOLOv5, yang dirancang untuk memperkaya aliran informasi gradien (*gradient flow*) sekaligus menjaga agar komputasi tetap ringan.

2. SPPF (*Spatial Pyramid Pooling Fast)*

SPPF berada di bagian belakang dari backbone, dimana modul ini berfungsi untuk mengumpulkan fitur atau *pooling* spasial dari berbagai ukuran dan menghubungkannya. Hal ini bertujuan agar model mampu mengenali objek tanpa dipengaruhi oleh variasi ukuran citra yang digunakan atau data yang digunakan.

b. Neck

Bagian tengah arsitektur YOLOv8 yang secara teknis disebut sebagai *Neck*, berfungsi sebagai jembatan integrasi fitur antara *Backbone* dan *Head*. Struktur *Neck* pada YOLOv8 mengadopsi evolusi dari konsep FPN (*Feature Pyramid Network*) dan PANet (*Path Aggregation Network*) yang bertujuan untuk melakukan ekstraksi fitur secara multi-skala. Bagian ini sangat krusial dalam deteksi parasit malaria karena objek target memiliki variasi ukuran yang signifikan, mulai dari stadium *ring* yang sangat kecil, hingga gametosit yang lebih besar [84], [91].

Proses Integrasi fitur pada *neck* YOLOv8 dilakukan dengan melalui 2 aliran informasi utama, yaitu:

1. Jalur *Top Down*

Aliran *Top-Down* bertujuan untuk membawa informasi semantik dari *feature map* pada lapisan *Backbone* yang lebih dalam menuju *feature map* dengan resolusi spasial yang lebih tinggi. Pada lapisan yang lebih dalam, model telah memperoleh informasi yang lebih abstrak mengenai karakteristik objek, tetapi ukuran *feature map* menjadi lebih kecil akibat proses *downsampling*. Oleh karena itu, dilakukan proses *upsampling* untuk meningkatkan kembali resolusi spasial *feature map* sehingga dapat digabungkan dengan fitur dari lapisan yang lebih rendah. Dalam konteks citra sediaan darah, penggabungan berbagai tingkat fitur tersebut membantu model memperoleh representasi yang lebih informatif, hal ini bertujuan untuk membedakan objek target, seperti parasit, dari objek atau pola lain yang terdapat pada citra [80], [91].

2. Jalur *Bottom Up*

Sedangkan, jalur *bottom up* memperkuat pelokalan objek dengan membawa informasi spasial yang memiliki tingkat persisi yang tinggi. Proses integrasi ini dilakukan dengan operasi *concatenation* (*Concat*), dimana fitur dari *backbone* digabungkan secara langsung dengan fitur *upscaling*. Penggabungan ini bertujuan untuk memastikan informasi tekstur halus dari membran sel darah dan parasit tetap terjaga, meskipun melewati banyak lapisan konvolusi [91], [92].

3. Peran Modul C2f dalam *Neck*

Pada YOLOv8, efisiensi fusi fitur ditingkatkan melalui penggunaan modul C2f (*Cross Stage Partial Bottleneck with 2 convolutions*). Di bagian *Neck*, modul C2f dikonfigurasi dengan parameter *shortcut = false*. Penghapusan koneksi *shortcut* pada bagian ini bertujuan untuk menyaring informasi dan mengurangi kelebihan data sebelum diteruskan ke bagian *head*. Implementasi modul C2f dengan nilai kedalaman (*n*) yang bervariasi memungkinkan jaringan untuk melakukan pengolahan fitur secara non-linear tanpa menambah beban komputasi yang berlebihan, hal ini sangat penting untuk mempertahankan kecepatan inferensi model [12], [80].

c. *Head*

Komponen terakhir pada sisi kanan Gambar 2.9 adalah *Head*, yang memiliki peran vital dalam merumuskan hasil akhir deteksi. YOLOv8 menerapkan struktur *Decoupled Head*, yang memisahkan tugas prediksi menjadi dua cabang paralel: cabang klasifikasi dan cabang regresi kotak pembatas atau *bounding box*. Pemisahan ini dilakukan untuk meminimalisir konflik antara tugas klasifikasi objek dan penentuan lokasi presisi, yang terbukti meningkatkan akurasi deteksi pada objek medis yang padat [91].

Blok *Detect* pada bagian *Head* beroperasi pada tiga skala resolusi yang berbeda guna memastikan fleksibilitas deteksi terhadap variasi ukuran parasit:

1. Skala P3 (80×80×256) : Digunakan untuk mendeteksi objek berukuran kecil (*small objects*) melalui resolusi spasial yang tinggi.

2. Skala P4 (40×40×512) : Digunakan untuk deteksi objek berukuran sedang (*medium objects*).

3. Skala P5 (20×20×512) : Digunakan untuk deteksi objek berukuran besar (*large objects*) dengan fitur semantik yang lebih kuat [12], [92].

Lebih dalam lagi, secara arsitektural meskipun tidak dijabarkan secara rinci, Di dalam diagram tingkat tinggi tersebut kinerja YOLOv8 ditopang oleh beberapa modul pemrosesan internal yang menjadi fondasi jaringannya. Berdasarkan literatur resmi Ultralytics, arsitektur ini dibangun berdasarkan referensi [12],[91] :

a. Modul *Conv*: Terdiri dari operasi konvolusi standar yang diikuti oleh *Batch Normalization* dan aktivasi *SiLU* untuk menstabilkan ekstraksi fitur sel darah.

b. Modul *Bottleneck*: Menerapkan struktur residual dengan koneksi *skip* untuk menjaga integritas informasi spasial parasit pada lapisan yang sangat dalam.

c. Modul SPPF (*Spatial Pyramid Pooling - Fast*): Berfungsi mengekstraksi fitur multi-skala secara efisien sebelum aliran data masuk ke bagian *Neck.*

d. Modul C2f (*Cross Stage Partial Fusion*): Evolusi dari modul terdahulu yang secara strategis menggabungkan *bottleneck* untuk menciptakan representasi fitur malaria yang kaya namun tetap efisien secara komputasi sehingga memungkinkan deteksi secara *real-time*.

Tabel 2.6 Detail Fungsi Blok Komponen Arsitektur YOLOv8 [12], [80], [84], [91]–[93].

Blok Komponen	Keterangan
Backbone	Bagian dasar jaringan yang berfungsi sebagai pengekstraksi fitur (feature extractor) utama. Penggunaan modul C2f (Cross Stage Partial Bottleneck with 2 convolutions) memungkinkan model untuk menangkap informasi gradien yang lebih kaya dan detail morfologi parasit pada sediaan darah tanpa meningkatkan beban komputasi secara signifikan.
Spatial Pyramid Pooling - Fast	Lapisan yang berfungsi mengumpulkan fitur spasial dari berbagai ukuran (*receptive fields*) melalui operasi pooling yang cepat. Komponen ini memastikan model memiliki pemahaman konteks global terhadap citra mikroskopis sebelum data diteruskan ke bagian fusi fitur.
Neck	Bertindak sebagai jembatan integrasi fitur yang menggabungkan informasi detail spasial tingkat rendah dengan informasi semantik tingkat tinggi melalui jalur *Top-Down* dan *Bottom-Up*. Struktur ini sangat krusial untuk mempertahankan eksistensi fitur parasit yang berukuran sangat kecil.
Upsample & *Concat*	Operasi untuk meningkatkan resolusi spasial (*Upsampling*) dan menggabungkan peta fitur dari

Blok Komponen	Keterangan
	lapisan berbeda (*Concatenation*). Hal ini membantu menjaga resolusi detail visual agar parasit stadium ring atau titik kecil lainnya tidak terabaikan selama proses konvolusi yang dalam.
Decoupled Head	Bagian akhir jaringan yang memisahkan tugas prediksi menjadi dua cabang paralel: klasifikasi (cls) untuk menentukan jenis parasite, dan regresi (bbox) untuk menentukan posisi kotak pembatas. Pemisahan ini meningkatkan akurasi karena setiap tugas dapat dioptimalkan secara mandiri.
Anchor Free Mechanism	Metode deteksi objek yang memprediksi pusat parasit secara langsung tanpa menggunakan kotak jangkar (*anchor boxes*) yang kaku. Pendekatan ini membuat model lebih fleksibel dalam mengenali berbagai bentuk dinamis parasit malaria, terutama pada stadium amoeboid.
Loss Function	Komponen penghitung galat yang terdiri dari *Binary Cross Entropy* untuk akurasi kelas, *Complete IoU* untuk presisi geometri kotak pembatas, dan *Distribution Focal Loss* untuk memperhalus estimasi batas objek, terutama pada area parasit yang padat atau saling tumpang tindih.

Dalam tabel 2.6 menjelaskan proses penlaian keberhasilan deteksi untuk YOLOv8 dilakukan dengan menentukkan beberapa metrics penting yang dapat menjadi tolak ukur keberhasilan kinerja model. Berikut ada beberapa parameter atau *metrics* yang harus diperhatikan :

1. mAP (*mean Average Precision)* tinggi

mAP (*mean Average Precision)* merupakan metrik evaluasi paling komprehensif untuk mengukur performa model deteksi objek. Metrik ini menghitung area di bawah kurva *Precision-Recall* pada nilai ambang batas *Intersection over Union* (IoU) tertentu. Terdapat 2 pengukuran untuk mAP ; mAP@0.5 (mAP50): Mengukur akurasi deteksi dengan syarat *bounding box* prediksi memiliki tumpeng tindih seminimalnya 50% dengan *ground truth*. Untuk deteksi sel darah dan pararsit malaria mikroskopis, pencapaian mAP50% diatas 85% sampai dengan 90% sudah dapat dianggap sebagai standar kinerja yang bagus dan siap untuk diuji [84]. Lalu ada mAP@0.5:0.95: mAP ini mengukur rata-rata persisi dari ambang batas IoU 50% sampai dengan 95% dengan interval 5%. Metrik ini bertujuan untuk menunjukkan seberapa persisi model membingkai bentuk parasit yang tidak beraturan secara geometris [91]

2. Analisis *Confussion Metrics* tinggi

Berbeda dengan deteksi objek umum, deteksi parasit malaria menuntut keseimbangan yang ketat untuk meminimalisir kesalahan diagnosis (*misdiagnosis*). Kinerja ini diukur melalui *precision, recall,* dan *F1-Score* menunjukkan bahwa model memiliki kemampuan yang baik dalam proses deteksi dan mengklarifikasikan objek yang benar.

Nilai mAP50 90%, mAP50-95 70% dan *F1-Score* diatas 80% dianggap menunjukkan performa yang sangat baik [92], [93].

2.6 *Hyperparameter*

Hyperparameter merupakan variabel konfigurasi eksternal yang nilainya ditentukan secara manual sebelum proses pelatihan (*training*) dimulai. Berbeda dengan parameter internal, seperti bobot dan bias, yang diperbarui secara otomatis oleh jaringan selama pelatihan, *hyperparameter* berfungsi untuk mengontrol perilaku keseluruhan algoritma pembelajaran. Dalam arsitektur YOLOv8, pemilihan kombinasi *hyperparameter* yang tepat, membuktikan sangat krusial untuk memastikan model mampu mengekstraksi fitur parasit malaria dengan tingkat presisi yang tinggi secara efisien [91].

Salah satu parameter paling esensial dalam proses optimasi ini adalah *initial learning rate* (lr0) yang bekerja beriringan dengan fungsi *optimizer*. *Learning rate* menentukan besarnya langkah pembaruan bobot model pada setiap iterasi berdasarkan gradien fungsi kerugian (*loss function*). Selain *initial learning rate*, parameter *final learning rate fraction* (lrf) turut memegang peranan penting dalam mengatur skema penurunan laju pembelajaran (*learning rate scheduler*) di sepanjang proses pelatihan. Berbeda dengan lr0 yang menetapkan besaran langkah pembaruan bobot pada awal pelatihan, lrf merepresentasikan rasio pengali terhadap lr0 yang menentukan besarnya *learning rate* pada epoch terakhir, dengan hubungan matematis dinyatakan sebagai $lr_{akhir} = lr0 \times lrf$. Penurunan *learning rate* secara bertahap ini krusial untuk menjaga stabilitas konvergensi model menjelang akhir pelatihan, dikarenakan langkah pembaruan bobot yang masih besar pada *epoch-epoch* akhir berisiko membuat

model melewati (*overshoot*) titik minimum optimal yang telah dicapai, sehingga merusak bobot yang sebelumnya sudah terkalibrasi dengan baik. Dalam penelitian ini, parameter lrf dikombinasikan dengan skema *cosine learning rate* (*cos_lr*) untuk menghasilkan kurva penurunan *learning rate* yang halus, hal ini membuat model melakukan penyesuaian akhir secara presisi tanpa mengalami fluktuasi ekstrem pada tahap akhir *training*. Penggunaan *optimizer* AdamW (*Adam with Weight Decay Fix*) menuntut penentuan *learning rate* yang sangat presisi. Nilai *learning rate* yang terlalu tinggi dapat menyebabkan fluktuasi yang ekstrem sehingga model gagal mencapai konvergensi dan justru melewati titik minimum global. Sebaliknya, nilai yang terlalu rendah akan menyebabkan proses konvergensi berjalan sangat lambat dan rentan membuat model terjebak pada area minimum lokal [49], [94].

Selain *learning rate*, pengaturan *batch size* dan jumlah *epoch* juga memegang peranan penting dalam menyeimbangkan stabilitas dan efisiensi komputasi. *Batch size* menentukan jumlah sampel citra yang diproses ke dalam memori sebelum bobot model diperbarui. Pengaturan *batch size* yang lebih besar dapat menstabilkan estimasi gradien selama pelatihan, namun menuntut kapasitas memori GPU yang jauh lebih besar. Sementara itu, *epoch* merujuk pada satu siklus iterasi lengkap dimana seluruh dataset telah melewati jaringan saraf. Jumlah *epoch* yang optimal diperlukan agar model memiliki waktu yang cukup untuk mempelajari pola morfologi *Plasmodium*, tanpa berujung pada kondisi di mana model sekadar menghafal data dan kehilangan kemampuan generalisasinya [54], [84].

Tujuan utama dari penyesuaian *hyperparameter* ini adalah mencapai kondisi *best fitting*, yaitu titik keseimbangan ideal antara kompleksitas model dan kemampuan generalisasinya terhadap data baru. Ketidakseimbangan dalam proses ini dapat memicu dua fenomena kegagalan utama, yaitu *underfitting* dan *overfitting*. *Underfitting* terjadi jika model terlalu sederhana untuk menangkap pola kompleks pada data sediaan darah, yang ditandai dengan tingginya tingkat kesalahan baik pada tahap pelatihan maupun validasi. Sebaliknya, *overfitting* terjadi ketika model terlalu rumit sehingga cenderung "menghafal" detail dan *noise* pada data latih secara berlebihan. Kondisi *overfitting* ini menghasilkan akurasi yang terlihat sangat tinggi pada data latih, namun performanya akan menurun drastis saat diuji menggunakan data baru yang belum pernah dilihat sebelumnya [73], [74].

Untuk menghindari risiko *overfitting* dan memastikan model berhenti belajar pada titik akurasi puncaknya, penelitian ini menerapkan teknik *early stopping* beserta pengaturan *patience*. *Early stopping* merupakan mekanisme regulasi yang akan menghentikan proses pelatihan secara otomatis, jika tidak ditemukan peningkatan performa pada data validasi setelah melewati sejumlah *epoch* tertentu. Batas toleransi inilah yang didefinisikan sebagai nilai *patience*. Pengaturan nilai *patience* yang terkalibrasi dengan baik memungkinkan model untuk mengakhiri pelatihan tepat sebelum kurva validasi menunjukkan penurunan secara berturut, sehingga efisiensi waktu komputasi dapat tercapai tanpa mengorbankan akurasi deteksi penyakit[94].

2.7 *State of The Art*

Tabel 2.7 *State Of The Art*

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
A Deep Architecture Based On Attention Mechanisms For Effective End-To-End Detection Of Early And Mature Malaria Parasites In A Realistic Scenario	2025	Zedda, L., Loddo, A., & Di Ruberto, C.	Pengembangan framework deteksi berbasis deep learning dengan mekanisme atensi, memperluas model YOLO-SPAM dan YOLO-PAM.	Menunjukkan akurasi tinggi dalam mendeteksi empat spesies malaria pada seluruh stadium infeksi (awal dan matang) dalam skenario realistik.
Review Of Application Yolov8 In Medical Imaging	2024	Widayani, A., Putra, A. M., Maghriebi, A. R., & Ridho, M. H. F.	Studi literatur sistematis mengevaluasi performa YOLOv8 pada berbagai modalitas seperti (X-Ray, CT-Scan, dan MRI).	YOLOv8 mencapai performa tinggi pada tumor otak (*Precision* >0,92, mAP >0,93) dan *Recall* (mAP

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
				0,87) menggunakan optimizer SGD.
Yolov8-CAB: Improved Yolov8 For Real-Time Object Detection	2024	Talib, M., Al-Noori, A. H. Y., & Suad, J.	Integrasi Context Attention Block (CAB) dan modifikasi Spatial Attention (SA) untuk meningkatkan ekstraksi fitur pada blok C2f.	Peningkatan signifikan pada akurasi deteksi objek kecil dan kemampuan ekstraksi fitur lemah tanpa menambah kompleksitas model yang besar.
What Is Yolov8: An In-Depth Exploration Of The Internal Features	2024	Yaseen, M.	Analisis mendalam fitur internal YOLOv8 (CSPNet backbone, FPN+PAN neck, dan Anchor-free approach).	Mengonfirmasi keunggulan YOLOv8 dalam hal presisi dan kemampuan real-time dibandingkan YOLOv5 pada benchmark COCO dan Roboflow 100.

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
Fracture Detection In Pediatric Wrist Trauma X-Ray Images Using Yolov8 Algorithm	2023	Ju, R. Y., & Cai, W.	Penggunaan algoritma YOLOv8 yang dikombinasikan dengan teknik augmentasi data intensif pada dataset GRAZPEDWRI-DX.	Mencapai nilai mAP50 sebesar 0,638, melampaui performa YOLOv7 dan model YOLOv8 orisinal dalam mendeteksi fraktur tulang anak.
Image Analysis And Machine Learning For Detecting Malaria	2018	Poostchi, M., Silamut, K., Maude, R. J., Jaeger, S., & Thoma, G.	Tinjauan teknik pengolahan citra, cell segmentation, dan klasifikasi otomatis untuk sediaan darah Tebal dan tebal.	Membuktikan Deep Learning mampu melakukan automatis diagnosis dengan mengatasi variasi morfologi dan artefak.
YOLO-Tryppa: A Novel YOLO-Based Approach For Rapid And Accurate	2025	Mura, D. A., Zedda, L.,	Modifikasi arsitektur YOLO khusus untuk parasit berukuran kecil (small objects) dengan mengeliminasi head P5 dan	Menghasilkan AP50 sebesar 71,3%, mengatasi masalah hilangnya fitur pada deteksi parasit berukuran mikro

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
Detection Of Small Trypanosoma Parasites		Loddo, A., & Di Ruberto, C.	mengoptimalkan head P2 menggunakan ghost convolutions.	dengan beban komputasi (GFLOPs) yang lebih rendah.
Automatic Patient-Level Recognition Of Four Plasmodium Species On Thin Blood Smear By A Real-Time Detection Transformer (RT-DETR) Object Detection Algorithm	2024	Guemas, E., Routier, B., dkk.	Penggunaan algoritma Real-Time Detection Transformer (RT-DETR) untuk membedakan 4 spesies Plasmodium pada citra sediaan darah Tebal dengan dataset masif (24.720 citra).	RT-DETR mampu mencapai akurasi tingkat pasien yang tinggi (99,8%), membuktikan bahwa arsitektur bebas-anchor (*anchor-free*) efektif untuk citra malaria.
Insights Into AI-Driven Malaria Diagnosis: A Systematic Review With	2025	Tiong, Jia Ying,	Tinjauan sistematis membandingkan CNN, Transfer Learning, dan YOLO/Faster R-CNN khusus untuk tahapan	Menemukan bahwa tantangan terbesar saat ini adalah ketidakseimbangan kelas (class imbalance) dan

Judul Penelitian	Tahun	Penulis	Metode Penelitian	Hasil
Implications For Plasmodium Knowlesi			darah Plasmodium (termasuk knowlesi).	kurangnya anotasi dataset, dimana metode seperti YOLO terbukti efektif jika dikombinasikan dengan adaptasi domain.
Automatic Recognition Of Parasitic Products In Stool Examination Using Object Detection Approach	2022	Naing, K. M., Boonsang, S., dkk.	Komparasi algoritma deteksi objek (YOLOv3, YOLOv4-Tiny, Faster R-CNN, SSD) untuk mendeteksi parasit pada sampel medis menggunakan Artificial Intelligence.	Arsitektur keluarga YOLO menunjukkan keseimbangan terbaik antara kecepatan (real-time) dan presisi pengenalan morfologi parasit dibandingkan SSD dan Faster R-CNN.

Penelitian yang dilakukan oleh Zedda, Loddo, dan Di Ruberto (2025) menunjukkan pendekatan yang komprehensif dalam pengenalan objek medis berskala mikro menggunakan arsitektur berbasis *Deep Learning*. Penelitian ini berjudul *"A deep architecture based on attention mechanisms for effective end-to-end detection of early and mature malaria parasites in a realistic scenario"*. Penelitian ini mengintegrasikan arsitektur keluarga YOLO dengan mekanisme atensi untuk mendeteksi parasit malaria secara *end-to-end* dari sediaan darah. Model berhasil mencapai akurasi yang tinggi dalam mengenali empat spesies *Plasmodium* yang berbeda pada seluruh stadium infeksi, baik pada fase awal maupun matang. Keberhasilan ini disebabkan oleh kemampuan mekanisme jaringan dalam mempertahankan fitur spasial dari parasit berukuran sangat kecil yang sering kali hilang pada lapisan konvolusi dalam. Penelitian ini membuktikan bahwa arsitektur bebas-jangkar (*anchor-free*) sangat tangguh dalam menangani variasi morfologi parasit di skenario klinis yang realistis. Keterkaitan penelitian ini dengan tugas akhir yang sedang dikembangkan adalah memberikan landasan arsitektural yang kuat bahwa penggunaan YOLOv8 yang secara bawaan telah mengadopsi sistem *anchor-free* dan *Decoupled Head* merupakan pilihan algoritma yang paling mutakhir dan tepat untuk mendeteksi stadium awal parasit pada citra mikroskopis.

Penelitian yang dilakukan oleh Tiong . (2025) memberikan perspektif yang sangat kritis terhadap tantangan implementasi kecerdasan buatan dalam diagnosis medis melalui tinjauan sistematis berjudul *"Insights into AI-Driven malaria diagnosis: A systematic review with implications for Plasmodium knowlesi"*. Penelitian yang dipublikasikan oleh Elsevier ini mengevaluasi berbagai teknik mulai

dari prapemrosesan hingga metode deteksi objek seperti YOLO dan Faster R-CNN dalam mendiagnosis tahapan darah parasit malaria. Hasil studi secara tegas menyoroti bahwa kendala paling persisten yang membatasi performa model AI saat ini adalah fenomena ketidakseimbangan kelas (*class imbalance*) pada *dataset* medis serta kurangnya anotasi yang berkualitas. Evaluasi ini membuktikan bahwa tanpa penanganan ketidakseimbangan data yang memadai, model cenderung mengalami bias terhadap kelas yang dominan. Keterkaitan penelitian ini dengan tugas akhir yang dilakukan adalah sebagai justifikasi utama atas penerapan strategi pembobotan kelas (*class weights* / image_weights). Strategi tersebut secara langsung menjawab kesenjangan riset yang disoroti oleh Tiong ., dengan memastikan model tidak bias meskipun jumlah *dataset* kelas *Vivax* jauh lebih mendominasi dibandingkan kelas *Falciparum*.

Penelitian yang dilakukan oleh Talib, Al-Noori, dan Suad (2024) berfokus pada inovasi efisiensi ekstraksi fitur melalui penelitian berjudul *"YOLOv8-CAB: Improved YOLOv8 for Real-time object detection"*. Penelitian ini memodifikasi struktur internal YOLOv8 dengan menambahkan *Context Attention Block* (CAB) dan mempertebal blok C2f (*Coarse-to-Fine*). Model yang dikembangkan berhasil mencapai peningkatan performa yang tajam dalam melokalisasi objek-objek berukuran kecil tanpa meningkatkan kompleksitas komputasi model secara berlebihan. Hal ini disebabkan oleh optimalisasi blok C2f yang mampu mengekstraksi fitur lemah (*weak features*) pada latar belakang gambar yang bervariasi. Penelitian ini secara empiris membuktikan bahwa kedalaman blok C2f memainkan peran paling vital dalam menjaga kualitas representasi visual dari objek kecil hingga ke tahap prediksi akhir. Keterkaitan

penelitian ini dengan tugas akhir yang diusulkan adalah memperkuat argumen teoritis bahwa struktur blok C2f pada YOLOv8 memiliki peran yang signifikan dalam menjaga detail tepi parasit agar tidak mengalami *vanishing gradient*, sehingga deteksi dapat tetap presisi pada perbesaran mikroskopis tertentu.

Penelitian yang dilakukan oleh Widayani . (2024) memberikan wawasan spesifik mengenai penerapan varian YOLO pada berbagai modalitas citra klinis dalam artikel berjudul *"Review of Application YOLOv8 in Medical Imaging"*. Penelitian ini mengevaluasi kinerja YOLOv8 dalam deteksi lesi dan klasifikasi penyakit pada pencitraan seperti X-Ray, CT-Scan, dan MRI. Model ini secara konsisten mencetak nilai *mean Average Precision* (mAP) yang tinggi, termasuk pada deteksi kanker payudara dengan rata-rata mAP 0,87. Keberhasilan ini sangat dipengaruhi oleh konfigurasi parameter pelatihan, di mana penggunaan fungsi optimasi algoritma yang tepat secara langsung menentukan akurasi klasifikasi. Keterkaitan penelitian ini dengan penelitian peneliti adalah memberikan pijakan ilmiah untuk melakukan eksperimen *hyperparameter tuning* secara komprehensif. Berdasarkan temuan tersebut, tugas akhir ini memodifikasi parameter fundamental (seperti *learning rate*, momentum, dan *weight decay*) untuk memastikan model YOLOv8 mencapai titik konvergensi terbaik pada citra sediaan darah.

Penelitian oleh Mura, Zedda, Loddo, dan Di Ruberto (2025) berjudul *"YOLO-Tryppa: A Novel YOLO-Based Approach for Rapid and Accurate Detection of Small Trypanosoma Parasites"* memperkenalkan modifikasi khusus untuk parasit renik. Penelitian ini mengusulkan model YOLO-Tryppa yang mengeliminasi *head* prediksi

P5 dan mengoptimalkan *head* P2 untuk meningkatkan lokalisasi objek kecil. Hasilnya menunjukkan pencapaian nilai AP50 sebesar 71,3%, yang membuktikan bahwa penyesuaian pada skala prediksi sangat krusial untuk objek yang hanya mencakup beberapa piksel dalam citra mikroskopis. Keterkaitan penelitian ini dengan tugas akhir adalah memberikan bukti bahwa untuk parasit darah, fokus deteksi pada skala spasial yang lebih halus (seperti P3 pada YOLOv8 standar) adalah kunci utama. Hal ini mendukung eksperimen tugas akhir dalam mempertahankan resolusi *input* yang tinggi (640 piksel) agar fitur parasit stadium *ring* tetap dapat terdeteksi oleh jaringan.

Penelitian yang dilakukan oleh Guemas . (2024) berjudul *"Automatic patient-level recognition of four Plasmodium species on thin blood smear by a real-time detection transformer (RT-DETR) object detection algorithm"* mengeksplorasi penggunaan algoritma berbasis *Transformer*. Penelitian ini menggunakan *dataset* masif sebanyak 24.720 citra untuk melatih model RT-DETR dalam membedakan empat spesies malaria. Model ini mampu mencapai akurasi tingkat pasien hingga 99,8%, yang menunjukkan bahwa pendekatan berbasis *real-time transformer* dapat menyaingi model konvensional. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai pembanding teknologi deteksi objek terkini. Meskipun RT-DETR menunjukkan akurasi yang luar biasa, penggunaan YOLOv8 dalam tugas akhir ini dipilih karena efisiensi beban komputasinya (GFLOPs) yang lebih rendah, sehingga lebih memungkinkan untuk diimplementasikan pada perangkat mikroskop digital dengan spesifikasi perangkat keras menengah di daerah endemik.

Penelitian oleh Naing . (2022) berjudul *"Automatic recognition of parasitic products in stool examination using object detection approach"* membandingkan performa berbagai algoritma deteksi seperti YOLOv3, YOLOv4-Tiny, Faster R-CNN, dan SSD. Hasil penelitian menunjukkan bahwa arsitektur keluarga YOLO memberikan keseimbangan paling optimal antara kecepatan pemrosesan (*real-time*) dan presisi pengenalan morfologi parasit dibandingkan model SSD. Model YOLO mampu mengenali detail tekstur parasit pada sampel medis secara konsisten. Keterkaitan penelitian ini dengan tugas akhir yang disusun adalah mengonfirmasi bahwa pemilihan keluarga YOLO (dalam hal ini versi terbaru, YOLOv8) adalah langkah yang tepat secara teknis untuk mencapai target sistem deteksi yang tidak hanya akurat secara medis, tetapi juga efisien secara waktu untuk kebutuhan diagnosis massal.

Penelitian yang dipresentasikan oleh Yaseen (2024) melalui artikel *"WHAT IS YOLOV8: AN IN-DEPTH EXPLORATION OF THE INTERNAL FEATURES OF THE NEXT-GENERATION OBJECT DETECTOR"* melakukan analisis mendalam terhadap inovasi arsitektur YOLOv8. Penelitian ini membedah keunggulan integrasi *CSPNet backbone*, *FPN+PAN neck*, serta transisi menuju sistem *anchor-free*. Hasil analisis menunjukkan peningkatan signifikan pada *benchmark* Microsoft COCO dibandingkan versi YOLOv5. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai sumber referensi teknis utama dalam Bab 2 Tinjauan Pustaka. Penjelasan Yaseen mengenai bagaimana modul C2f dan *Decoupled Head* bekerja menjadi landasan teori dasar bagi tugas akhir ini dalam menjelaskan mengapa YOLOv8 memiliki kapabilitas ekstraksi fitur yang lebih kuat untuk objek kecil seperti parasit malaria dibandingkan pendahulunya.

Penelitian oleh Ju dan Cai (2023) berjudul *"Fracture detection in pediatric wrist trauma X-ray images using YOLOv8 algorithm"* menyoroti pentingnya teknik augmentasi data dalam pencitraan medis. Penelitian ini menggunakan algoritma YOLOv8 untuk mendeteksi fraktur tulang pada anak dan berhasil mencapai nilai mAP50 sebesar 0,638. Keberhasilan ini didorong oleh penerapan berbagai teknik augmentasi citra yang mampu menangkap variasi data yang terbatas. Keterkaitan penelitian ini dengan tugas akhir Ivan adalah memperkuat metodologi pada Bab 3 terkait penggunaan augmentasi spasial dan warna. Sebagaimana riset Ju dan Cai, tugas akhir ini memanfaatkan augmentasi untuk memperluas variasi citra sediaan darah, sehingga model menjadi lebih tangguh terhadap perbedaan pencahayaan mikroskop dan kualitas pewarnaan Giemsa.

Penelitian fundamental oleh Poostchi . (2018) berjudul *"Image analysis and machine learning for detecting malaria"* memberikan gambaran historis dan perkembangan teknik diagnosis malaria otomatis. Penelitian ini meninjau transisi dari pengolahan citra klasik menuju era *Deep Learning* untuk mengatasi tantangan variasi morfologi parasit dan artefak sediaan. Kesimpulan penelitian menekankan bahwa *Deep Learning* adalah solusi masa depan untuk diagnosis malaria yang andal. Keterkaitan penelitian ini dengan tugas akhir adalah sebagai fondasi latar belakang masalah. Dengan merujuk pada tinjauan Poostchi, tugas akhir ini memposisikan diri untuk menjawab tantangan otomatisasi diagnosis tersebut melalui penggunaan YOLOv8 yang merupakan representasi teknologi *Deep Learning* paling mutakhir saat ini.

BAB III
METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini merupakan jenis penelitian kuantitatif yang dirancang dengan pendekatan penelitian terapan (*applied research*) dalam area pemrosesan citra medis dan kecerdasan buatan. Pendekatan kuantitatif digunakan karena proses evaluasi kinerja model deteksi parasit malaria diukur secara objektif menggunakan parameter matematis dan metrik statistik, seperti *Mean Average Precision* (mAP), presisi (*precision*), sensitivitas (*recall*), dan *F1-Score*, yang diekstraksi secara komputasional.

Sifat terapan dalam penelitian ini terbebani pada tahap pengembangan dan optimasi sistem. Proses ini mencakup *fine-tuning* arsitektur *You Only Look Once* versi 8 (YOLOv8m) yang dilatih pada dataset COCO. Hal ini dilakukan dengan *transfer learning* seperti melatih ulang model tersebut secara *custom* terhadap dataset malaria yang ada, dengan tujuan untuk menyesuaikan *head* kepada *p.falciparum* dan *p.vivax,* melalui penyesuaian iteratif pada *hyperparameter* fundamental yaitu *learning rate*, momentum, dan *weight decay* menggunakan *optimizer* AdamW. Selain itu, penelitian ini juga menerapkan teknik pembobotan kelas (*class weights*). Hal ini dilakukan sebagai bentuk rekayasa komputasional untuk menguji ketangguhan model, dalam menangani kondisi ketidakseimbangan data (*class imbalance*) antara kelas *Plasmodium Falciparum* dan *Plasmodium Vivax* pada sediaan mikroskopis.

3.2 Waktu dan Tempat Pelaksanaan

Penelitian ini dilaksanakan sekitar sembilan bulan, dimulai dari bulan Agustus 2025 sampai Juli 2026 yang dilaksanakan di Insitut Teknologi Sumatera, Lampung Selatan untuk perancangan pengintegrasian modul kamera dan mikroskop.

3.3 Alat dan Bahan

Adapun alat dan bahan yang diperlukan dalam penelitian ini akan dijelaskan dalam beberapa poin berikut.

3.3.1 Alat

Berikut ini adalah daftar alat yang digunakan dalam penelitian ini, beserta spesifikasi, jumlah dan fungsinya, sebagaimana tercantum pada Tabel 3.1.

Tabel 3.1 Spesifikasi Alat Software dan Hardware

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
Hardware	Laptop ASUS TUF GAMING A16	• AMD Ryzen 7 260 w/ Radeon 780M Graphics, 3800 Mhz, 8 Core(s), 16 Logical Processor(s) • 16 GB RAM • NVIDIA GFORCE RTX 5060 8GB • 1 TB SSD • Windows 11 Home 64-bit	1 Buah	Sebagai pusat komputasi, digunakan untuk menjalankan *software* pengolahaan citra dan model YOLO
	Mikroskop	• Lensa okuler Monokuler, Perbesaran 10x • Lensa objektif 4x-100x	1 Buah	Berfungsi sebagai pembesaran sampel darah sehingga parasite dapat terlihat dalam mikroskop secara detail
	Modul Kamera	• Resolusi 4K • *Output*: HDMI / *Type-C*	1 Buah	Berfungsi untuk menangkap citra mikroskopis melalui lensa mikroskop
Software	Visual Studio Code	• *Versi 1.115* • *Virtual Environment (venv)* • *Python 3.12.3* • *Pytorch 2.7.0. dev 20250310+cu124* • *Torchvision 0.22.0. dev 20250226+cu124* • *Ultralytics 8.4.7* • *CUDA v13.2*	-	Berperan sebagai wadah pembuatan model YOLO serta *Training Data*

Kategori	Nama Alat	Spesifikasi	Jumlah	Kegunaan
		• *Optuna v4.6* • *Opencv-Python 4.12.0.88* • *Numpy 2.2.6* • *Pillow 12.0.0* • *Pyyaml 6.0.3* • *Tqdm 4.67.1* • *Pandas 2.3.3* • *Matplotlib 3.10.7* • *Seaborn 0.13.2* • *Scipy 1.16.3* • *Scikit-Learn 1.8.0* • *Tkinter* • *seed=42*		
	LabelImg	• *Operating System*: Windows 10 atau lebih • *Python requirments*: Minimum *Python* 2.6 • CPU : 2 x 64-bit, 2.8 GHz atau lebih • *Memory*: 16 GB RAM minimum, dengan 1600 MHz DDR3	-	Berperan dalam membantu proses membuat dan mengambil *dataset* parasit malaria menggunakan format *labelimg*. Dilakukan agar setiap gambar memiliki *bounding box* dan file teks berisi dengan informasi *bounding box* tersebut.
	OS	• *Windows 11*	-	Untuk melakukan komputasi dalam komputer.

3.3.2 Bahan

Berikut adalah beberapa bahan yang digunakan dan diperlukan selama melakukan penelitian ini, lengkap dengan jumlah dan fungsinya, sebagaimana di tampilkan dalam Tabel 3.2.

Tabel 3.2 Daftar Bahan Penelitian

Nama Bahan	Jumlah	Kegunaan
Data Set Citra Mikroskopis Smear Darah Tebal	2 Dataset (2 kelas/2300 Citra)	Digunakan sebagai data pelatihan dan pengujian model YOLOv8m

3.4 Metode dan Persamaan yang Digunakan

Pengembangan sistem deteksi parasit malaria dalam penelitian ini didasari pada arsitektur *Deep Learning* YOLOv8m yang mengintegrasikan mekanisme ekstraksi fitur, lokalisasi objek, dan klasifikasi dalam satu jaringan saraf konvolusional. Untuk memandu proses pelatihan (*training*) agar mencapai konvergensi optimal, digunakan serangkaian persamaan matematis yang mencakup fungsi kerugian dan metrik evaluasi sebagai berikut.

3.4.1 Fungsi Kerugian (*Loss Function*)

Model YOLOv8 dioptimalkan menggunakan fungsi kerugian total (L_{total}) yang menggunakan tiga jenis perhitungan untuk memastikan presisi geometris dan akurasi klasifikasi. Komponen tersebut meliputi:

1. *Classification Loss*

Classification Loss dalam penelitian ini digunakan untuk mengukur kesalahan model dalam membedakan antara kelas *Plasmodium Falciparum* dan *Plasmodium Vivax*. Persamaan ini di dasarkan pada *Binary Cross-Entropy* (BCE), yang menghitung perbedaan antara probabilitas prediksi dan label aktual:

$$Lcls = -\frac{1}{N}\sum_{i=1}^{N}[Yi\log(Pi) + (1-Yi)\log(1-Pi)]\ [90] \quad (3.1)$$

Dimana N termasuk sebagai jumlah sampel, *Yi* Adalah label biner (0 atau 1), dan *Pi* adalah skor probabilitas yang dihasilkan model[90].

2. *Bounding Box Regression Loss* (CIoU)

Untuk meningkatkan akurasi pelokalan koordinat parasit yang berukuran kecil pada sediaan darah, penelitian ini menggunakan metode *Complete Intersection over Union* (CIoU). CIoU sendiri mempertimbangkan tumpang tindih area, jarak antarpusat, dan rasio aspek bounding box:

$$LCIoU = 1 - IoU + \frac{p^2(b,b^{gt})}{c^2} + av\ [93] \quad (3.2)$$

Dalam konteks pencitraan medis dan penelitian ini, penggunaan CIoU menjadi sangat krusial dalam meminimalisir deviasi posisi kotak merah pada objek mikroskopis [91].

3. *Distribution Focal Loss* (DFL)

DFL dalam penelitian ini berfungsi untuk memperhalus estimasi batas kotak pembatas pada kondisi dimana batas objek parasit tidak terlalu jelas atau saling tumpang tindih dengan sel darah merah lainnya.

3.4.2 Parameter Optimasi (AdamW)

Proses pembaruan bobot jaringan saraf dalam penelitian ini dikendalikan oleh *optimizer* AdamW (*Adam with Weight Decay Fix*). Algoritma ini dipilih karena kemampuannya dalam memisahkan penanganan peluruhan bobot (*Weight Decay*) dari pembaruan gradien utama, hal ini dapat menghilangkan kejadiannya *overfitting* pada *dataset* malaria yang memiliki ketimpangan kelas yang besar. Persamaan pembaruan bobot w pada langkah waktu t :

$$w_{t+1} = wt - n_t \left(\frac{\widehat{m_t}}{\sqrt{\widehat{v_t}+\epsilon}} + \lambda w_t \right) [95] \quad (3.3)$$

Dimana n mempresentasikan learning rate, $\widehat{m_t}$dan $\widehat{v_t}$ adalah estimasi momen gradien, sementara λ adalah parameter tingkat *weight decay* sebesar 0.005 yang di terapkan dalam penelitian ini.

3.4.3 Metrik Evaluasi Kinerja Sistem

Keberhasilan sistem yang mengendali morfologi parasit diukur secara kuantitatif melalui metrik statistic, yang dihitung berdasarkan nilai hasil *confusion matrix*. Parameter ini mencakup berbagai hal dari *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), *False Negative* (FN):

1. *Intersection over Union* (IoU)

IoU merupakan acuan dasar ilmiah untuk menentukan apakah sebuah kotak prediksi yang dihasilkan oleh model (B_{pred}), dapat dinyatakan sebagai tebakan yang benar (*True Positive*) atau salah (*False Positive*), hal ini dilakukan dengan membandingkannya terhadap kotak pelabelan asli dari pakar atau *ground truth* (B_{gt}). Persamaan matematis IoU dinyatakan sebagai berikut:

$$\text{IoU} = \frac{Luas\ (B_{pred} \cap B_{gt})}{Luas(B_{pred} \cup B_{gt})} [96] \qquad (3.4)$$

2. Sensitivitas (*Recall*)

Sensitivitas atau *recall* untuk mengukur model dalam menemukan kembali seluruh parasit malaria yang ada di dalam citra:

$$Recall = \frac{TP}{TP+FN} [93] \qquad (3.5)$$

3. Presisi (*Precision*)

Presisi atau *precision* mengukur tingkat keandalan model dalam memprediksi parasite tanpa terdistraksi oleh artefak atau kotoran:

$$Precision = \frac{TP}{TP+FP} [93] \qquad (3.6)$$

4. F1-*Score*

F1-*score* digunakan sebagai indikator keseimbangan antara persisi dan sensitivitas dalam klarifikasi diagnosis medis:

$$F1 - score = 2\ x\ \frac{precision\ x\ recall}{precision+recall} [93] \qquad (3.7)$$

Dalam konteks diagnosis medis seperti malaria, parameter Sensitivitas (*Recall*) memiliki prioritas tertinggi karena kesalahan sistem dalam melewatkan sel yang terinfeksi (*False Negative*) dapat berakibat fatal bagi pasien. Oleh karena itu, metrik ini dievaluasi secara ketat bersama dengan F1-Score untuk memastikan keandalan model [93].

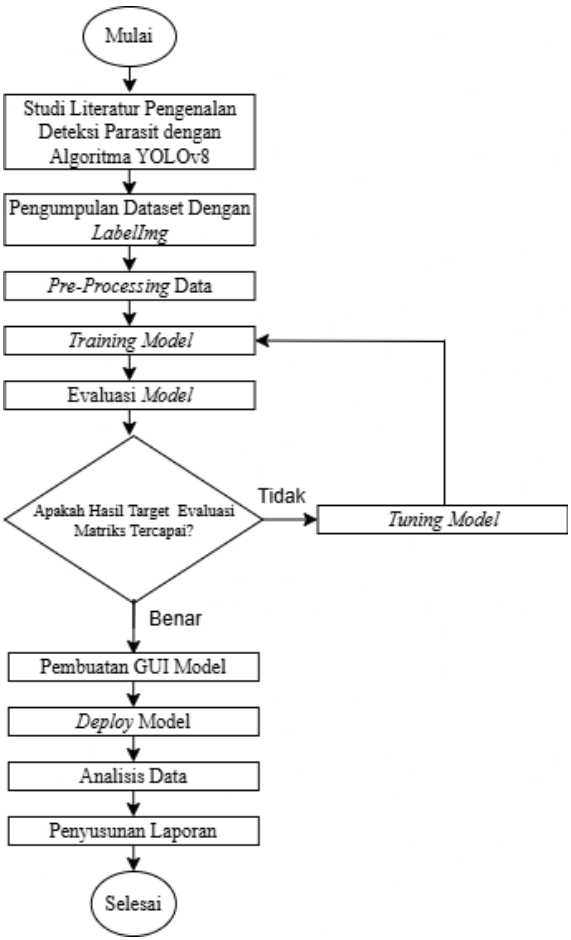
5. *Mean Average Precision* (mAP) 50

Metrik ini digunakan sebagai tolak ukur utama dalam deteksi objek yang menghitung rata-rata presisi pada berbagai tingkat sensitivitas dengan ambang batas IoU 0,5. [92], [97].

6. *Mean Average Precision* (mAP) 50-95

mAP@50-95 (mAP@[0.50:0.95]) merupakan metrik evaluasi yang paling ketat dan komprehensif dalam arsitektur YOLO modern. Metrik ini tidak menggunakan satu ambang batas IoU tunggal, tetapi mengkalkulasi nilai rata-rata mAP dari 10 tingkatan ambang batas IoU yang bervariasi, dimulai dari IoU = 0,50 hingga IoU = 0,95 dengan kenaikan interval *step* sebesar 0,05 [97].

3.5 Diagram Alir Penelitian



Gambar 3.1 Diagram Alir Penelitian

Sesuai dengan diagram alir 3.1 tahapan penelitian ini terbagi menjadi secara keseluruhan 4 tahap utama, dimulai dengan *image processing*, *pre-processing* data, *training data,* dan integrasi model YOLOv8 dengan modul kamera yang ada. Tahapan penelitian ini akan dijelaskan dalam beberapa sub bab berikut.

3.5.1 Studi Literatur

Langkah pertama diawali dengan tahap Studi Literatur Pengenalan Deteksi Parasit dengan Algoritma YOLOv8m. Pada fase esensial ini, dilakukan kajian komprehensif terhadap berbagai literatur dan publikasi ilmiah terkini yang relevan. Hal ini difokuskan pada karakteristik morfologi citra mikroskopis parasit malaria, penanganan data tidak seimbang (*class imbalance*), serta bedah arsitektur YOLOv8 seperti mekanisme ekstraksi fitur pada modul C2f dan sistem pelokalan *anchor-free*. Pemahaman teoritis ini menjadi fundamental sebelum memulai perancangan sistem secara teknis.

3.5.2 Pengumpulan Dataset

Langkah selanjutnya adalah, tahap pengumpulan dataset dengan *LabelImg*. Proses pelabelan dan penentuan posisi koordinat parasit pada citra sediaan darah tebal ini divalidasi secara langsung oleh tenaga ahli laboratorium kesehatan (analis parasitologi) Puskesmas Hanura. Hal ini dilakukan untuk memastikan akurasi kedudukan *ground truth* sebelum digunakan dalam proses pelatihan model. Citra-citra mentah tersebut kemudian diproses menggunakan perangkat lunak *LabelImg* untuk melakukan anotasi secara manual. Proses anotasi ini bertujuan untuk membuat kotak pembatas (*bounding box*) pada objek target dan memberikan label kelas spesifik (seperti *Plasmodium falciparum* atau *Plasmodium vivax*), yang berfungsi sebagai data kebenaran dasar (*ground truth*) bagi model.

3.5.3 Pre-Processing Data

Dataset berlabel kemudian dialirkan ke dalam tahapan *Pre-Processing* Data. Tahapan ini sangat krusial untuk menormalisasi variasi data dan membersihkan gangguan visual yang tidak diinginkan.

Proses pra-pemrosesan mencakup penyesuaian resolusi citra menjadi ukuran standar masukan YOLOv8m (640x640 piksel), penyesuaian kontras pencahayaan mikroskop, serta augmentasi data spasial. Tindakan manipulasi ini bertujuan untuk memperkaya variabilitas fitur agar model memiliki ketahanan (*robustness*) yang tinggi saat mengenali parasit dengan orientasi yang berbeda-beda.

3.5.4 *Training* Model

Dataset yang telah diolah, selanjutnya digunakan pada tahap *Training* Model. Pada fase ini, arsitektur YOLOv8 dilatih secara komputasional untuk mengenali pola parasit berdasarkan dataset latih. Setelah serangkaian iterasi (*epoch*) selesai, alur berlanjut ke tahap Evaluasi Model, di mana performa jaringan diuji menggunakan dataset validasi. Kinerja model dikuantifikasi menggunakan parameter metrik evaluasi standar seperti *Confusion Matrix*, presisi, *recall*, dan tingkat *Mean Average Precision* (mAP@50) untuk menilai kemampuan generalisasinya terhadap citra baru.

3.5.5 Evaluasi Model

Hasil evaluasi tersebut kemudian berakhir pada titik keputusan (*decision node*). Apabila hasil evaluasi (seperti nilai mAP atau keseimbangan F1-Score) belum memenuhi target atau terindikasi mengalami *overfitting/underfitting*, maka alur akan berbelok ke tahap Tuning Model. Pada proses iteratif ini, dilakukan penyesuaian ulang terhadap nilai *hyperparameter* (seperti *learning rate*, *optimizer* AdamW, *momentum,* atau *weight decay*), sebelum sistem dikembalikan ke tahap pelatihan. Siklus ini akan terus berulang hingga model berhasil mencapai konvergensi dan tingkat akurasi yang diharapkan.

3.5.6 Pembuatan GUI

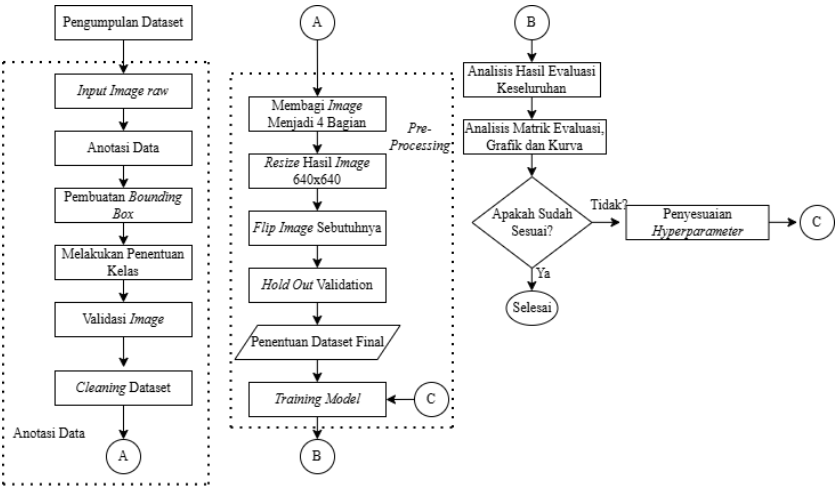
Jika model dinyatakan telah memenuhi atau melampaui target matriks evaluasi dengan menyatakan Ya, langkah selanjutnya adalah Pembuatan GUI Model. Tahap ini bertujuan untuk mengemas arsitektur *Deep Learning* yang kompleks ke dalam Antarmuka Pengguna Grafis (*Graphical User Interface*). Setelah antarmuka selesai dibangun, tahapan Deploy Model dilakukan pengimplementasikan sistem secara fungsional. Proses *deployment* ini memungkinkan model beroperasi secara *real-time* atau luring untuk menganalisis citra mikroskopis di lingkungan operasional yang sebenarnya.

3.5.7 Analisis Data

Setelah implementasi, dilakukan analisis data secara mendalam terhadap keluaran sistem. Analisis ini meninjau perbandingan hasil deteksi prediksi model terhadap hasil observasi (*dataset*) manual oleh tenaga medis, hal ini bertujuan untuk mengidentifikasi margin kesalahan yang mungkin timbul saat sistem dihadapkan pada data baru. Keseluruhan alur metodologi penelitian ini akhirnya dirangkum secara formal dalam tahap penyusunan laporan Tugas Akhir, sebelum keseluruhan rangkaian eksperimen dan pengembangan sistem dinyatakan Selesai.

3.6 Langkah Penelitian secara Spesifik

Langkah Penelitian dimulai dengan pengumpulan dataset dengan labelimg memiliki proses yang cukup panjang, proses tersebut dapat dilihat pada Gambar 3.2.



Gambar 3.2 Diagram Alir Penelitian Spesifik

1) Persiapan Dataset

Proses dimulai dari pengecekan terhadap dataset. Penelitian ini menggunakan dataset yang terdiri diri dari citra mikroskopis sediaan darah total yang sudah di anotasikan, yang dikumpulkan secara langsung pada desa hanura, lampung selatan. Citra-citra tersebut diambil melalui lensa okuler mikroskop dengan pembesaran 100x menggunakan kamera ponsel. Semua citra disimpan dalam ruang warna RGB dengan resolusi 3.024×4.032 piksel. Dataset ini dikategorikan ke dalam dua kelas: sediaan darah yang terinfeksi P. *falciparum*, sediaan darah yang terinfeksi P.*vivax*. Secara keseluruhan, dataset ini mencakup 2300 citra sediaan darah tebal (pada tingkat mikroskop) yang diperoleh dari berbagai pasien. Status infeksi semua pasien dikonfirmasi menggunakan metode *gold standard*, yaitu pemeriksaan mikroskopis sediaan darah tebal.

Citra pada tingkat mikroskop ini kemudian diproses lebih lanjut untuk menghasilkan 2300 citra berlabel secara individual pada tingkat

seluler (Tabel 3.3). Proses anotasi dataset dilakukan oleh seorang ahli mikroskopis dari Puskesmas Hanura, yang memverifikasi keberadaan infeksi, mengidentifikasi spesies parasit, serta secara manual memberi label pada setiap citra untuk menandai parasit.

Tabel 3.3 Rangkuman Jumlah Komposisi dan Label Dataset

Subset	Jumlah Citra	Parasit Berlabel
P.falciparum	217	218
P.Vivax	2083	4282
Total	2300	4500

Citra-citra yang telah dianotasi ini kemudian dikatalogkan dan disimpan dalam Google *Drive*. Dataset ini sebelumnya telah divalidasi, dianalisis, sehingga dapat dijadikan acuan dalam penelitian ini. Jumlah data yang di miliki berdasarkan dari tabel 3.3 termasuk sebagai data *imbalance*. Mengingat keterbatasan waktu pelatihan dan kapasitas komputasi, penelitian ini hanya menggunakan citra dari total dataset yang tersedia. Pemilihan subset dilakukan secara acak dan merata dari tiap kelas, serta diatur langsung melalui *script* pemrograman pada tahap pemuatan data, hal ini dilakukan untuk memastikan efisiensi proses tanpa mengganggu distribusi label pada dataset.

2) *Resizing Citra Dataset*

Setelah melakukan persiapan dataset, tahap selanjutkan dilakukan dengan *resizing* dataset. Hal ini bertujuan untuk melakukan pemfokusan kepada parasit yang ada, memisahkan elemen-elemen yang penting dan tidak penting dan menghindari *overfitting* dalam data.

Citra mikroskopis dari dataset original yang beresolusi 3024x 4032 piksel akan di-*cut* setelah digabungkan 4 gambar citra, tanpa mengubah piksel citra berdasarkan koordinat bounding box dari meta data dataset yang berukuran 640 x 640 piksel.

3) *Pre-processing*

Dataset harus diamati apakah kondisinya sudah cukup baik atau masih kurang. Jika kurang baik, maka perlu dilakukan *pre-processing*. Tahap ini sangat penting untuk menghilangkan *noise* atau gangguan yang dapat mengaburkan informasi dalam gambar. Berikut ini adalah teknik *pre-processing* yang akan dilakukan, seluruh citra yang ditampilkan diambil dari jurnal karya Briceno, dkk. yang berjudul "*Deep Learning-Based Malaria Parasite Detection: You Only Live Once Model for Accurate Species Identification of Plasmodium Falciparum and Plasmodium Vivax"* dan juga metode yang diajukan sendiri dalam pembuatan sistem ini.

a) Augmentasi Data

Dalam dataset yang diambil terdapat beberapa tantangan dalam *image* hal ini berupa *image* citra yang di ambil, bentuk parasit yang bervariasi sehingga pada proses training dapat menurunkan tingkat akurasi hasil akhir. Untuk mengatasi itu dilakukan proses augmentasi data, Dimana dilakukan *flip* atau rotasi secara *random* untuk menyesuaikan dengan *image* yang lainnya, penambahan *noise* pada gambar, dan penambahan atau pengurangan *brightness* secara random pada gambar. Dilakukan juga *mosaic* augmentasi dengan menggabungkan 4 gambar menjadi 1 dengan pengubahan gambar menjadi 1280x1280 secara sementara sebelum dilakukan *random*

perpective dan dilakukan *cutting* menjadi 640x640 agar dapat dibaca oleh YOLO itu sendiri.

4) Pembagian Dataset (*Hold Out Validation*)

Dataset yang telah melalui tahap pra-pemrosesan kemudian dibagi ke dalam tiga subset utama, yaitu data *training* (pelatihan), data *validation* (validasi) dan data *test*. Pada penelitian ini, metode evaluasi yang digunakan adalah *Hold-Out Validation* dengan rasio pembagian statis sebesar 80:10:10. Artinya, 80% dari total citra digunakan untuk melatih model agar mampu mengenali dan mengekstraksi fitur parasit secara mendalam, sedangkan 10% digunakan secara eksklusif untuk memvalidasi performa model dan 10% data digunakan untuk melakukan pengujian terhadap evaluasi model yang dapat dilihat pada tabel 3.4.

Tabel 3.4 Pembagian Data Final Training

No	Data *Training*	Data *Validation*	Data *Test*
1	80	10	10

Penggunaan metode *Hold-Out Validation* dengan rasio 80:10:10 dipilih sebagai pengganti *K-Fold Cross Validation* dengan beberapa justifikasi ilmiah dan teknis. Pertama, pelatihan arsitektur *deep learning* seperti YOLOv8m untuk deteksi objek beresolusi tinggi menuntut beban komputasi memori GPU dan waktu yang sangat massif [98]. Menggunakan K-Fold (misalnya 5-fold) berarti mengulang proses training penuh sebanyak 5 kali yang dinilai tidak efisien secara komputasional. Kedua, dataset telah diacak secara terstruktur sebelum dibagi (menggunakan konfigurasi *random seed* yang statis), untuk memastikan distribusi kelas *P. Falciparum dan P. Vivax* tersebar secara proporsional.

Dengan ukuran dataset yang ada, rasio 80% data latih dan 10% data validasi dan 10% *test* telah terbukti secara cukup stabil untuk menghasilkan model dengan tingkat generalisasi tanpa mengalami bias data [94].

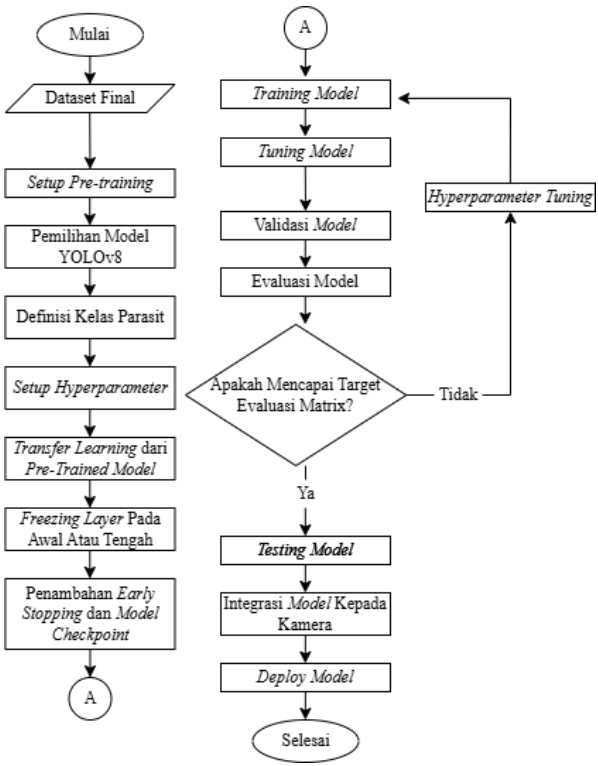
3.6.1 Proses Training Model

Pada proses *training model* disesuaikan dengan kebutuhan sistem pemantauan secara terus menerus atau berkelanjutan. Model dilatih dengan *dataset* yang mencerminkan kondisi deteksi nyata. Pada tahapan ini difokuskan kepada kemampuan model untuk mengenali dan mempelajari berbagai bentuk paraasit yang ada dalam malaria, beserta mempertahankan akurasi dan persisi selama periode deteksi yang lama.

Model YOLOv8m dipilih dikarenakan melibatkan desain jaringan neural baru yang dikembangkan untuk disesuaikan kepada bentuk parasit yang ada dalam malaria, Hal ini dilakukan dengan tujuan untuk meningkatkan performa, akurasi, persisi, dan mengurangi beban kerja tenaga medis yang ada di Desa Hanura. Proses *training* model meliputi beberapa tahapan seperti, *pre-training setup*, *training process*, *validation model*, dan *testing model*. Seperti yang diberikan pada Gambar 3.1.

Penelitian ini menerapkan teknik *transfer learning* dan *fine-tuning* menggunakan bobot pra-latih (*pre-trained weights*) YOLOv8m, yang sebelumnya telah dilatih secara ekstensif pada dataset COCO (berisi 80 kelas objek umum). Karena dataset malaria memiliki karakteristik spasial yang sangat spesifik, *fine-tuning* dilakukan dengan melatih ulang (*retraining*) lapisan-lapisan konvolusi dan menyesuaikan *head* klasifikasi agar secara eksklusif mendeteksi dua kelas target, yaitu *P. falciparum* dan *P. vivax*. Pendekatan ini memanfaatkan pengetahuan

dasar (ekstraksi bentuk dan tepi tepi) dari model awal, untuk mempercepat proses konvergensi dan meningkatkan akurasi deteksi parasit.



Gambar 3.3 Tahap Training Model

Berdasarkan Gambar 3.3 ditentukan terlebih dahulu dataset final, menentukkan parameter-parameter untuk dimasukkan dan digunakan dalam proses *training*. Selanjutnya akan menentukkan *base model* YOLOv8 yang akan digunakan, dalam kasus ini terpilih *base model* YOLOv8m, lalu menentukkan pengaturan lingkungan pengembangan, dan instansi *library* yang mendukung dalam proses pelatihan model.

Konfigurasi pelatihan model diimplementasikan menggunakan berkas berekstensi YAML (*Yet Another Markup Language*) yang berfungsi sebagai cetak biru utama sistem. Berkas ini memuat spesifikasi teknis yang krusial, meliputi jalur direktori dataset (*directory paths*), definisi arsitektur jaringan, dan skema augmentasi data. Pendefinisian jumlah dan nama kelas dalam konfigurasi ini sangat vital agar model dapat membedakan morfologi spesifik antar spesies parasit malaria. Selain itu, berkas ini juga mengatur *hyperparameter* pelatihan esensial seperti *batch size*, *learning rate*, *momentum*, dan jenis *optimizer* untuk memastikan stabilitas proses pembelajaran model.

3.6.2 Proses Training

Setelah melakukan *pre-training setup*, proses training dimulai dengan melakukan konfigurasi umum yang telah di tentukan sebelumnya. Model dilatih dengan menggunakan *Visual Studio Code* sebagai aplikasi utama, dikarenakan kemudahan dalam pemrograman, beserta mengubah hyperparameter setiap training, hal ini termasuk *learning rate, batch size, epoch,* dan *optimizer*.

Berikutnya dilakukan berbagai perbandingan *hyperparameter* yang dilakukan atau dicoba untuk menemukan konfigurasi model yang paling ideal untuk melakukan penelitian, seperti *learning rate, batch size, epoch,* pemilihan *optimizer*, *weight decay*, dan *momentum*. Berikutnya, juga melakukan *review* terhadap kinerja model dan juga arsitektur model untuk menemukan hasil yang optimal. Setelah ditemukan *hyperparameter* yang optimal, dilakukan pengujian terhadap skenario data augmentasi.

Proses pelatihan menggunakan *optimizer* AdamW, dengan fungsi kerugian yang terdiri dari tiga komponen sebagaimana telah

dijelaskan pada Sub bab 3.4.1, yaitu *Binary Cross-Entropy* (BCE) untuk menghitung kesalahan klasifikasi kelas parasit, *Complete Intersection over Union* (CIoU) untuk mengukur seberapa tepat posisi *bounding box* yang diprediksi, dan *Distribution Focal Loss* (DFL) untuk memperhalus prediksi batas kotak deteksi. Ketiga nilai kerugian ini dijumlahkan menjadi satu nilai *loss* total yang dipakai model untuk memperbarui bobotnya di setiap iterasi pelatihan. *Hyperparameter* ditetapkan berdasarkan kombinasi yang stabil, dengan konfigurasi Tabel 3.5 sebagai berikut :

Tabel 3.5 Konfigurasi *Hyperparameter*

Kategori	Parameter	Nilai
Konfigurasi Dasar & Sistem	*epochs*	150
	imgsz	640
	batch	8
	workers	2
	patience	50
Optimasi & Kecepatan Belajar	*optimizer*	AdamW
	lr0	0.000218
	lrf	0.00426
	momentum	0.8652
	weight_decay	8.35×10^{-5}
	cos_lr	TRUE
Pemanasan Jaringan (Warmup)	*warmup_epochs*	6.69
	warmup_momentum	0.9422

warmup_bias_lr	0.1

Konfigurasi ini dipilih untuk menjaga keseimbangan antara kecepatan konvergensi dan stabilitas pelatihan. Dengan pendekatan ini, diharapkan model mampu mempelajari fitur morfologis khas dari citra sel darah terinfeksi malaria secara akurat dan konsisten.

Setiap *training* yang telah dilatih dievaluasi secara terpisah menggunakan metrik seperti *precision*, *recall*, dan *F1-score*. Kurva *loss* dan *precision* per *epoch* divisualisasikan untuk memantau dinamika pelatihan sekaligus mendeteksi potensi *overfitting* atau *underfitting*. Hasil evaluasi model ini berupa berbagai macam metrik seperti *recall*, *precision*, *f1-score*, mAP@50, dan mAP@50-95. Metrik-metrik ini dihitung berdasarkan nilai yang diperoleh dari *confusion matrix*, yang mencakup *True Positives*(TP), *True Negatives*(TN), *False Positives*(FP), *False Negatives*(FN), *Bounding Box Ground Truth* (B_{gt}) dan *Bounding Box Predict* (B_{pred}).

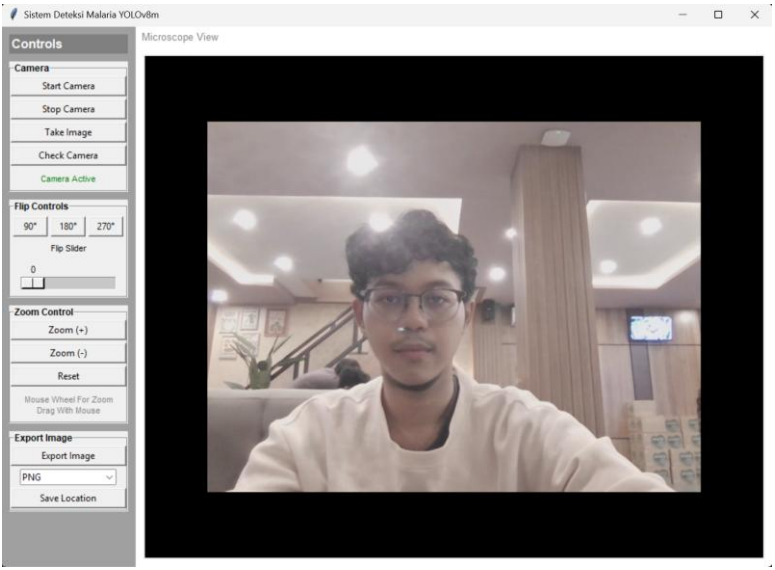
Setelah pelatihan, evaluasi keseluruhan dilakukan untuk memperoleh gambaran performa model. Hasil evaluasi mencakup perhitungan rata-rata *precision*, *recall*, dan *F1-score* pada seluruh skenario, serta analisis distribusi kesalahan melalui *confusion matrix*. Analisis ini memungkinkan identifikasi skenario terbaik dengan mempertimbangkan tidak hanya akurasi, tetapi juga kestabilan *loss*, distribusi kesalahan, dan generalisasi model terhadap variasi augmentasi data.

3.6.3 Integrasi *Hardware* dan *Software*

Tahap ini berfokus pada integrasi *webcam* atau *eyepiece camera* sebagai modul akuisisi citra dengan mikroskop konvensional, serta model YOLOv8m yang telah dilatih untuk mengklasifikasikan

parasit malaria pada sel darah merah. Kamera digunakan untuk menangkap citra mikroskopis secara *real-time*, kemudian citra tersebut dialirkan untuk diproses secara digital menggunakan bahasa pemrograman *Python* dengan bantuan pustaka *OpenCV*.

Proses *pre-processing* pada tahap integrasi meliputi persiapan preparat standar. Setelah citra siap, proses analisis dilakukan menggunakan bobot model terbaik (*best.pt*) melalui *framework PyTorch* dan pustaka *ultralytics*. Hasil inferensi yang dihasilkan berupa identifikasi spesies parasit, apakah terinfeksi *Plasmodium falciparum* atau *Plasmodium vivax*, yang kemudian ditampilkan secara visual melalui antarmuka pengguna grafis (GUI). Untuk mengoptimalkan kecepatan deteksi pada perangkat dengan daya komputasi terbatas, dilakukan juga pertimbangan teknik optimasi seperti konversi ke format yang lebih ringan, hal ini juga untuk memastikan sistem dapat beroperasi dengan latensi yang sangat rendah. Hasil visual penggunaan antarmuka pengguna grafis atau GUI dapat dilihat pada Gambar 3.4.



Gambar 3.4 Design GUI

Pada gambar ini terlihat baseline atau kerangka awal dari GUI, dimana di dalam GUI ini sendiri memiliki beberapa kategori fitur dimulai dari *camera*, *flip control*, *zoom control*, dan *export image*.

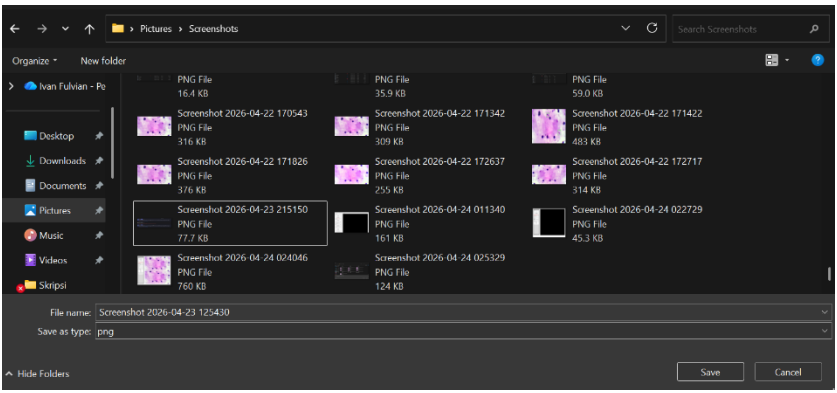
Di dalam masing-masing kategori fitur memiliki beberapa tombol atau fitur sendiri, dimulai dengan *camera* di dalam kategori fitur *camera* memiliki tombol *start camera*. Hal ini berfungsi untuk memulai proses atau model untuk model mulai melakukan identifikasi terhadap gambar yang diberi. Sedangkan, penggunaan *stop camera* berfungsi untuk menghentikan proses deteksi model yang sedang dilakukan, hal ini dilakukan untuk menghentikan proses deteksi. Dengan menyebabkan area yang sebelumnya terdapat gambar parasit akan menghasilkan warna hitam. Berikutnya ada *take image* hal ini bertujuan untuk mengambil gambar dari hasil deteksi yang sudah dilakukan. Lalu, terdapat *check camera* tombol ini berfungsi untuk memberitahu pengguna terkait terdeteksinya *camera* atau tidak di dalam GUInya,

apabila tidak terdeteksi maka akan memberikan teks "*camera not detected* " atau "*camera detected* " dalam warna merah.

Berikutnya terdapat fitur *flip controls*, fitur ini memiliki tujuan untuk melakukan rotasi terhadap gambar yang sudah diberi, dengan harapan dapat meningkatkan tingkat akurasi atau mempermudah pengguna dalam melakukan pendeteksian secara manual apabila perlu. Di dalam fitur *flip controls* terdapat beberapa tombol lagi dimulai dengan 90°, 180°, 270°. Dengan adanya slider untuk melakukan rotasi secara *custom* atau sesuai kebutuhan pengguna dengan maskimum *slider* 360°.

Lalu, terdapat fitur *zoom control,* fitur ini memberikan pengguna kemampuan untuk melakukan pembesaran gambar sesuai kebutuhan dari pengguna, dengan harapan dapat meningkatkan akurasi dari model atau mempermudah pengguna dalam melihat parasit. Di dalam fitur *zoom control* ini memiliki beberapa tombol lainnya, dimulai dengan *zoom* (+), fitur ini memberikan kemampuan pengguna untuk melakukan pembesaran gambar secara bertahap dengan tingkat pembesaran 10%. Lalu, terdapat fitur *zoom* (-) dengan kemampuan kebalikannya dari *zoom* (+), yang memberikan kemampuan kepada pengguna untuk melakukan pengurangan ukuran gambar. Berikutnya, terdapat fitur *reset,* hal ini bertujuan untuk melakukan *reset* terhadap peningkatan atau penurunan *zoom* yang telah dilakukan oleh pengguna.

Berikutnya terdapat fitur *export image,* hal ini memberikan kemampuan kepada pengguna untuk menyimpan hasil gambar dari GUI langsung ke dalam *folder* atau *file* yang ada, dengan memberikan tempat penyimpanan yang *custom* atau menyesuaikan dengan kebutuhan pengguna. Contoh tempat penyimpanan gambar dapat dilihat pada gambar 3.5.



Gambar 3.5 Lokasi Penyimpanan File

Tempat penyimpanan gambar dapat disimpan di dalam *folder* tertentu atau pengguna dapat membuat *folder* baru khusus untuk gambar-gambar yang sudah atau akan di ambil.

3.6.4 Uji Implementasi

Setelah proses integrasi model YOLOv8m dengan GUI dan kamera mikroskop selesai dilakukan, tahap selanjutnya adalah uji implementasi sistem. Uji implementasi bertujuan untuk memastikan bahwa setiap komponen sistem dapat berfungsi sesuai dengan rancangan yang telah dibuat.

Pengujian dilakukan pada fungsi utama GUI, meliputi koneksi dan aktivasi kamera, proses pengambilan citra, tampilan hasil deteksi

model, pengaturan orientasi citra, pembesaran citra, serta penyimpanan hasil gambar.

Pada tahap ini, pengujian difokuskan pada fungsi dan integrasi antara perangkat lunak, model deteksi, dan kamera mikroskop, bukan pada pengukuran performa model secara kuantitatif.

Evaluasi performa model dilakukan secara terpisah menggunakan *test set* dengan metrik Precision, Recall, F1-Score, mAP@50, dan mAP@50-95 sebagaimana dijelaskan pada sub bab 3.5.7.

3.7 Interpretasi Data/Analisis Data

Tahap interpretasi data merupakan bagian penting dalam penelitian ini yang bertujuan untuk menganalisis kinerja sistem deteksi malaria berbasis YOLOv8m. Setelah proses pelatihan selesai, model dievaluasi menggunakan test set yang telah dipisahkan dari data training dan validation dengan rasio 80:10:10. Evaluasi dilakukan berdasarkan metrik *precision*, *recall*, *F1-Score*, mAP@50, dan mAP@50-95 untuk menilai kemampuan model dalam mendeteksi dan membedakan Plasmodium falciparum dan Plasmodium vivax pada citra mikroskopis sediaan darah tebal.

Hasil evaluasi kemudian dibandingkan antar-skenario penanganan ketidakseimbangan kelas, yaitu oversampling dengan rasio 1:2, global augmentation, dan undersampling dengan rasio 1:1. Perbandingan dilakukan untuk menentukan skenario yang menghasilkan performa terbaik berdasarkan keseluruhan metrik evaluasi. Selain itu, hasil confusion matrix dan visualisasi deteksi digunakan untuk mengidentifikasi jenis kesalahan prediksi, seperti *false positive*, *false negativ*e, dan misklasifikasi antarspesies.

Interpretasi hasil dilakukan dengan menghubungkan nilai metrik dan karakteristik kesalahan prediksi dengan kondisi dataset, beserta strategi penanganan ketidakseimbangan kelas yang diterapkan. Hasil analisis digunakan sebagai dasar dalam menentukan model terbaik dan mengidentifikasi faktor yang memengaruhi performa sistem pada penelitian ini.

BAB IV
HASIL DAN PEMBAHASAN

4.1 Pengolahan Dataset Citra Mikroskopis

Tahap awal dan krusial adalah pengolahan dataset primer citra mikroskopis sediaan darah tebal yang diperoleh dari Puskesmas Hanura, Kabupaten Pesawaran, Lampung. Validitas dan kualitas representasi fitur pada fase pra pemrosesan ini memegang peranan vital, karena model *deep learning* sangat bergantung pada kualitas data masukan. Karakteristik sediaan darah tebal yang diwarnai dengan giemsa. Hal ini dilakukan untuk membuat latarbelakang dalam preparat menjadi jernih biru pucat atau pucat kemerahan agar sel-sel eritrosit warna kontras dan jelas [99].

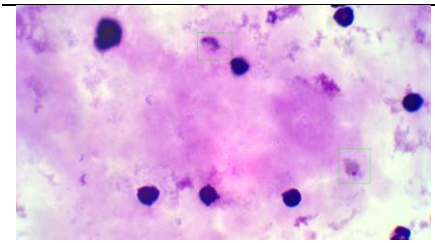
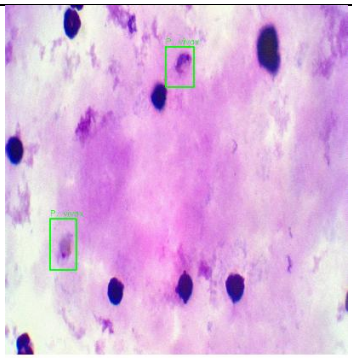
Hasil dataset primer yang berhasil diakuisisi berjumlah 2.300 citra digital. Distribusi citra tersebut terdiri dari 217 citra sediaan yang terinfeksi *Plasmodium falciparum* dan 2.083 citra yang terinfeksi *Plasmodium vivax*. Dengan tingkat keberatan semakin meningkat pada pelabelan objek (*bounding box*), dimana terdapat total 4.500 anotasi parasit murni yang diverifikasi, dengan rincian ketimpangan data yang sangat besar yaitu 4.282 *bounding box* untuk *Plasmodium vivax* dan hanya 218 *bounding box* untuk *Plasmodium falciparum.*

4.1.1 Penyesuaian Resolusi

Citra mentah (*raw image*) dari kamera mikroskop awalnya memiliki resolusi spasial yang sangat besar, yaitu 3.024 × 4.032 piksel. Proses *training* citra dengan resolusi tersebut secara langsung akan membebani memori komputasi (VRAM GPU) secara berlebihan dan memperlambat waktu *training*. Oleh karena itu, dilakukan proses

resizing citra menjadi 640 × 640 piksel dan menggabungkan 4 gambar citra menjadi 1 disaat proses *train* [100].

Tabel 4.1 Hasil Data *Resizing*

Sebelum	Sesudah
	

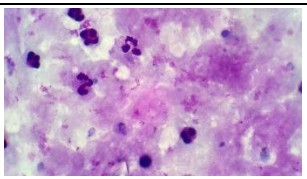
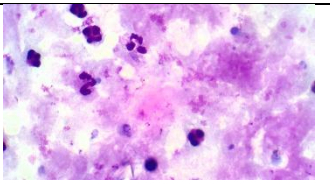
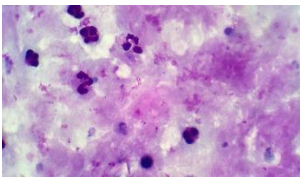
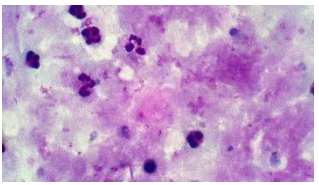
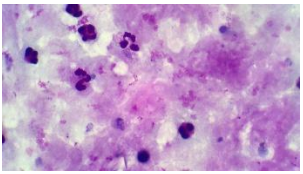
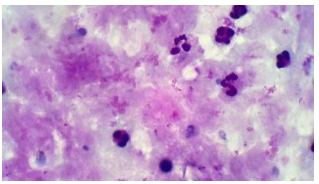
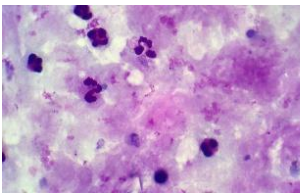
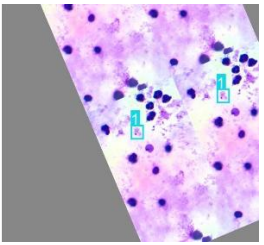
Hasil *Resizing* yang di tunjukkan pada tabel 4.1 memiliki tujuan untuk mengurangi beban secara komputasional, beserta juga membuat agar model YOLO bisa membaca dan ekstraksi fitur-fitur penting yang dilakukan pada fase *backbone* dari YOLO itu sendiri. Di tambah dengan fitur *mosaic* yang menambahkan 4 gambar menjadi 1 dengan resolusi sementara 1280x1280 dan dilakukan *cutting* dan resize menjadi 640x640 agar dapat dibaca kembali oleh YOLO.

4.1.2 Implementasi Augmentasi Data

Salah satu tantangan terbesar dalam penelitian ini adalah terdapatnya ketidakseimbangan data antar kelas. Berdasarkan data anotasi, sampel *P. Vivax* mendominasi secara ekstrem dibandingkan *P. Falciparum*. Apabila model YOLOv8m dilatih secara langsung menggunakan kondisi sekarang ini, model akan mengalami bias secara besar dan gagal melakukan klasifikasi pada kelas minoritas (*P.*

Falciparum). Augmentasi difokuskan pada manipulasi spasial, salah satunya dengan melakukan operasi putaran dinamis (penyesuaian orientasi *flip*) pada citra latih, beserta mengurangi terjadinya kelas *bias* disaat proses training.

Tabel 4.2 Hasil Augmentasi Data Yang Dilakukan

Subset	Sebelum	Sesudah
Brightness		
Penambahan *Noise*		
Flip		
Mosaic		

Dengan menggunakan augmentasi di Tabel 4.2 secara langsung membantu YOLOv8m untuk tidak hanya menghafal dari bentuk ataupun warna dari dataset. Hal ini secara langsung dapat meningkatkan ketahanan model dalam mengenali parasit pada berbagai variasi sediaan di bawah mikroskop [101].

4.1.3 Pembagian *Dataset*

Setelah seluruh citra melalui tahap prapemrosesan dan augmentasi, *dataset* dibagi menggunakan metode *Hold-Out Validation*. Untuk memastikan evaluasi kinerja model bersifat objektif, rasio pembagian dataset ditetapkan pada skala 80:10:10 yang dapat dilihat pada tabel 4.3.

Tabel 4.3 Distribusi Pembagian Dataset Akhir Citra

Kategori Data	Presentase
Train Set	80%
Validation Set	10%
Test Set	10%

Berdasarkan Tabel 4.3, penguncian 10% alokasi data sebagai data uji (*Test Set*) yang sepenuhnya terpisah dari pelatihan. Langkah ini secara langsung memastikan bahwa model terhindar dari kebocoran data (*data leakage*), sehingga metrik evaluasi akhir benar-benar merepresentasikan kemampuan generalisasi sistem saat memproses sampel sediaan darah baru[102].

4.2 Fine-Tuning Model YOLOv8m

Tahap berikutnya dilakukan proses pelatihan model dengan menerapkan metode *fine-tuning* pada arsitektur YOLOv8m (*Medium*). Pendekatan *fine-tuning* dipilih karena model pra-latih (*pretrained weights*) *yolov8m.pt*, yang telah memiliki pemahaman dasar yang kuat dalam mengekstraksi fitur visual tingkat rendah seperti garis, tepi, dan orientasi spasial dari dataset COCO.

Melalui *fine-tuning*, bobot jaringan tersebut disesuaikan kembali secara mendalam agar adaptif terhadap karakteristik morfologi

mikroskopis parasit malaria *P.falciparum* dan *P.vivax* [103]. Untuk menghindari terjadinya kelemahan pencarian parameter secara manual (*trial-and-error*) yang tidak efisien dan rentan terhadap bias subjektif, proses pencarian kombinasi *hyperparameter* terbaik dilakukan secara otomatis menggunakan algoritma *Optuna*[104].

Optimasi hyperparameter dilakukan menggunakan algoritma Optuna sebanyak 153 trial untuk memperoleh kombinasi hyperparameter yang memberikan performa terbaik pada dataset penelitian. Proses optimasi menghasilkan konfigurasi hyperparameter final yang kemudian digunakan secara konsisten pada seluruh skenario eksperimen pada Tabel 4.4 sebagai berikut :

Tabel 4.4 Nilai *Hyperparameter*

Parameter	**Nilai**
epochs	150
Imgsize	640
batch	8
workers	2
patience	30
optimizer	AdamW
lr0	0.000218
lrf	0.00426
momentum	0.8652
weight decay	8.35×10^{-5}

Konfigurasi hyperparameter yang diperoleh dari Tabel 4.4 digunakan sebagai konfigurasi tetap pada tahap eksperimen augmentasi

data berikutnya. Penggunaan konfigurasi yang sama pada setiap skenario bertujuan untuk menjaga konsistensi eksperimen sehingga perbedaan performa yang diperoleh dapat dikaitkan dengan perbedaan strategi penanganan ketidakseimbangan kelas berikutnya. Penetapan hyperparameter dilakukan melalui proses optimasi menggunakan algoritma *Optuna*. Pada setiap trial, kombinasi hyperparameter yang diuji dievaluasi berdasarkan performa model, terutama nilai mAP@50 [105],[106].

Penetapan *initial learning rate* (*lr0*) pada angka yang sangat kecil, yaitu 0,000218. Nilai laju pembelajaran yang rendah ini secara matematis mengurangi risiko terjadinya *catastrophic forgetting*, di mana model dapat kehilangan representasi fitur spasial umum yang telah dipelajari dari *pretrained.* [107].

Penetapan *final learning rate fact*or (lrf) dilakukan pada angka 0.00426 bertujuan untuk mengatur besarnya *learning rate* pada akhir proses pelatihan. Nilai lrf yang dipilih membantu menurunkan learning rate secara bertahap seiring bertambahnya epoch, sehingga proses pembaruan bobot menjadi lebih kecil pada tahap akhir pelatihan. Dengan penurunan yang bertahap ini, model dapat melakukan penyesuaian parameter secara lebih halus tanpa mengubah bobot secara terlalu besar, sehingga proses pelatihan tetap stabil dan model memiliki kesempatan untuk mencapai konvergensi yang lebih baik.

Sebagai penyeimbang dari laju pembelajaran yang lambat, *momentum* ditetapkan pada nilai 1 untuk memberikan pembelajaran yang hati-hati selama proses optimasi *gradient descent*. [108].

Dilanjutkan dengan parameter *weight decay* yang dioptimasi pada 8.346×10^{-5} (0,00008346) berperan sebagai mekanisme regularisasi L2 (*Ridge Regression*) yang bekerja secara presisi.

Setelah konfigurasi hyperparameter final ditetapkan, dilakukan eksperimen tambahan untuk menganalisis pengaruh variasi hyperparameter terhadap performa model. Pengujian dilakukan dengan mengubah nilai beberapa hyperparameter pada rentang yang telah ditentukan, yaitu learning rate, final learning rate factor, momentum, dan weight decay. Performa setiap konfigurasi dibandingkan berdasarkan nilai mAP@50, mAP@50-95. Hasil pengujian digunakan untuk mengidentifikasi hyperparameter yang memberikan pengaruh paling besar terhadap performa model pada dataset penelitian dapat dilihat pada Tabel 4.5[109].

Tabel 4.5 Rentang Nilai *Hyperparameter* Yang Diuji

Parameter	**Nilai**
epochs	150
Imgsize	640
batch	8
workers	2
patience	30
optimizer	AdamW
lr0	0.000218 – 0.0003
lrf	0.00426 – 0.006
momentum	0.8652 – 0.9

weight decay	8.35×10-5 – 9×10-5

Sebelum melakukan eksperimen terhadap augmentasi data dengan *hyperparameter* tertentu, dilakukan eksperimen terhadap seluruh *hyperparameter* yang dilakukan untuk menemukan *hyperparameter* apa yang memberikan hasil terhadap mAP@50 tertinggi. Dimana hasil eksperimen ini dapat dilihat pada Tabel 4.6

Tabel 4.6 Pengaruh Variasi *Hyperparameter*

Parameter	**Nilai**	**mAP@50**	**mAP@50-95**
lr0	0.0003	86.1%	56.2%
lrf	0.006	84.8%	55.6%
momentum	0.9	88.88%	57.92%
weight_decay	9×10-5	84%	54.9%

Berdasarkan hasil eksperimen pada Tabel 4.6, setiap hyperparameter menunjukkan pengaruh yang berbeda terhadap performa model. Variasi momentum menghasilkan nilai mAP@50 dan mAP@50-95 tertinggi dibandingkan variasi hyperparameter lainnya, yaitu masing-masing sebesar 88,88% dan 57,92%. Sementara itu, variasi lr0 menghasilkan mAP@50 sebesar 86,10% dan mAP@50-95 sebesar 56,20%, sedangkan variasi lrf menghasilkan mAP@50 sebesar 84,80% dan mAP@50-95 sebesar 55,60%. Variasi weight decay menghasilkan nilai terendah, yaitu mAP@50 sebesar 84% dan mAP@50-95 sebesar 54,90%.

Berdasarkan hasil eksperimen yang terekam pada Tabel 4.6, konfigurasi *hyperparameter* pada tabel 4.5 digunakan sebagai kombinasi yang paling efektif dalam menghasilkan performa tertinggi.

Konfigurasi ini berhasil menyentuh titik puncak fungsional dengan capaian mAP@50 maksimal sebesar 0.91 dan mAP@50-95 sebesar 0.59.

4.3 Analisis Pengaruh Distribusi dan Augmentasi Dataset

Pada tahap ini, evaluasi pelatihan model dilakukan menggunakan konfigurasi *hyperparameter* terbaik yang terdapat pada Tabel 4.5. Eksperimen difokuskan pada analisis perbandingan tiga skenario distribusi dan augmentasi data yang berbeda, untuk mengidentifikasi strategi paling optimal dalam menangani ketidakseimbangan kelas (*class imbalance*) pada sediaan darah mikroskopis.

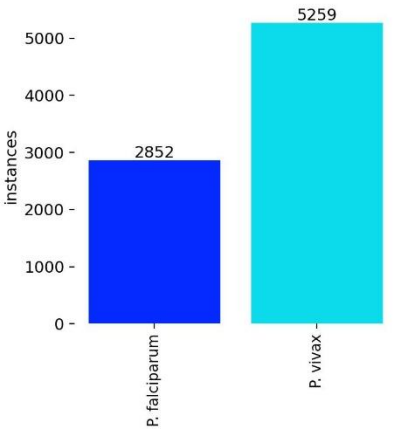
Proses augmentasi pada skenario 1 menghasilkan peningkatan jumlah citra dari 2.300 menjadi 2728 gambar, augmentasi pada skenario 2 meningkatkan citra menjadi 6.900, dengan skenario 3 menjadi 1.946. Penambahan variasi citra bertujuan memperkaya karakteristik data yang dipelajari model, sehingga model tidak hanya mengenali pola dari satu orientasi atau kondisi pencahayaan tertentu. Dengan begitu, augmentasi diharapkan meningkatkan kemampuan generalisasi model terhadap data baru. Pada penelitian ini, pengaruh augmentasi dievaluasi melalui performa model pada tahap pengujian yang ditunjukkan oleh nilai *precision*, *recall*, *F1-score*, dan mAP

4.3.1 Skenario I: Pelatihan dengan *Oversampling*

Pada skenario pertama, manipulasi data difokuskan secara eksklusif pada kelas minoritas (*P. Falciparum*). Augmentasi dilakukan untuk melipatgandakan jumlah citra *Falciparum* sehingga mencapai rasio kurang lebihnya 1:2 terhadap *P. vivax*. Strategi ini bertujuan untuk meningkatkan representasi spasial dari *ring-form Falciparum* tanpa

merusak variasi natural dari morfologi *Vivax* yang sudah cukup banyak. Berdasarkan Tabel 4.7, pendekatan ini menghasilkan konvergensi yang paling stabil dengan metrik *Mean Average Precision* (mAP) tertinggi, menunjukkan bahwa rasio 1:2 memberikan keseimbangan optimal antara variasi fitur medis dan beban komputasi [79], [108], [110].

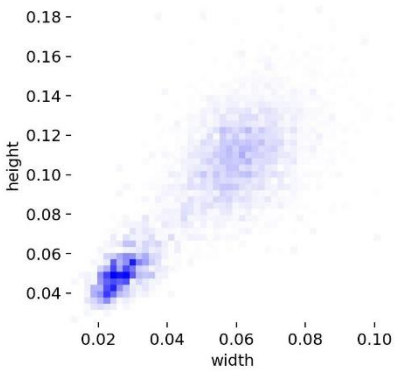
Proses *oversampling* ini mengubah total dataset yang didapatkan dengan total jumlah gambar menjadi 2.728 gambar, label menjadi 2.852 label *P.Falciparum*, dan 5.259 label *P.Vivax* dapat dilihat pada Gambar 4.1.



Gambar 4.1 Hasil Pembagian Labels Dalam Training Skenario 1

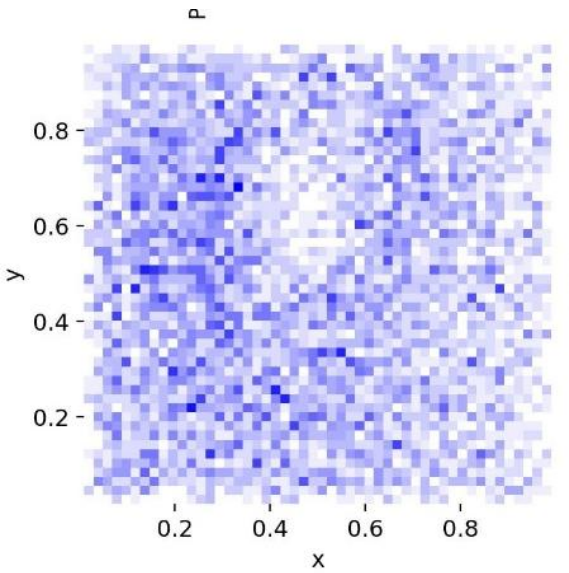
Berdasarkan Gambar 4.1 menunjukkan hasil distribusi label setelah augmentasi data pada kelas *P. Falciparum*. Strategi *oversampling* dengan rasio 1:2 ini diterapkan untuk menghindari *overfitting,* sekaligus menghindari bias terhadap kelas mayoritas. Rasio 1:2 dipilih agar model tetap dapat mempelajari variasi morfologi alami *P. Vivax* secara luas dan *P. Falciparum*. Hal ini dilakukan untuk memastikan fitur cincinnya (*ring form*) dapat terdeteksi oleh jaringan konvolusi model [110]. Analisis terkait luas objek parasit ini

selanjutnya dibuktikan pada grafik *scatter plot* dimensi kotak pembatas di Gambar 4.2.



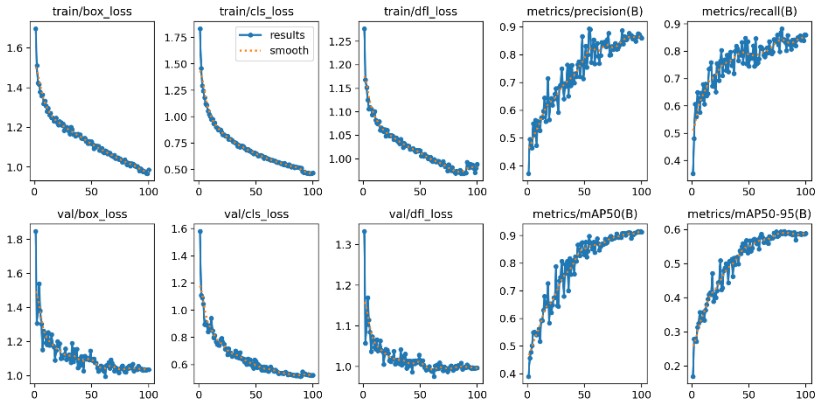
Gambar 4.2 Hasil Width vs Height Scatter Plot Skenario 1

Berdasarkan Gambar 4.2 analisis pada grafik dimensi kotak pembatas (*width vs height scatter plot*), membuktikan permasalahan utama model dalam deteksi parasit malaria. Hampir seluruh klaster titik terkonsentrasi pada area sudut kiri bawah grafik (berada di area nilai 0.02 hingga 0.06). Hal ini membuktikan bahwa ukuran parasit malaria sangat kecil dan menempati kurang dari 10% area citra sediaan darah tebal. Karakteristik ini menjadi alasan utama digunakannya *learning rate* yang sangat rendah (0.000218) pada *optimizer* AdamW, hal ini dikarenakan laju pembelajaran yang agresif dapat membuat model melewati fitur-fitur spasial berukuran sangat kecil [111]. Penggunaan hyperparameter ini dengan melakukan augmentasi *oversampling* terhadap *P.Falciparum* menunjukkan model tidak mengalami bias secara spasial, dapat dilihat pada gambar 4.3.



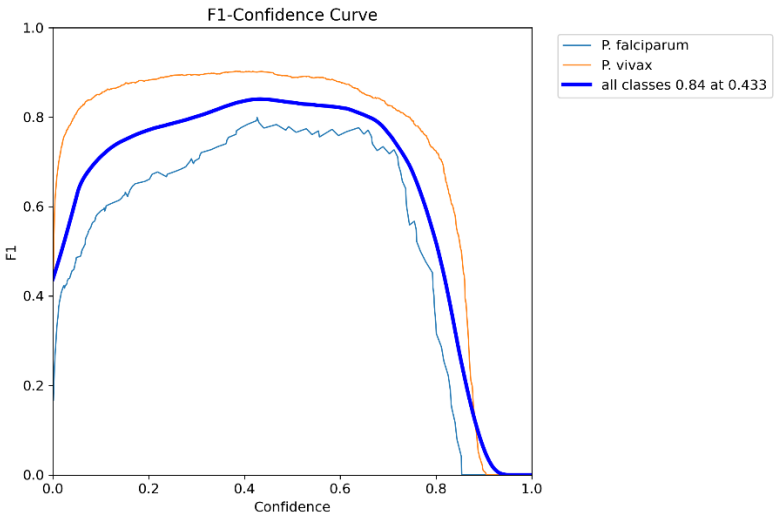
Gambar 4.3 Hasil Grafik scatter plot Skenario 1

Gambar 4.3 menampilkan persebaran posisi titik tengah (center point) dari seluruh kotak pembatas parasit yang terdeteksi, dengan sumbu x dan y dinormalisasi pada rentang 0 hingga 1 sesuai ukuran citra. Warna biru yang lebih pekat menunjukkan area dengan jumlah parasit yang lebih banyak ditemukan. Berdasarkan hasil ini, posisi parasit relatif merata di seluruh area citra tanpa terpusat kuat pada satu titik tertentu. Distribusi posisi yang merata ini penting karena mencegah model mengalami bias spasial, yaitu kondisi di mana model justru menghafal dimana biasanya parasit muncul, bukan mempelajari bentuk dan warna parasit itu sendiri. Dengan begitu, model dipaksa untuk benar-benar mengenali fitur biologis dari parasit. Hal ini dapat dilihat pada Gambar 4.4.



Gambar 4.4 Hasil Proses Training Skenario 1

Berdasarkan gambar 4.4 Grafik ini memvisualisasikan perjalanan optimasi jaringan konvolusi selama 100 siklus pembelajaran (*epoch*). Deretan grafik di sebelah kiri menunjukkan penurunan nilai kerugian (*loss*) secara konsisten pada fase awal. Terdapat indikasi *overfitting* ringan pada *epoch* akhir, khususnya pada metrik *box_loss* dimana jarak antara kurva pelatihan dan validasi sedikit melebar. Namun, kondisi ini tidak memengaruhi performa akhir secara signifikan. Grafik di sebelah kanan membuktikan bahwa nilai metrik mAP50 tetap stabil mendekati 0.90 tanpa mengalami penurunan performa. Hal ini mengonfirmasi bahwa arsitektur jaringan berhasil mengekstraksi fitur tanpa mengalami kerusakan fungsional[112]. Keseimbangan lokalisasi ini dianalisis lebih spesifik pada kurva F1-*Confidence* di Gambar 4.7.

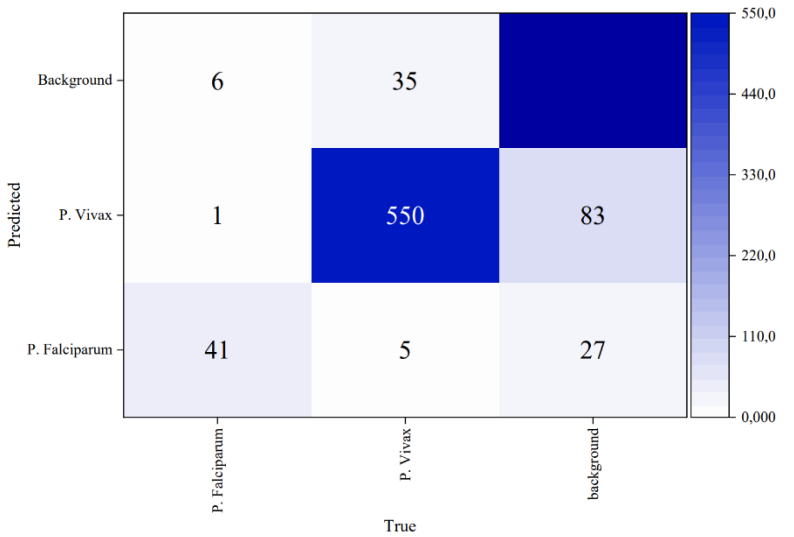


Gambar 4.5 Hasil Kurva F1-Confidence Skenario 1

Berdasarkan Gambar 4.5, kurva ini digunakan untuk menentukan titik keseimbangan optimal antara ketepatan deteksi (*Precision*), kepekaan model (*Recall*), dan tingkat *confidence*. Berdasarkan observasi grafik, garis biru tebal yang merepresentasikan rata-rata performa model secara global, yang menyentuh titik puncak skor F1 sebesar 0.84 pada ambang batas keyakinan (*confidence threshold*) di angka 0.433. Hasil ini memberikan justifikasi bahwa sistem klasifikasi beroperasi pada performa maksimalnya ketika batas toleransi keraguan prediktif diatur pada kurang lebihnya 43% [113], [114].

Selain itu, fenomena dimana kurva untuk kelas *P. Vivax* (oranye) lebih superior dibandingkan kurva *P. Falciparum* (biru tipis) merupakan sebagai hasil yang sudah dalam prediksi awal dan dapat dipertanggungjawabkan, karena skenario eksperimen dirancang dengan distribusi rasio 1:2. Hasil ini memberikan porsi variasi fitur visual lebih

besar pada kelas mayoritas. Di mana kinerja prediksi kelas ini di analisis lagi secara absolut melalui Matriks Kebingungan pada Gambar 4.6.

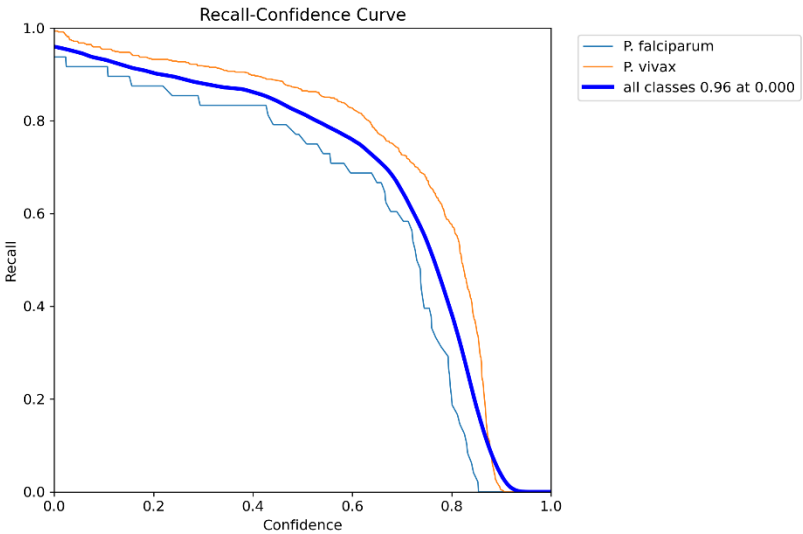


Gambar 4.6 Hasil Confusion Matrix Skenario 1

Berdasarkan gambar 4.6, hasil matriks ini menjadi penting untuk mencari distribusi tebakan benar dan klasifikasi salah yang dihasilkan oleh algoritma terhadap anotasi aktual sediaan darah. Pada sel di area tengah, model mampu melokalisasi 550 citra *P. Vivax* dengan benar dan hanya salah mengklasifikasikan 1 citra sebagai kelas minoritas. Untuk kelas *P. Falciparum*, model berhasil mengidentifikasi 41 citra secara tepat dengan 5 kesalahan prediksi (*false positive*) sebagai *P. vivax*.

Tingkat kesalahan silang (*crossclass misclassification*) yang sangat kecil menjadi bukti kuat bahwa sistem tidak mengalami kebingungan dalam membedakan morfologi biologis antara spesies parasit. Evaluasi juga menunjukkan bahwa sisa kesalahan terbesar berada dari sel latar belakang (*background*), yang mencerminkan bias

natural algoritma terhadap artefak mikroskop atau sisa zat pewarna *Giemsa*.



Gambar 4.7 Hasil Kurva Recall Skenario I

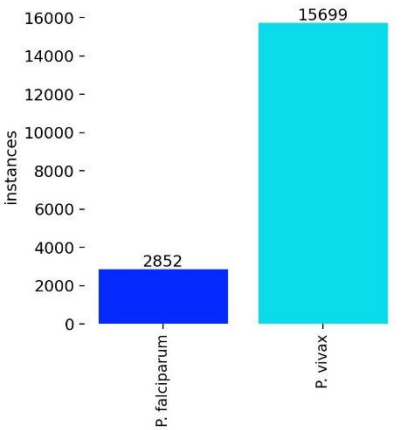
Berdasarkan dari Gambar 4.7, yang merupakan salah satu metrik evaluasi sangat penting dalam sistem diagnosis berbantuan komputer (*Computer-Aided Diagnosis*). Grafik ini mengukur kemampuan model dapat mempertahankan presisi saat diberikan sebanyak mungkin sel yang terinfeksi (*Recall*). Garis biru tebal menunjukkan pencapaian nilai rata-rata *recall* global sebesar 0.96. Pada tingkat spesies, model mampu mendeteksi *P. Falciparum* dengan nilai mAP sebesar 0.839. Tingkat akurasi di atas 80% ini termasuk nilai yang sangat baik teringat juga parasit malaria memiliki ukuran yang sangat kecil. Bentuk kurva yang stabil dan mendatar sebelum menurun tajam membuktikan bahwa model ini memiliki tingkat deteksi positif palsu (*false positive*) yang rendah. Hal ini mengonfirmasi bahwa sistem dapat

dioperasikan secara *real-time* tanpa menghasilkan alarm kesalahan yang berlebihan[115].

4.3.2 Skenario II: Pelatihan Dengan *Global Augmentation*

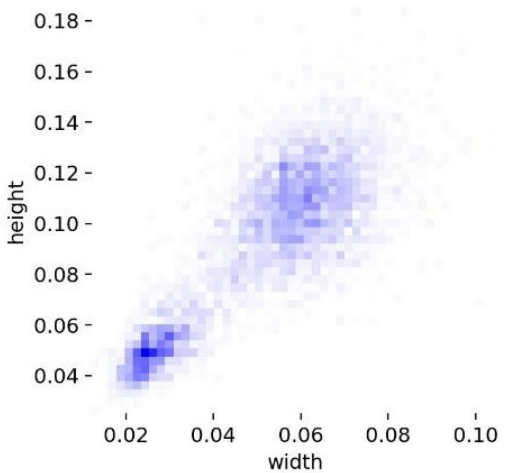
Dilanjutkan pada skenario II dengan melakukan augmentasi data secara *global*, atau melakukan augmentasi data secara keseluruhan dengan metode augmentasi yang sama seperti sebelumnya. Strategi ini bertujuan untuk meningkatkan representasi spasial dari *ring-form Falciparum* dan juga menambahkan jumlah data. Hal ini dilakukan untuk menghindari terjadinya *bias* terhadap satu kelas, beserta membuat model mempelajari morfologi seluruh parasit baik *P.Vivax* atau *P.Falciparum*.

Metode pelatihan ini menggunakan hyperparameter yang sama seperti skenario 1 dan juga 3. Proses augmentasi ini menghasilkan total jumlah label citra menjadi kurang lebih 1:5.5. Hasil label *P. Vivax* memiliki total jumlah 15.699 label citra, *P.Falciparum* memiliki jumlah total 2.85 label. Dengan hasil augmentasi memiliki total gambar keseluruhan menjadi 6.900 dapat dilihat juga pada gambar 4.8.



Gambar 4.8 Hasil Pembagian Labels Dalam Training Skenario 2

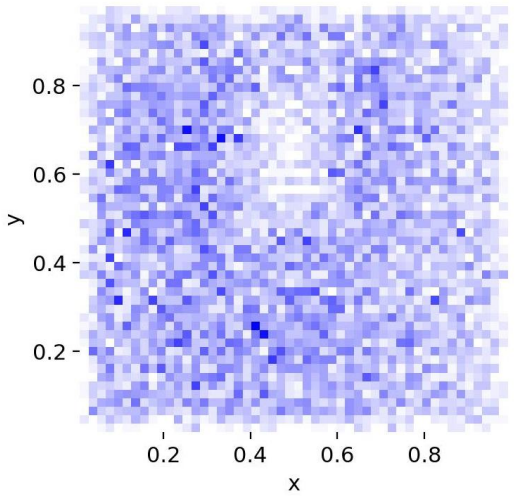
Gambar 4.8 menampilkan jumlah data untuk masing-masing kelas, setelah proses augmentasi dilakukan pada seluruh dataset. Pendekatan ini membuat jumlah data menjadi sangat tidak seimbang. Kelas *P. Vivax* meningkat menjadi 15.699 kotak target, sedangkan *P. Falciparum* hanya berjumlah 2.852 kotak target dengan total gambar mencapai 6900 gambar. Akibatnya, model melihat terlalu banyak contoh gambar *P. vivax*, sehingga berisiko membuat model menjadi bias atau lebih memihak pada kelas mayoritas tersebut. Dampak dari ketidakseimbangan ini dapat dilihat langsung pada perubahan ukuran parasit di Gambar 4.9.



Gambar 4.9 Hasil Scatter Plot Width vs Height Skenario 2

Gambar 4.9 menampilkan grafik perbandingan ukuran kotak pembatas parasit (*width vs height scatter plot*). Pada Skenario I, mayoritas titik persebaran objek terkonsentrasi pada area kiri bawah grafik, yang menunjukkan ukuran objek parasit yang kecil. Sementara itu, pada Skenario II terlihat persebaran titik yang lebih luas hingga ke bagian tengah grafik. Perbedaan tersebut berkaitan dengan penerapan

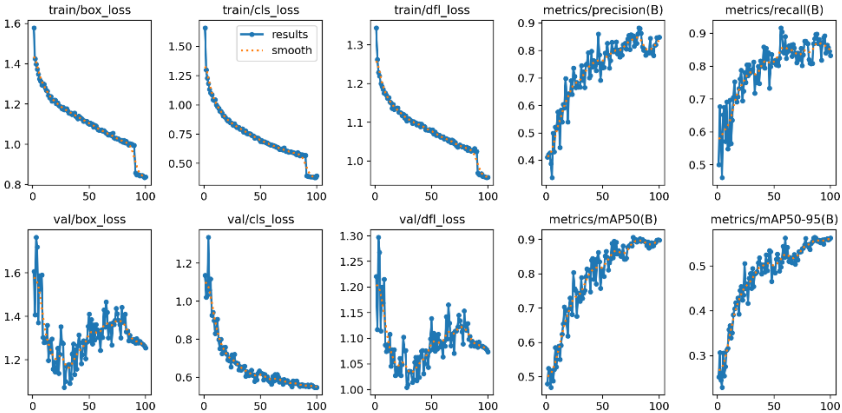
augmentasi secara global pada seluruh dataset, termasuk penggunaan parameter *scale* sebesar 0,4046 dan *mosaic* sebesar 1. Penerapan augmentasi tersebut menghasilkan variasi ukuran dan posisi objek yang lebih luas dibandingkan distribusi objek pada data asli. Kondisi yang dihasilkan oleh skenario II, menunjukkan bahwa augmentasi pada Skenario II menghasilkan distribusi ukuran objek yang berbeda dibandingkan dengan Skenario I [116]. Perubahan ukuran sintetik ini berpotensi membuat model kebingungan, yang mana polanya juga memengaruhi letak posisi parasit pada Gambar 4.10



Gambar 4.10 Hasil Scatter Plot Skenario 2

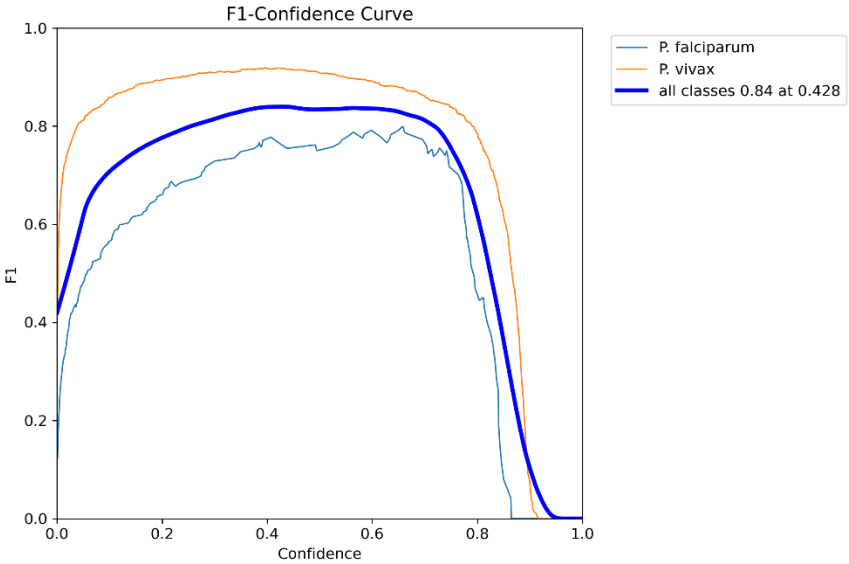
Berdasarkan gambar 4.10 grafik persebaran posisi parasit di dalam citra (*x vs y scatter plot*). Titik-titik biru pada grafik ini terlihat jauh lebih pekat dan padat dibandingkan skenario sebelumnya. Kepadatan yang tidak beraturan ini terjadi dikarenakan aktifnya parameter *translate* 0.0847 dan *mosaic* 1, yang mengacak posisi objek hingga saling bertumpuk di seluruh sudut gambar. Dampak buruk dari

rekayasa data yang berlebihan ini langsung memengaruhi stabilitas proses belajar model pada Gambar 4.11.



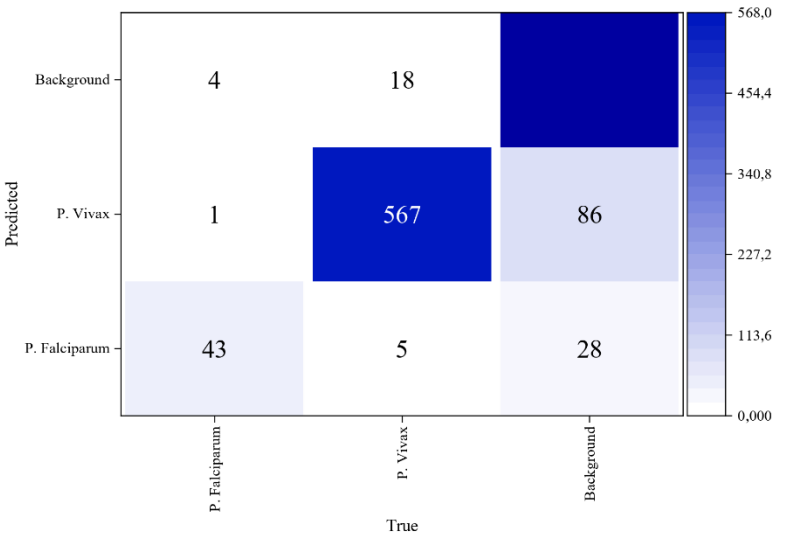
Gambar 4.11 Hasil Proses Training Model Skenario 2

Gambar 4.11 memberikan grafik hasil pelatihan dan validasi model selama 100 *epoch*. Akibat ukuran dan posisi data yang tidak wajar, model menunjukkan gejala *overfitting* yang parah. Hal ini terlihat jelas pada grafik *val/box_loss* dan *val/dfl_loss*, yang dibandingkan dengan grafik *train/box_loss* dan *train/dfl_loss*, dimana garis kurva mengalami naik turun secara tajam dan terjadi kenaikan berat setelah *epoch* ke-30. Kurva pelatihan menunjukkan peningkatan fluktuasi dan perbedaan antara performa training dan validation, yang mengindikasikan terjadinya overfitting. Model berhasil menghafal data latih, namun kehilangan ketepatan dalam menebak letak kotak parasit saat diuji menggunakan data baru [74]. Kegagalan ini kemudian menurunkan kualitas keseimbangan performa model yang dapat dilihat pada Gambar 4.12.



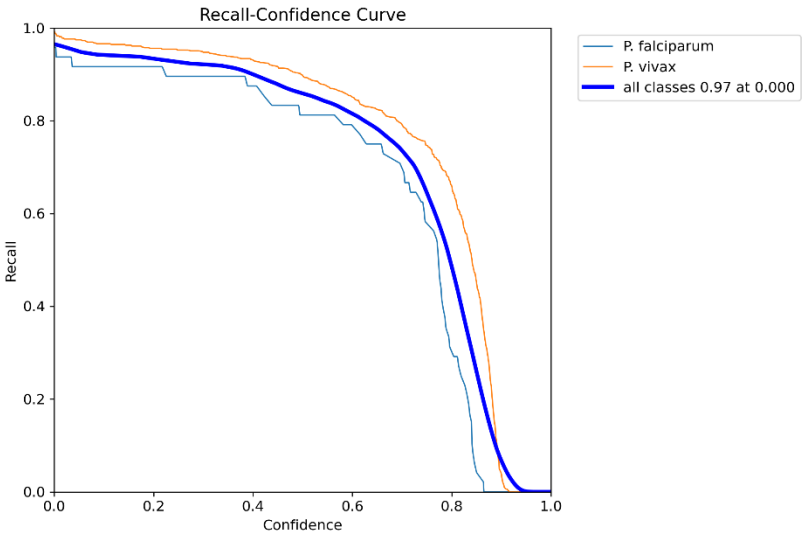
Gambar 4.12 Hasil Kurva Confidence F1 Curve Skenario 2

Berdasarkan gambar 4.12, kurva *F1-Confidence* berfungsi untuk menilai keseimbangan antara ketepatan (*Precision*) dan keberhasilan (*Recall*) model. Garis biru tebal menunjukkan nilai rata-rata keseluruhan sebesar 0.84 pada batas keyakinan 0,428. Meskipun angka rata-rata tinggi, terdapat jarak yang sangat jauh antara kurva oranye (*P. Vivax*) dan kurva biru tipis (*P. Falciparum*). Jarak kurva yang lebar ini menunjukkan bahwa, tingginya nilai rata-rata model hanya berasal dari keberhasilan deteksi pada kelas *P. Vivax*. Sehingga, model menjadi bias terhadap data mayoritas dan kurang mempelajari dalam mengenali kelas minoritas. Detail kesalahan tebakan akibat bias ini dapat dilihat lebih jelas pada Matriks Kebingungan di Gambar 4.13.



Gambar 4.13 Hasil Confusion Matriks Skenario 2

Berdasarkan hasil dari gambar 4.13, memberikan jumlah prediksi model yang benar dan salah. Model berhasil menebak 567 gambar *P. vivax* dan 43 gambar *P. falciparum* dengan tepat. Namun, kelemahan utama dari skenario ini adalah tingginya angka deteksi positif palsu (*false positive*) dari area latar belakang (*background*). Model salah mengklasifikasikan 86 artefak kotoran sebagai *P. vivax* dan 28 artefak sebagai *P. falciparum*. Tingginya kesalahan ini didukung oleh fitur augmentasi *erasing* 0.4 dan *mixup* 0.2869 yang menumpuk kotoran buatan, sehingga model menjadi terlalu sensitif dan sering mengira *noise* sebagai parasit[117]. Sensitivitas yang ini diukur kembali pada Gambar 4.14.

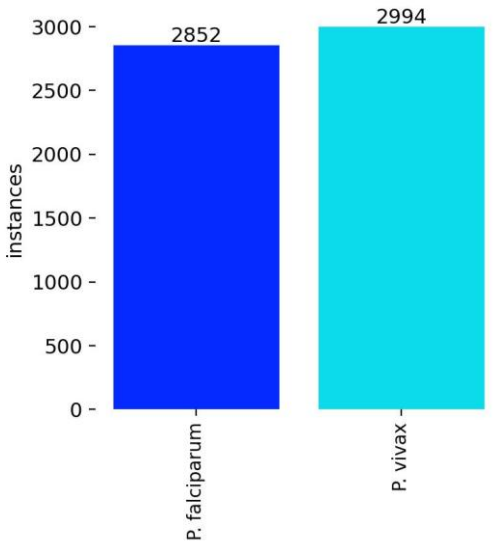


Gambar 4.14 Hasil Kurva Recall Confidence Skenario 2

Hasil gambar 4.14 memberikan Kurva *Recall Confidence,* yang berguna untuk mengukur kemampuan model dalam menangkap seluruh target parasit. Garis biru tebal menunjukkan tingkat penangkapan maksimal di angka 0.97 pada tingkat keyakinan terendah. Namun, kurva kelas *P. Falciparum* (biru tipis) lebih menurun cepat dibandingkan kelas *P. vivax* (oranye) sejalan dengan naiknya batas keyakinan model. Berdasarkan hasil evaluasi ini, dapat disimpulkan bahwa penerapan augmentasi secara menyeluruh dan agresif menjadi model tidak efisien[116],[117]. Pendekatan tersebut menghasilkan variasi ukuran dan posisi objek yang lebih luas dibandingkan data asli, yang berkaitan dengan penurunan performa pada data uji, sehingga menghasilkan indikasi *overfitting* yang berkaitan dengan distribusi spasial hasil augmentasi. Hal ini menciptakan bias kelas yang berbahaya untuk diagnosis medis, sehingga membuktikan bahwa pengaturan pada menjadi Skenario I jauh lebih optimal.

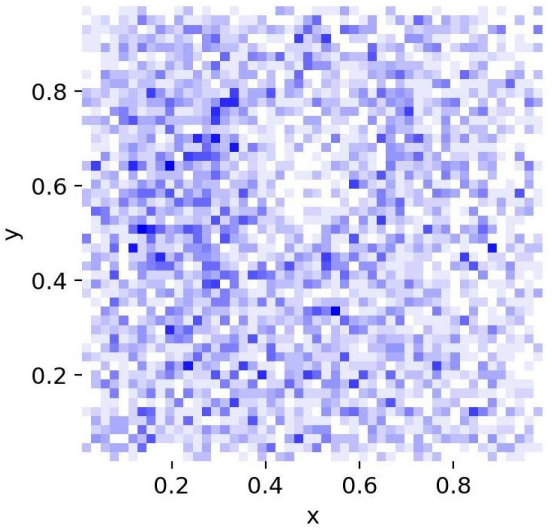
4.3.3 Skenario III: Pelatihan Dengan *Undersampling*

Evaluasi dilanjutkan pada skenario ketiga dengan menerapkan pendekatan keseimbangan data dengan rasio 1:1. Hal ini dilakukan melalui metode *undersampling*. Strategi ini bertujuan untuk menguji performa model ketika dilatih menggunakan jumlah data target yang sama rata, dengan harapan dapat menghilangkan bias terhadap kelas mayoritas [118]. Sama seperti pengujian sebelumnya, metode pelatihan pada skenario ini tetap menggunakan nilai *hyperparameter* mutlak yang sama dengan Skenario I dan II. Hal ini dilakukan untuk menjaga konsistensi eksperimen. Proses *undersampling* ini memotong jumlah label citra kelas *P. vivax* secara acak untuk menyesuaikan dengan jumlah kelas *P. falciparum*. Hasilnya, kedua kelas memiliki perbandingan rasio kurang lebih 1:1 dengan *P. Falciparum* memiliki label sebanyak 2.852 label citra dan *P. Vivax* memiliki 2.994 label citra dengan total citra 1.946 yang didapatkan setelah augmentasi. Perubahan sebaran jumlah data untuk Skenario III ini dapat dilihat pada Gambar 4.15.



Gambar 4.15 Hasil Pembagian Data 1:1 Skenario 3

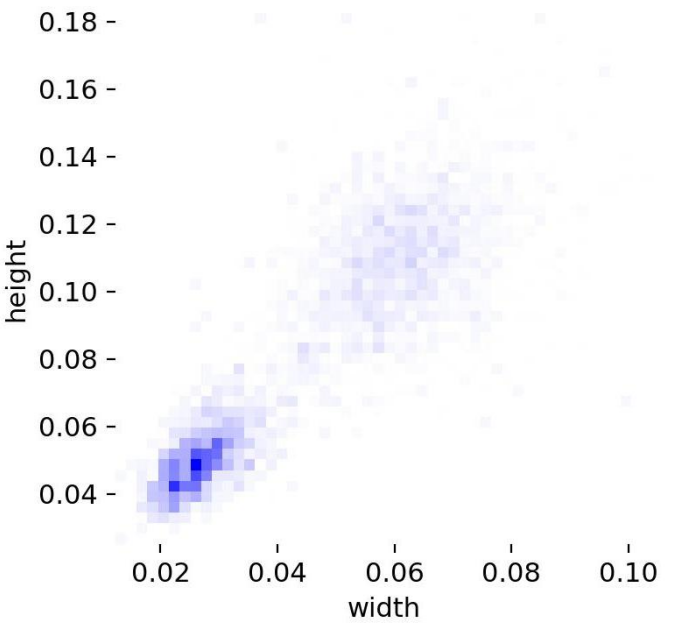
Gambar 4.15 menampilkan visualisasi distribusi data latih (*training set*) yang digunakan pada Skenario III. Berdasarkan grafik batang pada sudut kiri atas, terlihat bahwa tidakseimbangnya jumlah target yang terjadi pada dataset mentah berhasil diatasi, sehingga mencapai rasio kurang lebih 1:1. Kelas *P. Falciparum* memiliki total 2.852 kotak target. Sedangkan, populasi kelas *P. Vivax* yang sebelumnya dominan, setelah dilakukan metode *undersampling* secara acak menjadi 2.994 kotak target. Dengan metode *undersampling* total gambar menjadi 4.159. Namun, konsekuensi komputasional dari pemotongan ini adalah terbuangnya ribuan sampel *P. vivax* murni, yang berisiko menghilangkan kekayaan variasi morfologi parasit di dalam memori pelatihan jaringan. Hal ini dapat dilihat pada Gambar 4.16.



Gambar 4.16 Hasil Grafik Distribusi Grafik *Scatter Plot* Skenario 3

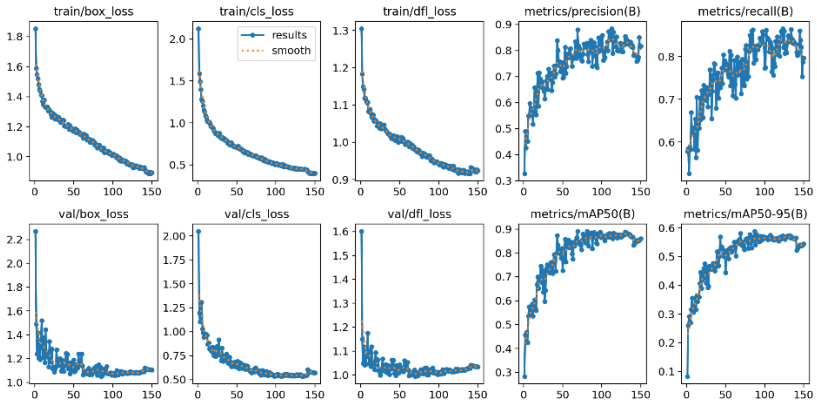
Selain pembuktian keseimbangan jumlah kelas, Gambar 4.16 juga memvisualisasikan persebaran letak dan ukuran parasit (*bounding box*) di dalam citra. Pada grafik distribusi koordinat spasial Gambar 4.16, titik-titik biru tersebar secara acak menutupi area sumbu X dan Y. Meskipun, secara kasar sebaran pada Gambar 4.16 terlihat merata, tetapi densitas titik koordinat pada grafik ini menurun jika dibandingkan dengan titik spasial pada Skenario I (Rasio 1:2).

Penurunan kepadatan spasial ini menjadi indikator awal bahwa model berpotensi mengalami defisit mengenai titik lokasi alami parasit[119]. Kehilangan referensi spasial ini dapat memicu kebingungan jaringan arsitektur YOLOv8m dalam membedakan objek parasit dengan area kotoran di latar belakang (*background*) yang kosong.



Gambar 4.17 Hasil Grafik Height vs Width Skenario 3

Gambar 4.17 menunjukkan persebaran dimensi objek berdasarkan nilai *width* dan *height* bounding box pada Skenario III. Sebagian besar titik terkonsentrasi pada rentang ukuran yang relatif kecil. Dibandingkan dengan Skenario I, persebaran ukuran bounding box pada Skenario III terlihat lebih kecil. Kondisi tersebut berkaitan dengan terjadinya penerapan *undersampling* pada kelas *P. Vivax,* yang mengurangi jumlah sampel dan variasi ukuran objek yang tersedia dalam data pelatihan. Pengecilan variasi ukuran bounding box ini dapat membatasi keragaman fitur model. Hal ini juga berpotensi untuk mempengaruhi kemampuan model dalam mengenali objek dengan karakteristik ukuran yang berbeda.



Gambar 4.18 Hasil Training Model Skenario 3

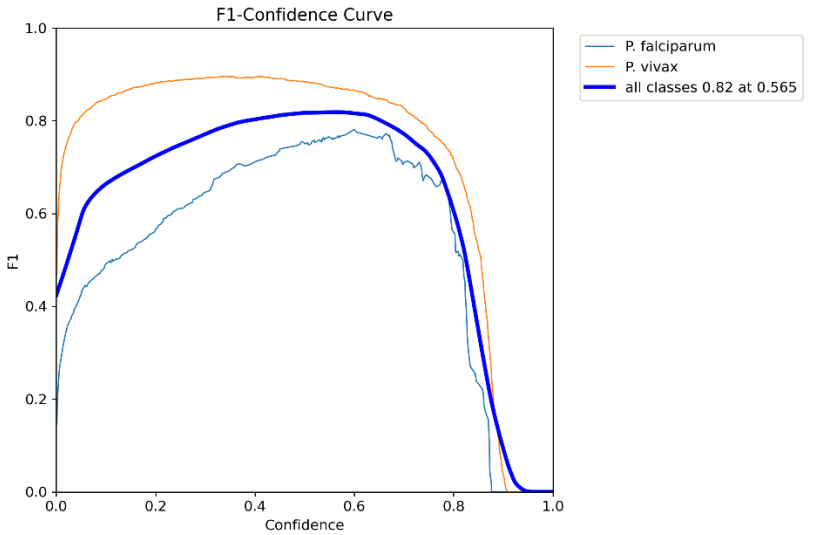
Gambar 4.18 memberikan performa pelatihan dan validasi arsitektur YOLOv8m pada Skenario III. Pelatihan ini menggunakan keseimbangan data rasio 1:1 selama 150 *epoch*. Secara keseluruhan, grafik ini memberikan proses pembelajaran model selama 150 *epoch*, namun mengalami stagnasi berat pada *epoch* 100 keatas akibat hilangnya variasi data. Pada tiga metrik kerugian pelatihan atau *training loss* (*train/box_loss*, *train/cls_loss*, dan *train/dfl_loss*), kurva menunjukkan penurunan yang konsisten sampai mendekati angka nol. Hal ini membuktikan bahwa arsitektur dasar model berfungsi dengan baik dan mampu mengenali serta menghafal pola data latih yang diberikan.

Namun, indikasi permasalahan generalisasi data mulai terlihat jelas pada kurva kerugian validasi (*validation loss*). Pada grafik *val/box_loss* dan *val/dfl_loss* (baris bawah), kurva mengalami penurunan di awal pelatihan, tetapi tertahan atau mendatar (*plateau*) sejak *epoch* ke-100 sampai akhir pelatihan di *epoch* 150. Garis validasi tersebut bahkan menunjukkan sedikit fluktuasi di kisaran angka 1.1 hingga 1.2 dan tidak mampu turun lebih jauh. Kondisi ini merupakan

gejala awal dari *overfitting*, di mana model menjadi sangat pintar menghafal data latih, tetapi kesulitan untuk menerapkan pengetahuannya pada data baru. Stagnasi ini adalah konsekuensi langsung dari penerapan metode *undersampling*, dimana pembuangan ribuan data *P. Vivax* secara paksa membuat jumlah data pelatihan yang lebih sedikit, sehingga mengurangi keragaman morfologi yang tersedia untuk dipelajari model.

Dampak berkurangnya variasi data juga terlihat pada performa model selama proses pelatihan. Nilai mAP@50 meningkat secara bertahap pada awal, kemudian stabil pada nilai 0,86-0,88. Sementara itu, nilai Precision dan Recall berfluktuasi pada nilai 0,80-0,85. Kondisi tersebut menunjukkan bahwa peningkatan performa model terbatas setelah mencapai tahap tertentu selama proses pelatihan[73].

Hasil evaluasi pada Skenario III ini memberikan kesimpulan yang sangat penting bagi pengembangan sistem deteksi. Penerapan keseimbangan kelas dengan rasio 1:1 melalui *undersampling*, membuktikan bahwa, dapat merugikan kapabilitas arsitektur dalam mendeteksi objek. Meskipun data menjadi seimbang secara matematis, pembuangan data medis minor menyebabkan sistem kehilangan informasi fitur visual yang penting, sehingga akurasi tertahan dan tidak mampu menyamakan tingkat kecerdasan model pada skenario rasio 1:2.



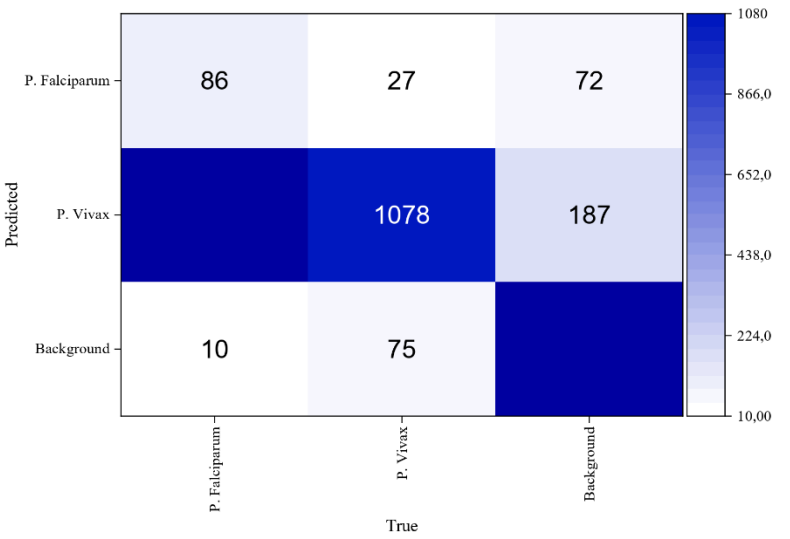
Gambar 4.19 Grafik *F1-Curve* Skenario 3

Gambar 4.19 memberikan Kurva *F1-Confidence* dari arsitektur model pada Skenario III. Berdasarkan grafik pada Gambar 4.19, nilai rata-rata F1-Score mencapai nilai puncak sebesar 0,82 pada *confidence threshold* 0,565. Nilai tersebut menunjukkan titik ambang batas yang menghasilkan keseimbangan *precision* dan *recall* terbaik berdasarkan hasil evaluasi pada Skenario III.

Meskipun model pada skenario ini dilatih menggunakan dataset dengan rasio kelas yang seimbang mutlak (1:1), grafik *F1-curve* menghasilkan ketidakseimbangan performa yang masih terjadi secara signifikan. Garis oranye yang mewakili kelas *P. vivax* tetap mendominasi dengan nilai *F1-Score* yang sangat tinggi (mendekati 0,90), beserta mengalami kestabilan pada rentang ambang batas keyakinan yang lebar. Namun, garis biru tipis yang mewakili kelas *P. Falciparum* tidak mencapai garis yang sama, dimana nilai puncaknya

hanya mampu menyentuh kisaran angka 0.78. Selain itu, kurva *P. Falciparum* juga terlihat lebih tidak stabil dibandingkan kelas *P. Vivax*.

Hasil ini memberikan pembuktian yang sangat penting bagi pengembangan model. Perbedaan kurva yang lebar antara kedua kelas membuktikan bahwa menyamakan kuantitas data target (jumlah *bounding box* rasio 1:1), tidak secara lagnsung meningkatkan kesulitan model dalam mengenali fitur visual kedua objek. Kelas *P. Vivax* tetap lebih mudah dideteksi, dikarenakan sisa data latih yang digunakan bersifat murni (tanpa augmentasi) sehingga memiliki struktur morfologi alami yang kuat. Di sisi lain, kelas *P. falciparum* tetap lebih sulit diklasifikasikan meskipun jumlah datanya sudah diperbanyak melalui augmentasi. Selanjutnya, pencapaian batas maksimal *F1-Score* di angka 0.82 ini memberikan konfirmasi bahwa metode pemotongan data ekstrem (*undersampling*), yang diterapkan pada Skenario III menurunkan potensi model untuk deteksi.



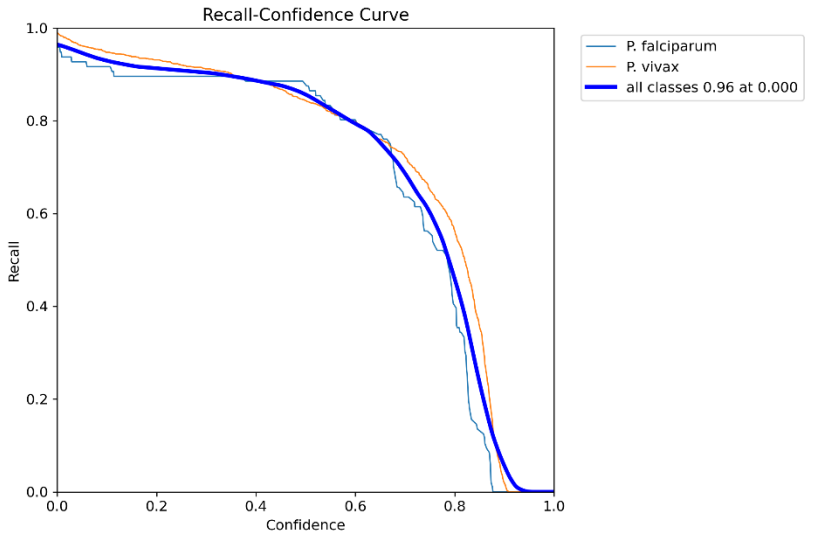
Gambar 4.20 Confusion Matrix Skenario 3

Gambar 4.20 menampilkan Matriks Kebingungan (*Confusion Matrix*) yang merekam ketepatan prediksi model pada dataset validasi untuk Skenario III. Pada skenario keseimbangan rasio 1:1, model menunjukkan kemampuan yang cukup baik dalam mengenali kelas dominan pada data uji, hal ini berdasarkan dari keberhasilannya memprediksi 1.078 target *P. Vivax* secara tepat (*True Positive*). Selain itu, model juga berhasil mengidentifikasi 86 target *P. Falciparum* dengan benar. Meskipun model mampu mendeteksi keberadaan target secara umum, matriks ini menangkap kelemahan akibat penerapan metode *undersampling*.

Kelemahan utama dari skenario ini terlihat pada tingginya angka positif palsu (*False Positive*) yang dihasilkan oleh model. Model melakukan kesalahan berat dengan memprediksi area latar belakang (*background*) yang kosong sebagai parasit. Berdasarkan Gambar 4.20, sebanyak 187 area latar belakang salah dikenali sebagai *P. Vivax*, dan 72 area latar belakang lainnya dikira sebagai *P. Falciparum*. Kenaikan kesalahan tebakan terhadap latar belakang ini menjadi efek dari proses *undersampling*. Saat ribuan citra *P. Vivax* dibuang secara paksa untuk menyeimbangkan rasio target, model yang kehilangan ribuan contoh informasi visual mengenai apa yang "bukan parasit" (*negative samples*). Akibat kekurangan referensi visual terhadap variasi kotoran latar belakang, arsitektur YOLOv8m menjadi lebih sensitif dalam salah melakukan deteksi[120].

Selain kesalahan terhadap latar belakang, matriks ini juga mencatat terjadinya kebingungan antar-kelas dan negatif palsu (*False Negative*). Terdapat 27 target *P. Vivax* yang bentuknya menyerupai *ring-form* sehingga keliru diprediksi sebagai *P. Falciparum*. Di sisi lain, model juga gagal mengenali75 target *P. Vivax* dan 10 target *P.*

Falciparum. Kegagalan deteksi serta tingginya angka salah tebak (*False Positive*) pada Skenario III, memberikan kesimpulan yang sangat kuat terkhususinya pada hasil akhirnya [12], [120], [121].



Gambar 4.21 Hasil Curva Recall Skenario 3

Gambar 4.21 memberikan Kurva *Recall Confidence* yang mengevaluasi tingkat sensitivitas arsitektur YOLOv8m pada Skenario III terhadap perubahan batas atas keyakinan (*confidence threshold*). Metrik *Recall* (sensitivitas) merupakan indikator yang sangat penting dalam sistem evaluasi kinerja model, karena metrik ini mengukur seberapa tangguh model dalam menemukan seluruh target parasit tanpa melewatkannya (*False Negative*). Berdasarkan grafik tersebut, garis biru tebal yang merepresentasikan rata-rata keseluruhan kelas. Hal ini menunjukkan bahwa model mampu mencapai nilai *Recall* maksimal sebesar 0.96 pada ambang batas terendah (0).

Hasil terbesar dari grafik ini terletak pada jarak antara kurva kelas *P. Falciparum* (garis biru tipis) dan *P. Vivax* (garis oranye).

Berbeda dengan kurva *F1-Score* di mana kedua kelas memiliki perbedaannya performa yang sangat lebar, pada Kurva *Recall* ini, kedua garis terlihat bergerak bersamaan dengan jarak yang sangat rapat. Pada rentang batas atas keyakinan (0.4 hingga 0.6), garis *P. Falciparum* mampu menyetarakan dan sampai menyentuh garis *P. Vivax*. Pergerakan kurva ini membuktikan bahwa penyeimbangan dataset secara matematis menjadi rasio 1:1, berhasil dalam menyetarakan sensitivitas model [103]. Arsitektur jaringan tidak menunjukkan bias terhadap kelas mayoritas, tetapi memberikan beban perhatian yang sama besarnya dalam melakukan pencarian terhadap kelas *P. falciparum* maupun *P. vivax*.

Meskipun model terbukti memiliki tingkat sensitivitas pencarian yang seimbang dan tinggi, hasil ini harus dievaluasi secara detail bersama dengan matriks presisi sebelumnya. Tingginya angka *Recall* pada Skenario III membuktikan kemampuan model dalam menyaring *background/noise*. Karena model dilatih dengan penyeimbangan data (*undersampling* pada *P. vivax*), model menjadi agresif dan sensitif dalam menebak objek, hal ini terjadi untuk mempertahankan nilai *Recall* yang tinggi antar kedua kelas. Hasil ini yang menjadikan peningkatan angka positif palsu (*False Positive*) pada matriks kebingungan. Oleh karena itu, dapat disimpulkan bahwa memaksakan keseimbangan rasio 1:1 berhasil meratakan sensitivitas deteksi, namun terjadinya kehilangan kemampuan model dalam mempelajari fitur visual, yang dimana memiliki kepentingan yang berat terkhususi dalam deteksi mikroskopis malaria.

4.4 Evaluasi Performa Sistem Deteksi Model

Berikutnya melakukan penilaian evaluasi performa sistem deteksi model terhadap arsitektur YOLOv8m yang telah melalui proses

fine-tuning, dilakukan analisis komparatif secara menyeluruh terhadap hasil pengujian dari ketiga skenario manipulasi dataset. Pengujian ini dievaluasi secara ketat pada data uji (*test set*) yang sepenuhnya terpisahkan sebesar 10% dari total citra. Pemisahan ini diterapkan untuk memastikan objektivitas evaluasi dan menghindari terjadinya kebocoran data (*data leakage*), sehingga metrik yang dihasilkan dapat membantu proses diagnosis dengan tenaga kerja medis. Rekap kuantitatif dari metrik performa akhir seluruh skenario dapat dilihat pada Tabel 4.7.

Tabel 4.7 Rekap Hasil Model Skenario

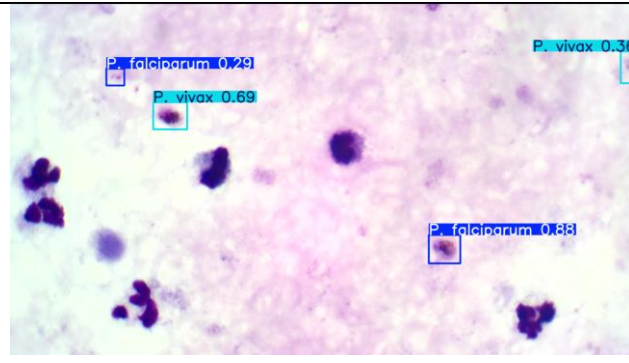
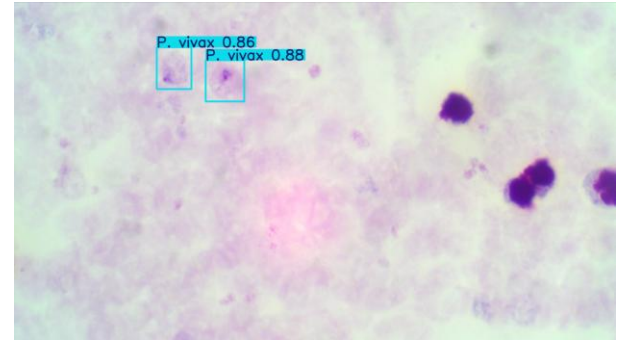
Skenario Eksperimen Data	***Precision***	***Recall***	***F1-Score***	***mAP@50***	***mAP@50-95***
Skenario I (Oversampling 1:2)	86%	83%	84%	91%	59%
Skenario II (Global Augmentasi)	84%	85%	84%	89.84%	56%
Skenario III (Undersampling 1:1)	81%	82%	82%	87%	55%

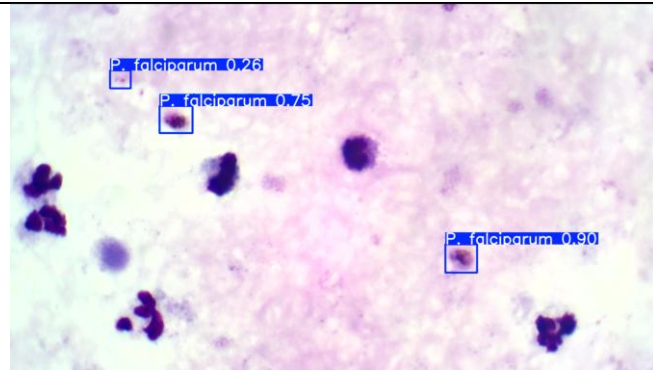
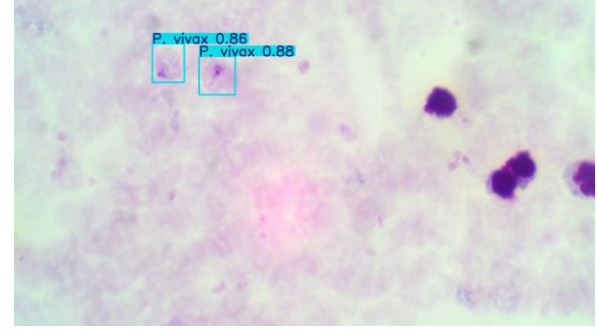
Rekap hasil komputasional pada Tabel 4.7 memberikan status konvergensi pembelajaran model dari ketiga metode penanganan data. Skenario I mencatatkan karakteristik *Best Fitting*, sebuah kondisi komputasional paling ideal dimana arsitektur klasifikasi CNN berhasil mengoptimalkan pembobotan deteksi, tanpa kehilangan kemampuan

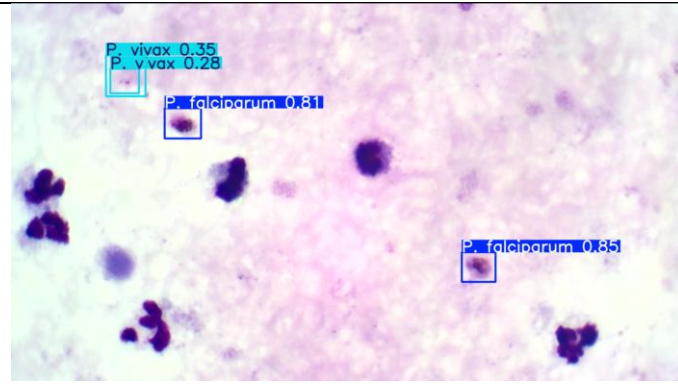
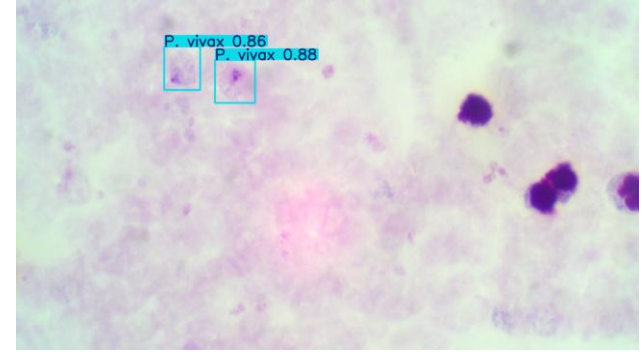
generalisasi. Pada kondisi ini, jaringan konvolusi mampu mengambil karakteristik parasit secara baik. Sebaliknya, Skenario II memberikan hasil *Overfitting* Spasial. Melakukan augmentasi global yang terlalu besar memenuhi ruang pelatihan dengan artefak sintetik, sehingga memaksa *hidden layers* untuk menghafal pola pewarnaan, sehingga sistem menjadi sangat sensitif saat diuji dengan data baru [120]. Selain itu, Skenario III mengalami Stagnasi Dini (*Plateau Curve*). Metode *undersampling* yang diimplementasikan secara berat mengurangi kekayaan fitur visual parasit secara drastis, sehingga pembelajaran model tertahan secara prematur sebelum mampu mencapai tingkat akurasi yang tinggi [72], [120].

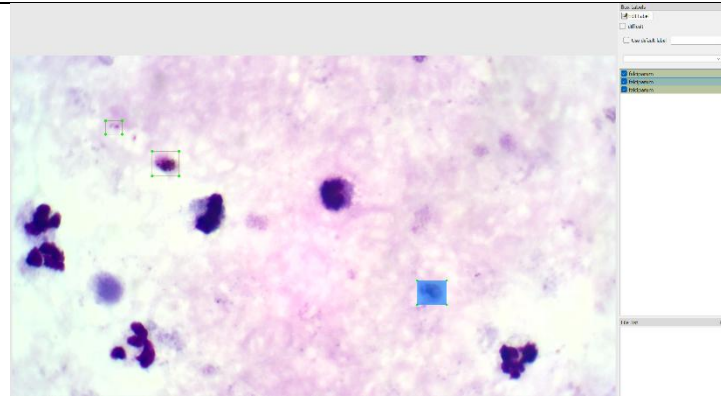
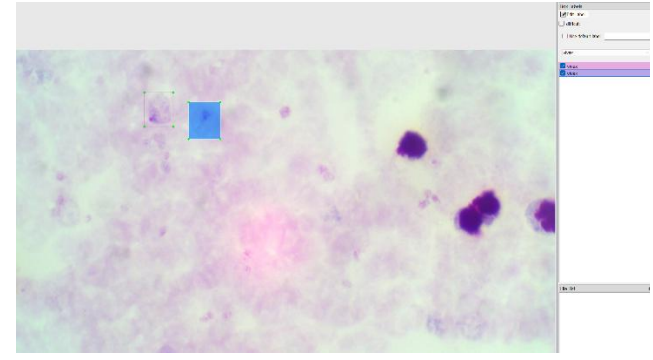
Untuk menarik kesimpulan dari paragraf sebelumnya, berdasarkan tabel 4.7, perbandingan performa ketiga metode skenario untuk menangani ketidakseimbangan kelas, yaitu Skenario I (*Over sampling* 1:2), Skenario II (*Global Augmentation*), Skenario III (*Undersampling*). Hasil tersebut menunjukkan bahwa Skenario I dengan metode *oversampling,* memiliki performa terbaik secara keseluruhan dibandingkan dengan skenario II dan skenario III. Skenario I yang memberikan hasil nilai mAP@50 sebesar 91%, mAP@50-95 sebesar 59%, *precision* 86%, *recall* 83%, *F1-score* sebesar 84%. Berdasarkan hasil ini, beserta hasil yang diberikan pada tabel 4.8 skenario I menjadi model yang paling ideal untuk diintegrasikan kedalam GUI.

Tabel 4.8 Hasil Evaluasi Dengan *Test Set* Serta Validasi

Skenario	Hasil Falciparum	Hasil Vivax
Augmentasi Semua		

Skenario	Hasil Falciparum	Hasil Vivax
Augmentasi 1:2		

Skenario	Hasil Falciparum	Hasil Vivax
Augmentasi 1:1		

Skenario	Hasil Falciparum	Hasil Vivax
Validasi		

Proses evaluasi berikut dapat di buktikan hasilnya dengan menggunakan *LabelImg* dengan file atau gambar yang sama dengan *dataset* yang diambil oleh tenaga kerja kesehatan yang ada di puskesmas Hanura secara langsung pada Tabel 4.8. Berdasarkan hasil yang diberikan pada Tabel 4.8. Membuktikan kembali bahwa skenario I menjadi model terbaik untuk diintegrasikan ke dalam GUI.

4.4.1 AnalisisAkurasi Spasial (mAP@50 dan mAP@50-95)

Metrik mAP@50 dan mAP@50-95 merupakan pengukuran paling penting untuk mengevaluasi akurasi lokalisasi geometri (*bounding box regression*), sekaligus ketepatan klasifikasi pada arsitektur YOLOv8m. Berdasarkan hasil yang ada pada komparasi Tabel 4.7, Skenario I (Rasio 1:2) dan Skenario II sama-sama mencatatkan nilai rata-rata presisi tertinggi mAP@50 yang stabil di 90%-an, melebihi hipotesis awal penelitian. Maka oleh karena itu, kualitas model yang sesungguhnya teruji pada metrik mAP@50-95 dengan rentang ambang batas IoU (0.50 hingga 0.95), dimana Skenario I memiliki hasil yang diatas skenario lainnya dengan nilai 0.59, meninggalkan Skenario II (0.56) dan Skenario III (0.55).

Hasil Skenario I pada rentang mAP@50-95 ini memberikan keberhasilan sinergi antara fungsi kerugian, *Complete Intersection over Union* dan *Distribution Focal Loss,* yang terkalibrasi oleh *optimizer* AdamW. Penggunaan laju pembelajaran awal *lr0* yang sangat kecil (0,000218) pada Skenario I, memberikan lapisan konvolusi di dalam blok *Decoupled Head* untuk tidak mengabaikan fitur-fitur minor. Hasilnya, jaringan mampu memprediksi batas kotak prediksi secara presisi.

Sedangkan, penerapan *undersampling* yang berat pada Skenario III menghasilkan penurunan yang drastis pada isi fitur spasial model. Hilangnya ribuan data *Plasmodium Vivax* asli membuat sistem kekurangan referensi visual mengenai variasi bentuk parasit. Kurangnya informasi ini memaksa proses *bounding box regression* melebihi kapasitas pembelajarannya, yang dapat disebut sebagai stagnasi dini (*plateau*) pada kurva validasi sejak *epoch* ke-100, beserta berhentinya mAP@50 pada angka terendah yaitu 87%

4.4.2 Analisis *Precision, Recall,* dan *F1-Score*

Precision, *Recall*, dan *F1-Score* digunakan untuk mengevaluasi performa model dalam mendeteksi dan mengklasifikasikan parasit pada masing-masing skenario. Evaluasi dilakukan menggunakan test set yang telah dipisahkan dari proses pelatihan. Precision menunjukkan proporsi prediksi positif yang benar, sedangkan Recall menunjukkan kemampuan model dalam mendeteksi objek target yang terdapat pada data uji. *F1-Score* digunakan untuk menggambarkan keseimbangan antara *Precision* dan *Recall*.[122].

Berdasarkan hasil pada Tabel 4.7, Skenario I dengan oversampling rasio 1:2 menghasilkan *Precision* sebesar 86%, *Recall* sebesar 83%, dan *F1-Score* sebesar 84%. Skenario II dengan *global augmentation* menghasilkan *Precision* sebesar 84%, *Recall* sebesar 85%, dan *F1-Score* sebesar 84%. Sementara itu, Skenario III dengan *undersampling* rasio 1:1 menghasilkan *Precision* sebesar 81%, *Recall* sebesar 82%, dan *F1-Score* sebesar 82%.

Berdasarkan ketiga metrik tersebut, Skenario I menghasilkan *Precision* tertinggi dan *F1-Score* yang sama dengan Skenario II, sedangkan Skenario II menghasilkan *Recall* sedikit lebih tinggi.

Meskipun begitu, Skenario I menunjukkan kombinasi *Precision*, *Recall*, dan *F1-Score* yang lebih seimbang dibandingkan Skenario III. Hasil ini menunjukkan bahwa *oversampling* dengan rasio 1:2, dapat mempertahankan performa deteksi yang lebih baik pada dataset penelitian dibandingkan *undersampling* dengan rasio 1:1.

Nilai *Precision* yang lebih rendah pada Skenario III dibandingkan Skenario I menunjukkan bahwa model menghasilkan lebih banyak *false positive* pada data uji. Kondisi tersebut dapat dikaitkan dengan berkurangnya jumlah data *P. Vivax* akibat proses *undersampling*, sehingga variasi data yang tersedia selama pelatihan menjadi terbatas. Sementara itu, Skenario II memiliki *Recall* tertinggi sebesar 85%, tetapi nilai *Precision* sebesar 84%. Hal ini menunjukkan bahwa, masih terdapat prediksi positif yang tidak sesuai dengan anotasi *ground truth*.

Secara keseluruhan, hasil *Precision*, *Recall*, dan *F1-Score* mendukung hasil evaluasi mAP@50 dan mAP@50-95 bahwa Skenario I merupakan skenario dengan performa keseluruhan terbaik pada pengujian. Hasil model dari Skenario I ini yang kemudian dipilih untuk diintegrasikan secara fungsional ke dalam Antarmuka Pengguna Grafis (GUI), dengan tujuan dan harapan untuk mendukung digitalisasi skrining malaria secara otomatis dan luring di Puskesmas Hanura[12], [90], [119], [122].

Untuk membandingkan capaian penelitian ini dalam konteks perkembangan riset deteksi parasit malaria berbasis *deep learning*, hasil model Skenario I (mAP@50 = 91%) dibandingkan dengan penelitian-penelitian relevan pada Tabel 2.7. Dibandingkan dengan Ju dan Cai yang menerapkan YOLOv8 pada deteksi fraktur tulang (mAP50 =

63,8%), penelitian ini menunjukkan performa yang jauh lebih superior, yang mengartikan bahwa karakteristik visual parasit malaria pada citra mikroskopis meski berukuran kecil memiliki pola morfologi yang lebih konsisten untuk dipelajari model dibandingkan variasi bentuk fraktur tulang yang sangat heterogen antar-pasien.

Sementara itu, dibandingkan dengan Mura dkk. yang mengembangkan arsitektur khusus YOLO-Tryppa untuk deteksi parasit *Trypanosoma* berukuran mikro (mAP50 = 71,3%), penelitian ini justru mencatatkan mAP@50 yang lebih tinggi (91%) meskipun tidak melakukan modifikasi arsitektur khusus, melainkan murni melalui strategi *fine-tuning* dan penyeimbangan kelas (*oversampling*). Hal ini mengindikasikan bahwa untuk kasus deteksi *P. falciparum* dan *P. vivax* pada penelitian ini, penanganan *class imbalance* memberikan kontribusi yang sepadan dengan modifikasi arsitektur yang lebih kompleks.

Perbandingan dengan Widayani dkk, yang melaporkan *precision* di atas 92% pada penerapan YOLOv8 untuk berbagai modalitas citra medis umum, menunjukkan bahwa nilai *precision* penelitian ini (86%) masih berada sedikit di bawah rentang tersebut. Kesenjangan ini konsisten dengan temuan pada analisis Skenario II, di mana model menunjukkan kerentanan terhadap kesalahan klasifikasi akibat kemiripan visual antara morfologi parasit stadium awal dengan artefak pewarnaan darah sebuah tantangan spesifik pada citra hematologi yang tidak selalu dijumpai pada modalitas citra medis lain seperti X-Ray atau CT-Scan.

4.5 Implementasi Perancangan Antarmuka Pengguna (GUI)

Deksripsikan bahwa GUI dibangun menggunakan *Python* dengan *library Tkinter* sebagai *framework*nya, *OpenCV* untuk akuisisi kamera, *Pillow* (PIL) dengan tujuan untuk melakukan manipulasi citra dan *Ultralystics* untuk integrasi model YOLOv8m. Ukuran *window* utama di tetapkan pada resolusi 3024x 4032 piksel. Dapat dilihat pada Gambar 4.22.



Gambar 4.22 GUI Antarmuka Pengguna

Pada Gambar 4.22, GUI antarmuka pengguna memiliki berbagai fungsi dan fitur di dalam GUI tersebut. Dimulai dari pemilihan model, dimana tenaga kesehatan bisa memilih model terlebih dahulu lalu dilanjutkan dengan bagian berikutnya berupa *camera,* dimana pada bagian ini pengguna dapat memulai camera, *stop* camera, *switch* camera, *take image*, dan check camera. Memulai camera dan *stop* camera dibuat dengan tujuan untuk menghentikan proses diagnosis disaat perlu, terkhususnya apabila suhu perangkat sudah meningkat melewati batas tahannya. *Take image* dibuat untuk mengambil gambar dari gambar yang sudah ditunjukkan dari *camera* dan disimpan untuk

dikirimkan kepada tenaga kesehatan lainnya. Terakhir, *check camera* dibuat untuk melakukan evaluasi terhadap *camera* apakah sudah terpasang dengan benar atau terdapat masalah pada *camera*nya itu sendiri.

Berikutnya, terdapat fitur *flip*, *zoom*, dan *export image*, masing-masing ini memiliki tujuannya sendiri, untuk *flip* dan *zoom* dibuat untuk memutarkan camera agar tenaga kesehatan dapat identifikasikan bentuk parasitnya serta jenisnya dikarenakan bentuk parasit yang tidak menetap, lalu untuk *export image*, dibuat dengan tujuan untuk mengubah hasil gambar yang ditangkap menjadi, *pdf, jpg, jpeg, png*, dst.

BAB V
KESIMPULAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang dilakukan dalam tugas akhir berjudul *"Fine-Tuning Model You Only Look Once V8M untuk Deteksi Parasit Malaria pada Citra Mikroskopis Sediaan Smear Darah"*, maka dapat diperoleh kesimpulan sebagai berikut:

1. Dataset citra mikroskopis sediaan darah tebal yang diperoleh dari Puskesmas Hanura terdiri dari 2.300 citra, dengan 217 citra *P. Falciparum* dan 2.083 citra *P. Vivax*. Dataset kemudian melalui proses cutting dan resizing menjadi citra berukuran 640 × 640 piksel, dilanjutkan dengan augmentasi dan pembagian data menggunakan rasio 80:10:10 untuk *training*, *validation*, dan *test set*. *Dataset* hasil pengolahan tersebut digunakan sebagai data pelatihan dan pengujian model YOLOv8m.

2. Proses *fine-tuning* arsitektur YOLOv8m dilaksanakan dengan pendekatan *transfer learning* dari bobot pra-latih *yolov8m.pt* (COCO). Dengan menggunakan optimasi *hyperparameter* otomatis berbasis algoritma *Optuna* dengan total 153 *trial*. Konfigurasi *hyperparameter* terbaik ditemukan pada *Trial* 141 dengan penetapan *lr0* = 0,000218, *momentum* = 0,8652, dan *weight decay* = $8{,}35\times10^{-5}$ menggunakan *optimizer* AdamW. Penggunaan tiga skenario distribusi dan augmentasi dataset memberikan perbedaan karakteristik konvergensi yang cukup besar: Skenario I (*Oversampling* Terkontrol 1:2) mencapai kondisi *Best Fitting* dengan konvergensi yang paling stabil, Skenario II (*Global Augmentation*) menyebabkan *overfitting* spasial akibat dominasi

data sintetis yang distortif, dan Skenario III (*Undersampling* 1:1) mengalami stagnasi dini (*plateau*) yang membatasi kapasitas ekstraksi fitur model akibat hilangnya kekayaan variasi morfologi alami *P. vivax*.

3. Berdasarkan hasil evaluasi pada test set, Skenario I dengan *oversampling* rasio 1:2 menghasilkan performa keseluruhan terbaik dibandingkan *global augmentation* dan *undersampling* rasio 1:1. Skenario I memperoleh mAP@50 sebesar 91%, mAP@50-95 sebesar 59%, *Precision* sebesar 86%, *Recall* sebesar 83%, dan *F1-Score* sebesar 84%. Skenario II menghasilkan *Precision* 84%, *Recall* 85%, *F1-Score* 84%, mAP@50 89,84%, dan mAP@50-95 56%, sedangkan Skenario III menghasilkan *Precision* 81%, *Recall* 82%, *F1-Score* 82%, mAP@50 87%, dan mAP@50-95 55%. Berdasarkan keseluruhan metrik tersebut, *oversampling* dengan rasio 1:2 merupakan strategi penanganan ketidakseimbangan kelas dengan performa terbaik pada dataset.

4. Model Skenario I yang telah divalidasi diintegrasikan ke dalam Antarmuka Pengguna Grafis (GUI) berbasis *Python* dengan *OpenCV* dan *PyTorch,* untuk mendukung operasi deteksi secara *real-time* melalui kamera yang terpasang pada mikroskop konvensional. GUI yang dikembangkan dilengkapi empat modul fitur utama, yaitu *Camera* (*start*, *stop*, *take image*, dan *check camera*), *Flip Control* (rotasi 90°/180°/270° dengan *slider* kustom hingga 360°), *Zoom Control* (pembesaran bertahap ±10% dengan *reset*), dan *Export Image* ke direktori pilihan pengguna. Sistem ini dapat dioperasikan pada komputer atau laptop standar di lingkungan Puskesmas tanpa memerlukan perangkat keras

tambahan, sehingga menjadi solusi yang terjangkau dalam mendukung digitalisasi skrining malaria di daerah endemis.

5.2 Saran

1. Penelitian berikutnya disarankan untuk memperluas dataset dengan menggunakan citra mikroskopis dari berbagai fasilitas pelayanan kesehatan, variasi kualitas preparat, kondisi pencahayaan, pewarnaan Giemsa, serta perangkat mikroskop yang berbeda. Penambahan variasi data tersebut diharapkan dapat memberikan representasi data yang lebih beragam dan meningkatkan kemampuan generalisasi model pada kondisi citra yang berbeda..
2. Penelitian selanjutnya dapat melakukan perbandingan performa antara YOLOv8m dengan arsitektur deteksi objek lainnya, seperti YOLOv11, RT-DETR, EfficientDet, atau Faster R-CNN, menggunakan dataset dan metrik evaluasi yang sama. Perbandingan tersebut dapat digunakan untuk mengetahui perbedaan performa masing-masing arsitektur dalam mendeteksi *P. Falciparum* dan *P. Vivax* pada dataset penelitian.
3. Penelitian selanjutnya dapat mengembangkan model untuk mendeteksi spesies *Plasmodium* lainnya, seperti *Plasmodium malariae*, *Plasmodium ovale*, dan *Plasmodium knowlesi*. Penambahan kelas tersebut dapat memperluas cakupan objek yang dapat dideteksi oleh sistem pada citra mikroskopis malaria.
4. Penelitian selanjutnya dapat melakukan optimasi model dan implementasi sistem pada perangkat dengan sumber daya komputasi yang lebih terbatas. Optimasi dapat diarahkan pada pengurangan kebutuhan komputasi dan waktu inferensi, namun tetap mempertahankan performa deteksi yang diperoleh pada penelitian ini.

5. Pengembangan GUI selanjutnya dapat menambahkan fitur pendukung, seperti penyimpanan riwayat hasil deteksi, pembuatan laporan otomatis, penghitungan jumlah parasit yang terdeteksi, serta visualisasi hasil deteksi yang lebih informatif. Penambahan fitur tersebut dapat meningkatkan kemudahan penggunaan dan mendukung dokumentasi hasil deteksi.

DAFTAR PUSTAKA

[1] H. Mayasari, "Eliminasi Malaria Di Berbagai Negara: Literature Review," *Journal of Nursing and Public Health*, vol. 11, no. 1, pp. 73–83, 2023.

[2] Kemenkes, "Buku Saku Pengobatan Malaria," 2023.

[3] I. Lusi and M. Usman, "Pemetaan Persebaran Penyakit Malaria di Kecamatan Punduh Pidada, Kabupaten Pesawaran, Provinsi LampungMapping the Distribution of Malaria in Punduh Pidada District, Pesawaran Regency, Lampung Province," *Spatial: Wahana Komunikasu dan Informasi Geografi*, no. 1, pp. 85–94, 2023.

[4] Nani Sri, "*Environmental Factors to Malaria Incidence : A Literature Review*," *Journal of Community Medicine and Public Health Research*, vol. 5, no. 2, pp. 197–207, 2024.

[5] R. Varo, N. Balanza, A. Mayor, and Q. Bassat, "*Diagnosis of clinical malaria in endemic settings*," *Expert Rev. Anti. Infect. Ther.*, vol. 19, no. 1, pp. 79–92, 2021.

[6] N. Kumar, "*Evaluation of malaria diagnostic methods as a key for successful control and elimination programs*," *Trop. Med. Infect. Dis.*, vol. 5, no. 2, 2020.

[7] Oyegoke, L. Maharaj, Akoniyon, I. Kwoji, A. T. Roux, T. S. Adewumi, R. Maharaj, B. T. Oyebola, M. A.

Adeleke, and M. Okpeku, "*Malaria diagnostic methods with the elimination goal in view*," *Parasitol. Res.*, vol. 121, no. 7, pp. 1867–1885, 2022.

[8] J, Sam., "*Should Deep-Sequenced Amplicons Become the New Gold Standard for Analyzing Malaria Drug Clinical Trials*?" *Antimicrobial Chemotherapy*, vol. 65, pp. 3–18, 2021.

[9] A. Amir, F. Cheong, J. R. De Silva, and Y. L. Lau, "*Diagnostic tools in childhood malaria*," *Parasit. Vectors*, vol. 11, no. 1, pp. 1–12, 2018.

[10] A. Blaine., "Update on Malaria Diagnostics and Test Utilization," *J. Clin. Microbiol.*, vol. 55, no. 7, pp. 3–46, 2017.

[11] K. Tam, D. Eaton, A. Mayo, A. James, C. Tefertiller, K. C. Stenson, C. Curtin, D. Ota, F. Laurent, M. J. Berger, J. Dengler, and I. K. Fox, "*Health Care Utilization in Veterans With Tetraplegia in the First Year After Cervical Spinal Cord Injury: Identifying Opportunities for Dissemination of Treatment Information*," *Arch. Phys. Med. Rehabil.*, Aug. 2025.

[12] A. Widayani, A. M. Putra, A. R. Maghriebi, D. Z. C. Adi, and Moh. H. F. Ridho, "*Review of Application YOLOv8 in Medical Imaging*," *Indonesian Applied Physics Letters*, vol. 5, no. 1, pp. 23–33, 2024.

[13] L. Ezzeddini, J. Ktari, T. Frikha, N. Alsharabi, A. Alayba, A. J. Alzahrani, A. Jadi, A. Alkholidi, and H.

Hamam, "*Analysis of the performance of Faster R-CNN and YOLOv8 in detecting fishing vessels and fishes in real time*," *PeerJ Comput. Sci.*, vol. 10, pp. 1–15, 2024.

[14] M. Peckham, "*What is a microscope? How the microscope has evolved over three hundred and fifty years*," *J. Phys. Conf. Ser.*, vol. 2877, no. 1, 2024.

[15] H. Lee and I. J. Rhyu, "*Antonie van Leeuwenhoek and the dawn of microscopic observation: a narrative review from Delft's lens to the modern microscope*," *Applied Microscopy*, vol. 56, no. 1. Springer, 01-Dec-2026.

[16] C. Prestel, "*Malaria Diagnostic Practices in U.S. Laboratories*," *J. Clin. Microbiol.*, vol. 56, no. 8, 2017.

[17] Y. Wang, X. Zhang, J. Xu, X. Sun, X. Zhao, H. Li, Y. Liu, J. Tian, X. Hao, X. Kong, Z. Wang, J. Yang, and Y. Su, "*The Development of Microscopic Imaging Technology and its Application in Micro- and Nanotechnology*," *Frontiers in Chemistry*, vol. 10. Frontiers Media SA, 05-Jul-2022.

[18] M. Weber and J. Huisken, "*Multidisciplinarity Is Critical to Unlock the Full Potential of Modern Light Microscopy*," *Front. Cell Dev. Biol.*, vol. 9, Oct. 2021.

[19] A. Wollman, R. Nudd, E. G. Hedlund, M. C. Leake, and M. C. Leake, "*IX. An account of Mr. Leeuwenhoek's microscopes*," *Philos. Trans. R. Soc. Lond.*, vol. 41, no. 458, pp. 503–519, 1740.

[20] S. Iyer, "*Watching the embryo: Evolution of the microscope for the study of embryogenesis*," *BioEssays*, 2021.

[21] L. Franken, K. Grünewald, E. J. Boekema, and M. C. A. Stuart, "*A Technical Introduction to Transmission Electron Microscopy fsor Soft-Matter: Imaging, Possibilities, Choices, and Technical Developments*," *Small*, vol. 16, no. 14. Wiley-VCH Verlag, 01-Apr-2020.

[22] *World Health Organization*, *World malaria report 2024*. Geneva: Global Malaria Programme (GMP), 2024.

[23] Caitlin A, "*The history of the microscope reflects advances in science and medicine*," *Semin. Diagn. Pathol.*, vol. 42, no. 2, pp. 74–257, 2025.

[24] Mijithra Ganesan, "*Foldscope microscope, an inexpensive alternative tool to conventional microscopy Applications in research and education: A review*," *Microsc Res Tech*, vol. 85, no. 11, pp. 3484–3494, 2022.

[25] Suman, "*Microscope In Dentistry: A Review Article*," *Innovare Journal of Medical Sciences*, vol. 9, no. 2, pp. 15–21, 2021.

[26] T. Araki, "*The history of optical microscope," Mechanical Engineering Reviews*, vol. 4, no. 1, pp. 16-00242-16–00242, 2017.

[27] W. Wimmer, “Carl Zeiss, Ernst Abbe*, and Advances in the Light Microscope*,” *Micros. Today*, vol. 25, no. 4, pp. 50–57, 2017.

[28] L, Preston, “*Malaria Diagnostic Practices in U.S. Laboratories*,” *J. Clin. Microbiol.*, vol. 56, no. 8, 2017.

[29] N. White, “*Severe malaria*,” *Malar. J.*, pp. 1–17, 2022.

[30] A. Chakraborty, “*NU Understanding the biology of the Plasmodium*,” *Life Sci.*, 2016.

[31] B. Dinko and G. Pradel, “*Immune Evasion by Plasmodium falciparum Parasites: Converting a Host Protection Mechanism for the Parasite’s Benefit*,” no. June, pp. 82–95, 2016.

[32] M. Jessica Molina-Franky, M. Patarroyo, M. Kalkum, “*The Cellular and Molecular Interaction Between Erythrocytes and Plasmodium falciparum Merozoites*,” *Front. Cell. Infect. Microbiol.*, vol. 12, 2022.

[33] M. Poostchi, K. Silamut, R. J. Maude, S. Jaeger, and G. Thoma, “*Image analysis and machine learning for detecting malaria*,” *Translational Research*, vol. 194. Mosby Inc., pp. 36–55, 01-Apr-2018.

[34] M. Fikadu and E. Ashenafi, “*Malaria: An Overview*,” *Infection and Drug Resistance*, vol. 16. Dove Medical Press Ltd, pp. 3339–3347, 2023.

[35] Dr. N. Saxena, Dr. S. C. Meena, and Dr. S. S. Shekhawat, "*Malaria: A backyard enemy*," *Pharma Innov.*, vol. 12, no. 3, pp. 489–496, Jan. 2023.

[36] J. Poespoprodjo, N. M. Douglas, D. Ansong, S. Kho, and N. M. Anstey, "*Malaria,*" *The Lancet*, vol. 402, no. 10419, pp. 2328–2345, Dec. 2023.

[37] J. Roth, D. Korevaar, M. M. G. Leeflang, and P. F. Mens, "*Molecular malaria diagnostics: A systematic review and meta-analysis*," *Critical Reviews in Clinical Laboratory Sciences*, vol. 53, no. 2. Taylor and Francis Ltd, pp. 87–105, 03-Mar-2016.

[38] M. Rana and M. Bhushan, "*Machine learning and deep learning approach for medical image analysis: diagnosis to detection*," *Multimed. Tools Appl.*, vol. 82, no. 17, pp. 26731–26769, 2023.

[39] Ms. Aayushi, "*A Systematic Review on Data Scarcity Problem in Deep Learning: Solution and Applications*," *Association for Computing Machinery*, vol. 54, no. 10, pp. 300–360, 2022.

[40] D. Muchlinski, "*Machine learning and deep learning*," *Elgar Encyclopedia of Technology and Politics*, pp. 114–118, 2022.

[41] C. Janiesch, P. Zschech, and K. Heinrich, "*Machine learning and deep learning*," no. 31, pp. 685–695, 2021.

[42] Dr. Sheshang Degadwala and Dhairya Vyas, "*Systematic Analysis of Deep Learning Models vs. Machine Learning*," *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, vol. 10, no. 4, pp. 60–70, 2024.

[43] O. Hodas, and A. Vishnu, "*Deep Learning For Computational Chemistry*," *J. Comput. Chem.*, vol. 38, no. 16, pp. 1291–1307, 2017.

[44] O. Al-jarrah, P. D. Yoo, S. Muhaidat, G. K. Karagiannidis, and K. Taha, "*Efficient Machine Learning for Big Data : A Review*," pp. 1–8.

[45] K. Singh, "*A Review on Conventional Machine Learning vs Deep Learning*," *2018 International Conference on Computing, Power and Communication Technologies (GUCON), Greater Noida, India,* pp. 347–352, 2018.

[46] S. Pramila P. Shinde, "*A Review of Machine Learning and Deep Learning Applications*," *2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBEA)*, 2018.

[47] S. Razavi, "*Deep learning, explained: Fundamentals, explainability, and bridgeability to process-based modelling*," *Environmental Modelling & Software*, vol. 144, 2021.

[48] A. Mosso Vázquez, D. Juárez-Romero, J. A. Hernández-Pérez, D. Echeverría Sosa, J. E. Loría Yah, R. J.

González Horta, G. I. de A. Pech Carveo, and C. A. Decena Chan, "*Una Revisión de los Fundamentos de Aprendizaje Profundo El Modelo de Red Neuronal XOR*," *Programación Matemática y Software*, vol. 15, no. 1, 2023.

[49] M. Taye, "*Theoretical Understanding of Convolutional Neural Network: Concepts, Architectures, Applications, Future Directions*," *Computation*, vol. 11, no. 3. MDPI, 01-Mar-2023.

[50] A. Purwono, P. Ma'arif, W. Rahmaniar, H. I. K. Fathurrahman, A. Z. K. Frisky, and Q. M. U. Haq, "*Understanding of Convolutional Neural Network* (CNN): *A Review*," *International Journal of Robotics and Control Systems*, vol. 2, no. 4, pp. 739–748, 2022.

[51] A. Upreti, "*Convolutional Neural Network* (CNN): *A comprehensive overview*," vol. 3, no. 4, pp. 488–493.

[52] G. Lindsay, "*Convolutional Neural Networks as a Model of the Visual System: Past, Present, and Future*," 2018.

[53] Teguh Wahyono, "*Python for Machine Learning* (Dasar-dasar Pemrograman Python untuk Machine Learning dan Kecerdasan Buatan)," 2013.

[54] S. Tiwari, G. Jain, D. K. Shetty, M. Sudhi, J. M. Balakrishnan, and S. R. Bhatta, "*A Comprehensive Review on the Application of 3D Convolutional Neural Networks in Medical Imaging*," *Engineering Proceedings*, vol. 59, no. 1, 2023.

[55] F. Mohammad Gouse Galety, "*Deep Neural Network Concepts for Classification using Convolutional Neural Network: A Systematic Review and Evaluation*," 2021.

[56] Y. Lee, "*The* CNN: *The Architecture Behind Artificial Intelligence Development*," no. 4, pp. 4–12, 2023.

[57] T. Saad Albawi, "*2017 International Conference on Engineering and Technology*," vol. 3, no. 8, pp. 19–49, 2017.

[58] R. Sarno, S. Sabila, M. Malikhah, D. Purbawa, and M. S. Ardani, *Machine Learning dan Deep Learning-Konsep dan Pemrograman Python*. 2022.

[59] B. Wang, J.-W. Hsieh, M.-C. Chang, P.-Y. Chen, L. Ke, and S. Lyu, "*Learnable Discrete Wavelet Pooling* (LDW-Pooling) *For Convolutional Networks*," Oct. 2021.

[60] A. Zafar, N. Saba, A. Arshad, A. Alabrah, S. Riaz, M. Suleman, S. Zafar, and M. Nadeem, "*Convolutional Neural Networks: A Comprehensive Evaluation and Benchmarking of Pooling Layer Variants*," *Symmetry (Basel).*, vol. 16, no. 11, Nov. 2024.

[61] N. I. Galanis, P. Vafiadis, K. G. Mirzaev, and G. A. Papakostas, "*Convolutional Neural Networks: A Roundup and Benchmark of Their Pooling Layer Variants*," *Algorithms*, vol. 15, no. 11, Nov. 2022.

[62] X. Zhao, L. Wang, Y. Zhang, X. Han, M. Deveci, and M. Parmar, "*A review of convolutional neural networks in computer vision*," *Artif. Intell. Rev.*, vol. 57, no. 4, Apr. 2024.

[63] Zewen Li, "*Survey of Convolutional Neural Networks Analysis, Applications, and Prospect*," vol. 7, no. 4, pp. 1–21, 2020.

[64] H. Yingge, I. Ali, and K. Y. Lee, "*Deep neural networks on chip - A survey*," in *Proceedings - 2020 IEEE International Conference on Big Data and Smart Computing, BigComp 2020*, 2020, pp. 589–592.

[65] N. Bilous, V. Malko, M. Frohme, and A. Nechyporenko, "*Comparison of* CNN-*Based Architectures for Detection of Different Object Classes*," *AI (Switzerland)*, vol. 5, no. 4, pp. 2300–2320, Dec. 2024.

[66] S. Basha, S. Dubey, V. Pulabaigari, and S. Mukherjee, "*Impact of fully connected layers on performance of convolutional neural networks for image classification*," *Neurocomputing*, vol. 378, pp. 112–119, Feb. 2020.

[67] P. Kocsis, P. Súkeník, G. Brasó, M. Nießner, L. Leal-Taixé, and I. Elezi, "*The Unreasonable Effectiveness of Fully-Connected Layers for Low-Data Regimes*," Oct. 2022.

[68] C. Yeh, M. Lin, P. Chang, and L. W. Kang, "*Enhanced visual attention-guided deep neural networks for image*

classification," *IEEE Access*, vol. 8, pp. 163447–163457, 2020.

[69] B. Zhang, Q. Zhao, W. Feng, and S. Lyu, "*AlphaMEX: A smarter global pooling method for convolutional neural networks*," *Neurocomputing*, vol. 321, pp. 36–48, Dec. 2018.

[70] H. Chen, B. J. Hwang, J. S. Wu, and P. T. Liu, "*The effect of different deep network architectures upon CNN-based gaze tracking*," *Algorithms*, vol. 13, no. 5, May 2020.

[71] W. Wang, J. Tian, C. Zhang, Y. Luo, X. Wang, and J. Li, "*An improved deep learning approach and its applications on colonic polyp images detection*," *BMC Med. Imaging*, vol. 20, no. 1, Jul. 2020.

[72] S. Ali and H. Maseeh, "*Dropout: An Effective Approach to Prevent Neural Networks from Overfitting*," *Asian Journal of Research in Computer Science*, vol. 18, no. 2, pp. 163–185, Feb. 2025.

[73] Olivia Harris and Michael Andrews, "*Effects and results of dropout layer in reducing overfitting with convolutional Neural Networks (CNN)," World Journal of Advanced Engineering Technology and Sciences*, vol. 13, no. 2, pp. 836–853, Dec. 2024.

[74] M. Xiao, Y. Wu, G. Zuo, S. Fan, H. Yu, Z. A. Shaikh, and Z. Wen, "*Addressing Overfitting Problem in Deep Learning-Based Solutions for Next Generation Data-*

Driven Networks," *Wirel. Commun. Mob. Comput.*, vol. 4, no. 6, pp. 1–10, 2021.

[75] H. Hu, "*Galaxy classification based on convolutional neural networks with dropout technique*," *Applied and Computational Engineering*, vol. 22, no. 1, pp. 42–52, Oct. 2023.

[76] Y. Zeng, T. Dai, B. Chen, S. T. Xia, and J. Lu, "*Correlation-based structural dropout for convolutional neural networks*," *Pattern Recognit.*, vol. 120, no. 10, Dec. 2021.

[77] F. Sultana, A. Sufian, and P. Dutta, "*A Review of Object Detection Models based on Convolutional Neural Network*," vol. 5, no. 6, Oct. 2019.

[78] S. Reddy, N. Pillay, and N. Singh, "*Comparative Evaluation of Convolutional Neural Network Object Detection Algorithms for Vehicle Detection*," *J. Imaging*, vol. 10, no. 7, Jul. 2024.

[79] T. Diwan, G. Anirudh, and J. V. Tembhurne, "*Object detection using YOLO: challenges, architectural successors, datasets and applications*," *Multimed. Tools Appl.*, vol. 82, no. 6, pp. 9243–9275, Mar. 2023.

[80] Y. Wang, "*Comparative Analysis of Object Detection Architectures for Enhanced Performance and Application Suitability*," *Applied and Computational Engineering*, vol. 166, no. 1, pp. 70–77, Jun. 2025.

[81] H. Chen, "*A Comparative Study Of Various Object Detection Algorithms*," *International Research Journal of Modernization in Engineering Technology and Science*, no. 6, pp. 1–8, Jun. 2024.

[82] X. Pan, Z. Luo, and L. Zhou, "*Comprehensive Survey of State-of-the-Art Convolutional Neural Network Architectures and Their Applications in Image Classification*," *Innovations in Applied Engineering and Technology*, pp. 1–16, Mar. 2022.

[83] Dr. S. Gothane, "*A Practice for Object Detection Using YOLO Algorithm,*" *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, pp. 268–272, Apr. 2021.

[84] S. Bhattacharjee, "*A Literature-based Performance Assessment of the YOLO (You Only Look Once) CNN Approach for Real-time Object Detection*," *Computology: Journal of Applied Computer Science and Intelligent Technologies*, vol. 4, no. 2, pp. 18–40, Apr. 2025.

[85] S. Patil, A. Kharade, A. M. Kesarkar, U. D. Bankarmali, and N. Magdum, "*Object Detection Using YOLO*," vol. 7.

[86] G. Lavanya and S. D. Pande, "*Enhancing Real-time Object Detection with YOLO Algorithm*," *EAI Endorsed Transactions on Internet of Things*, vol. 10, 2024.

[87] Thrupthi C P, Dr. Chitra K, and Mrs Harilakshmi V M, "*Object Detection for Autonomous Vehicles Using YOLO Algorithm*," *International Journal of Advanced Research in Science, Communication and Technology*, pp. 180–184, Nov. 2024.

[88] R. Ju and W. Cai, "*Fracture detection in pediatric wrist trauma X-ray images using YOLOv8 algorithm*," *Sci. Rep.*, vol. 13, no. 1, Dec. 2023.

[89] Mr. J. Rajasekhar, "*Understanding Yolo: Real-Time Object Detection Explained*," *Interantional Journal Of Scientific Research In Engineering And Management*, vol. 08, no. 07, pp. 1–9, Jul. 2024.

[90] N. Jegham, C. Y. Koh, M. Abdelatti, and A. Hendawi, "*YOLO Evolution: A Comprehensive Benchmark and Architectural Review of YOLOv12, YOLO11, and Their Previous Versions*," vol. 14, no. 3, Mar. 2025.

[91] M. Yaseen, "*What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detecto*r," vol. 10, no. 6, Aug. 2024.

[92] M. Talib, A. H. Y. Al-Noori, and J. Suad, "*YOLOv8-CAB: Improved YOLOv8 for Real-time Object Detection*," *Karbala International Journal of Modern Science*, vol. 10, no. 1, pp. 56–68, 2024.

[93] L. Zedda, A. Loddo, and C. Di Ruberto, "*A deep architecture based on attention mechanisms for effective end-to-end detection of early and mature malaria*

parasites in a realistic scenario," *Comput. Biol. Med.*, vol. 186, Mar. 2025.

[94] M. Andrzej D. Dobrzycki, *An Analysis of Layer-Freezing Strategies for Enhanced Transfer Learning in YOLO Architectures*, vol. 13. IEEE, 2015.

[95] S. Selvakumari and M. Durairaj, "*Indian Journal Of Science And Technology A Comparative Study Of Optimization Techniques In Deep Learning Using The Mnist Dataset*," 2025.

[96] H. Rezatofighi, N. Tsoi, J. Gwak, A. Sadeghian, I. Reid, and S. Savarese, "*Generalized Intersection over Union: A Metric and A Loss for Bounding Box Regression*," 2019.

[97] D. Mura, L. Zedda, A. Loddo, and C. Di Ruberto, "*YOLO-Tryppa: A Novel YOLO-Based Approach for Rapid and Accurate Detection of Small Trypanosoma Parasites*," *J. Imaging*, vol. 11, no. 4, Apr. 2025.

[98] S. Zahra Nematzadeh, "*Comparative Studies on Breast Cancer Classifications with K-Fold Cross Validations Using Machine Learning Techniques*," *UTM*, vol. 1, no. 3, pp. 1–6, 2015.

[99] E. Mutiara Hoy Yuliana, Y. Sundara Mulia, I. Kurniati, and P. Kemenkes Bandung, "*Perbandingan Kualitas Preparat Malaria Yang Digenangi Dengan Direndam Dalam Larutan Giemsa Comparison Of The Quality Of Malaria Preparations Flooded With Soaked In Giemsa*

Solution," *JMLS) Journal of Medical Laboratory and Science*, vol. 5, no. 1, 2025.

[100] K. Naing, S. Boonsang, S. Chuwongin, V. Kittichai, T. Tongloy, S. Prommongkol, P. Dekumyoy, and D. Watthanakulpanich, "*Automatic recognition of parasitic products in stool examination using object detection approach*," *PeerJ Comput. Sci.*, vol. 8, 2022.

[101] H. SKom, Mk. C. Dewi, MCsp, H. Dwi Purnomo, T. Wahyono, and D. R Widiasari, "*Yolov8 Analysis for vehicle classification Under various*."

[102] R. Figueiredo and H. A. Mendes, "*Analyzing Information Leakage on Video Object Detection Datasets by Splitting Images into Clusters with High Spatiotemporal Correlation*," vol. 11, 2023.

[103] M. Chitra and C. Shanmuganathan, "*Robust Object Detection in Jam-Packed Scenes Through Enhanced YOLOv8: A Deep Learning Method*," in *2024 5th International Conference on Smart Electronics and Communication (ICOSEC)*, 2024, pp. 1707–1711.

[104] N. Sabrina, Luqman, I. Ahmad, S. M. Mohamad Maharum, Z. Mansor, B. Wei, and V. Kumar, "*Precision Detection of Small Brown Planthoppers in Agriculture via YOLOv8 Fine-Tuning*," in *2025 IEEE 11th International Conference on Smart Instrumentation, Measurement and Applications (ICSIMA)*, 2025, pp. 171–176.

[105] J. Leonardy, M. R. Salim, R. E. Putra, A. Virgono, U. A. Ahmad, M. K. Delimayanti, and W. P. Tresna, "*Optimizing Convolutional Layer in YOLOv8: Enhancing Accuracy and Efficiency for Camouflaged Object Detection in Complex Environments*," in *2025 IEEE 8th International Conference on Electrical, Control and Computer Engineering (InECCE)*, 2025, pp. 543–546.

[106] J. Tiong, K. Hasikin, R. Ngui, P. C. S. Divis, C. K. Loo, K. W. Lai, F. W. Cheong, and W. Y. Wan Sulaiman, "*Insights into AI-Driven malaria diagnosis: A systematic review with implications for Plasmodium knowlesi*," *Acta Trop.*, vol. 271, p. 107842, Nov. 2025.

[107] B. Yilmaz and U. Kutbay, "*YOLOv8-Based Drone Detection: Performance Analysis and Optimization*," *Computers*, vol. 13, no. 9, Sep. 2024.

[108] Y. Lee, M. P. Patil, J. G. Kim, Y. B. Seo, D. H. Ahn, and G. Do Kim, "*Hyperparameter optimization of apple leaf dataset for the disease recognition based on the YOLOv8*," *J. Agric. Food Res.*, vol. 21, Jun. 2025.

[109] I. Ratih and D. R. Wijaya, "*Object Detection Model for Student and Lecturer Classification Using YOLOv8 and Optuna*," in *2025 IEEE International Conference on Industry 4.0, Artificial Intelligence, and Communications Technology (IAICT)*, 2025, pp. 654–659.

[110] L. Fan, S. Tang, M. Ariffin, M. I. S. Ismail, and X. Wang, "*Impact of Image Preprocessing and Crack Type Distribution on YOLOv8-Based Road Crack Detection*," *Sensors*, vol. 25, no. 7, Apr. 2025.

[111] M. F. Tariq and M. A. Javed, "*Small Object Detection with YOLO: A Performance Analysis Across Model Versions and Hardware*," Apr. 2025.

[112] A. Degale Desta and C. Jian, "*Enhancing YOLOv8 for Vehicle Detection in Intelligent Traffic Management*."

[113] E. Ariyanda, M. Sarosa, S. Wibowo, W. N. Hidayat, Y. M. Azis, and I. Mahfudi, "*Performance Evaluation of YOLOv8 for Automatic Bullet Impact Detection and Scoring on Shooting Targets*," in *2026 International Conference on Current Research in Artificial Intelligence and Data Science (ICCRAIDS)*, 2026, vol. 1, pp. 1–7.

[114] A. Sodhro, S. Kannam, and M. Jensen, "*Real-time efficiency of YOLOv5 and YOLOv8 in human intrusion detection across diverse environments and recommendation*," *Internet of Things (The Netherlands)*, vol. 33, Sep. 2025.

[115] A. Mekled, S. Abdennadher, and O. M. Shehata, "*Performance Evaluation of YOLO Models in Varying Conditions*: A Study on Object Detection and Tracking," in *2024 International Conference on Computer and Applications (ICCA)*, 2024, pp. 1–6.

[116] Y. Lin, "*Research on small object detection method based on YOLOv8:Application of high-resolution detection layer and Mosaic data augmentation*," 2025.

[117] X. Dai, X. Zhao, F. Cen, and F. Zhu, "*Data Augmentation Using Mixup and Random Erasing,*" in *2022 IEEE International Conference on Networking, Sensing and Control (ICNSC)*, 2022, pp. 1–6.

[118] S. Jindal, "*Evaluating the Impact of Dataset Resampling: A Comparative Analysis of VGG-16, ResNet50, and YOLO v11*," *International Journal of High School Research*, vol. 7, no. 11, pp. 124–131, Nov. 2025.

[119] B. Gašparović, G. Mauša, J. Rukavina, and J. Lerga, "*Comparative Analysis of YOLOv7 with Modified Mosaic Augmentation Against YOLOv8-11 for Object Detection in Unbalanced Datasets*," in *2025 10th International Conference on Smart and Sustainable Technologies (SpliTech)*, 2025, pp. 1–4.

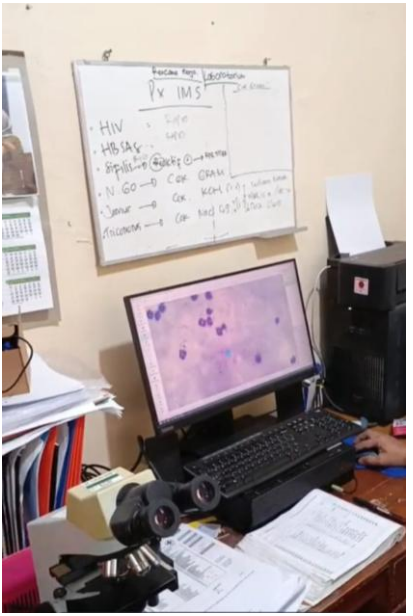
[120] A. Dal Pozzolo, O. Caelen, R. A. Johnson, and G. Bontempi, "*Calibrating Probability with Undersampling for Unbalanced Classification*." *2025 10th International Conference on Smart and Sustainable Technologies (SpliTech)*, 2025, pp. 5-19.

[121] A. Mbanefo and N. Kumar, "*Evaluation of malaria diagnostic methods as a key for successful control and elimination programs*," *Trop. Med. Infect. Dis.*, vol. 5, no. 2, 2020.

[122] O. K. Sahingoz, G. Karatas Baydogmus, and E. Kugu, "*A Systematic Literature Review of You Only Look Once Architectures (v1–v12) in Healthcare Systems*," *Diagnostics*, vol. 16, no. 6. Multidisciplinary Digital Publishing Institute (MDPI), 01-Mar-2026.

LAMPIRAN

Lampiran 1. Dokumentasi Pengambilan Dataset Desa Hanura

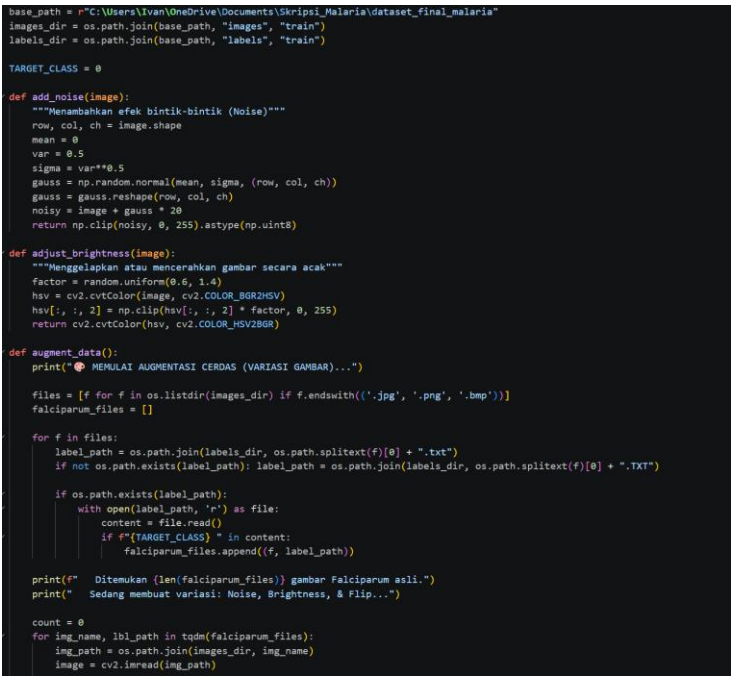


Lampiran 1.1 Dokumentasi Preparat Parasit



Lampiran 2. Dokumentasi *Source Code*

Lampiran 2.1 *Source Code Pre-processing Dataset*



```
base_path = r"C:\Users\Ivan\OneDrive\Documents\Skripsi_Malaria\dataset_final_malaria"
images_dir = os.path.join(base_path, "images", "train")
labels_dir = os.path.join(base_path, "labels", "train")

TARGET_CLASS = 0

def add_noise(image):
    """Menambahkan efek bintik-bintik (Noise)"""
    row, col, ch = image.shape
    mean = 0
    var = 0.5
    sigma = var**0.5
    gauss = np.random.normal(mean, sigma, (row, col, ch))
    gauss = gauss.reshape(row, col, ch)
    noisy = image + gauss * 20
    return np.clip(noisy, 0, 255).astype(np.uint8)

def adjust_brightness(image):
    """Menggelapkan atau mencerahkan gambar secara acak"""
    factor = random.uniform(0.6, 1.4)
    hsv = cv2.cvtColor(image, cv2.COLOR_BGR2HSV)
    hsv[:, :, 2] = np.clip(hsv[:, :, 2] * factor, 0, 255)
    return cv2.cvtColor(hsv, cv2.COLOR_HSV2BGR)

def augment_data():
    print("🚀 MEMULAI AUGMENTASI CERDAS (VARIASI GAMBAR)...")

    files = [f for f in os.listdir(images_dir) if f.endswith(('.jpg', '.png', '.bmp'))]
    falciparum_files = []

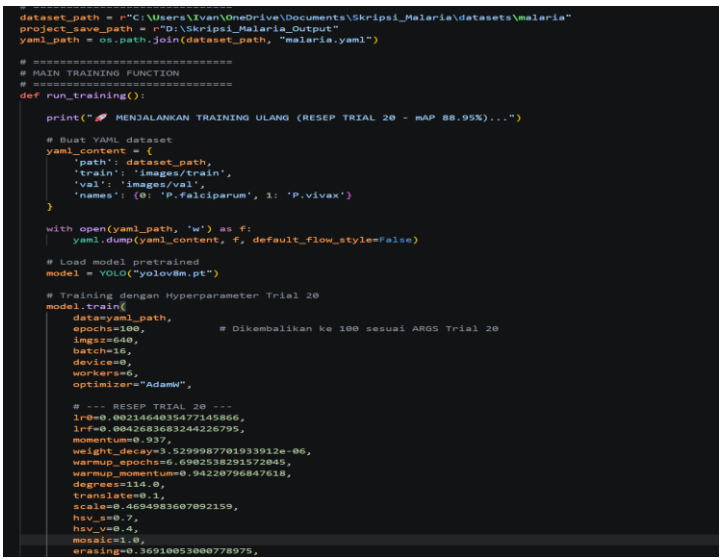
    for f in files:
        label_path = os.path.join(labels_dir, os.path.splitext(f)[0] + ".txt")
        if not os.path.exists(label_path): label_path = os.path.join(labels_dir, os.path.splitext(f)[0] + ".TXT")

        if os.path.exists(label_path):
            with open(label_path, 'r') as file:
                content = file.read()
                if f"{TARGET_CLASS} " in content:
                    falciparum_files.append((f, label_path))

    print(f"   Ditemukan {len(falciparum_files)} gambar Falciparum asli.")
    print("   Sedang membuat variasi: Noise, Brightness, & Flip...")

    count = 0
    for img_name, lbl_path in tqdm(falciparum_files):
        img_path = os.path.join(images_dir, img_name)
        image = cv2.imread(img_path)
```

Lampiran 2.2 *Source Code* Proses *Training* Model



```
dataset_path = r"C:\Users\Ivan\OneDrive\Documents\Skripsi_Malaria\datasets\malaria"
project_save_path = r"D:\Skripsi_Malaria_Output"
yaml_path = os.path.join(dataset_path, "malaria.yaml")

# ==============================
# MAIN TRAINING FUNCTION
# ==============================
def run_training():

    print("🚀 MENJALANKAN TRAINING ULANG (RESEP TRIAL 20 - mAP 88.95%)...")

    # Buat YAML dataset
    yaml_content = {
        'path': dataset_path,
        'train': 'images/train',
        'val': 'images/val',
        'names': {0: 'P.falciparum', 1: 'P.vivax'}
    }

    with open(yaml_path, 'w') as f:
        yaml.dump(yaml_content, f, default_flow_style=False)

    # Load model pretrained
    model = YOLO("yolov8m.pt")

    # Training dengan Hyperparameter Trial 20
    model.train(
        data=yaml_path,
        epochs=100,           # Dikembalikan ke 100 sesuai ARGS Trial 20
        imgsz=640,
        batch=16,
        device=0,
        workers=6,
        optimizer="AdamW",

        # --- RESEP TRIAL 20 ---
        lr0=0.0021464035477145866,
        lrf=0.004268368324226795,
        momentum=0.937,
        weight_decay=3.5299987701933912e-06,
        warmup_epochs=6.6902538291572045,
        warmup_momentum=0.94220796847618,
        degrees=114.0,
        translate=0.1,
        scale=0.4694983607092159,
        hsv_s=0.7,
        hsv_v=0.4,
        mosaic=1.0,
        erasing=0.3691005300778975,
```

Lampiran 2.3 *Source Code* Pencarian *Best* Hyperparameter Model

```
def run_optuna_training():

    print("🚀 MENJALANKAN OPTUNA HYPERPARAMETER SEARCH...")

    # Buat YAML dataset
    yaml_content = {
        'path': dataset_path,
        'train': 'images/train',
        'val': 'images/val',
        'names': {0: 'P.falciparum', 1: 'P.vivax'}
    }

    with open(yaml_path, 'w') as f:
        yaml.dump(yaml_content, f, default_flow_style=False)

    # Persistent study
    sampler = optuna.samplers.TPESampler(seed=42)

    study = optuna.create_study(
        study_name="malaria_yolo_study",
        direction="maximize",
        storage="sqlite:///malaria_yolo_study.db",
        load_if_exists=True,
        sampler=sampler
    )
```

Lampiran 2.4 *Source Code Split Dataset*

```
# --- 3. PEMBAGIAN 80:10:10 ---
train_idx = int(total_files * 0.8)
val_idx = int(total_files * 0.9)  # 80% + 10%

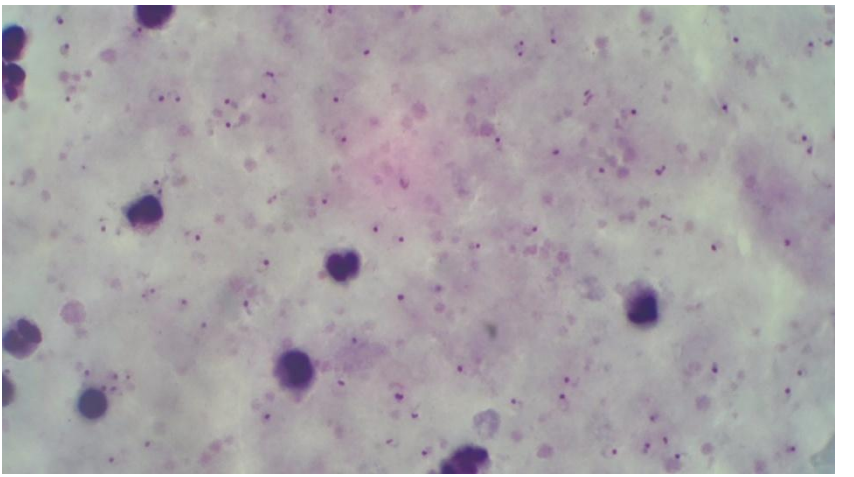
train_set = data_pairs[:train_idx]
val_set = data_pairs[train_idx:val_idx]
test_set = data_pairs[val_idx:]

print(f"✅ Training Set (80%)  : {len(train_set)} file")
print(f"✅ Validation Set (10%): {len(val_set)} file")
print(f"✅ Test Set (10%)      : {len(test_set)} file")

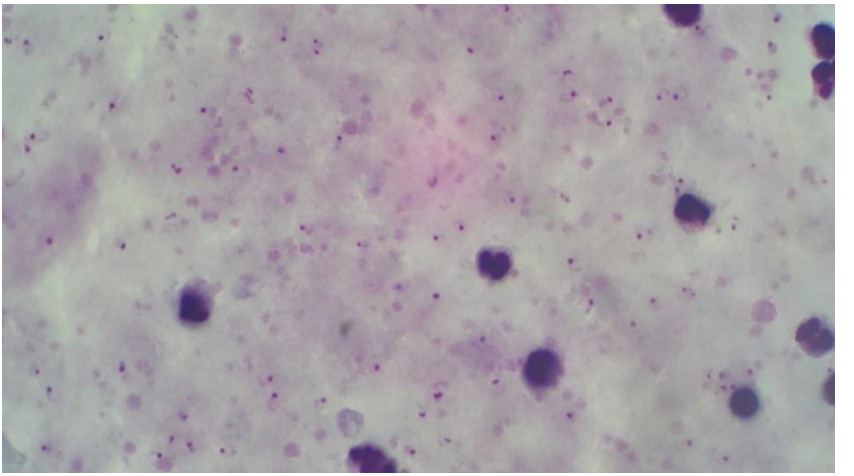
# --- 4. PEMBUATAN FOLDER ---
for split in ['train', 'val', 'test']:
    os.makedirs(os.path.join(dataset_dest, 'images', split), exist_ok=True)
    os.makedirs(os.path.join(dataset_dest, 'labels', split), exist_ok=True)
```

Lampiran 3. Sampel *Dataset* Penelitian

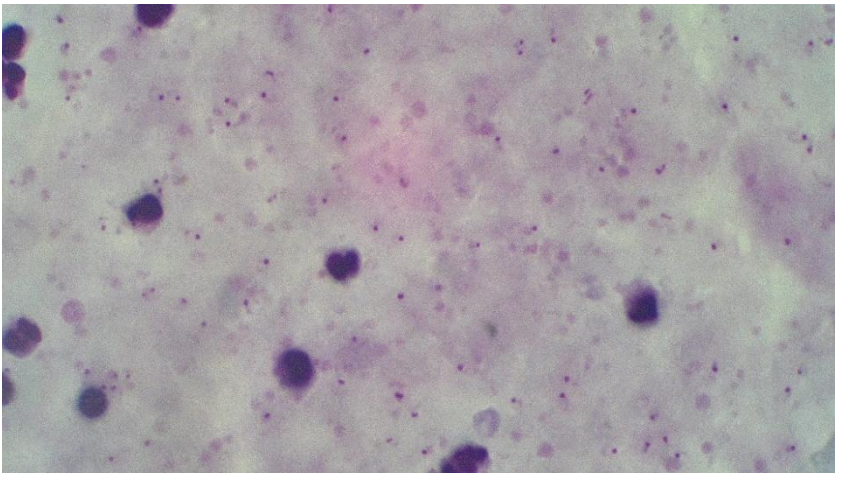
Lampiran 3.1 Dataset *RAW*



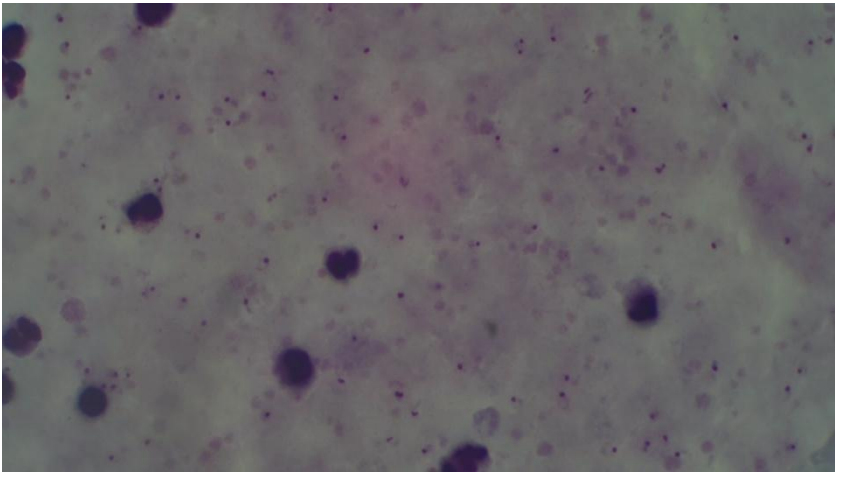
Lampiran 3.2 Dataset Augmentasi *Flip*



Lampiran 3.3 Dataset Augmentasi *Noise*



Lampiran 3.4 Dataset Augmentasi *Brightness*



Lampiran 4.

4.1 Jumlah Proses Trial

